UNIVERSIDAD ADOLFO IBAÑEZ

TESIS DE MAGÍSTER

Efectos de las olas de calor en la demanda eléctrica en Chile en un contexto de Cambio Climático

Autor:
Jorge Petit-laurent

Profesores guía:
Cristian Martinez-Villalobos

Comité de defensa:
Javiera Barrera
Carlos Silva
Katerina Goubanova

Tesis realizada acorde a los requerimientos para el grado de Master of Science in Data Science de la

Facultad de Ingeniería y Ciencias

31 de julio de 2026

UAI | FACULTAD DE INGENIERÍA Y CIENCIAS

UNIVERSIDAD ADOLFO IBAÑEZ

Resumen

Facultad de Ingeniería y Ciencias

Master of Science in Data Science

Efectos de las olas de calor en la demanda eléctrica en Chile en un contexto de Cambio Climático

por Jorge Petit-laurent

El cambio climático está intensificando la frecuencia, severidad y duración de las olas de calor, generando una presión sin precedentes sobre los sistemas eléctricos. Sin embargo, la mayoría de los estudios de demanda eléctrica se basan en datos agregados a escala nacional y modelos climatológicos de baja resolución, dejando una brecha significativa en la comprensión espacialmente desagregada de los impactos extremos. Esta investigación aborda dicha brecha cuantificando la sensibilidad de la demanda eléctrica a las olas de calor a nivel de subestación del Sistema Eléctrico Nacional (SEN) de Chile. Para ello, se desarrolla un *pipeline* metodológico integrado que combina: (i) proyecciones climáticas de alta resolución (12.5 km, horarias) del modelo regional CNRM-ALADIN64, corregidas mediante *Unbiased Quantile Mapping* (UQM) con referencia dual (CR2MET y ERA5-Land); (ii) una climatología de olas de calor y frío basada en umbrales horarios (1979–2100, SSP3-7.0); (iii) datos horarios de retiros eléctricos a nivel de (barra, cliente) —2.567 series candidatas en 399 subestaciones del SEN— (2017–2025); y (iv) Modelos Aditivos Generalizados (GAM) con interacciones tensoriales que capturan la respuesta no lineal de la demanda a las variables climáticas. Los 2.529 modelos GAM per-(barra, cliente) ajustados revelan una heterogeneidad espacial significativa en la sensibilidad térmica entre las subestaciones, con respuestas cualitativamente distintas entre macrozonas climáticas. Las proyecciones bajo SSP3-7.0 indican un aumento desproporcionado en los picos de demanda durante eventos de ola de calor. Estos hallazgos son cruciales para la planificación de infraestructura eléctrica resiliente a los extremos climáticos y para políticas de adaptación diferenciadas territorialmente.

Palabras clave: olas de calor, demanda eléctrica, cambio climático, modelos aditivos generalizados, corrección de sesgo, Chile, sensibilidad térmica, proyecciones climáticas.

UNIVERSIDAD ADOLFO IBAÑEZ

Abstract

Faculty of Engineering and Science

Master of Science in Data Science

Effects of Heat Waves on Electricity Demand in Chile in a Climate Change Context

by Jorge Petit-laurent

Climate change is intensifying the frequency, severity, and duration of heat waves, placing unprecedented stress on power systems. Yet most electricity demand studies rely on nationally aggregated data and coarse-resolution climate models, leaving a significant gap in the spatially disaggregated understanding of extreme impacts. This research addresses this gap by quantifying the sensitivity of electricity demand to heat waves at the substation level across Chile's National Electric System (SEN). We develop an integrated methodological pipeline combining: (i) high-resolution climate projections (12.5 km, hourly) from the CNRM-ALADIN64 regional model, bias-corrected via Unbiased Quantile Mapping (UQM) with dual reference data (CR2MET and ERA5-Land); (ii) an hourly-based heat and cold wave climatology (1979–2100, SSP3-7.0); (iii) hourly withdrawal data at the bus–customer level (2,567 candidate series across 399 SEN substations) (2017–2025); and (iv) Generalized Additive Models (GAM) with tensor product interactions capturing the non-linear demand response to climate variables. The 2,529 fitted per-(bus, customer) GAMs reveal significant spatial heterogeneity in thermal sensitivity across substations, with qualitatively distinct response patterns between climatic macro-zones. Projections under SSP3-7.0 indicate disproportionate increases in peak demand during heat wave events. These findings are critical for planning climate-resilient electrical infrastructure and for designing spatially differentiated adaptation policies.

Keywords: heat waves, electricity demand, climate change, generalized additive models, bias correction, Chile, thermal sensitivity, climate projections.

Publicaciones derivadas de esta tesis

Artículo enviado a *international journal of climate*

1. J. Petit-Laurent, C. Martinez-Villalobos, K. Goubanova, C. Chadwick y P. Nabat, "The future of atmospheric heatwaves in Chile projected by a regional climate model", *International Journal of Climatology*. **En segunda ronda de revisión** (julio de 2026). Reproducido íntegro en el Apéndice M.

Artículo en conferencia con revisión de pares

2. J. Petit-Laurent, C. Martinez-Villalobos y K. Goubanova, "Substation-Level Heat-Wave Vulnerability of the Chilean Grid Under Global Warming", en *2026 IEEE International Conference on Environment and Electrical Engineering and 2026 IEEE Industrial and Commercial Power Systems Europe (EEEIC/I&CPS Europe)*, Lisboa, Portugal, 2026. **Aceptado y presentado**; en proceso de indexación en IEEE *Xplore*. Reproducido íntegro en el Apéndice M.

Índice general

Resumen I

Abstract II

Publicaciones derivadas de esta tesis III

Lista de Abreviaciones VI

1. Introducción **1**
1.1. Motivación y Contexto 1
1.2. Brecha de Conocimiento 2
1.3. Pregunta de Investigación y Objetivos 3
1.4. Contribuciones y Alcance 4
1.5. Estructura de la Tesis 5

2. Problema **7**
2.1. Planteamiento 7
2.2. Alcance y delimitaciones 7
2.3. Definiciones operativas 8

3. Estado del arte y brechas de investigación **9**
3.1. Eje 1: Modelamiento climático y corrección de sesgo 9
3.2. Eje 2: Demanda eléctrica con variables climáticas y *Machine Learning* . 11
3.3. Eje 3: Impacto de olas de calor en los sistemas eléctricos 13
3.4. Eje 4: Contexto chileno de extremos climáticos y demanda energética . 14
3.5. Síntesis de brechas 15

4. Hipótesis y objetivos específicos **16**
4.1. Hipótesis 16
4.2. Objetivos específicos 16

5. Metodología **18**
5.1. Arquitectura general del estudio 18
5.2. Datos 18
5.3. Corrección de sesgo climático 22
5.4. Limpieza y curación de datos de demanda 24
5.5. Georreferenciación: vínculo clima-demanda 26
5.6. Definición y detección de olas de calor 28
5.7. Modelos Aditivos Generalizados (GAM) 29
5.8. Validación cruzada 34
5.9. Proyecciones bajo escenarios de cambio climático 35

6. Resultados **39**
6.1. Validación de la corrección de sesgo (SO.1) . . . 39
6.2. Climatología de olas de calor y frío (SO.5) . . . 40
6.3. Datos de demanda del SEN . . . 47
6.4. Selección del modelo GAM (SO.3) . . . 48
6.5. Efectos parciales y sensibilidad térmica (SO.2 y SO.3) . . . 49
6.6. Validación cruzada (SO.3) . . . 53
6.7. Proyecciones bajo SSP3-7.0 (SO.4) . . . 54
6.8. Síntesis de resultados . . . 59

7. Discusión **67**
7.1. Interpretación de los resultados en el contexto de la literatura . . . 67
7.2. Comparación con estudios previos en Chile . . . 70
7.3. Limitaciones metodológicas . . . 71
7.4. Implicancias para la política energética . . . 73

8. Conclusiones y trabajos futuros **76**
8.1. Conclusiones principales . . . 76
8.2. Trabajos futuros . . . 78
8.3. Implicancias . . . 79
8.4. Síntesis final . . . 79

A. Metodología Detallada de Corrección de Sesgo Climático **88**

B. Detalle del Pipeline de Datos de Demanda Eléctrica **97**

C. Metodología de Detección y Caracterización de Olas de Calor **105**

D. Campaña Experimental GAM y Selección de Modelo **115**

E. Diagnósticos del Modelo GAM canónico **119**

F. Validación Cruzada Detallada **126**

G. Catálogo de Curvas de Sensibilidad Térmica (335 SEs) **129**

H. Georreferenciación SE–Píxel ALADIN **132**

I. Proyecciones de Demanda Eléctrica bajo SSP3-7.0 **137**

J. Evaluación del Modelo Regional CNRM-ALADIN64 **144**

K. Comparación de Productos Climáticos Corregidos: CR2MET vs. ERA5-Land **156**

L. Modelo SE-agregado: Análisis de Robustez **160**

M. Anexos: artículos derivados de esta tesis **165**

Lista de Abreviaciones

AC	Aire acondicionado (*Air Conditioning*)
ACF	Función de autocorrelación (*Autocorrelation Function*)
CDC	Curva de Duración de Carga (*Load Duration Curve*)
CEN	Coordinador Eléctrico Nacional
CMIP6	*Coupled Model Intercomparison Project Phase 6*
CORDEX	*Coordinated Regional Climate Downscaling Experiment*
DTR	Amplitud Térmica Diaria (*Diurnal Temperature Range*)
EWMA	Media Móvil Ponderada Exponencialmente (*Exponentially Weighted Moving Average*)
fREML	*fast Restricted Maximum Likelihood*
GAM	Modelo Aditivo Generalizado (*Generalized Additive Model*)
GCM	Modelo de Circulación General (*General Circulation Model*)
LOMO	*Leave-One-Month-Out* (validación cruzada)
MAPE	Error Porcentual Absoluto Medio (*Mean Absolute Percentage Error*)
OdC	Ola de Calor
OdF	Ola de Frío
RCM	Modelo Climático Regional (*Regional Climate Model*)
RMSE	Raíz del Error Cuadrático Medio (*Root Mean Square Error*)
SE	Subestación Eléctrica
SEN	Sistema Eléctrico Nacional
SSP	*Shared Socioeconomic Pathway*
UQM	*Unbiased Quantile Mapping*

Capítulo 1

Introducción

1.1. Motivación y Contexto

El cambio climático está alterando los patrones de los eventos meteorológicos extremos: el análisis debe desplazarse de las *medias* climáticas a los *extremos* [1]. Las olas de calor (OdC) se están volviendo más frecuentes, intensas y duraderas en todo el mundo, estirando la "cola" de la distribución de temperaturas [2]. Investigaciones recientes han identificado que la **duración** de las OdC está aumentando de forma acelerada [3], y que su **magnitud** —el estrés térmico integrado en el tiempo— escala de forma superlineal bajo escenarios de altas emisiones [4]. Estas anomalías térmicas amenazan la salud humana y la estabilidad de las infraestructuras críticas [5]; los análisis basados en promedios subestiman el riesgo futuro.

El sector eléctrico es excepcionalmente vulnerable a estas anomalías térmicas [6], dado que las OdC imponen un "doble estrés" al sistema. Por un lado, en términos de **impacto en oferta e infraestructura**, las altas temperaturas reducen la eficiencia de las centrales termoeléctricas [7, 8] y de otras fuentes renovables —como la energía solar concentrada [9]— y disminuyen la capacidad de transporte de las líneas de transmisión [10, 11]. Por otro lado, en términos de **impacto en demanda**, a medida que las temperaturas superan los umbrales de confort térmico, la demanda de refrigeración —impulsada principalmente por el uso de aire acondicionado (AC)— aumenta de forma no lineal [11, 12]. Este *riesgo compuesto* (*compound risk*) crea un escenario donde la demanda pico coincide con una oferta degradada, aumentando la probabilidad de cortes de suministro y apagones (*blackouts*) [5, 13].

Chile y su Sistema Eléctrico Nacional (SEN) enfrentan esta misma presión climática. El país ha sido identificado como un *hotspot* de cambio climático, exhibiendo tendencias documentadas de aumento en la frecuencia e intensidad de las OdC a lo largo de su territorio, desde la zona árida del Norte Grande hasta las regiones templadas de la Patagonia [14, 15]. Asimismo, el SEN opera bajo condiciones de creciente vulnerabilidad: alta participación de energías renovables variables [16], redes de transmisión extensas y topográficamente desafiantes, y una adopción de AC en acelerado crecimiento que altera el perfil histórico de sensibilidad térmica de la demanda [17] [18]. Esta vulnerabilidad quedó expuesta durante el apagón nacional del 25 de febrero de 2025, que dejó sin suministro a millones de personas durante varias horas [19]. Cuantificar la respuesta horaria de la demanda eléctrica a las OdC en el SEN es, por tanto, una necesidad estratégica para la planificación de infraestructura, la seguridad energética y la adaptación climática del país.

1.2. Brecha de Conocimiento

A pesar de la relevancia estratégica establecida, la cuantificación precisa del nexo OdC-demanda en Chile permanece incipiente, y la literatura internacional adolece de limitaciones metodológicas significativas que impiden capturar la heterogeneidad real de la respuesta del sistema. Los modelos de impacto agregado, que promedian la demanda a nivel nacional o de gran zona, utilizando datos climáticos de baja resolución espaciotemporal, ya no son suficientes para capturar los fenómenos extremos relevantes para la operación y planificación del sistema eléctrico. El enfoque de "promedio nacional" introduce sesgos que *ocultan* los picos de demanda horarios inducidos por el calor y la heterogeneidad espacial de la sensibilidad térmica.

La **brecha de granularidad espacial** es pronunciada: el SEN abarca más de 4.000 km, con regímenes climáticos, composiciones de carga y penetración del AC radicalmente distintos entre subestaciones (SEs). Modelar esta diversidad con una única curva de sensibilidad nacional equivale a cometer una *falacia ecológica*: asumir que la respuesta al clima es homogénea cuando los determinantes locales, temperatura, humedad, composición sectorial, altitud, varían de manera sistemática entre zonas del SEN [20, 21]. La vulnerabilidad, además, no está distribuida uniformemente: factores socioeconómicos, la calidad de la vivienda y las condiciones microclimáticas locales modulan de forma significativa la exposición térmica de los usuarios [22,23]. Al agregar la demanda al nivel nacional, los modelos existentes subestiman los picos locales que determinan los requisitos de capacidad de transmisión. La probabilidad de congestión durante una OdC queda así subvalorada.

En el eje de los datos climáticos, la **brecha climática**, el uso de proyecciones de baja resolución espacial no captura fenómenos locales críticos como la Isla de Calor Urbana (ICU) [24] ni las teleconexiones que generan diferencias de temperatura pronunciadas entre valles interiores y zonas costeras. Los datos climáticos diarios pierden la variabilidad intradiaria que determina el momento exacto del pico de demanda, esencial para el despacho operacional. Además, las técnicas de corrección de sesgo que no preservan la estructura de los extremos subestiman la intensidad de los eventos más severos [25,26]. La combinación de baja resolución espacial y corrección de sesgo insuficiente produce, por tanto, proyecciones que infravaloran el impacto de las OdC en la demanda futura, conduciendo a una planificación de expansión del sistema insuficiente.

Los estudios previos en Chile [17,18] han analizado la relación temperatura-demanda a nivel agregado o con variables climáticas de baja resolución. La evidencia internacional muestra que integrar datos granulares con modelos estadísticos flexibles mejora la caracterización del nexo calor-demanda [27–29]. De este modo, en Chile, a la fecha de esta tesis, no existe un estudio que integre de manera robusta: (i) proyecciones climáticas horarias de alta resolución corregidas para preservar extremos, (ii) datos públicos de demanda eléctrica a nivel de subestación (SE) del SEN, y (iii) detección horaria de OdC y olas de frío, conectados mediante modelos estadísticos capaces de capturar la heterogeneidad espacial de la sensibilidad térmica a lo largo del territorio nacional. Esta desconexión metodológica define la brecha que el presente trabajo aborda.

1.3. Pregunta de Investigación y Objetivos

La pregunta de investigación central que articula esta tesis es la siguiente: ¿cómo varía espacialmente la sensibilidad de la demanda eléctrica a las Olas de Calor (OdC) entre las subestaciones del SEN, y cómo evolucionará esta respuesta bajo el escenario de cambio climático SSP3-7.0 al horizonte 2100?

El objetivo general es desarrollar y aplicar un *pipeline* metodológico integrado que estime, caracterice y proyecte la heterogeneidad espacial de la respuesta de la demanda eléctrica del SEN a las Olas de Calor, mediante proyecciones climáticas horarias de alta resolución y Modelos Aditivos Generalizados (GAMs) ajustados por subestación.

Para alcanzar el Objetivo General se establecen los siguientes Objetivos Específicos:

1. **SO.1 (Eje Climático — Corrección de Sesgo):** Generar un conjunto de datos climáticos horarios de alta resolución espacial (0,11°, dominio CORDEX-CHP12) para cinco variables (temperatura del aire, punto de rocío, viento superficial, precipitación y radiación solar), aplicando la técnica de *Unbiased Quantile Mapping* (UQM) [26] sobre el modelo regional CNRM-ALADIN64, utilizando ERA5-Land como referencia a resolución horaria. El método preserva por construcción la señal de cambio climático en los extremos, abordando directamente la limitación documentada por [25].

2. **SO.2 (Eje Demanda — Heterogeneidad Espacial y por Cliente):** Caracterizar la heterogeneidad espacial y por tipo de cliente de la sensibilidad térmica de la demanda eléctrica ajustando un GAM independiente para 2.567 series candidatas (barra, cliente) del SEN, agregables a 399 SE, estratificadas en distribuidoras, clientes regulados y clientes libres no regulados, describiendo la variación geográfica y por estrato de las curvas de sensibilidad no lineal en función de la temperatura y métricas de OdC a lo largo del territorio nacional.

3. **SO.3 (Eje Modelado — GAM por (barra, cliente)):** Estimar la sensibilidad climática no lineal de la demanda para cada serie mediante un Modelo Aditivo Generalizado que incorpora dos variables climáticas (temperatura, punto de rocío), interacciones entre temperatura y hora del día, entre temperatura y época del año, y entre hora del día y día de la semana (control de calendario), y efectos paramétricos para día de semana, festivos, tendencia y *dummy* COVID-19.

4. **SO.4 (Eje Impacto — Proyecciones SSP3-7.0):** Cuantificar el impacto del cambio climático en la demanda eléctrica del SEN bajo el escenario SSP3-7.0 (2015–2100), estimando los cambios en la demanda promedio, la demanda pico y la morfología de la Curva de Duración de Carga (CDC), tanto a nivel agregado del SEN como desagregado por subestación y macrozona.

5. **SO.5 (Eje Climatología — Detección de OdC):** Detectar, catalogar y caracterizar los eventos de Olas de Calor y olas de frío en el período 1979–2100 para el dominio CORDEX-CHP12, utilizando definiciones horarias basadas en percentiles (p90 de temperatura máxima diaria para OdC, p10 de temperatura mínima diaria para frío) y duración mínima de tres días consecutivos, calculando además métricas de magnitud en grados-hora (°C·h) como métrica de severidad integrada.

1.4. Contribuciones y Alcance

Esta tesis integra climatología de extremos, estadística aplicada e ingeniería energética en un *pipeline* metodológico que resuelve dos limitaciones de los estudios previos: la *agregación espacial*, que oculta la heterogeneidad del SEN, y el *desajuste de escala climática*, que subestima el riesgo de los extremos.

En el plano metodológico, el trabajo desarrolla:

1. **(i) Corrección de sesgo con preservación de extremos horarios (Contribución Clima):** Se implementa un *pipeline* UQM con ERA5-Land como referencia horaria para cinco variables climáticas del modelo CNRM-ALADIN64, garantizando la consistencia física de los extremos proyectados [26].
2. **(ii) Climatología horaria de OdC y olas de frío 1979–2100 (Contribución Clima/Energía):** Una caracterización de los eventos extremos de calor y frío con definición horaria y métricas de magnitud integrada (°C·h) para el dominio CORDEX-CHP12 (período histórico y proyecciones al 2100 bajo SSP3-7.0), que resuelve la variabilidad intradiaria ausente en los catálogos de resolución diaria.
3. **(iii) Modelado GAM con interacciones tensoriales por (barra, cliente) (Contribución Estadística/Energía):** Se ajustan 2.529 GAMs independientes, uno por serie (barra, cliente), agregables a 399 SE del SEN, con una formulación que incluye interacciones entre temperatura y hora del día, época del año y día de la semana, y efectos paramétricos de calendario y COVID-19, capturando la respuesta no lineal horaria de la demanda a la temperatura y la heterogeneidad por tipo de cliente [20, 27].
4. **(iv) Heterogeneidad espacial y por tipo de cliente de la sensibilidad térmica en el SEN (Contribución aplicada):** Una descripción de la variación geográfica y por estrato de cliente (distribuidoras, clientes regulados y clientes libres no regulados) de la sensibilidad de la demanda a las OdC a lo largo del SEN (Arica a Chiloé), a una granularidad (barra, cliente) que los modelos nacionales agregados no alcanzan, identificando las barras y macrozonas más vulnerables al calor extremo [20, 21].

En el plano aplicado, el trabajo entrega:

1. **(i) Cuantificación de impactos en la CDC del SEN:** Una estimación del cambio en la Curva de Duración de Carga del SEN bajo SSP3-7.0, desagregada por subestación y macrozona, un nivel de detalle que la literatura chilena previa, centrada en agregados nacionales, no aborda, incluyendo el impacto diferencial de las horas de OdC sobre la demanda pico y los percentiles extremos (P95, P99) de la distribución de demanda.
2. **(ii) Métricas de resiliencia para planificación:** Los resultados proveen insumos cuantitativos para la planificación de expansión del SEN, identificando las SEs y períodos con mayor riesgo de sobrecarga durante OdC futuras [5, 11].
3. **(iii) *Pipeline* reproducible de código abierto:** Todos los componentes del *pipeline* (corrección de sesgo, detección de OdC, extracción de forzantes climáticas, ajuste GAM y proyecciones) están implementados con código abierto documentado, facilitando la replicación y extensión a otros dominios y escenarios.

Dos de estas contribuciones han sido sometidas de forma independiente a revisión de pares. La rama climática —extendida al escenario SSP5-8.5 y con una validación de la corrección de sesgo bajo no estacionariedad— se encuentra en segunda ronda de revisión en *International Journal of Climatology* [30]. La rama eléctrica —reformulada como un modelo por subestación y complementada con una razón de riesgo de cola de las anomalías de demanda— fue aceptada y presentada en la conferencia IEEE EEEIC/I&CPS Europe 2026 [31]. Ambos manuscritos se reproducen íntegros en el Apéndice M.

El alcance se delimita en tres planos. En el plano geográfico, se considera el SEN completo, desde la Región de Arica y Parinacota hasta la Región de Los Lagos (Chiloé), cubierto por el dominio CORDEX-CHP12 y representado por 2.567 series candidatas (barra, cliente), de las cuales 2.529 se ajustan, agregables a 399 SE del SEN; la demanda se estratifica en tres tipos de cliente (distribuidoras, libres regulados y libres no regulados). En el plano climático, se utilizan proyecciones del modelo CNRM-ALADIN64 forzado por CNRM-ESM2-1 bajo el escenario SSP3-7.0 (2015–2100). Las proyecciones de demanda se limitan a este escenario; su extensión a SSP5-8.5 queda como trabajo futuro, pendiente de la corrección de sesgo del punto de rocío (Td) para ese escenario. La rama climática del trabajo sí cubre ese escenario: [30] muestra que las métricas de olas de calor bajo SSP3-7.0 y SSP5-8.5 colapsan en una única curva al expresarse en función del calentamiento regional, de modo que la elección de escenario reescala el horizonte temporal más que la forma de la respuesta térmica. En el plano energético, y como delimitación explícita, esta tesis modela exclusivamente la **demanda** eléctrica: no se modelan la respuesta de la oferta, la operación de la red, los mecanismos de mercado ni la elasticidad de precios, se asume una red estática (sin expansión futura de infraestructura) y no se consideran escenarios de transición tecnológica (adopción de AC, vehículos eléctricos), los cuales se proponen como trabajo futuro. El trabajo se concentra así en la caracterización de alta resolución de la sensibilidad de la demanda, como *input* para futuros estudios de resiliencia y planificación del sistema eléctrico chileno.

1.5. Estructura de la Tesis

La tesis se organiza en ocho capítulos, desde el fundamento teórico hasta los resultados empíricos y sus implicancias. El **Capítulo 2 (Planteamiento del Problema)** formaliza el problema de investigación, el alcance y las definiciones operativas de OdC, ola de frío y métricas de severidad que guían el estudio. El **Capítulo 3 (Estado del Arte)** revisa la literatura en cuatro ejes: corrección de sesgo de modelos climáticos regionales, modelado estadístico de la demanda eléctrica, climatología de extremos de calor, y el contexto energético chileno, sintetizando las brechas que motivan esta tesis. El **Capítulo 4 (Hipótesis)** enuncia formalmente las cuatro hipótesis de trabajo derivadas de la pregunta de investigación y los objetivos específicos. El **Capítulo 5 (Datos y Metodología)** describe el *pipeline* completo de investigación: datos climáticos (CNRM-ALADIN64, ERA5-Land), datos de demanda (registros oficiales del CEN, 2.567 series (barra, cliente) agregables a 399 SE), corrección de sesgo UQM (SO.1), detección horaria de OdC (SO.5), construcción de forzantes climáticas y ajuste del GAM por (barra, cliente) (SO.2 y SO.3), y metodología de proyecciones SSP3-7.0 (SO.4). El **Capítulo 6 (Resultados)** presenta los hallazgos empíricos: validación de la corrección de sesgo, climatología de OdC histórica y proyectada, selección y diagnóstico del modelo GAM, curvas de sensibilidad térmica por subestación y

macrozona, y proyecciones de impacto en la CDC del SEN. El **Capítulo 7 (Discusión)** interpreta los resultados en el contexto de la literatura internacional, aborda las limitaciones metodológicas del estudio y discute las implicancias para la planificación y resiliencia del SEN. Finalmente, el **Capítulo 8 (Conclusiones)** sintetiza los hallazgos, responde formalmente a la pregunta de investigación, señala las limitaciones y propone líneas prioritarias de trabajo futuro.

Capítulo 2

Problema

2.1. Planteamiento

Los estudios sobre demanda eléctrica y cambio climático tienden a operar con agregaciones nacionales o regionales amplias, lo que oculta una heterogeneidad espacial fundamental: en un país con la extensión latitudinal de Chile, una subestación del desierto de Atacama y una subestación del sur lluvioso de La Araucanía presentan sensibilidades térmicas radicalmente distintas, heterogeneidad que se acentúa todavía más al descender a la granularidad (barra, cliente) que esta tesis adopta como unidad de análisis. Un modelo nacional único promedia estas diferencias, subestimando la vulnerabilidad de las zonas más expuestas y sobreestimando la de las menos expuestas.

Este problema se agudiza durante eventos de corta duración y alta intensidad como las olas de calor. Un análisis agregado temporalmente, basado en anomalías mensuales o estacionales, promedia los picos horarios que ocurren durante un evento extremo, diluyendo precisamente la señal de interés: el incremento brusco de demanda en cargas específicas, a granularidad (barra, cliente), agregables a subestación, durante las horas más críticas del evento. Para el despacho eléctrico y la seguridad de la red, la variable crítica es la demanda pico en condiciones extremas y su distribución en el territorio.

En un sistema con restricciones espaciales de transmisión, una subestación con alta sensibilidad térmica y capacidad de transmisión limitada representa un punto de estrés local que los modelos agregados pueden ocultar. Cuantificar esa sensibilidad a granularidad (barra, cliente) del Sistema Eléctrico Nacional (SEN), y proyectarla bajo un escenario explícito de cambio climático, es un insumo necesario para informar la planificación de expansión del sistema y la priorización territorial de vulnerabilidades.

2.2. Alcance y delimitaciones

El foco de esta investigación es la *sensibilidad térmica de la demanda eléctrica a granularidad (barra, cliente) del SEN*, separando tres dimensiones del problema: (i) el forzante climático derivado del cambio climático, (ii) la heterogeneidad espacial y por tipo de cliente de la sensibilidad térmica, y (iii) la proyección de impactos futuros bajo el escenario SSP3-7.0. La extensión de las proyecciones de demanda al escenario de altas emisiones SSP5-8.5 se reserva como trabajo futuro, pendiente de la corrección de sesgo del punto de rocío (Td) para ese escenario.

Los datos de demanda corresponden a los retiros horarios de energía activa que el Coordinador Eléctrico Nacional (CEN) publica a granularidad **(barra, cliente)**. El análisis trabaja sobre la serie de cada par (barra, cliente), estratificada en tres tipos de cliente según su rol en el mercado mayorista: distribuidoras de servicio público, clientes libres regulados y clientes libres no regulados. Esta granularidad permite separar las respuestas térmicas heterogéneas que coexisten dentro de una misma barra, por ejemplo, una distribuidora residencial junto a un cliente industrial libre, evitando la dilución de las curvas de sensibilidad por mezcla de cargas. Las series se agregan adicionalmente a nivel de subestación (SE) como modelo SE-agregado complementario, agregación que además habilita el vínculo con el píxel climático ALADIN. La penetración de aire acondicionado no se modela de forma explícita; su efecto queda incorporado solo indirectamente en la asimetría entre la respuesta térmica a temperaturas altas y bajas.

La red eléctrica se trata como estática en los escenarios base; no se modelan cambios en infraestructura ni en la matriz de generación.

2.3. Definiciones operativas

Periodo de referencia: 1980–2010.

Una **hora de calor extremo** es aquella en que la temperatura del aire a 2 m (T_{as}) supera el umbral local θ_{90}: el percentil 90 de la temperatura máxima diaria, calculado por píxel de la grilla ALADIN. Un **día extremo de calor** contiene al menos una de estas horas, y una **ola de calor** es un evento de tres o más días extremos consecutivos. Las **olas de frío** se definen igual, con el percentil 10 de la temperatura mínima diaria.

Cada evento se mide por su duración (días), su intensidad (°C, exceso máximo sobre el umbral) y su **magnitud** (°C·horas, suma de la anomalía térmica sobre las horas del evento). La literatura clásica usa °C·días calculados sobre medias diarias; aquí se usa la resolución horaria, que preserva los picos intra-diarios del evento. La formalización completa (umbrales, días extremos, eventos, métricas y la variable binaria de evento HW_t) está en el Apéndice C.

Capítulo 3

Estado del arte y brechas de investigación

3.1. Eje 1: Modelamiento climático y corrección de sesgo

La evaluación de los impactos del cambio climático en sistemas energéticos depende críticamente de la calidad de las proyecciones de variables meteorológicas, especialmente la temperatura a escalas espaciales y temporales finas. Los Modelos de Circulación General (GCMs) del *Coupled Model Intercomparison Project Phase 6* (CMIP6) [32] son la principal herramienta para proyecciones climáticas a largo plazo, pero su resolución nativa (generalmente superior a los 100 km) es insuficiente para capturar fenómenos locales que influyen en la demanda eléctrica, como las islas de calor urbanas [24]. Se establece así la necesidad fundamental de técnicas de *downscaling*, dinámico o estadístico, para reducir la escala de las proyecciones de los GCMs a una resolución relevante para el análisis de impacto local [24, 25].

Una limitación adicional de los GCMs y los modelos regionales es el uso de datos climáticos diarios: si bien permiten una idea general de los consumos medios en períodos largos [33, 34], no son suficientes para modelar eventos intradiarios, como los picos de demanda eléctrica durante olas de calor, los cuales se concentran en pocas horas de máxima intensidad [12, 35, 36]. Para superar esta limitación y calibrar las proyecciones del modelo regional CNRM-ALADIN64, esta tesis adopta un enfoque de *doble referencia*: CR2MET como referencia observacional para las variables diarias de temperatura máxima y mínima (Tmax, Tmin), y ERA5-Land, reanálisis horario de alta resolución del ECMWF, como referencia para las variables horarias (temperatura superficial *tas*, temperatura de rocío *Td*, viento *sfcWind*, precipitación *pr* y radiación solar *rsds*). Esta estrategia combina la densidad de estaciones de superficie chilenas incorporadas en CR2MET con la consistencia física y resolución temporal de ERA5-Land, garantizando que la corrección de sesgo preserve tanto la climatología local como los patrones intradiarios relevantes para la modelación de la demanda.

La corrección de sesgo (*bias correction*) es un paso estándar en la climatología de impacto. Métodos como el *Delta Change Method* o el mapeo de cuantiles simple (*Quantile Mapping*, QM) han sido ampliamente utilizados [20], pero el *Delta Change* no corrige adecuadamente la varianza ni los extremos [37], mientras que el QM estándar puede alterar de forma no física las señales de cambio proyectadas. Métodos más avanzados, dentro de la familia del mapeo de cuantiles, se han convertido en el estándar de la disciplina; en particular, el *Unbiased Quantile Mapping* (UQM) de [26] está diseñado explícitamente para preservar los cambios en media *y* varianza del modelo

proyectado, evitando la sobreescritura de la señal de cambio climático que aqueja a otros métodos de la familia. En aplicaciones con datos diarios, el UQM puede combinarse con una ventana estacional móvil para incrementar el tamaño muestral de la estimación de cuantiles; cuando la corrección se realiza a resolución horaria, como en el presnete trabajo, utilizando ERA5-Land como referencia, la alta frecuencia temporal provee muestras suficientes sin necesidad de ventana móvil. Dependiendo de las características estadísticas de cada variable, el UQM se aplica en modo *aditivo* (variables con distribuciones simétricas o con soporte en toda la recta real, como *tas* y *Td*) o *multiplicativo* (variables con soporte positivo y distribuciones asimétricas, como *pr* y *rsds*).

Un aspecto físico crítico es la corrección de la amplitud de la variación diaria de temperatura (*Diurnal Temperature Range*, DTR): al aplicar UQM de forma separada a Tmax y Tmin, se garantiza que el rango diario corregido sea físicamente consistente, evitando las inconsistencias físicas que pueden surgir al corregir univariadamente temperaturas extremas diarias [38]. Existe, además, una advertencia crítica en la literatura: los métodos de corrección de sesgo que no preservan explícitamente la señal de cambio en los extremos pueden subestimar los impactos adversos de eventos extremos, como se ha demostrado en estudios de rendimiento agrícola [25]. El UQM responde directamente a esta limitación al preservar por construcción los cambios proyectados en media y varianza, incluyendo las colas de la distribución, lo que lo hace adecuado para estudios de impacto centrados en eventos extremos como las olas de calor. La verificación de esa propiedad bajo no estacionariedad —entrenamiento en un estado climático y prueba en otro— se documenta para este mismo modelo regional en [30], donde el sesgo absoluto mediano en la cola P90–P99,9 cae de 1,5–3,8 °C en el modelo crudo a ∼0,5 °C tras el ajuste UQM en pruebas de estrés con validaciones fuera del rango de entrenamiento.

Brecha: A pesar de que el uso de *downscaling* y métodos avanzados de corrección de sesgo es una práctica establecida en la ciencia climática [24–26, 37], su aplicación integrada para generar proyecciones de temperatura *a escala horaria*, específicamente diseñadas para alimentar modelos de demanda eléctrica granular en Chile, no ha sido documentada en la literatura. Los estudios de impacto energético suelen basarse en metodologías climáticas simplificadas, dejando sin cubrir la integración con modelos de demanda granular a resolución horaria.

3.1.1. Detección de olas de calor: definiciones y métricas

La detección y caracterización de olas de calor (*heatwaves*) requiere la adopción de definiciones operacionales precisas, cuya elección tiene consecuencias directas sobre los resultados. La revisión sistemática de [39] establece que no existe una definición universalmente aceptada, pero que la familia de definiciones basadas en umbrales percentílicos —típicamente el percentil 90 de la temperatura máxima diaria en el período de referencia histórico— es la más robusta para comparaciones regionales e interestudios. En esta línea, [40] provee una evaluación cuantitativa de las métricas más utilizadas para medir olas de calor, mostrando que las definiciones percentílicas capturan tanto la frecuencia como la intensidad de los eventos de manera más coherente que los umbrales absolutos, especialmente en regiones con alta variabilidad climática interanual como Chile. La resolución temporal de los datos de entrada también importa: las definiciones basadas en datos *diarios* (Tmax, Tmin) son las más comunes en la literatura [2, 41], pero la disponibilidad de datos horarios permite detectar eventos de calor nocturno y calcular métricas de severidad más precisas, como

los *grados-hora* (*degree-hours*) de exceso térmico por encima del umbral, en lugar de los *grados-día* agregados diariamente; esta distinción es relevante para la modelación de demanda eléctrica, donde la intensidad horaria del evento determina el pico de consumo. Los trabajos de [2] y [41] documentan tendencias regionales en la frecuencia, duración e intensidad de las olas de calor a escala global, utilizando umbrales percentílicos por cuadrícula (*pixel-level thresholds*), lo cual es metodológicamente más apropiado que umbrales regionales únicos cuando se trabaja con datos de modelos climáticos de alta resolución espacial, como CNRM-ALADIN64. Sobre esta base, la tesis adopta un enfoque de detección horaria con umbrales percentílicos calculados por píxel sobre el período histórico simulado, lo que permite caracterizar eventos diurnos y nocturnos y calcular métricas de magnitud en grados-hora.

3.2. Eje 2: Demanda eléctrica con variables climáticas y *Machine Learning*

La relación entre la temperatura ambiente y la demanda eléctrica es uno de los nexos más estudiados en la literatura energética [42–44]. La temperatura es consistentemente el principal predictor del consumo [34, 45], especialmente en los extremos del espectro —calefacción en invierno y refrigeración en verano— [12,20,44]. Los enfoques para modelar esta relación han evolucionado desde modelos econométricos lineales [46], que utilizaban métricas agregadas como los grados-día de calefacción y refrigeración (*degree-days*), hacia modelos de *Machine Learning* (ML) más flexibles y no lineales [47–49]. Estudios recientes demuestran la superioridad de enfoques semi-paramétricos o no paramétricos para capturar la respuesta no lineal del consumo a temperaturas extremas, por ejemplo, dividiendo la temperatura en rangos (*bins*) para estimar efectos marginales variables [44].

Tradicionalmente, los estudios se han basado en datos de demanda agregados a nivel de país, sistema, región o ciudad [33, 50]; sin embargo, este enfoque oculta una heterogeneidad considerable en los patrones de consumo, impulsada por factores socioeconómicos, características de las edificaciones y microclimas locales. Un avance significativo en la resolución de esta heterogeneidad proviene del trabajo de [20], que combina datos de demanda desagregados con variables climáticas para estimar la sensibilidad térmica de distintos tipos de consumidores, y de [21], que demuestra el poder de combinar datos granulares con variables climáticas y socioeconómicas para modelar la demanda a escala de cliente individual en regiones con climas diversos. En el contexto chileno, la arquitectura del Sistema Eléctrico Nacional (SEN) ofrece una fuente de granularidad alternativa: los medidores en barras y series (barra, cliente) del Coordinador Eléctrico Nacional, que registran demanda horaria real para 2.567 series candidatas (agregables a 399 subestaciones). Este nivel de desagregación —intermedio entre el medidor individual y los totales regionales, con estratificación adicional por tipo de cliente (distribuidoras, libres regulados y libres no regulados)— permite capturar heterogeneidad geográfica, estructural y de tipo de consumidor sin depender de datos de acceso restringido, y es el nivel de análisis adoptado en esta tesis.

La proyección de la demanda eléctrica bajo escenarios de cambio climático debe considerar que la adaptación de hogares e industria —como la adopción masiva de aire acondicionado— modifica la sensibilidad de la demanda a la temperatura a largo plazo. Ignorar estos procesos de adaptación puede llevar a una subestimación significativa de los futuros aumentos en el consumo eléctrico durante olas de calor.

El método CARE (*Climate Adaptive Response Estimation*) propuesto por [27] ofrece un marco para estimar funciones de daño climático que distinguen explícitamente entre las respuestas de corto plazo (uso intensivo de equipos existentes) y las adaptaciones de largo plazo (adopción de nuevas tecnologías), y se aplica directamente a la proyección de escenarios futuros.

La literatura que modela la relación clima-demanda ha evolucionado hacia enfoques de *machine learning* más complejos. Una vertiente significativa utiliza modelos no paramétricos o de "caja negra" —redes neuronales, *gradient boosting*— para capturar las complejas no linealidades de la demanda; por ejemplo, [47] emplea XGBoost para modelar el efecto de la temperatura. Si bien estos modelos alcanzan un alto rendimiento predictivo, su principal limitación radica en la **opacidad interpretativa**: dificultan el aislamiento y la cuantificación del efecto específico de una variable —como una ola de calor— sobre la demanda, que es precisamente el objetivo central de esta tesis.

Los Modelos Aditivos Generalizados (*Generalized Additive Models*, GAMs) combinan interpretabilidad y flexibilidad predictiva, y son la herramienta metodológica preferente para el análisis de la demanda eléctrica en este contexto [51]. Los GAMs generalizan los modelos lineales permitiendo que los predictores sean modelados como funciones suaves (no lineales, e.g., *splines*), pero mantienen una estructura aditiva que permite **interpretar el efecto marginal** de cada componente por separado: el efecto de la temperatura, la estacionalidad, la hora del día, el tipo de día. Esta capacidad de "abrir la caja" es fundamental para desentrañar los *drivers* específicos de la demanda durante eventos extremos. El estimador de máxima verosimilitud restringida rápida (*fast REML*) de [52] es el fundamento computacional que hace viable el ajuste de GAMs con miles de observaciones horarias, mientras que los *tensor product interactions* permiten capturar interacciones no lineales entre predictores continuos —como la temperatura y la hora del día— de forma parsimoniosamente parametrizada [53, 54]. Las bases B-spline con restricciones de forma propuestas por [55] extienden además el repertorio de GAMs al permitir imponer monotonicidad o convexidad cuando la teoría lo exige, herramienta directamente aplicable a curvas dosis–respuesta como la sensibilidad calor–demanda. La idoneidad de los GAMs para el pronóstico de carga a corto plazo (STLF) y el manejo de datos de alta resolución está documentada en la literatura energética reciente: [56] demuestra la superioridad de los modelos aditivos semiparamétricos para datos de demanda de alta resolución, [57] aplica GAMs con términos suaves bidimensionales para la previsión de demanda eléctrica de mediano plazo en Europa, y [58] propone una metodología adaptativa basada en GAMs para redes inteligentes, que maneja series temporales heterogéneas.

3.2.1. Inercia térmica y suavizado exponencial

La demanda eléctrica no solo responde a la temperatura instantánea, sino también a la historia térmica acumulada de las horas previas. Este fenómeno —la *inercia térmica* de las edificaciones— se debe a que las masas constructivas (muros, losas, techos) almacenan calor y lo liberan con un desfase de horas a más de un día, según la inercia de la envolvente. En la literatura de modelos de demanda, este efecto se captura usualmente mediante medias móviles exponenciales (*Exponentially Weighted Moving Averages*, EWMA) de la temperatura, que asignan un peso decreciente a las observaciones pasadas; la incorporación de un predictor EWMA-temperatura en un

GAM permite que el modelo aprenda simultáneamente la respuesta a la temperatura actual y la memoria térmica acumulada del edificio, sin necesidad de simular explícitamente la física de la envolvente. Diagnosticar si la inercia térmica queda bien capturada exige, además, herramientas de visualización de efectos suavizados en series de alta frecuencia [59].

3.2.2. Concurvidad, selección de k y diagnósticos

Un aspecto metodológico crítico al ajustar GAMs con múltiples predictores suaves es la *concurvidad* (*concurvity*): el análogo no lineal de la multicolinealidad, que surge cuando una función suave de un predictor puede ser aproximada como combinación de funciones suaves de otros predictores. La concurvidad elevada infla los errores estándar de los coeficientes y puede hacer inestable la estimación de efectos individuales. En esta línea, [60] y [61] documentan umbrales prácticos de concurvidad y estrategias para mitigarla, incluyendo la selección de variables mediante penalización doble (*double penalty selection*) y la descomposición de tensores de alta dimensión en interacciones de menor orden. Asimismo, la elección del número de nodos (k) por término suave determina la flexibilidad máxima del spline; valores de k insuficientes sesgan el ajuste (*underfitting*), mientras que valores excesivos no suponen un problema gracias a la penalización de suavidad estimada por REML, y la heurística de k por año de datos —propuesta en la práctica por [61]— provee un punto de partida calibrado para series temporales estacionales. Los diagnósticos residuales estándar incluyen la prueba de adecuación de k de Wood, el análisis de la función de autocorrelación (ACF) de los residuos para detectar correlación serial no capturada, y la inspección visual de los efectos parciales; la incorporación de un término AR(1) en el ajuste permite corregir la correlación serial sin distorsionar los efectos suaves estimados [52].

Brecha: Si bien la literatura reconoce la importancia del análisis granular [20, 21] y valida el uso de GAMs con interacciones de producto tensorial para datos energéticos [53, 56], existe una brecha clara en la aplicación sistemática de esta metodología —incluyendo la captura de inercia térmica y la corrección de autocorrelación serial— a la totalidad de las series (barra, cliente) del SEN chileno (2.567 series candidatas estratificadas por tipo de cliente, agregables a 399 SEs). Los estudios existentes operan a escala de ciudad, edificio o medidor individual, sin cubrir un sistema nacional completo a resolución horaria con proyecciones climáticas corregidas de extremos. Una versión reducida del enfoque que se propone aquí —un modelo por subestación, sin estratificación por tipo de cliente— se aplicó a 133 subestaciones del SEN en [31]; la formulación per-(barra, cliente) de esta tesis amplía esa cobertura y añade la dimensión de estrato de consumidor.

3.3. Eje 3: Impacto de olas de calor en los sistemas eléctricos

Las olas de calor representan una amenaza multidimensional para los sistemas eléctricos, un fenómeno conocido como *riesgo compuesto* (*compound risk*) [6]. Este riesgo se manifiesta por la coincidencia de un aumento extremo en la demanda eléctrica —principalmente por refrigeración— con una degradación simultánea de la capacidad de generación y transmisión de la red [10]. La literatura ha desarrollado marcos de evaluación a nivel de sistema para cuantificar esta amenaza, reconociendo que analizar la demanda de forma aislada es insuficiente para comprender la vulnerabilidad del sistema [6, 10].

El lado de la oferta se ve afectado de múltiples maneras. Las altas temperaturas ambiente reducen la eficiencia y la capacidad máxima de las centrales termoeléctricas, especialmente las turbinas de gas, cruciales para satisfacer la demanda punta [7]. Al mismo tiempo, las altas temperaturas aumentan la resistencia de las líneas de transmisión y provocan su dilatación y hundimiento (*thermal sagging*), obligando a los operadores a reducir su capacidad de transporte para mantener la seguridad y generando cuellos de botella en la red [6, 10].

La consecuencia última de este riesgo compuesto es un aumento en la probabilidad de apagones (*blackouts*) [5]. Los apagones durante olas de calor no son solo un problema de conveniencia; tienen consecuencias sanitarias severas: la falta de acceso a refrigeración exacerba el estrés por calor, amplificando significativamente el riesgo de morbilidad y mortalidad en poblaciones vulnerables [5]. El evento del 25 de febrero de 2025 en Chile —el apagón más extenso registrado en el SEN, que dejó sin suministro a más de diez millones de personas durante horas en pleno período estival— ilustra la materialidad de este riesgo en el contexto nacional y la urgencia de cuantificarlo bajo escenarios de mayor frecuencia de olas de calor [19]. Este nexo entre la resiliencia de la red y la salud pública proporciona una justificación social y económica urgente para estudiar y mitigar estos riesgos.

Brecha: A pesar de que la literatura internacional ha establecido marcos conceptuales para el riesgo compuesto [6, 10], existe una falta de cuantificación integrada de la exposición del sistema eléctrico chileno al estrés por calor. Específicamente, falta un análisis que conecte proyecciones climáticas de alta resolución con modelos de demanda granular para estimar la frecuencia y magnitud de los déficits de suministro futuros durante olas de calor, periodos en los cuales los efectos humanitarios de los apagones se amplifican de manera crítica. Un primer avance en esa dirección, derivado de este trabajo, cuantifica la vulnerabilidad a olas de calor de la red chilena a nivel de subestación y traslada el aparato de la razón de riesgo desde el clima hacia las anomalías de demanda [31].

3.4. Eje 4: Contexto chileno de extremos climáticos y demanda energética

Chile, y en particular su zona central y sur, ha experimentado un aumento documentado en la frecuencia, duración e intensidad de las olas de calor durante las últimas décadas [14, 15]. La megasequía que ha afectado a la zona central desde 2010 es expresión del mismo forzamiento climático que intensifica los eventos de calor extremo: el debilitamiento del sistema de alta presión del Pacífico Sur que regula el clima mediterráneo de la región [15]. Esta tendencia histórica es consistente con las proyecciones de cambio climático para la región bajo los SSPs. Esta evidencia chilena proviene en su mayoría de redes de estaciones de cobertura espacial limitada y resolución diaria; el análisis de olas de calor de esta tesis —a resolución horaria y con cobertura completa del territorio continental, sobre proyecciones corregidas que alcanzan el año 2100— amplía ese diagnóstico y, sobre todo, lo enlaza con la demanda eléctrica, cuantificación que se desarrolla en el Capítulo de Resultados.

Estudios de impacto para Chile ya han comenzado a explorar las consecuencias del cambio climático en el sector energético. Investigaciones basadas en arquetipos de viviendas y escenarios climáticos proyectan una disminución significativa en la demanda de calefacción, pero un aumento drástico en la demanda de refrigeración,

especialmente en ciudades como Santiago [17]. Otros estudios confirman las tendencias de calentamiento, particularmente en el sur de Chile, proyectando cambios en las zonas climáticas que desafían la adecuación de las normativas de construcción actuales y alterarán los futuros patrones de consumo energético [62]. El contexto de pobreza energética es también relevante: [23] muestra que la vulnerabilidad energética de los hogares chilenos tiene una fuerte dimensión territorial y climática, con impactos diferenciados en las zonas más expuestas a temperaturas extremas, lo que anticipa una respuesta de demanda heterogénea ante las olas de calor proyectadas.

El impacto de las tendencias climáticas no será homogéneo. La vulnerabilidad energética de las viviendas sociales y la calidad de su aislamiento son factores clave que modularán la demanda futura [22]. La zonificación térmica y la eficiencia de la envolvente determinan la sostenibilidad y resiliencia del sistema ante el clima proyectado.

Brecha: A pesar de que la literatura chilena ha establecido las tendencias climáticas generales [14, 15, 62] y ha comenzado a modelar sus impactos en la demanda a nivel de arquetipo de vivienda [17], existe una brecha clara en la traducción de estas tendencias climáticas —a alta resolución espacial y temporal— a impactos directos sobre la demanda eléctrica observada a nivel de subestación, y en la construcción de una climatología de olas de calor específicamente referida a los píxeles del SEN chileno.

3.5. Síntesis de brechas

Las cuatro brechas identificadas a lo largo de este capítulo —ausencia de análisis de demanda a nivel de subestación a escala nacional; desconexión entre proyecciones climáticas corregidas y modelos de demanda; atención insuficiente a la resolución horaria en eventos extremos; y ausencia de una climatología de olas de calor referida a la infraestructura eléctrica chilena— se cierran en esta tesis mediante un ***pipeline* integrado** que vincula proyecciones climáticas CNRM-ALADIN64 —corregidas por sesgo con UQM a resolución horaria—, una climatología de olas de calor referida a 2.567 series (barra, cliente) —agregables a 399 SE del SEN— y modelos GAM con interacciones de producto tensorial, para cuantificar los impactos futuros de las olas de calor sobre la demanda eléctrica del sistema chileno bajo el escenario SSP3-7.0 (con SSP5-8.5 como extensión natural).

Capítulo 4

Hipótesis y objetivos específicos

4.1. Hipótesis

Las hipótesis siguientes orientan el diseño metodológico; cada una es contrastable mediante el modelo GAM o las proyecciones climáticas.

1. **H1 (No linealidad y heterogeneidad espacial).** La sensibilidad de la demanda eléctrica a la temperatura es no lineal y espacialmente heterogénea entre las subestaciones del SEN, con respuestas cualitativamente distintas entre zonas climáticas (ej. desierto norte vs. zona central mediterránea vs. sur lluvioso).
2. **H2 (Interacciones tensoriales).** La sensibilidad térmica de la demanda varía significativamente según la hora del día y la estación del año, de modo que las interacciones tensoriales de la temperatura con la hora del día y con la época del año son estadísticamente significativas y mejoran la capacidad predictiva del modelo respecto a un GAM sin interacciones.
3. **H3 (Cambio climático amplifica los picos).** Bajo el escenario de calentamiento SSP3-7.0, los picos de demanda (colas de la CDC) y las horas etiquetadas como ola de calor se ven afectados de forma desproporcionada respecto al promedio anual.
4. **H4 (Intensificación de las olas de calor).** La frecuencia, duración y magnitud de las olas de calor en Chile aumentarán significativamente hacia 2050–2080 respecto al período histórico (1980–2010), con patrones espaciales que varían por macrozonas.

4.2. Objetivos específicos

Los objetivos específicos se organizan en dos ejes complementarios: el eje climático (SO.1, SO.5) y el eje de modelado e impacto energético (SO.2–SO.4).

- **SO.1 (Eje Climático — Corrección de Sesgo).** Generar forzantes climáticas de alta resolución (0.11°, horaria) para el período histórico (1979–2014) y futuro (2015–2100; SSP3-7.0), aplicando *Unbiased Quantile Mapping* (UQM) con ERA5-Land como referencia horaria para las variables *tas*, *Td*, *sfcWind*, *pr* y *rsds*, preservando la señal de cambio climático en los extremos.
- **SO.5 (Eje Climatología — Detección de OdC).** Detectar, catalogar y caracterizar eventos de olas de calor y frío en Chile (1979–2100), utilizando definiciones basadas en resoluciones horarias y umbrales percentílicos (P90/P10), para generar una climatología de referencia.

- **SO.2 (Eje IA — Heterogeneidad).** Caracterizar la heterogeneidad espacial y por tipo de cliente de la sensibilidad térmica de la demanda eléctrica ajustando un GAM independiente para cada una de las 2.567 series candidatas (barra, cliente) del SEN —agregables a 399 SE—, analizando la variabilidad de las curvas de respuesta térmica (*tas*) entre zonas climáticas y entre estratos Distribuidoras / Clientes regulados / Clientes libres.
- **SO.3 (Eje IA — Modelado).** Estimar la sensibilidad climática no lineal de la demanda horaria para cada serie (barra, cliente) mediante GAMs con (i) dos variables climáticas (temperatura del aire y de rocío), (ii) interacciones tensoriales de la temperatura con la hora del día y con la época del año, y de la hora del día con el día de la semana, y (iii) efectos paramétricos para día de semana, festivos, tendencia y *dummy* COVID-19.
- **SO.4 (Eje Energía — Impacto).** Proyectar los impactos futuros bajo SSP3-7.0 asumiendo red estática, cuantificando cambios en la demanda *peak* (P95/P99) y la Curva de Duración de Carga (CDC) a nivel per-(barra, cliente), agregado por subestación y macrozona, y agregado SEN.

Capítulo 5

Metodología

5.1. Arquitectura general del estudio

La metodología se estructura como un *pipeline* secuencial e integrado de cinco fases, cada una autocontenida pero conectada a las demás mediante flujos de datos explícitos. El diseño busca aislar la contribución exclusiva del cambio climático sobre la demanda eléctrica horaria, manteniendo trazabilidad completa desde las forzantes climáticas crudas hasta las proyecciones de impacto.

Las cinco fases son:

1. **Corrección de sesgo climático:** Ajuste estadístico de las salidas del modelo climático regional CNRM-ALADIN64 contra ERA5-Land a resolución horaria, mediante UQM, preservando la señal de cambio climático en los extremos.
2. **Datos de demanda eléctrica:** Descarga, deduplicación y curación de series horarias de demanda eléctrica con granularidad (barra, cliente), extraídas de los registros oficiales del Coordinador Eléctrico Nacional (CEN). Las series se agregan adicionalmente a nivel de subestación eléctrica (SE) como modelo SE-agregado complementario.
3. **Detección de olas de calor y frío:** Identificación de eventos extremos térmicos a escala horaria-píxel, basada en umbrales percentílicos climatológicos y un criterio de persistencia temporal.
4. **Modelado GAM:** Ajuste de Modelos Aditivos Generalizados (*Generalized Additive Models*, GAM) por par (barra, cliente), cuantificando la respuesta no lineal de la demanda ante variables climáticas y covariables temporales. Un ajuste paralelo a nivel SE se conserva como modelo SE-agregado complementario.
5. **Proyecciones de impacto:** Simulación de la demanda futura (2025–2100) bajo el escenario SSP3-7.0, asumiendo una red eléctrica estática.

La Figura 5.1 esquematiza la arquitectura completa del flujo de trabajo y la Figura 5.2 detalla los flujos de datos entre fases.

5.2. Datos

5.2.1. Forzantes climáticas: modelo regional CNRM-ALADIN64

Para caracterizar el clima histórico y futuro se utilizan las simulaciones del Modelo Climático Regional (MCR) **CNRM-ALADIN64** [63], desarrollado en el marco del

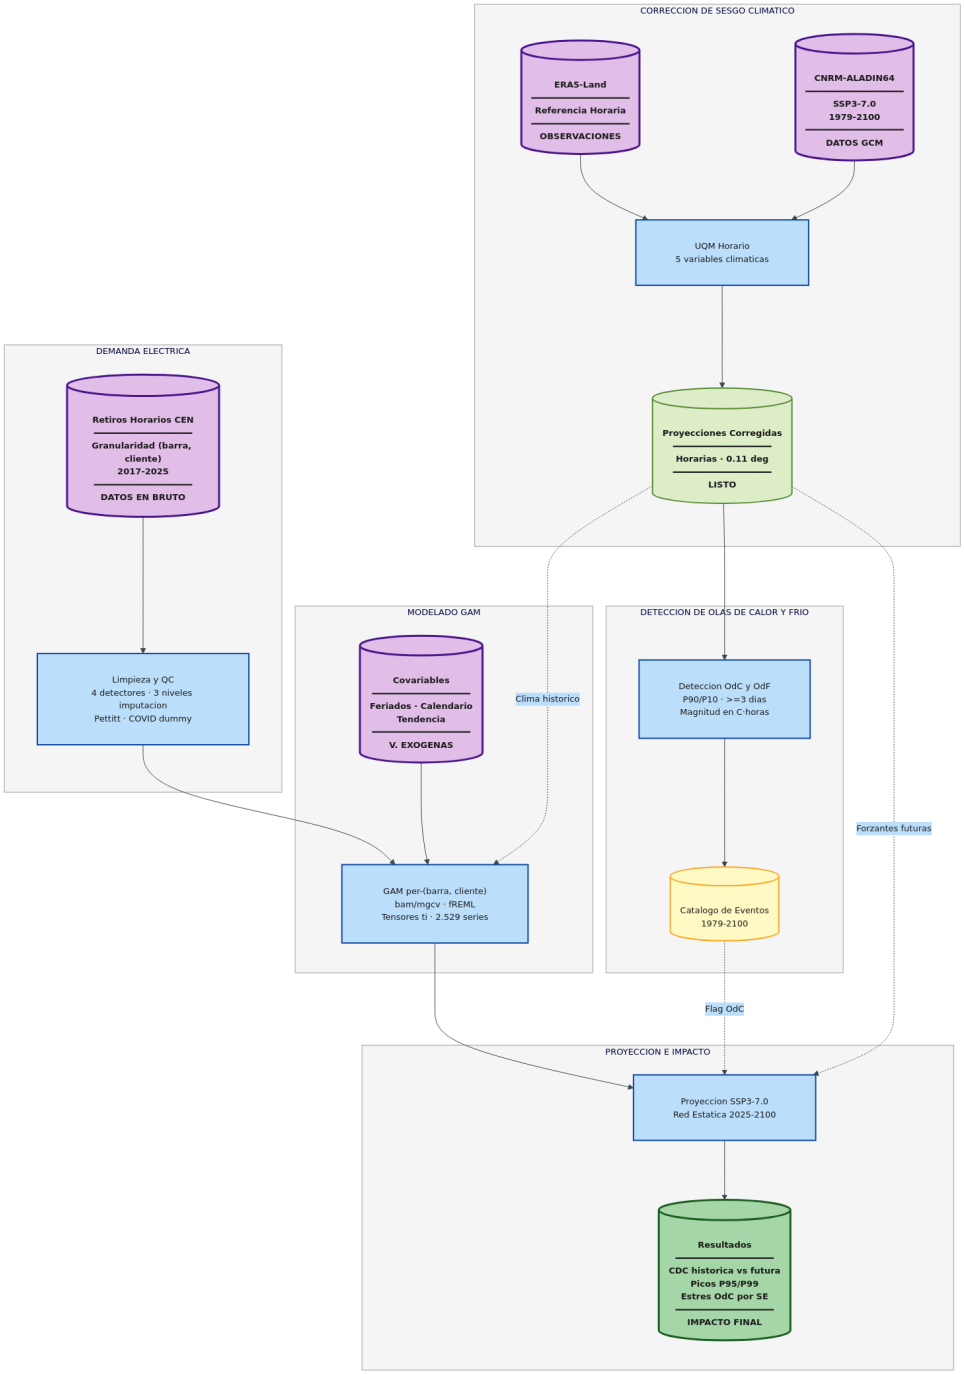

FIGURA 5.1: Arquitectura del flujo de trabajo metodológico integrado. La **corrección de sesgo** ajusta las salidas del modelo regional CNRM-ALADIN64 mediante *Unbiased Quantile Mapping* (UQM) contra ERA5-Land a resolución horaria. La **detección de olas de calor y frío** opera a nivel de píxel, con umbrales P90/P10 sobre el periodo 1980–2010. La **demanda eléctrica** se limpia y cura con granularidad (barra, cliente): 2.567 series candidatas agregables a 399 SE del SEN. El **modelado GAM** ajusta el modelo aditivo generalizado por serie (barra, cliente) con variables climáticas, temporales e interacciones, complementado por un modelo SE-agregado (335 SE). Las **proyecciones** bajo SSP3-7.0 asumen una red estática.

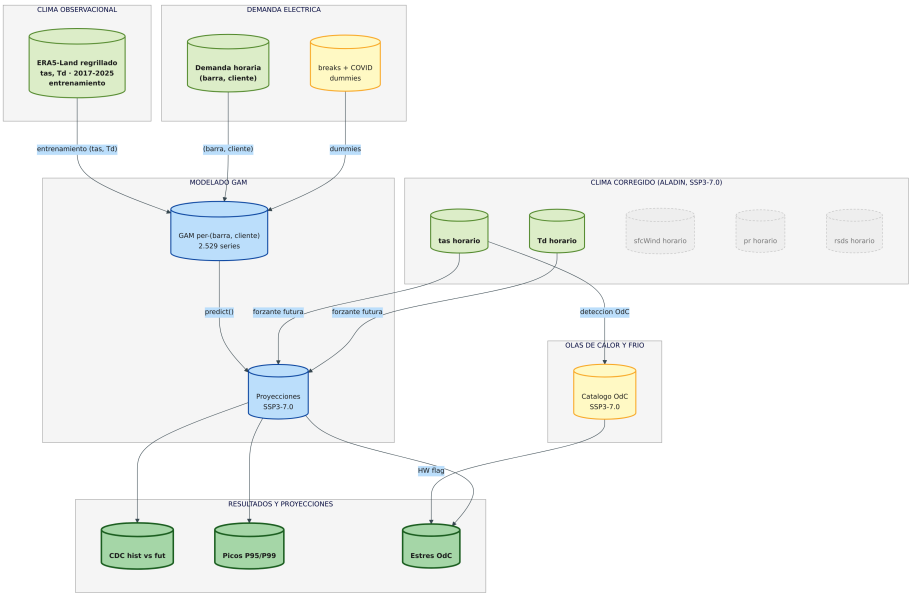

FIGURA 5.2: Flujo de datos completo entre las etapas del trabajo. El GAM se entrena con clima observacional (ERA5-Land regrillado a la malla ALADIN) y la demanda horaria por (barra, cliente). El clima corregido de ALADIN bajo SSP3-7.0 cumple dos roles: alimenta la detección de olas de calor y frío y actúa como forzante futura de las proyecciones. El modelo emplea temperatura del aire y de rocío; las demás variables corregidas (atenuadas) se produjeron pero no integran la especificación final. Las proyecciones se evalúan durante las horas etiquetadas como ola de calor.

programa *Coordinated Regional Climate Downscaling Experiment* (CORDEX) [64]. El dominio de simulación corresponde a CORDEX-CHP12, centrado en Chile, con una resolución espacial horizontal de 0,11° (aproximadamente 12 km). La grilla resultante contiene 255 × 68 puntos, de los cuales 8.270 corresponden a píxeles terrestres que cubren el territorio nacional. Esta misma configuración —CNRM-ALADIN versión 6.4 sobre CORDEX-CHP12, forzada por CNRM-ESM2-1 `r1i1p1f2`— es la empleada en [30] y [31], trabajos coautorados con el equipo del CNRM responsable de la ejecución de la simulación.

Como condiciones de borde, el MCR es forzado por el Modelo de Circulación General (GCM) **CNRM-ESM2-1** (miembro de ensamble `r1i1p1f2`) [65]. Se consideran dos periodos continuos con calendario estandarizado de 365 días (sin años bisiestos):

- **Periodo histórico:** 1979–2014 (36 años), utilizado para calibración y validación.
- **Periodo futuro:** 2015–2100 (86 años), bajo el escenario de forzamiento radiativo SSP3-7.0 [66], correspondiente a emisiones medias-altas consistentes con el marco CMIP6 [32].

Las variables climáticas extraídas del modelo ALADIN se resumen en la Tabla 5.1.

5.2.2. Datos de observación para la corrección de sesgo

La corrección de sesgo requiere un conjunto de observaciones de referencia contra el cual ajustar las distribuciones del modelo. Se emplearon dos fuentes complementarias, seleccionadas en función de la variable y la resolución temporal requerida:

CUADRO 5.1: Variables climáticas utilizadas del modelo CNRM-ALADIN64 y sus referencias de observación para la corrección de sesgo.

Variable	**Abreviación**	**Resolución**	**Referencia**
Temperatura del aire (2 m)	`tas`	Horaria	ERA5-Land (horaria)
Temperatura de rocío	`Td`	Horaria	ERA5-Land (horaria)
Viento superficial (10 m)	`sfcWind`	Horaria	ERA5-Land (horaria)
Radiación solar descendente	`rsds`	Horaria	ERA5-Land (horaria)
Precipitación	`pr`	Horaria	ERA5-Land (horaria)

- **CR2MET v2.5** [67]: Grilla observacional diaria de alta resolución ($\sim$0,05°) para Chile, basada en la interpolación de estaciones meteorológicas y productos satelitales. Se utiliza como referencia para la corrección de temperatura máxima diaria (T_{max}), temperatura mínima diaria (T_{min}) y precipitación diaria. Su resolución espacial superior permite capturar gradientes topográficos esenciales en la compleja orografía chilena.
- **ERA5-Land** [68]: Reanálisis global a $\sim$9 km de resolución con frecuencia horaria. Se utiliza como referencia para las variables que requieren resolución subdiaria: temperatura del aire horaria (`tas`), temperatura de rocío (`Td`), viento superficial (`sfcWind`), radiación solar (`rsds`) y precipitación horaria (`pr`).

El modelo GAM emplea exclusivamente forzantes corregidas contra **ERA5-Land**, cuya resolución horaria nativa permite la corrección directa sin reconstrucción temporal. Las correcciones contra CR2MET se documentan en el Apéndice K como producto complementario.

5.2.3. Datos de demanda eléctrica

Los datos de demanda eléctrica provienen de los registros oficiales del Coordinador Eléctrico Nacional (CEN), que publican retiros horarios de energía activa (kWh) a granularidad **(barra, cliente)**. El periodo cubierto comprende desde enero de 2017 hasta abril de 2025, totalizando 73.008 registros horarios por serie.

El proceso de constitución del panel parte del universo completo de pares (barra, cliente) disponibles en los registros del Coordinador y aplica un **censo** con dos criterios mínimos de inclusión: (i) al menos **36 meses** de observaciones horarias y (ii) al menos **1 GWh acumulado** en el periodo de cobertura. La intersección de ambos filtros, ejecutada sobre las 3.676 barras registradas en *Infotécnica* del CEN, produce el panel final de **2.567 series candidatas**, estratificadas en tres tipos de cliente según el rol del consumidor en el mercado mayorista:

- Distribuidoras (**388 series**, 15,1 %): distribuidoras de servicio público (clientes regulados servidos por la empresa concesionaria local, predominantemente residenciales y comerciales pequeños). Su retiro horario en el CEN figura agregado a nivel de barra de inyección.
- Clientes regulados (**140 series**, 5,5 %): clientes libres regulados, esto es, grandes consumidores cuya conexión se realiza bajo contrato regulado por la Comisión Nacional de Energía (CNE) pero con retiro directo (sin pasar por una distribuidora).

- Clientes libres (**2.039 series**, 79,4 %): clientes libres no regulados, mayoritariamente industriales y mineros con contratos bilaterales y tarifa libre.

La granularidad (barra, cliente) permite separar las respuestas térmicas heterogéneas que coexisten dentro de una misma barra (p. ej., distribuidora residencial junto a un cliente industrial libre), evitando la dilución de las curvas de sensibilidad por mezcla de cargas. Como complemento, las series se agregan a **340 subestaciones** como modelo SE-agregado, sobre el que se ajusta un GAM agregado a nivel de subestación para comparación macrorregional. La agregación a subestación sigue la nomenclatura oficial del SEN y habilita el vínculo con el píxel climático ALADIN y el modelado de sensibilidad térmica [20, 21].

Uso dual de la población. El análisis principal de la tesis se realiza sobre las **2.529 series** exitosamente ajustadas por el modelo aditivo generalizado per-(barra, cliente) (Sección 5.7.2), correspondientes al 98,5 % del censo (38 series descartadas: 19 errores numéricos de ajuste y 19 por cobertura intra-ventana insuficiente). En paralelo, el modelo SE-agregado (335 SE convergentes de las 340 agregadas) se conserva por dos razones: (i) comparabilidad con modelos previos de la literatura GAM/demanda que operan a nivel de subestación [20, 21]; y (ii) verificación empírica de la estrategia de granularidad mediante una prueba de equivalencia estadística entre ambas agregaciones (Sección 5.9).

El proceso de limpieza y curación de datos se detalla en la Sección 5.4. Los procedimientos completos, incluyendo estadísticas descriptivas por SE y las figuras de diagnóstico de calidad, se documentan en el Apéndice B.

5.3. Corrección de sesgo climático

Las salidas directas de los modelos climáticos regionales presentan sesgos sistemáticos respecto a las observaciones locales, particularmente en la distribución de extremos [37]. Incluso métodos estadísticos avanzados de corrección de sesgo subestiman los impactos de eventos extremos cuando no preservan las colas de la distribución [25]. Por ello se seleccionó UQM, un método diseñado explícitamente para preservar las colas de la distribución en la corrección de sesgo.

5.3.1. Método: *Unbiased Quantile Mapping* (UQM)

El método base seleccionado es el ***Unbiased Quantile Mapping*** (UQM) implementado en la librería `climQMBC` v1.1 [26]. A diferencia del mapeo de cuantiles tradicional (*Quantile Mapping*, QM), que puede amortiguar o distorsionar las tendencias climáticas proyectadas, UQM descompone la serie temporal modelada en un componente de tendencia y uno de variabilidad. La corrección se aplica únicamente al componente de variabilidad, preservando íntegramente la señal de cambio climático del modelo original. Esta preservación explícita de los cambios en media y varianza, incluyendo los extremos térmicos, responde directamente a la advertencia de [25] sobre la subestimación de impactos extremos en métodos que distorsionan las colas. La elección de UQM frente a las alternativas de la misma familia (QM, DQM, QDM y SDM) se sustenta en la comparación sistemática de los cinco métodos sobre este mismo modelo regional reportada en [30] centradas en los eventos extremos.

5.3.2. Corrección horaria directa contra ERA5-Land

Las cinco variables climáticas utilizadas en el modelado GAM (`tas`, `Td`, `sfcWind`, `rsds`, `pr`) se corrigen a **resolución horaria** utilizando **ERA5-Land** como referencia de reanálisis [68]. La corrección se aplica directamente sobre las series horarias del modelo ALADIN, sin necesidad de ventana móvil ni reconstrucción temporal: la frecuencia horaria provee muestras suficientes para una estimación robusta de cuantiles (aproximadamente 8.760 datos por año por píxel).

El modo de corrección se seleccionó según la naturaleza física y estadística de cada variable:

- **Modo aditivo** (distribución normal): temperatura del aire (`tas`), temperatura de rocío (`Td`).
- **Modo multiplicativo** (distribución Weibull): viento superficial (`sfcWind`), precipitación (`pr`), radiación solar (`rsds`).

La corrección horaria directa presenta dos ventajas fundamentales respecto a estrategias que operan a escala diaria: (i) preserva la estructura subdiaria del ciclo de temperatura sin requerir un paso de reescalamiento posterior, y (ii) no introduce los problemas de consistencia termodinámica ($T_{min} > T_{max}$) que pueden afectar a la corrección diaria independiente de extremos. Una limitación conocida de todo mapeo de cuantiles es que su calibración se valida dentro de la muestra. Un ejercicio de validación fuera de muestra bajo no estacionariedad, entrenando en décadas cálidas y evaluando en décadas frías, y viceversa, realizado sobre este mismo modelo regional en [30] muestra que el ajuste reduce el sesgo de la cola P90–P99,9 entre tres y siete veces, y que el residuo de la configuración análoga a la tarea de proyección es frío, de modo que las forzantes proyectadas resultan conservadoras.

Nota sobre la referencia alternativa CR2MET. Además de la corrección contra ERA5-Land, se implementó un procedimiento alternativo aplicado a las temperaturas diarias (T_{max}, T_{min}) y a la precipitación, tomando como referencia la grilla observacional **CR2MET v2.5** [67], la cual incorpora información de estaciones meteorológicas locales y puede representar mejor ciertos gradientes espaciales asociados a la topografía chilena. Sin embargo, el ajuste diario contra CR2MET introduce complejidades adicionales, incluyendo la necesidad de una ventana móvil de 11 días para robustecer la estimación de cuantiles, un paso de reconstrucción horaria por reescalamiento lineal, y una corrección vía rango térmico diurno (DTR) para evitar inversiones $T_{min} > T_{max}$. Además, dado que algunas variables requeridas por el modelo GAM no están disponibles en CR2MET, su uso obligaría a combinar temperaturas ajustadas contra CR2MET con otras variables ajustadas contra ERA5-Land, introduciendo un producto climático híbrido cuya consistencia física debe evaluarse cuidadosamente. A esto se suma que CR2MET no cubre necesariamente el mismo período requerido para el acoplamiento con los datos eléctricos debido a su menor rango de cobertura temporal en comparación con ERA5-Land. Esta limitación obligaría a contraer la ventana de entrenamiento de los modelos estadísticos para garantizar la coincidencia simultánea de ambas series, reduciendo la muestra efectiva respecto a la implementación de este trabajo. Estas complicaciones no están presentes en el camino horario directo basado en ERA5-Land. El presente trabajo utiliza exclusivamente las forzantes corregidas contra ERA5-Land para el modelado GAM y las proyecciones. El Apéndice K presenta una comparación detallada de ambos productos corregidos, discutiendo las ventajas y limitaciones de cada referencia, mientras

que la base corregida contra CR2MET se conserva como un producto complementario para aplicaciones en que la prioridad sea la representación local de temperatura diarias y en que no se requiera integrar, en un mismo modelo, variables horarias adicionales corregidas contra ERA5-Land.

5.3.3. Derivación de la temperatura de rocío

La temperatura de rocío (`Td`) se deriva de la temperatura del aire (`tas`) y la humedad específica (`huss`) mediante la **fórmula de Magnus** [69]:

$$T_d = \frac{b \cdot \alpha(T, RH)}{a - \alpha(T, RH)}, \qquad \alpha(T, RH) = \frac{a \cdot T}{b + T} + \ln(RH) \tag{5.1}$$

donde $a = 17{,}625$ y $b = 243{,}04\,^{\circ}\text{C}$ son las constantes de Magnus, y RH se obtiene de `huss` y `tas`. La serie de T_d cruda del ALADIN se corrige posteriormente mediante UQM aditivo contra ERA5-Land. La humedad relativa corregida no se computa como producto final; el GAM emplea directamente la T_d corregida como predictor de confort térmico.

Los detalles completos de la formulación matemática, la interpolación de grillas y las métricas de validación se documentan en el Apéndice A. La comparación entre los productos corregidos con CR2MET y ERA5-Land se presenta en el Apéndice K. La descripción del modelo ALADIN se presenta en el Apéndice J.

5.4. Limpieza y curación de datos de demanda

Las series horarias de demanda descargadas de la API del CEN presentan anomalías propias de sistemas de telemetría operacional: picos espurios, periodos de datos muertos (valores constantes o nulos), vacíos por mantenimiento y quiebres estructurales asociados a cambios en la configuración de la red. Las anomalías se detectaron y trataron de forma automatizada sobre cada par (barra, cliente). El detalle del procedimiento, junto con el listado de constantes literales empleadas, se documenta en el Apéndice B.

5.4.1. Detección de anomalías: cuatro detectores asimétricos

Se aplicaron **cuatro detectores asimétricos** complementarios, ejecutados sobre la rejilla horaria reindexada de cada serie (Tabla 5.2). La unión lógica de las cuatro *flags* se reemplaza por NaN antes de la imputación.

La asimetría del detector (3) ($+6\sigma$ vs -4σ) refleja el comportamiento esperado del sistema: el umbral superior tolera picos de demanda térmica genuinos, mientras que el inferior descarta valles profundos asociados a desconexión o falla de telemetría. El detalle de la cobertura horaria resultante por serie y por estrato, junto con la distribución de *flags* por detector, se presenta en el Apéndice B.

5.4.2. Imputación de datos faltantes

Los vacíos resultantes de la detección de anomalías y los datos originalmente faltantes se tratan mediante una **estrategia de imputación por niveles** (*tiered gap filling*), graduada según la duración del vacío:

CUADRO 5.2: Umbrales literales del procedimiento de limpieza per-(barra, cliente). Todos los detectores son **asimétricos**: aceptan picos de demanda genuinos con mayor laxitud que valles, dado que el sistema tiende a observar excedencias térmicas con mayor frecuencia que "apagones aparentes".

Detector	Umbral	Estratificación
(1) Gradiente adaptativo	$\lvert\Delta y_t\rvert > \max(500\ \text{kW/h}, 0{,}5 \cdot \tilde{y})$	Global por serie; $\tilde{y}$ es la mediana de la serie.
(2) IQR estacional	$y_t < Q_1 - 3{,}0 \cdot \text{IQR}$ *o* $y_t > Q_3 + 3{,}0 \cdot \text{IQR}$	Por celda (mes, hora-del-día); 288 celdas/serie.
(3) z-score asimétrico MAD	$z_t > 6{,}0\,\sigma_{\text{MAD}}$ *o* $z_t < -4{,}0\,\sigma_{\text{MAD}}$	Por celda (mes, hora-del-día); $\sigma_{\text{MAD}} = 1{,}4826 \cdot \text{MAD}$.
(4) Datos muertos	Razón $y_t/\tilde{y}_{\text{mh}} < 0{,}15$, persistente ≥ 12 h consecutivas	$\tilde{y}_{\text{mh}}$ = mediana por celda (mes, hora-del-día).

- **Vacíos $\leq$ 6 horas (corto):** Interpolación lineal entre los valores válidos adyacentes.
- **Vacíos de 7 a 72 horas (medio):** Imputación *seasonal naive*: se reemplaza con el valor de la misma hora del mismo día de la semana anterior (desplazamiento de 168 h); si ese ancla también está vacía, se intenta con el correspondiente a dos semanas antes (336 h).
- **Vacíos $>$ 72 horas (largo):** Se mantienen como NaN y se excluyen del entrenamiento GAM.

Aplicada al conjunto de 2.529 series (barra, cliente), la estrategia resuelve la mayoría de los vacíos cortos y medios; los prolongados quedan como `NaN` y se excluyen del entrenamiento. El detalle por estrato se presenta en el Apéndice B.

5.4.3. Detección de quiebres estructurales

Las series (barra, cliente) presentan quiebres de nivel (saltos permanentes en la media) asociados a cambios en la topología de la red, conexión o desconexión de grandes consumidores, o reasignación de barras. Se aplicó el **test de Pettitt** [70], test no paramétrico basado en rangos, con $\alpha = 0{,}05$, segmentos mínimos de 12 meses y hasta 3 quiebres por serie mediante segmentación binaria iterativa.

El test detecta quiebres estructurales en la mayoría de las series candidatas. La concentración de quiebres en el estrato Distribuidoras es coincidente con el desmantelamiento normativo establecido por la **Ley N. 21.194** [**?**] (promulgada el 22 de diciembre de 2019), que reorganizó el esquema de retiros horarios (barra, cliente) para clientes regulados; este cambio se materializa en los registros del CEN en abril de 2022, momento en que las 388 series del estrato Distribuidoras terminan su registro horario. El test de Pettitt identifica correctamente estos finales abruptos como quiebres estructurales significativos. Por esta razón los quiebres se tratan de manera diferenciada:

- Para las series del estrato Distribuidoras, los quiebres se interpretan como término administrativo del registro, no como cambio estructural de la demanda subyacente. La serie completa se conserva para el ajuste GAM hasta la

última observación válida; estas series alimentan la inferencia de sensibilidad térmica histórica pero se excluyen de la proyección climática (Sección 5.9).

- Para los estratos Clientes regulados y Clientes libres (clientes en operación), un quiebre significativo se interpreta como cambio topológico real; el segmento más reciente se utiliza para el ajuste.

5.4.4. Variable *dummy* COVID-19

El periodo de confinamiento por la pandemia de COVID-19 (15 de marzo a 30 de septiembre de 2020) alteró sustancialmente los patrones de demanda eléctrica en Chile. Se incorporó una variable indicadora binaria que toma valor 1 durante dicho periodo para aislar su efecto de las estimaciones de sensibilidad climática. Esta variable entra como predictor paramétrico en la fórmula GAM (Sección 5.7.2).

5.4.5. Clasificación de calidad y selección final

Cada serie (barra, cliente) se evaluó con un índice compuesto de calidad que pondera cobertura temporal, estabilidad estructural, magnitud de la demanda y consistencia de los patrones diarios. De las **2.567 series candidatas**, se ajustaron **2.529** en el modelo per-(barra, cliente) (19 errores de ajuste y 19 descartes por cobertura insuficiente). Se mantiene además un modelo SE-agregado que converge para 335 SE (de 340 candidatas) (Apéndice L). Los criterios detallados y las fichas por serie se presentan en el Apéndice B. La Figura 5.3 resume el flujo completo.

5.5. Georreferenciación: vínculo clima-demanda

Para alimentar el GAM con las forzantes climáticas correctas, cada subestación eléctrica debe vincularse con el píxel ALADIN más cercano a su ubicación geográfica. La cadena de georreferenciación sigue los pasos:

1. Se extrae la coordenada UTM (Este, Norte, Huso) de cada subestación desde la base de datos *Infotécnica* del CEN.
2. Las coordenadas UTM se transforman a latitud/longitud (WGS84).
3. Se identifica el píxel de la grilla ALADIN (0,11°) cuyo centro se encuentra a menor distancia euclidiana de la subestación.
4. Se extraen las series horarias de las cinco variables climáticas corregidas (temperatura del aire, temperatura de rocío, viento superficial, radiación solar de onda corta y precipitación) para cada píxel asignado.

Este procedimiento genera un emparejamiento unívoco SE↔píxel, constante en el periodo histórico y en las proyecciones futuras. Dado que la resolución espacial del modelo es de aproximadamente 12 km, esta asignación debe interpretarse como una aproximación local al clima de cada subestación, no como una representación de la variabilidad microclimática dentro del píxel. Los detalles del mapeo, incluyendo las distancias SE-píxel y la verificación visual, se presentan en el Apéndice H.

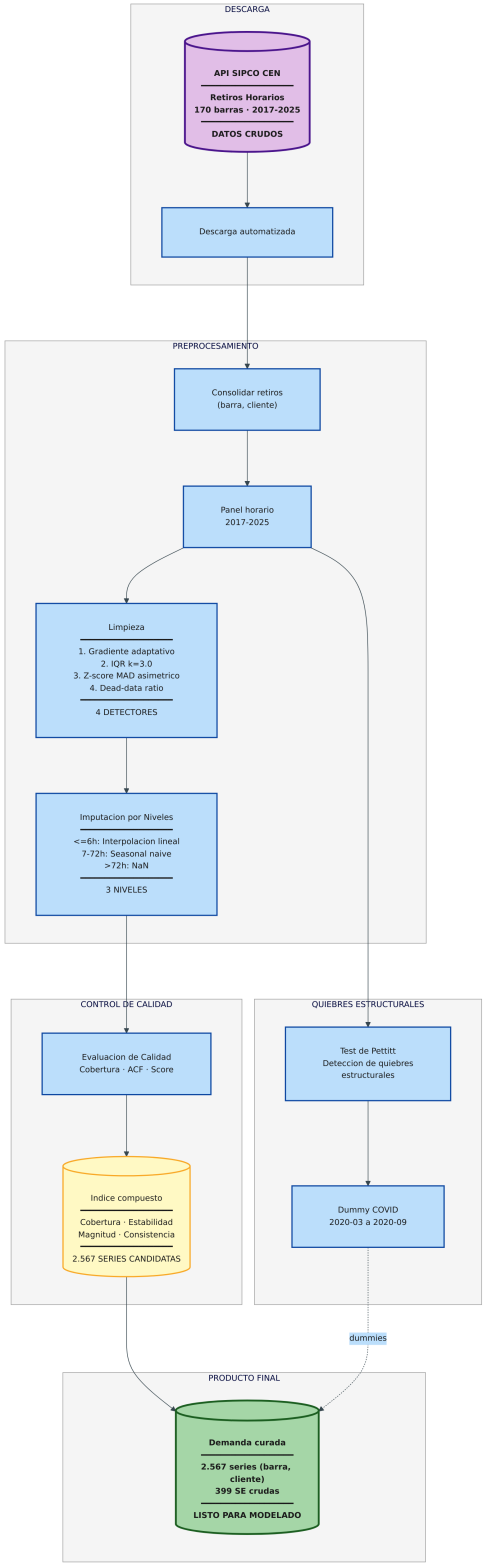

FIGURA 5.3: Pipeline de limpieza y curación de datos de demanda eléctrica. Se aplican cuatro detectores de anomalías secuenciales, seguidos de una imputación por niveles graduada según la duración del vacío. El test de Pettitt detecta quiebres estructurales y se identifica el periodo COVID como variable indicadora.

5.6. Definición y detección de olas de calor

La definición operacional de olas de calor adoptada en esta tesis se basa en umbrales percentílicos locales, siguiendo las recomendaciones de [40] y [41]. La detección opera sobre las series de temperatura corregida por sesgo del modelo ALADIN a resolución de píxel. Los umbrales se calculan a partir de extremos diarios, mientras que la identificación de horas extremas se realiza sobre la serie horaria de temperatura, lo que vincula directamente los eventos de calor con la demanda eléctrica horaria.

5.6.1. Algoritmo de detección

El procedimiento consta de cinco pasos secuenciales:

1. **Cómputo de extremos diarios:** A partir de la serie horaria corregida de `tas`, se calcula la temperatura máxima diaria (T_{max}) y la temperatura mínima diaria (T_{min}) para cada píxel.
2. **Umbrales climatológicos:** Se construyen, para cada píxel, el percentil 90 de T_{max} (P90) y el percentil 10 de T_{min} (P10) sobre el periodo de referencia 1980–2010 (31 años). Estos umbrales son constantes en el tiempo y específicos de cada ubicación, capturando la variabilidad climática local.
3. **Clasificación horaria:** Cada hora t se clasifica como *extrema* si la temperatura instantánea T_t excede el umbral P90 del píxel correspondiente. Esta resolución horaria vincula directamente los episodios de calor con las horas de demanda punta.
4. **Clasificación diaria:** Un día se clasifica como *extremo* si contiene al menos una hora extrema.
5. **Detección de eventos:** Una **ola de calor** se define como una secuencia de **3 o más días extremos consecutivos**. Este umbral de persistencia distingue los eventos sostenidos, potencialmente asociados a impactos acumulativos sobre la demanda, de las excedencias térmicas aisladas. El criterio alternativo de un solo día extremo, que maximiza el número de eventos detectados y facilita la comparación con la literatura climatológica, se emplea en [30]; la exigencia de tres días adoptada aquí es más restrictiva y produce, por construcción, catálogos de menor frecuencia, centrándose en eventos de mayor impacto.

5.6.2. Métricas de caracterización

Cada evento detectado se caracteriza mediante tres métricas complementarias:

- **Duración** [días]: Número de días consecutivos del evento.
- **Intensidad** $[°C]$: Diferencia entre la T_{max} más alta alcanzada durante el evento y el umbral P90 local, cuantificando la severidad del pico térmico.
- **Magnitud** $[°C \cdot horas]$: Integral de la excedencia horaria de temperatura sobre el umbral durante la duración completa del evento. La resolución horaria de esta métrica captura la carga térmica acumulada con mayor precisión que la magnitud convencional en °C · días [40], lo que la hace más relevante para el análisis del estrés del sistema eléctrico.

Las **olas de frío** se definen con las mismas reglas, aplicando el umbral P10 sobre T_{min}: un día es extremo frío si $T_{min} <$ P10, y una ola de frío requiere 3 o más días consecutivos.

Cada evento genera una variable binaria horaria $HW_t \in \{0, 1\}$ que indica si el instante t pertenece a un evento, lo que permite segmentar la demanda durante y fuera de olas de calor. Los catálogos completos de eventos y sus distribuciones espaciales se presentan en el Apéndice C. La Figura 5.4 esquematiza el procedimiento.

5.7. Modelos Aditivos Generalizados (GAM)

Para modelar la relación no lineal entre la demanda eléctrica y las variables climáticas se utilizan Modelos Aditivos Generalizados [51]. Los GAM combinan la flexibilidad de los métodos no paramétricos con la interpretabilidad de los modelos lineales: cada predictor ingresa al modelo a través de una función de suavizado estimada empíricamente, cuyo efecto marginal puede visualizarse y analizarse independientemente. Esta propiedad es fundamental para el análisis de políticas energéticas, donde interesan tanto la precisión predictiva como la comprensión de los mecanismos causales [27]. La Figura 5.5 presenta la arquitectura del modelo final.

5.7.1. Campaña experimental

La especificación GAM final se seleccionó mediante una campaña sistemática de 28 configuraciones organizadas en cuatro grupos (tratamiento de la respuesta, predictores climáticos, estructura temporal y síntesis), evaluadas sobre 5 SE piloto seleccionadas por diversidad geográfica y climática. La descripción detallada de cada grupo se presenta en el Apéndice D (Figura 5.6). La comparación se realizó mediante un **índice compuesto de ranking**:

$$\text{Score} = 0{,}4 \cdot (1 - \text{MAPE}/100) + 0{,}3 \cdot \text{DevExpl} + 0{,}2 \cdot (1 - r_{\text{AIC}}/N) + 0{,}1 \cdot (1 - |\text{ACF}_1|) \tag{5.2}$$

donde MAPE es el error porcentual absoluto medio, DevExpl la devianza explicada, r_{AIC} el ranking por AIC entre los N modelos candidatos, y ACF_1 la autocorrelación residual de primer orden. Los pesos reflejan la priorización del error predictivo (0,4) y la capacidad explicativa (0,3), con menor peso al criterio de información (0,2) y a la autocorrelación residual (0,1).

El modelo final, en su variante per-(barra, cliente), es la configuración con mejor desempeño en el *score* compuesto sobre las cinco SE piloto; se detalla en la Sección 5.7.2. La ficha completa de cada experimento, con sus métricas por SE piloto y la tabla comparativa del ranking, se presenta en el Apéndice D.

5.7.2. Formulación del modelo

La demanda eléctrica horaria de cada serie (barra, cliente) i se modela bajo un enlace logarítmico (familia Gaussiana) como:

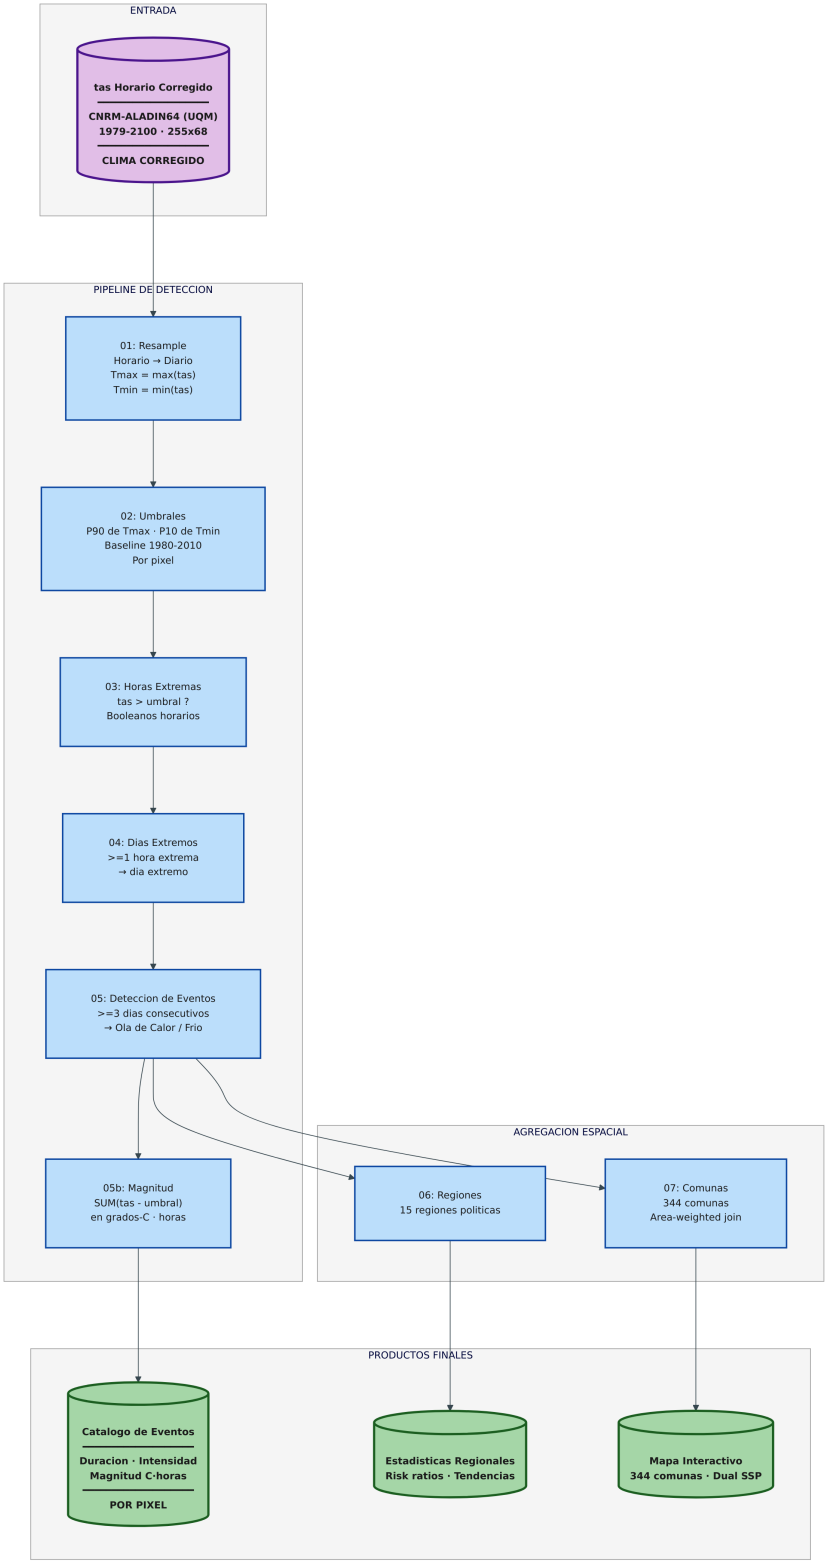

FIGURA 5.4: Pipeline de detección y caracterización de olas de calor y frío. El algoritmo opera en cinco etapas: remuestreo diario, cómputo de umbrales percentílicos P90/P10, identificación de horas y días extremos, detección de eventos ($\geq$ 3 días consecutivos) y cálculo de magnitud en °C·horas. Los productos se agregan a nivel regional y comunal.

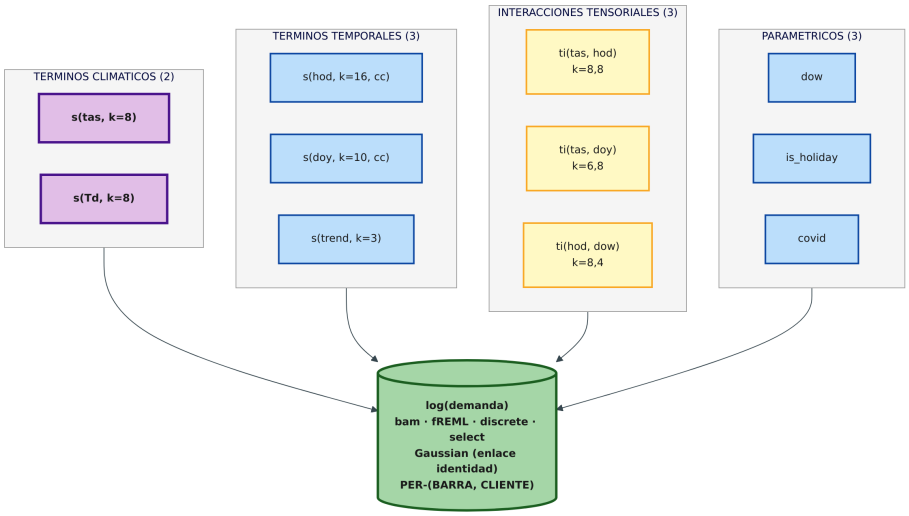

FIGURA 5.5: Arquitectura del modelo aditivo generalizado canónico de la tesis, ajustado a granularidad per-(barra, cliente). El modelo integra 2 términos climáticos (`tas`, `Td`), 3 términos temporales cíclicos/lineales (hora del día, día del año y tendencia), 3 interacciones tensoriales (temperatura×hora, temperatura×estación y hora×día de la semana) y 3 términos paramétricos. La respuesta es log(demanda) con enlace logarítmico y familia Gaussiana, ajustada por máxima verosimilitud restringida (REML) mediante el paquete `mgcv`. El modelo SE-agregado conserva además `sfcWind`, `rsds`, `pr` y la EWMA térmica.

$$\begin{aligned}\log(y_{i,t}) = \beta_0 &+ s(\texttt{tas}_t,\, k=8) + s(\texttt{Td}_t,\, k=8) \\ &+ s(\texttt{hod}_t,\, k=16,\, \text{cc}) + s(\texttt{doy}_t,\, k=10,\, \text{cc}) \\ &+ s(\texttt{trend}_t,\, k=3) \\ &+ ti(\texttt{tas}_t,\, \texttt{hod}_t;\, k=(8,8)) \\ &+ ti(\texttt{tas}_t,\, \texttt{doy}_t;\, k=(6,8)) \\ &+ ti(\texttt{hod}_t,\, \texttt{dow}_t;\, k=(8,4)) \\ &+ \texttt{dow}_t + \texttt{is_holiday}_t + \texttt{covid_dummy}_t + \varepsilon_{i,t}\end{aligned} \tag{5.3}$$

La especificación per-(barra, cliente) adopta dos decisiones de diseño para robustecer el ajuste frente a series cortas y heterogéneas:

- **Selección de predictores climáticos.** El bloque climático retiene únicamente $s(\texttt{tas})$ y $s(\texttt{Td})$. Los suavizadores $s(\texttt{pr})$, $s(\texttt{rsds})$, $s(\texttt{sfcWind})$ y el término de inercia térmica $s(\widetilde{T})$ basado en una media móvil exponencialmente ponderada ($\alpha = 0{,}05$) se omiten en la formulación per-serie. La selección responde a tres razones propias del grano (barra, cliente): (i) la distribución de `pr` se vuelve degenerada (>80 % de horas con $\texttt{pr} = 0$) cuando se considera el píxel ALADIN fijo por SE; (ii) `rsds` y `sfcWind` aportaban grados de libertad efectivos marginales en el modelo SE-agregado y resultan sistemáticamente penalizados a cero por el mecanismo de selección extra (`select=TRUE`, [60]) en las series más cortas; (iii) la EWMA térmica introduce concurvidad excesiva con $s(\texttt{tas})$ y con el tensor $ti(\texttt{tas}, \texttt{doy})$ en series con menos de tres años de cobertura, ya que ambos términos capturan formas alternativas de inercia térmica.

- **Dimensión de base.** El grado de libertad de cada suavizador se fija siguiendo la regla de aproximadamente una función base por cada tres años de observación [60], y se valida iterativamente mediante la diagnostica de Pya & Wood [55] (el criterio de aceptación y la tasa de cumplimiento se reportan en la Sección 5.7.4).

La estimación emplea una penalización adicional de selección (`select=TRUE`, [52,60]) que empuja términos espurios hacia cero, y REML como criterio de selección de suavidad. Las componentes se organizan en cuatro bloques funcionales:

Bloque climático. En la formulación per-(barra, cliente) ingresan dos variables meteorológicas como *splines* marginales: temperatura del aire (`tas`) y temperatura de rocío (`Td`). El efecto $s(\texttt{tas})$ captura la conocida respuesta en forma de "U" (o "J") de la demanda a la temperatura, con un mínimo cercano a la zona de confort térmico y pendientes asimétricas para calentamiento y enfriamiento.

Inercia térmica. El término de inercia térmica $s(\widetilde{T}_t)$ se basa en una media móvil exponencialmente ponderada (EWMA) con parámetro $\alpha = 0{,}05$:

$$\widetilde{T}_t = \alpha \cdot T_t + (1 - \alpha) \cdot \widetilde{T}_{t-1} \tag{5.4}$$

y captura la masa térmica de los edificios y la inercia de los sistemas de climatización [59]. En esta tesis, la EWMA se evaluó como predictor candidato, pero se omite de la formulación per-(barra, cliente) por la concurvidad que introduce con $s(\texttt{tas})$ y con el tensor $ti(\texttt{tas,,doy})$. En consecuencia, la dependencia térmica acumulada queda representada indirectamente por la interacción temperatura-estación, mientras que $s(\widetilde{T}_t)$ se conserva solo en el modelo SE-agregado (Sección 5.7.5).

Estructura temporal. La hora del día (`hod`) y el día del año (`doy`) se modelan con *splines* cíclicos (`bs="cc"`) que garantizan continuidad en los bordes (hora 23→0, día 365→1). En la formulación canónica de la Ecuación 5.3, los festivos ingresan como un indicador paramétrico `is_holiday`; si se desea modelar un perfil horario específico para festivos, el suavizado condicional $s(\texttt{hod, by} = \texttt{is_holiday})$ debe incorporarse explícitamente en la ecuación..

Un aspecto técnico relevante es la parametrización del término de tendencia $s(\texttt{trend_index})$. En la formulación per-(barra, cliente) se adopta una dimensión de base muy conservadora, siguiendo la heurística propuesta por [60] para evitar la concurvidad excesiva con la estacionalidad anual: combinada con la penalización extra de selección, acota la concurvidad del par $s(\texttt{doy}) \leftrightarrow s(\texttt{trend_index})$ por debajo del umbral adoptado (su valor y la discusión de la métrica se reportan en la Sección 5.7.4).

Interacciones tensoriales. Las interacciones se especifican mediante tensores de tipo `ti()` (*tensor interaction*), siguiendo la descomposición de tipo ANOVA recomendada por [71] para evitar la confusión entre efectos marginales e interacciones. Se incluyen tres interacciones en la formulación per-serie:

- $ti(\texttt{tas,hod})$: captura cómo la sensibilidad térmica varía según la hora del día (por ejemplo, mayor respuesta en horas de demanda punta).
- $ti(\texttt{tas,doy})$: modela la estacionalidad de la respuesta térmica (por ejemplo, mayor sensibilidad al calor en verano que en primavera).

- $ti(\texttt{hod}, \texttt{dow})$: interacción de calendario que captura cómo el perfil horario de demanda varía según el día de la semana (perfiles laborales frente a fines de semana); actúa como control y no interviene en la respuesta térmica.

Efectos paramétricos. El día de la semana (`dow`), el indicador de festivo (`is_holiday`) y la variable *dummy* COVID-19 ingresan como factores paramétricos lineales.

5.7.3. Estimación e implementación computacional

Dado el volumen de datos (típicamente $n > 30{,}000$ observaciones horarias para el segmento post-quiebre por serie), se utiliza la función `bam()` del paquete `mgcv` de R [52], que implementa estimación por *fast Restricted Maximum Likelihood* (fREML, o REML según el ajuste) con discretización de covariables (`discrete=TRUE`). Este enfoque reduce la complejidad computacional de $\mathcal{O}(n^3)$ a $\mathcal{O}(n \cdot k^2)$, habilitando el ajuste masivo de **2.529** series (barra, cliente) [72].

La opción `select=TRUE` activa una penalización adicional (*extra shrinkage penalty*) sobre cada término suavizado, permitiendo que términos redundantes o espurios sean encogidos a cero durante la estimación [52]. El resultado es una selección automática de variables dentro del GAM.

El ajuste se realiza con el paquete `mgcv`.

5.7.4. Diagnósticos: `gam.check`, concurvidad, ACF

Cada serie ajustada genera tres diagnósticos canónicos:

- `gam.check` **(k-index).** Para cada suavizador se reporta el cociente EDF/k' y el k-index de la diagnostica de Pya & Wood [55]. La regla de aceptación es k-index ≥ 1 y test $p \geq 0{,}05$. En la población per-(barra, cliente) esta condición se satisface para el 93 % de las series; en las restantes el flag se documenta como advertencia pero no constituye criterio de exclusión, ya que bajo `select=TRUE` el sobre-dimensionamiento se neutraliza automáticamente.
- **Concurvidad.** Se computa la matriz de concurvidad `worst` entre suavizadores. El criterio operacional, tomado de [60], exige concurvidad `worst`$< 0{,}8$ para todos los pares estructuralmente independientes (excluyendo el par marginal–tensor, cuyo solapamiento corresponde a un artefacto numérico conocido en `mgcv`, ver [71] §5.6). La combinación de una dimensión de base muy conservadora para la tendencia con `select=TRUE` mantiene la concurvidad $s(\texttt{doy}) \leftrightarrow s(\texttt{trend_index})$ con mediana *estimate* $\approx 0{,}569$ (bajo el umbral 0,8) en las 2,529 series. La cifra se reporta a nivel del par específico (tipo `estimate` de `mgcv`), que es la métrica directamente comparable con [60]. El escalar `worst` sobre todos los pares ($\approx 1{,}0$ en presencia de tensores tipo `ti(X,Y)`) refleja el solapamiento estructural $s(X) \leftrightarrow ti(X, Y)$ y *no* debe leerse como diagnóstico operativo ([71] §5.6.2). El contraste con la cifra del ajuste SE-agregado (Apéndice L) y la elección de la métrica reportada se documenta en el Apéndice E.2.2.
- **ACF de residuos.** La autocorrelación residual de primer orden es elevada (ACF_1 mediana 0,851 sobre 2,529 series; ver Tabla 5.3), inherente a los datos horarios de demanda eléctrica [61]. Las estimaciones de los suavizados son consistentes bajo autocorrelación, pero los intervalos de confianza puntuales son anti-conservadores. Se evaluó un término AR(1) (parámetro `rho` de `bam()`), incompatible con la aproximación `discrete=TRUE` requerida por el volumen de

datos; como mitigación se reportan intervalos simultáneos obtenidos por simulación posterior, que resultan entre 1,3 y 1,7 veces más anchos que los puntuales.

CUADRO 5.3: Métricas resumen del ajuste per-(barra, cliente), agregadas sobre las 2,529 series ajustadas.

Estrato	n	R^2 **med.**	**MAPE med. (%)**	ACF_1 **med.**
Clientes libres	2,005	0,628	6,49	0,841
Distribuidoras	385	0,686	1,51	0,879
Clientes regulados	139	0,250	2,53	0,891
Global	2,529	0,624	5,02	0,851

5.7.5. Dimensión de base según granularidad del ajuste

Para la dimensión de base de los *splines* (k) se adoptó un protocolo dual ajustado a la granularidad del ajuste:

- **Formulación per-(barra, cliente)**: dimensión de base reducida, siguiendo la regla de una función base por cada tres años de observación [60], para robustecer el ajuste sobre series cortas y ruidosas en la granularidad por cliente.
- **Modelo SE-agregado**: dimensión de base ligeramente superior, adecuada al mayor número de observaciones efectivas tras la agregación; conserva la formulación completa con cinco variables climáticas y EWMA, aplicada a 335 SE convergentes, para inferencia macroregional supletoria.

Este protocolo dual explota la mayor riqueza de las series por cliente para la inferencia local. El modelo SE-agregado complementa esa inferencia verificando la forma de la respuesta térmica en comparaciones macrorregionales.

5.8. Validación cruzada

El modelo final se validó con cinco técnicas complementarias que cubren distintas dimensiones del desempeño predictivo:

1. **LOMO (*Leave-One-Month-Out*):** Se entrena excluyendo un mes calendario y se predice sobre el mes excluido. Las 12 iteraciones proporcionan una estimación robusta del error promedio y su variabilidad mensual.
2. **Ventana rodante (*Rolling window*):** Se expande progresivamente el conjunto de entrenamiento y se evalúa sobre una ventana fija de 6 meses subsecuentes. Esta técnica evalúa la degradación temporal del modelo.
3. **Extrapolación estacional:** Se entrena excluyendo todos los meses de verano (diciembre–febrero) y se predice sobre ellos. Esta prueba es crítica para evaluar la capacidad del modelo de capturar la respuesta a temperaturas extremas estivales, el rango más relevante para las proyecciones de olas de calor.
4. **Retención de meses cálidos (*Warm-months holdout*):** Se reserva el 10 % de meses más cálidos de cada serie (por temperatura media mensual) como conjunto de prueba independiente. Evalúa la capacidad de extrapolación a condiciones térmicas cercanas a las proyectadas.

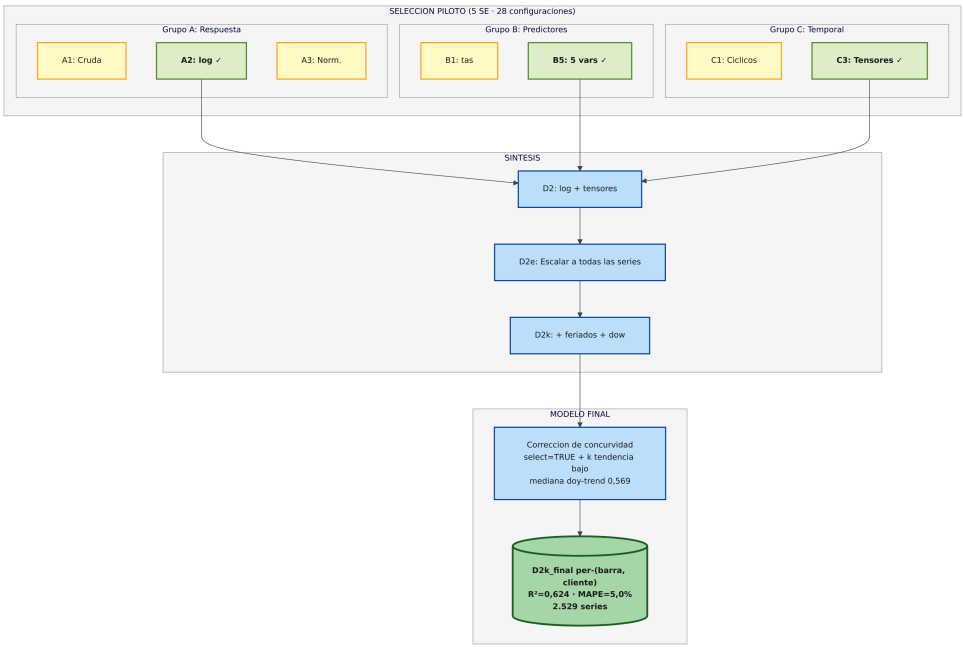

FIGURA 5.6: Campaña experimental de selección del modelo GAM. Se evaluaron variantes organizadas en cuatro grupos (A: tratamiento de la respuesta, B: predictores climáticos, C: estructura temporal, D: síntesis y refinamiento). El modelo final incorpora una dimensión de base muy conservadora para el término de tendencia y la penalización extra de selección, lo que controla la concurvidad entre tendencia y estacionalidad.

5. **Estabilidad de efectos parciales:** Se generan 20 réplicas con submuestras aleatorias del 80 % de los datos y se comparan las funciones de suavizado $s(\texttt{tas})$ estimadas. La estabilidad visual de las curvas indica que la estimación es robusta frente a la composición del conjunto de entrenamiento.

Las métricas de evaluación son el MAPE, la devianza explicada, el R^2 ajustado y la capacidad de reproducir los picos históricos (P95 y P99). Los resultados por SE y por técnica se presentan en el Apéndice F; los diagnósticos residuales (QQ-plot, ACF, concurvidad, verificación de k), en el Apéndice E. La Figura 5.7 esquematiza la estrategia.

5.9. Proyecciones bajo escenarios de cambio climático

5.9.1. Supuesto de red estática

Las proyecciones de demanda futura se generan bajo el supuesto de **red estática**: las funciones de suavizado estimadas por el GAM ($s(\cdot)$, $ti(\cdot,\cdot)$) y los coeficientes paramétricos se mantienen congelados en sus valores históricos estimados. El único insumo que varía es el vector de forzantes climáticas futuras proveniente del modelo ALADIN corregido por sesgo bajo SSP3-7.0. Las variables temporales (hora, día de la semana, estacionalidad) se proyectan mecánicamente según el calendario.

Este enfoque, consistente con la metodología de [12] y [20],permite aislar la señal climática en las variaciones proyectadas, sin confundir con factores socioeconómicos (crecimiento demográfico, penetración de aire acondicionado, eficiencia energética)

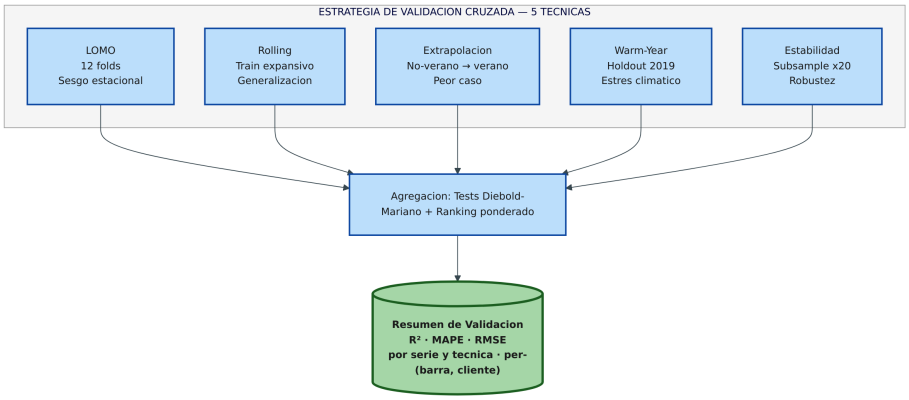

FIGURA 5.7: Estrategia de validación cruzada del modelo final. Se emplean cinco técnicas complementarias: LOMO (sesgo estacional), ventana rodante (generalización temporal), extrapolación estacional (peor caso térmico), *warm-year holdout* (estrés climático) y estabilidad de efectos parciales (robustez de los suavizados).

que requerirían supuestos adicionales. Las limitaciones de este supuesto se discuten en el Capítulo 7.

5.9.2. Procedimiento de proyección

Para cada SE ajustada, la proyección sigue tres pasos:

1. **Covariables futuras:** Se construyen las covariables horarias para el periodo 2025–2100 bajo SSP3-7.0. Las variables climáticas provienen de las series ALADIN corregidas (Sección 5.3); las variables de calendario se proyectan mecánicamente.
2. **Predicción:** Se evalúa la ecuación (5.3) con los parámetros estimados en el periodo histórico, obteniendo $\widehat{\log(y_{i,t})}$ para cada hora futura.
3. **Análisis de impacto:** Se comparan las distribuciones de demanda proyectada en ventanas temporales sucesivas (2025–2040, 2041–2060, 2061–2080, 2081–2100) con la distribución de referencia histórica. Las métricas de impacto incluyen: cambio en la demanda media anual, cambio en los picos (P95, P99), alteraciones en la Curva de Duración de Carga (CDC) y el diferencial de demanda durante olas de calor futuras respecto al diseño histórico.

5.9.3. Aislamiento de la señal climática y población de proyección

La estructura del panel (barra, cliente) requiere dos decisiones metodológicas para aislar la señal climática de las demás variaciones en el horizonte proyectivo. Ambas decisiones se enmarcan en la práctica estándar para proyecciones contrafactuales bajo el supuesto de red estática [12].

Tratamiento del término de tendencia. El término $s(\texttt{trend_index})$ captura, durante el entrenamiento, la componente residual de variación temporal no atribuible a las covariables climáticas ni al calendario. Bajo el supuesto de red estática, esta componente no debe extrapolarse fuera del rango de entrenamiento: hacerlo introduciría señales asociadas a la composición cambiante del panel (entrada de nuevos clientes, salida de series del estrato regulado por la reorganización normativa de 2022) más

que a cambios reales en la demanda subyacente. En consecuencia, durante la proyección el índice de tendencia se mantiene fijo en su valor terminal del periodo de entrenamiento, en línea con [12].

Población de proyección y cobertura temporal. El ajuste GAM se realiza sobre las **2.529 series (barra, cliente)** que el censo de calidad (Sección 5.4.5) entrega como candidatas exitosas. La agregación a nivel de sistema bajo el escenario SSP3-7.0 hereda el conjunto completo de series para las cuales el estimador GAM produce una predicción horaria válida sobre todo el horizonte 1980–2100, sin imponer un filtro adicional de actividad en una fecha de corte arbitraria. La Tabla 5.4 resume el embudo de población desde el censo hasta el agregado del sistema.

CUADRO 5.4: Embudo de series (barra, cliente) desde el censo de calidad hasta el agregado del sistema bajo SSP3-7.0. Cada recorte se justifica con el motivo numérico de exclusión; no se aplica un filtro de actividad en una fecha de corte arbitraria.

Etapa	n	**Periodo observado**	**Razón del recorte**
Censo (criterios de inclusión)	2,567	varía ($\geq$36 m, $\geq$1 GWh)	inclusión mínima
Ajuste GAM exitoso	2,529	2017-01 a 2025-04 (varía)	38 fallos numéricos
Con proyección 1980–2100	2,529	proyección horaria completa	rescate canónico (0 sin predicción)
Agregado del sistema	**2.529**	baseline 1980–2010 vs. futuros	sin filtro adicional

La cobertura temporal observada por estrato revela dos discontinuidades administrativas relevantes para la interpretación, ninguna de las cuales implica desaparición física de la demanda:

- **Estrato Distribuidoras (**385 **series con proyección).** En 377 de 388 series del estrato la observación horaria termina de forma simultánea el 1-mayo-2022 a las 05:00 UTC por efecto de la Ley N. 21,194, que reorganizó el formato del reporte horario de las empresas distribuidoras (Sección 5.4.3). La demanda física asociada a esos medidores no se extingue: lo que cambia es la forma de su registro en la base operacional del coordinador.
- **Estrato Clientes libres (*cliff* secundario).** Un total de 611 series Clientes libres terminan en una segunda discontinuidad administrativa el 1-marzo-2024 a las 05:00 UTC, asociada a la segunda fase de la reorganización del reporte. En 35 barras este *cliff* no es compensado por series Clientes libres activas posteriores.
- **Estrato Clientes regulados (**140 **series,** 139 **con proyección).** La distribución de fechas terminales se dispersa entre 2020 y 2024 sin un patrón administrativo único reconocible.

Restringir el agregado del sistema únicamente a las series con reporte activo en una fecha reciente (por ejemplo, octubre de 2024) captaría apenas el segmento industrializado del sistema (aproximadamente 2,4 GW), excluyendo cerca de 3,5 GW de demanda físicamente persistente cuyo formato de reporte fue simplemente reorganizado. El peak agregado del sistema chileno es del orden de 9–10 GW, de modo que ese filtro dejaría fuera más de un tercio de la potencia observable, sesgando el agregado en su composición: descartaría desproporcionadamente el segmento residencial-comercial pequeño (distribuidoras), que es precisamente el de mejor calidad de ajuste GAM ($R^2 = 0{,}686$, MAPE $= 1{,}51$ %) y, por su naturaleza térmicamente acoplada, el más informativo para una proyección climática.

Mecánicamente, la proyección procede de forma idéntica sobre las 2,529 series: el GAM aplica la sensibilidad térmica aprendida en su periodo de entrenamiento individual a las forzantes climáticas SSP3-7.0 sobre la ventana 1980–2100, fijando `trend_index` en el valor terminal de cada periodo de entrenamiento, conforme al supuesto de red estática. Las series excluidas en cada etapa del embudo no se descartan del análisis: alimentan la inferencia histórica de sensibilidad térmica (Capítulo 6) y la caracterización por estrato, que cubre el total de 2,529 ajustes.

Métricas de agregación. El agregado del sistema se calcula sobre la población definida en la Tabla 5.4 y se construye sobre tres elementos:

- **Baseline.** Promedio de la predicción GAM sobre la ventana 1980–2010, baseline climático histórico común a todas las series proyectadas, construido sobre la predicción GAM.
- **Ventanas futuras.** *near* (2030–2050), *mid-century* (2041–2060) y *end-century* (2081–2100). Las tres se evalúan sobre el mismo conjunto de 2,529 series para garantizar comparabilidad longitudinal del estimador.
- **Estadístico de impacto.** Se reporta el cambio relativo ponderado por demanda

$$\Delta_{\text{dw}} \;=\; \frac{\sum_i D_{i,\text{future}}}{\sum_i D_{i,\text{baseline}}} \;-\; 1,$$

  donde $D_{i,\bullet}$ es la demanda media de la serie i en la ventana correspondiente. Complementariamente se reporta la mediana per-serie del mismo cociente, con sus deciles, como medida robusta frente a la heterogeneidad de magnitudes entre estratos.

5.9.4. Escenarios y alcance

Las proyecciones se presentan bajo el escenario **SSP3-7.0**. Este escenario, correspondiente a un forzamiento radiativo de 7,0 W/m^2 al 2100, representa una trayectoria de emisiones medias-altas consistente con políticas climáticas débiles y desarrollo regional heterogéneo [66]. Las proyecciones de demanda bajo SSP5-8.5 se contemplan como trabajo futuro, pendiente de la corrección de sesgo del punto de rocío (Td) bajo dicho escenario.

Los mapas espaciales de cambio y las series temporales por SE se presentan en el Apéndice I.

Capítulo 6

Resultados

Este capítulo presenta los resultados organizados siguiendo el flujo metodológico del estudio: corrección de sesgo climático (SO.1), climatología de olas de calor (SO.5), datos de demanda eléctrica, selección del modelo GAM (SO.3), análisis de efectos parciales y sensibilidad térmica (SO.2 y SO.3), validación cruzada (SO.3) y proyecciones de impacto bajo SSP3-7.0 (SO.4). Cada sección responde directamente a una o más hipótesis de la tesis, cuya síntesis se presenta en la Sección 6.8.

6.1. Validación de la corrección de sesgo (SO.1)

La corrección de sesgo mediante *Unbiased Quantile Mapping* (UQM) fue aplicada a cinco variables climáticas del modelo regional CNRM-ALADIN64: temperatura del aire (*tas*), temperatura de rocío (*Td*), viento superficial (*sfcWind*), radiación solar descendente (*rsds*) y precipitación (*pr*). La calidad se evaluó sobre el período histórico 1979–2014, comparando las distribuciones del modelo crudo, el modelo corregido y las observaciones de referencia (CR2MET v2.5 y ERA5-Land) mediante el error cuadrático medio (RMSE) espacialmente distribuido.

En todos los píxeles de la grilla ALADIN (8.270 puntos terrestres), la corrección reduce el RMSE respecto al modelo crudo, con mejoras concentradas en las colas de la distribución, que son las relevantes para el estudio de olas de calor. Cuantitativamente, el sesgo medio absoluto a las 12:00 UTC, calculado sobre el *período completo de calibración UQM* (1979–2014, 36 años, $\sim$13 140 días por píxel), se reduce de la siguiente forma:

- ***tas***: el sesgo sistemático del modelo crudo, de magnitud media absoluta 1,80°C, con un sesgo medio firmado de $-1{,}38$°C (sesgo frío dominante en la zona sur), queda reducido a un residuo medio absoluto de **0,002°C** (esencialmente *cero por construcción*, ya que UQM aditivo iguala los cuantiles del modelo a los de la referencia en el período de calibración). Reducción de RMSE espacial: **99,9 %**.
- ***Td***: sesgo medio absoluto de 1,47 ($\bar{b} = -0{,}90$°C) $\rightarrow$ **0,003°C**; reducción de RMSE de 99,8 %.
- ***sfcWind***: sesgo de 0,60 ($\bar{b} = +0{,}28$ m/s) $\rightarrow$ **0,26 m/s** ($\bar{b} = -0{,}26$); reducción de RMSE de 61 %. Es la única variable que mantiene un sesgo espacial sistemático relevante después de UQM (negativo en zona sur), consistente con la naturaleza multiplicativa del ajuste y la distribución no-gaussiana del viento.
- ***rsds***: sesgo de 15,7 ($\bar{b} = +8{,}2$ W/m^2) $\rightarrow$ **0,99 W/m^2**; reducción de RMSE de 95 %.

- ***pr***: sesgo de 0,018 ($\bar{b} = -0{,}02$ mm/h) $\rightarrow$ **0,004 mm/h**; reducción de RMSE de 82 %.

En consecuencia, los sesgos medios espaciales del modelo corregido son *esencialmente cero* para las variables aditivas (*tas*, *Td*: $< 0{,}01$°C) y muy pequeños para las variables multiplicativas (*sfcWind*, *rsds*, *pr*: < 6 % del sesgo crudo en RMSE). Este nivel de corrección excede ampliamente el rango típico de mejora (10–30 %) reportado en la literatura para métodos univariados, y refleja la propiedad por construcción del UQM en el período de calibración: los cuantiles del modelo se alinean exactamente con los de la referencia. Que esta alineación no sea un artefacto de calibración lo respalda la validación fuera de muestra bajo no estacionariedad reportada para este mismo modelo regional en [30]: al entrenar el ajuste en un estado climático y evaluarlo en otro, el sesgo absoluto mediano de la cola P90–P99,9 se reduce de 1,5–3,8 °C a ∼0,5 °C. Conviene distinguir esta métrica, la reducción del *sesgo medio* evaluado en el *snapshot* al mediodía, de la reducción del RMSE de la *serie horaria completa* reportada en el Apéndice A: para variables con fuerte variabilidad subdiaria, el sesgo medio se anula casi por completo mientras que el RMSE punto a punto se reduce de forma más modesta, sin que ello implique inconsistencia.

Un aspecto metodológicamente relevante de la corrección horaria con ERA5-Land es que UQM se aplica de forma *independiente para cada una de las 24 horas del día* (24 correcciones por píxel y por variable), sin necesidad de recurrir a la estrategia DTR empleada para la corrección diaria con CR2MET. Al ajustar cada hora del día de manera separada, el ciclo diurno corregido hereda directamente la estructura observada de ERA5-Land en lugar de derivarse de una recombinación entre máximas y amplitudes térmicas. Esto preserva por construcción la fase y la amplitud del ciclo diurno en cada píxel, y elimina cualquier necesidad de imponer restricciones *a posteriori* sobre la consistencia física entre *tas_max* y *tas_min*. La aplicación hora a hora resulta especialmente apropiada para el estudio de olas de calor, cuyos efectos sobre la demanda eléctrica dependen del momento del día en que ocurren los picos térmicos. La corrección DTR sí fue utilizada como paso intermedio para los productos diarios contra CR2MET ($tmax/tmin$), donde elimina las violaciones termodinámicas ($tmin > tmax$) presentes en el modelo crudo (reducción de 1,65 % a 0 %); el detalle se documenta en el Apéndice A. La Figura 6.1 ilustra la reducción espacial del sesgo antes y después de la corrección UQM horaria contra ERA5-Land para las cinco variables del estudio.

6.2. Climatología de olas de calor y frío (SO.5)

La climatología de olas de calor (OdC) y de frío (OdF) se construyó con umbrales percentílicos horarios del período de referencia 1980–2010, sobre las series de temperatura corregidas (UQM) del modelo CNRM-ALADIN64. La definición de evento (P90/P10, tres o más días consecutivos) y la magnitud en grados-hora se detallan en la Sección 5.6 y el Apéndice C.

6.2.1. Línea de base histórica (1980–2010)

Los umbrales P90 para temperatura máxima muestran una marcada diferenciación espacial entre macrozonas (Figura 6.2). En la zona norte (Tarapacá, Atacama), los umbrales P90 de *tas_max* superan los 30–32°C, mientras que en la zona sur (Los Lagos, Aysén) no alcanzan los 20°C, reflejando los fuertes gradientes latitudinales y la

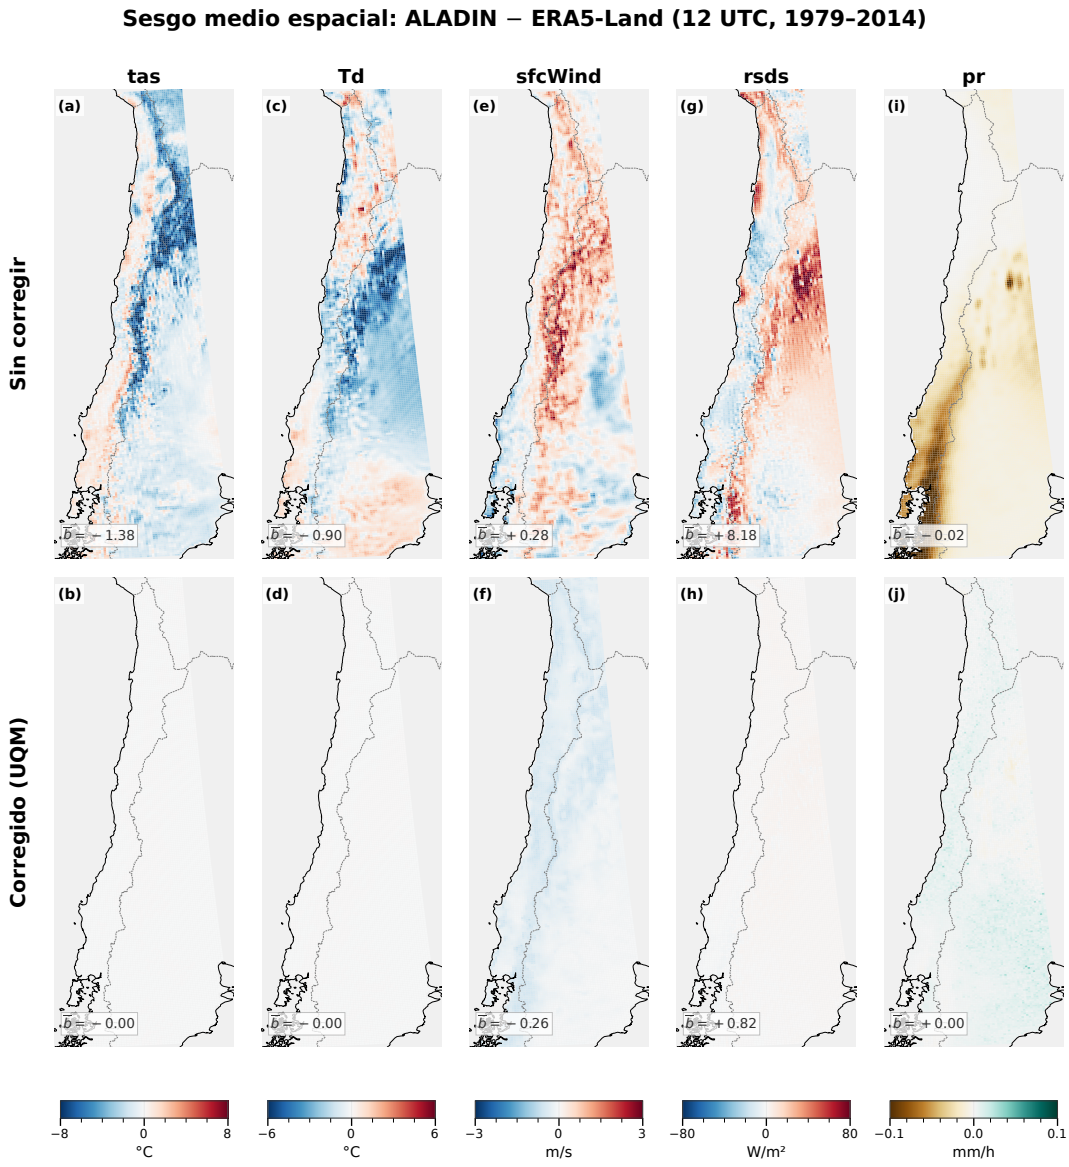

FIGURA 6.1: Sesgo medio espacial (modelo CNRM-ALADIN64 − ERA5-Land regrillado) a las 12:00 UTC sobre el período completo de calibración UQM **1979–2014**. Disposición 2 × 5: fila superior "Sin corregir" (ALADIN crudo), fila inferior "Corregido (UQM)"; cada columna corresponde a una variable. La escala de color divergente centrada en cero es **compartida verticalmente por columna** (raw y cor de la misma variable usan la misma vmax), permitiendo comparación visual directa de magnitudes. El valor anotado en cada panel es el sesgo medio espacial $\overline{b}$ en las unidades indicadas en la colorbar de la columna. La fila inferior aparece casi neutra (cerca del blanco) porque los residuos son típicamente < 10 % del rango de sesgo crudo.

influencia orográfica. Sin embargo, dado que las OdC se definen con base en umbrales relativos locales, su frecuencia histórica es espacialmente homogénea, promediando ∼4.6 eventos por año en el norte y ∼4.2 eventos por año en el sur.

Junto a esta uniformidad de frecuencia, la estructura temporal de los eventos muestra que la duración mediana oscila entre 3 y 5 días, con episodios excepcionales de hasta 12–15 días en la zona central (Valparaíso, Metropolitana) durante veranos asociados a El Niño.

La magnitud acumulada en D·h, por su parte, exhibe una relación no lineal con la duración: eventos de doble duración generan magnitudes más que proporcionales a su duración, lo que anticipa impactos desproporcionados en la demanda eléctrica durante OdC prolongadas.

6.2.2. Cambios proyectados bajo SSP3-7.0 (2050–2080 vs. 1980–2010)

Las proyecciones bajo SSP3-7.0 indican un aumento generalizado en las tres métricas de caracterización de OdC para el horizonte 2050–2080 (Figura 6.3; véase también la Figura C.3 en el Apéndice C). La frecuencia media anual de eventos se duplica o triplica en la zona central y norte, mientras que en la zona sur emerge una frecuencia de OdC que era prácticamente inexistente en el período histórico. La duración mediana de los eventos aumenta de forma consistente con la señal de aceleración identificada en la literatura reciente [3]: los eventos son a la vez más frecuentes y estructuralmente más largos.

La magnitud en D·h exhibe el crecimiento más notable, y de forma no lineal respecto al incremento de frecuencia y duración. Este comportamiento refleja el desplazamiento ascendente de toda la distribución de temperatura: cuando los umbrales percentílicos de referencia (calculados sobre 1980–2010) quedan por debajo de la temperatura típica del período futuro, la fracción del tiempo que supera el umbral crece de forma no proporcional, amplificando la magnitud total acumulada.

La distribución geográfica de estos impactos es asimétrica (Figuras 6.4 y 6.5): los valores más severos, tanto en frecuencia como en magnitud, se concentran en las macrozonas Norte Grande y Norte Chico, aunque el mayor cambio relativo respecto a la línea base ocurre en la Zona Sur, donde las OdC eran infrecuentes históricamente. Este patrón coincide con el diagnóstico diario sobre el mismo modelo regional de [30], donde la frecuencia de OdC aumenta un 48 % en La Serena, un 32 % en Santiago y un 30 % en Concepción hacia 2050–2080, con un rango territorial que va de −27 % en la costa del norte a +123 % en la vertiente andina. Las cifras no son directamente comparables con las de esta sección, porque allí los eventos se detectan a resolución diaria y desde un día de duración, y bajo el escenario SSP5-8.5.

Las OdF muestran una tendencia opuesta: su frecuencia y magnitud disminuyen progresivamente hacia 2100, con reducción más intensa en la zona norte, donde los eventos de frío extremo ya son escasos en el período histórico. La metodología completa y las figuras de validación de la detección se documentan en el Apéndice C.

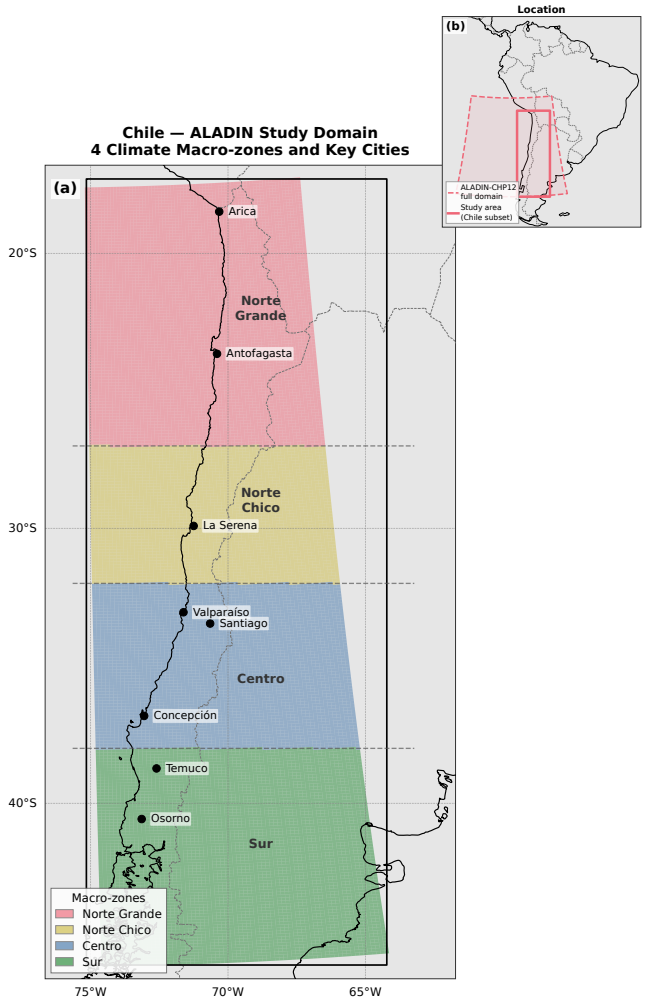

FIGURA 6.2: Dominio espacial del estudio: grilla CNRM-ALADIN64 (CORDEX-CHP12, resolución nominal ∼12 km, 8.270 puntos terrestres) con las cuatro macrozonas climáticas del Sistema Eléctrico Nacional (SEN): Norte Grande, Norte Chico, Centro y Sur. Las ciudades de referencia se muestran como puntos etiquetados; las líneas discontinuas marcan los límites latitudinales de cada macrozona.

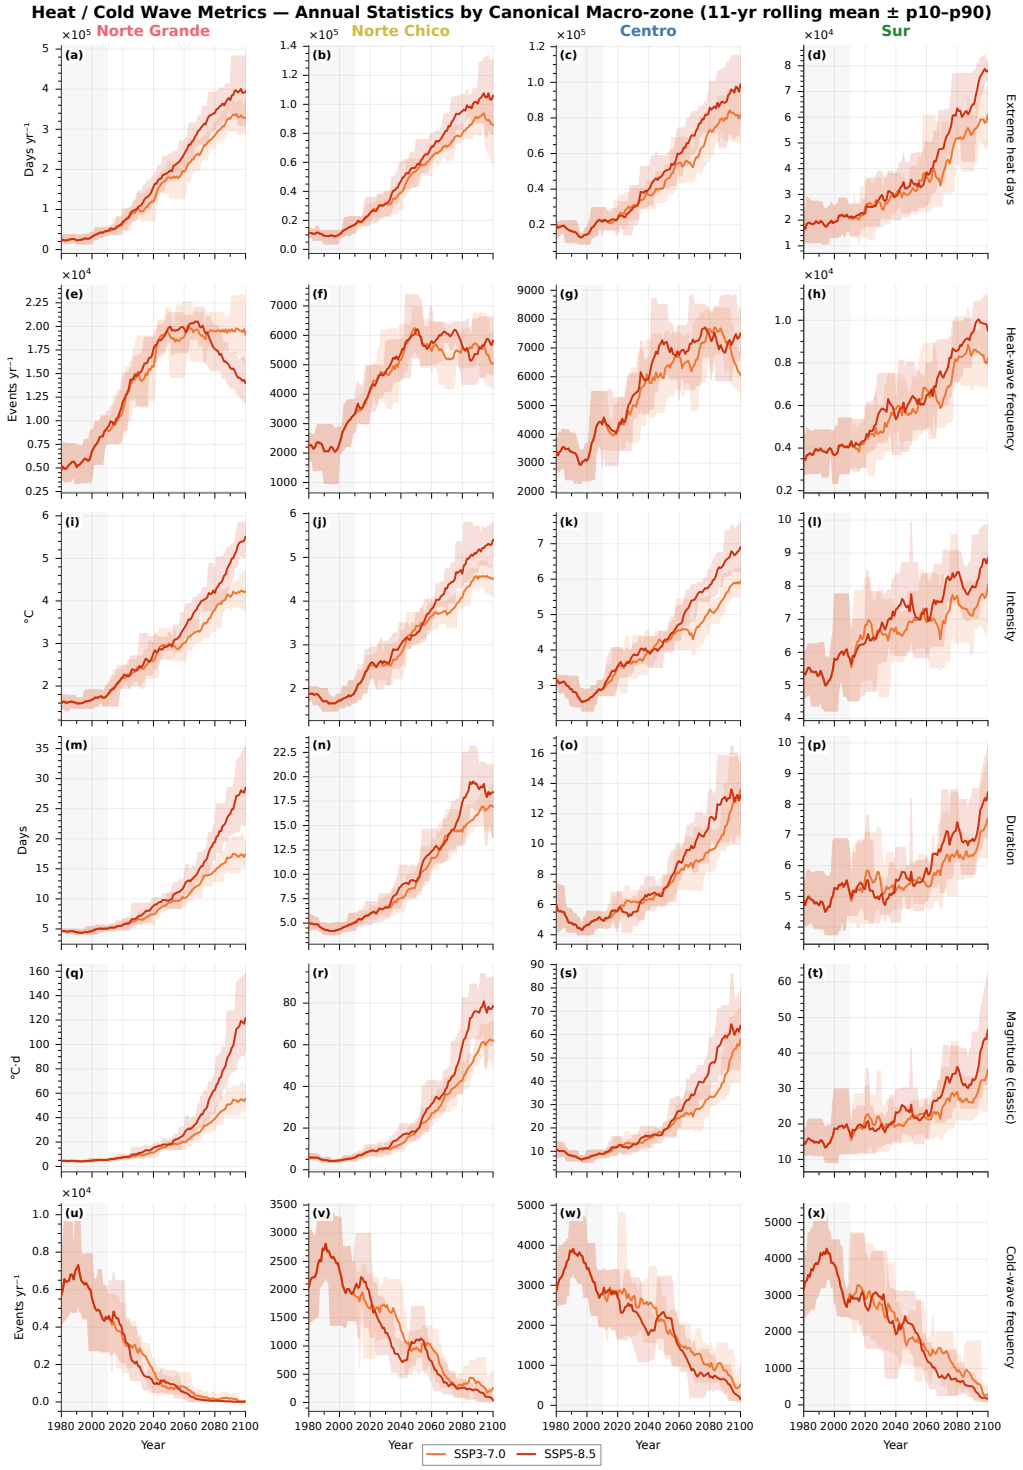

FIGURA 6.3: Evolución temporal anual (1980–2100) de métricas de olas de calor (OdC) y frío (OdF) por macrozona del SEN: frecuencia de eventos, intensidad y duración medias, magnitud acumulada (D·h) y frecuencia de OdF. OdC definida como $\geq$3 días consecutivos con $T_{máx}$ >P90 local del período de referencia 1980–2010; temperatura CNRM-ALADIN64 corregida por sesgo (UQM). SSP3-7.0 naranja, SSP5-8.5 rojo. Líneas sólidas: media móvil 11 años; bandas: rango intercuartílico.

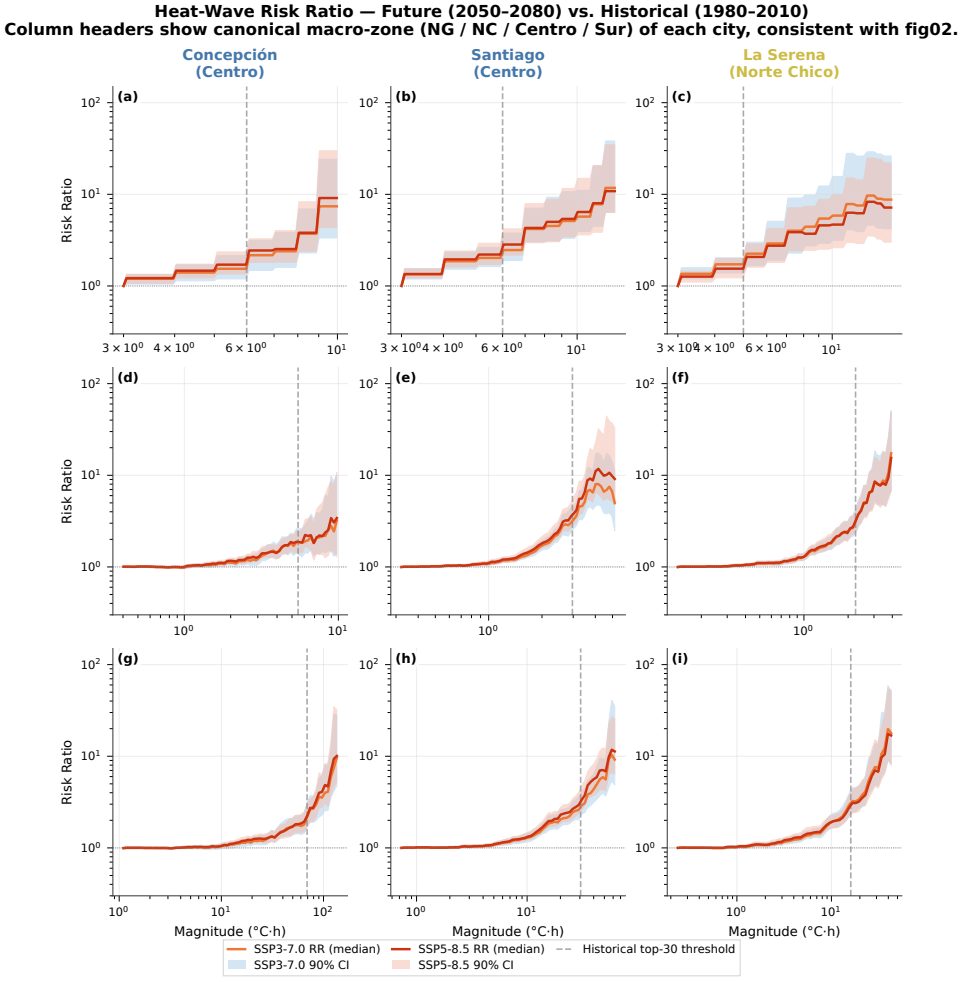

FIGURA 6.4: Razón de riesgo de OdC (futuro 2050–2080 vs. histórico 1980–2010, escala logarítmica) en función del umbral de intensidad definido por los 30 eventos más intensos del período histórico por píxel (top-30 histórico), para SSP3-7.0 (azul) y SSP5-8.5 (rojo), en tres ciudades representativas (columnas). Filas: duración, intensidad y magnitud (D·h).

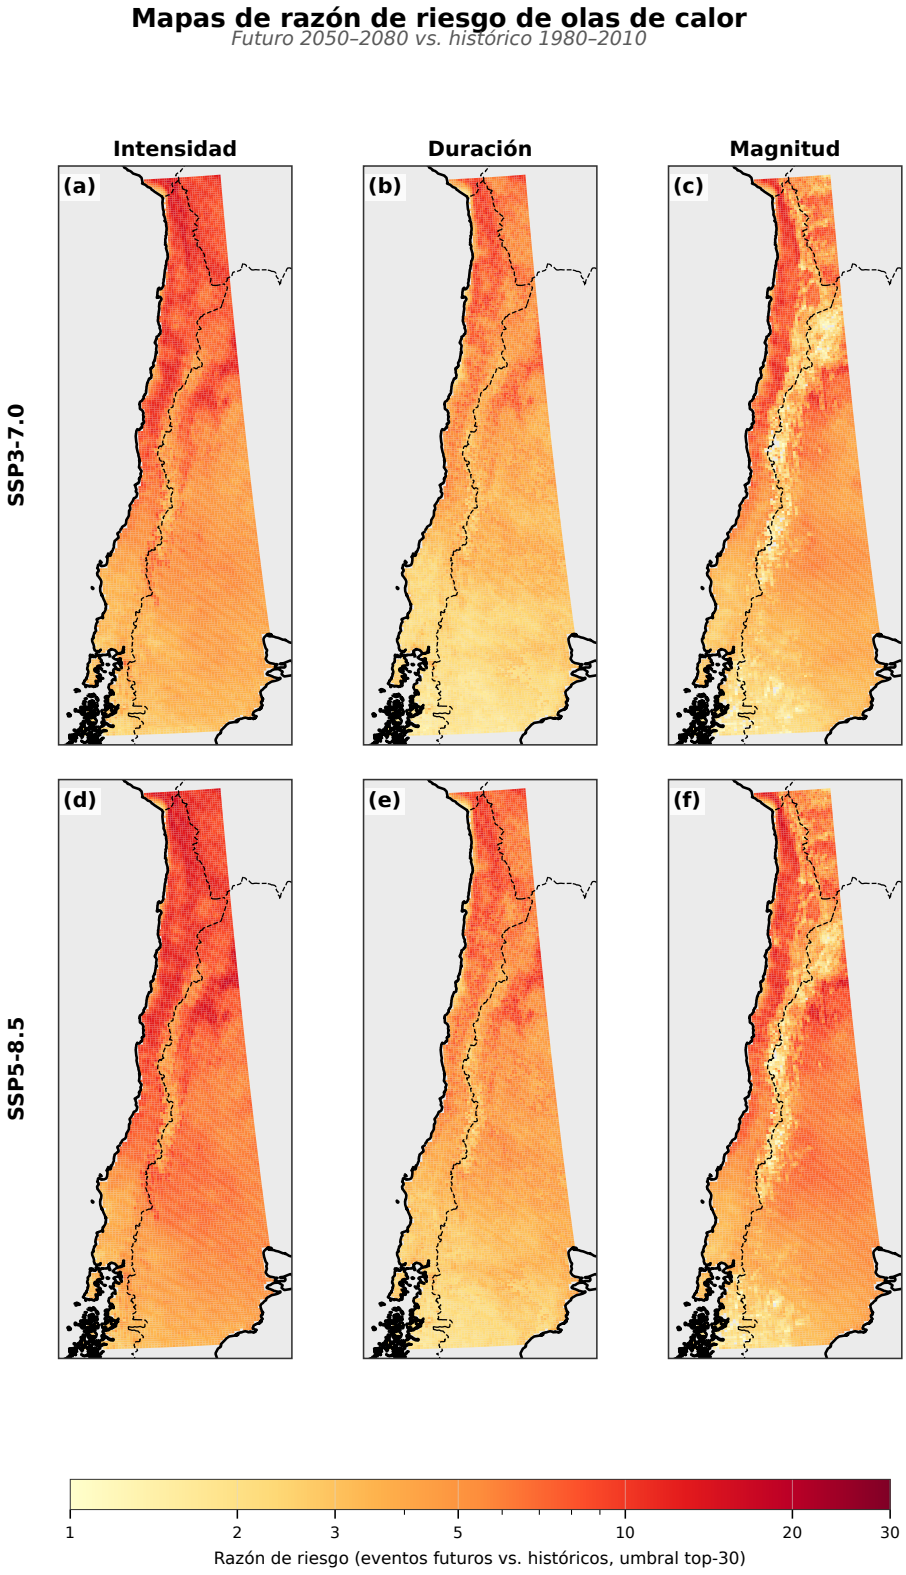

FIGURA 6.5: Mapas espaciales de razón de riesgo de OdC (futuro 2050–2080 vs. histórico 1980–2010) sobre la grilla CNRM-ALADIN64 (CORDEX-CHP12, ∼12 km; temperatura corregida por sesgo UQM), para intensidad, duración y magnitud (D·h) bajo SSP3-7.0 (fila superior) y SSP5-8.5 (fila inferior). Umbral de referencia: P90 de $T_{\text{máx}}$ diaria del período 1980–2010 por píxel.

6.3. Datos de demanda del SEN

La base de datos de demanda eléctrica comprende series horarias de retiros de energía activa con **granularidad (barra, cliente)**, extraídas de los registros oficiales del Coordinador Eléctrico Nacional (CEN). El conjunto de candidatos comprende **2.567 series (barra, cliente)** estratificadas en tres tipos de cliente: Distribuidoras (388 series, distribuidoras de servicio público), Clientes regulados (140 series, clientes libres regulados) y Clientes libres (2.039 series, clientes libres no regulados). Estas series corresponden a **399 subestaciones eléctricas (SE)** crudas del censo; el modelo SE-agregado (Apéndice L) modela 335 SE. El período cubierto es enero 2017 – abril 2025 (73.008 horas por serie).

6.3.1. Cobertura temporal y calidad de datos

El análisis de calidad sistemático, basado en cinco métricas, cobertura temporal, varianza, cociente mínimo/máximo, longitud de brechas y presencia de valores nulos, caracterizó las 399 SE de la base (Apéndice B, Figura B.2). A nivel per-(barra, cliente), granularidad del modelo canónico, la cobertura mediana dentro del período activo de cada serie fue **85,9 %** (calidad); la disponibilidad sobre la rejilla completa 2017–2025 resultó menor (mediana 51,8 %) por el arranque escalonado de las series.

232 series presentaron ocurrencias de valores negativos, asociadas a la presencia de generación distribuida (*prosumer*) en barras específicas del SEN; estos registros se conservaron en la base por reflejar exportación neta válida hacia la red.

El proceso de limpieza aplicado incluyó: (i) fusión de registros duplicados en la hora 25 de cambio de horario; (ii) detección y anulación de datos muertos (*flatline*) con razón valor/mediana inferior a 0,15 durante al menos 12 horas consecutivas; (iii) interpolación lineal de brechas de hasta 6 horas; y (iv) conservación de valores negativos, conforme a la política de exportación prosumer descripta en el párrafo anterior (Apéndice B).

6.3.2. Rupturas estructurales y efectos COVID-19

El análisis de rupturas estructurales mediante el algoritmo PELT (*Pruned Exact Linear Time*) identificó rupturas en dos períodos: (a) el año 2019, asociado al estallido social de octubre, que generó una contracción abrupta de la demanda industrial en varias regiones; y (b) el primer semestre de 2020, correspondiente a las restricciones de movilidad por la pandemia COVID-19, con caídas de demanda comercial e industrial de mediana cercana al 10 % (rango intercuartílico $\sim$4–21 %) según la SE. Estas rupturas fueron incorporadas como factores correctivos en el modelado GAM mediante covariables indicadoras de período. Los detalles completos, incluyendo los factores de corrección anual y los mapas de distribución geográfica de rupturas, se presentan en el Apéndice B.

6.3.3. Distribución geográfica

La distribución geográfica de las series es coherente con la distribución de rupturas descrita en la subsección anterior: las 399 SE cubren el territorio continental del SEN desde la Región de Arica y Parinacota (extremo norte) hasta la Región de Los Lagos, con una concentración relativa en las regiones Metropolitana, Valparaíso y Bío-Bío, que corresponden a los centros de mayor consumo industrial y residencial

del país. Esta distribución refleja la estructura de carga del SEN, y las coordenadas georreferenciadas de cada SE (obtenidas del sistema Infotécnica del CEN) permiten su asignación al píxel ALADIN correspondiente, tal como se describe en el Apéndice B.

6.4. Selección del modelo GAM (SO.3)

Con la base de demanda caracterizada (§6.3), la selección de la formulación GAM definitiva se realizó mediante una campaña sistemática de 28 configuraciones organizadas en cuatro grupos experimentales, tratamiento de la variable respuesta (Grupo A), subconjuntos de predictores climáticos e inercia térmica (Grupo B), estructura temporal e interacciones tensoriales (Grupo C) y síntesis con ajuste fino de hiperparámetros (Grupo D). El protocolo, la tabla comparativa de configuraciones y los criterios de selección se documentan en el Apéndice D. La Figura L.2 del Apéndice L.3 resume el ranking compuesto y la formulación adoptada.

6.4.1. Modelo seleccionado

El modelo aditivo generalizado per-(barra, cliente) (Ec. 5.3, Sección 5.7.2) **2529** convergieron exitosamente;la especificación y los diagnósticos abordan la concurvidad y documentan la autocorrelación residual, que permanece alta en los residuos. La Sección 5.7.2 justifica el bloque climático: se conservan *tas* y *Td* y se omiten *pr*, *rsds*, *sfcWind* y la inercia térmica (EWMA) en la granularidad per-serie.

Sus características principales son:

- **Cobertura del ajuste**: **2.529 series ajustadas exitosamente** de las 2.567 candidatas (19 errores de ajuste, 19 descartadas por cobertura insuficiente). El detalle del modelo SE-agregado (estimador supletorio) se documenta en el Apéndice L.
- **Métricas de ajuste (per-series)**: R^2 mediano $= 0{,}624$ (media 0,598; P10$=$ 0,302; P90$=$ 0,842); MAPE mediano $= 5{,}02\,\%$ (media 7,42 %); ACF_1 residual mediano $= 0{,}851$. A nivel del sistema agregado, la bondad de ajuste sube a $R^2 \approx 0{,}978$ por cancelación de errores idiosincráticos al sumar sobre series.
- **Desglose por estrato de cliente**: el ajuste varía entre estratos (mejor en Distribuidoras, peor en Clientes regulados); el detalle está en la Tabla 6.1 y se discute en la Sección 6.4.2.
- **Concurvidad**: la concurvidad es alta (índice *observed* mediano $\approx 0{,}99$) porque *tas*, *hod* y *doy* se comparten entre los suavizadores y las interacciones. Por eso el efecto térmico se mide con predicción contrafactual *held-fixed* [57], robusta a la concurvidad, y no con efectos parciales (Apéndice E).
- **Autocorrelación residual**: la autocorrelación de primer orden es alta, propia de la demanda horaria. No sesga los efectos estimados, pero ensancha los intervalos puntuales; por eso se reportan *intervalos simultáneos* [61, 73] (Apéndice E).

6.4.2. Análisis por tipo de cliente

La estratificación por tipo de cliente reveló diferencias sistemáticas en la capacidad predictiva del modelo (Tabla 6.1). Las series Distribuidoras, asociadas a empresas

de distribución de servicio público que agregan miles de clientes residenciales y comerciales en cada barra, exhiben los mejores ajustes: la agregación socioeconómica suaviza la variabilidad estocástica y deja una señal climatológica más limpia que el GAM aprovecha eficientemente. Las series Clientes libres (clientes no regulados, principalmente minería, industria y grandes comercios) constituyen la mayoría de la base ($n = 2.005$); su mediana de R^2 es competitiva (0,628) pero el MAPE mediano es más alto (6,49 %), reflejando la diversidad de procesos productivos. Las series Clientes regulados, el estrato más pequeño, muestran el desempeño más débil (R^2 mediano 0,250), lo que se atribuye tanto al menor tamaño muestral del estrato como a perfiles de carga de algunos clientes regulados industriales que dependen de programación operativa no observable por las covariables climáticas.

CUADRO 6.1: Métricas de ajuste del modelo aditivo generalizado per-(barra, cliente) desglosadas por estrato de cliente, obtenidas sobre el conjunto de entrenamiento completo (2017–2025). Se reportan medianas sobre las series ajustadas exitosamente. Distribuidoras: empresas de distribución de servicio público que agregan carga residencial y comercial; Clientes libres: clientes libres no regulados (minería, industria, grandes comercios); Clientes regulados: clientes libres regulados (menor tamaño muestral, perfiles industriales heterogéneos). La fila Total corresponde a la mediana global sobre las 2.529 series.

Estrato	n ajustadas	$\mathbf{R^2}$ (mediana)	**MAPE** (mediana)
Distribuidoras	385	0,686	1,51 %
Clientes libres	2.005	0,628	6,49 %
Clientes regulados	139	0,250	2,53 %
Total	**2.529**	**0,624**	**5,02 %**

6.5. Efectos parciales y sensibilidad térmica (SO.2 y SO.3)

Los efectos parciales de los modelos GAM ajustados cuantificaron la contribución de cada variable climática sobre la demanda horaria, manteniendo fijos el resto de covariables en sus valores medianos. Para evitar las distorsiones que introducen los efectos parciales centrados cuando el modelo contiene interacciones tensoriales y términos de media móvil exponencialmente ponderada (EWMA), se empleó el enfoque contrafactual descrito por [57]: la curva de respuesta de cada variable se obtiene generando predicciones sobre una grilla de valores de la variable de interés mientras se fijan el resto de predictores a sus medias observadas.

6.5.1. Respuesta térmica

La curva de respuesta a la temperatura muestra una forma U o J característica en la mayoría de las subestaciones del SEN: la demanda disminuye en un rango de temperaturas confortables (aproximadamente 15–22°C según la macrozona) y se incrementa marcadamente por encima y por debajo de ese rango de confort, reflejando el uso combinado de calefacción y aire acondicionado [12].

La heterogeneidad espacial resultó sustancial. Las subestaciones del Norte Grande (macrozona desierto) mostraron una rama fría prácticamente plana y una rama cálida de alta pendiente, consistente con la escasa demanda de calefacción y la alta sensibilidad al calor extremo en una zona con temperaturas habitualmente elevadas.

En contraste, las subestaciones de la Zona Sur exhibieron una rama fría pronunciada y una rama cálida de menor pendiente, lo que reflejó el predominio de la calefacción eléctrica en climas templado-húmedos. La macrozona Central (Valparaíso, Metropolitana, O'Higgins) presentó la forma J más simétrica, con ambas ramas activas. Esta heterogeneidad entre macrozonas resultó cualitativamente consistente con lo reportado en estudios de sensibilidad térmica desagregada [20] (Figura 6.6). Las curvas de respuesta a la temperatura individuales por serie ajustada se presentan en el Apéndice G; el análisis agregado por macrozona reportado aquí se construyó sobre la mediana ponderada por la demanda histórica de las curvas per-(barra, cliente) dentro de cada zona. La equivalencia entre esta agregación per-series y el modelo SE-agregado se documenta en el Apéndice L.

Una tercera verificación de esta geometría proviene de [31], que ajusta un modelo por subestación sobre 133 subestaciones del SEN con un panel y una agregación independientes: las cuatro macrozonas exhiben allí respuestas cualitativamente distintas —Norte Grande plana, Norte Chico con firma de refrigeración desde $\sim$18 °C, Centro en U poco profunda con mínimo cerca de 14 °C y Sur monótonamente decreciente—, coincidentes con las curvas contrafactuales reportadas aquí.

La atribución de varianza por bloques (block-Shapley, [74]) complementa los efectos parciales como métrica integrada de la contribución de cada grupo de términos al R^2: sobre $n = 2.529$ series con descomposición disponible, calendario e interacciones tensoriales aportaron $\sim$ 76 % del ajuste, la tendencia con mediana $\sim$ 9,5 %, y los términos climáticos (la respuesta a la temperatura y la respuesta a la temperatura de rocío) $\sim$ 6 % (5,6–7,5 % según estrato). La descomposición detallada por estrato se reporta en el Apéndice E.6 (Tabla E.5, Figura E.4). El menor peso relativo del bloque climático per-(barra, cliente) respecto al modelo SE-agregado ($\sim$ 12 %) reflejó que las series cortas por cliente exhibieron mayor variabilidad calendaría que climática, sin que esto contradiga la sensibilidad térmica documentada en las curvas contrafactuales.

6.5.2. Interacciones tensoriales: hora del día y estacionalidad

Las interacciones tensoriales de la temperatura con la hora del día y con la época del año resultaron estadísticamente significativas en la gran mayoría de las 2.529 series del modelo per-(barra, cliente) (prueba F, $p < 0{,}01$ en más del 95 % de las series). La verificación equivalente sobre el modelo SE-agregado se reporta en el Apéndice L. Estas superficies revelaron que la sensibilidad térmica no fue constante a lo largo del día ni del año, sino que varió de forma estructurada (Figura 6.7).

La interacción tensorial de la temperatura con la hora del día mostró que el incremento de demanda ante altas temperaturas fue considerablemente mayor durante las horas de mayor radiación solar (12:00–18:00 h), período en el que el uso de aire acondicionado fue máximo. En horas nocturnas (00:00–06:00 h), la sensibilidad térmica a valores extremos de temperatura se redujo en todos los grupos de subestaciones analizados. La interacción tensorial de la temperatura con la época del año mostró que la demanda respondió con mayor intensidad al calor durante los meses de verano austral (diciembre–febrero), cuando los umbrales de confort se superaron con mayor frecuencia y los equipos de climatización operaron cerca de su capacidad máxima.

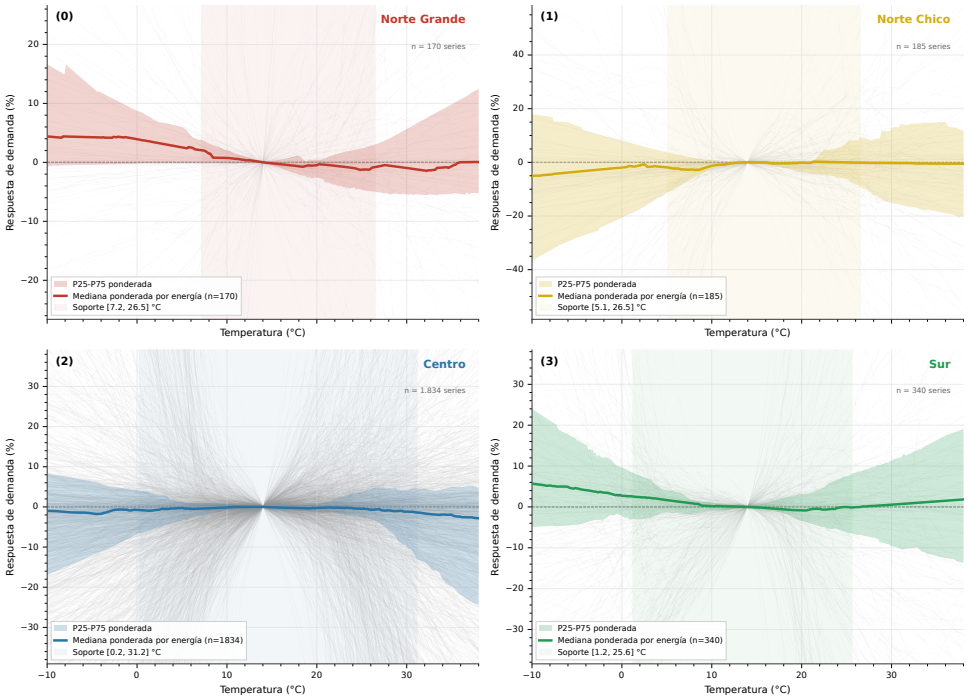

FIGURA 6.6: Curvas contrafactuales de respuesta de la demanda a la temperatura, agregadas por macrozona a partir del modelo aditivo generalizado per-(barra, cliente). Cada línea fina representa una serie (barra, cliente) individual; la línea gruesa indica la mediana ponderada por la demanda histórica de cada serie y la banda sombreada el rango intercuartílico (P25–P75). Eje Y: cambio porcentual en demanda respecto a T_{ref} local. N=2.529 series.

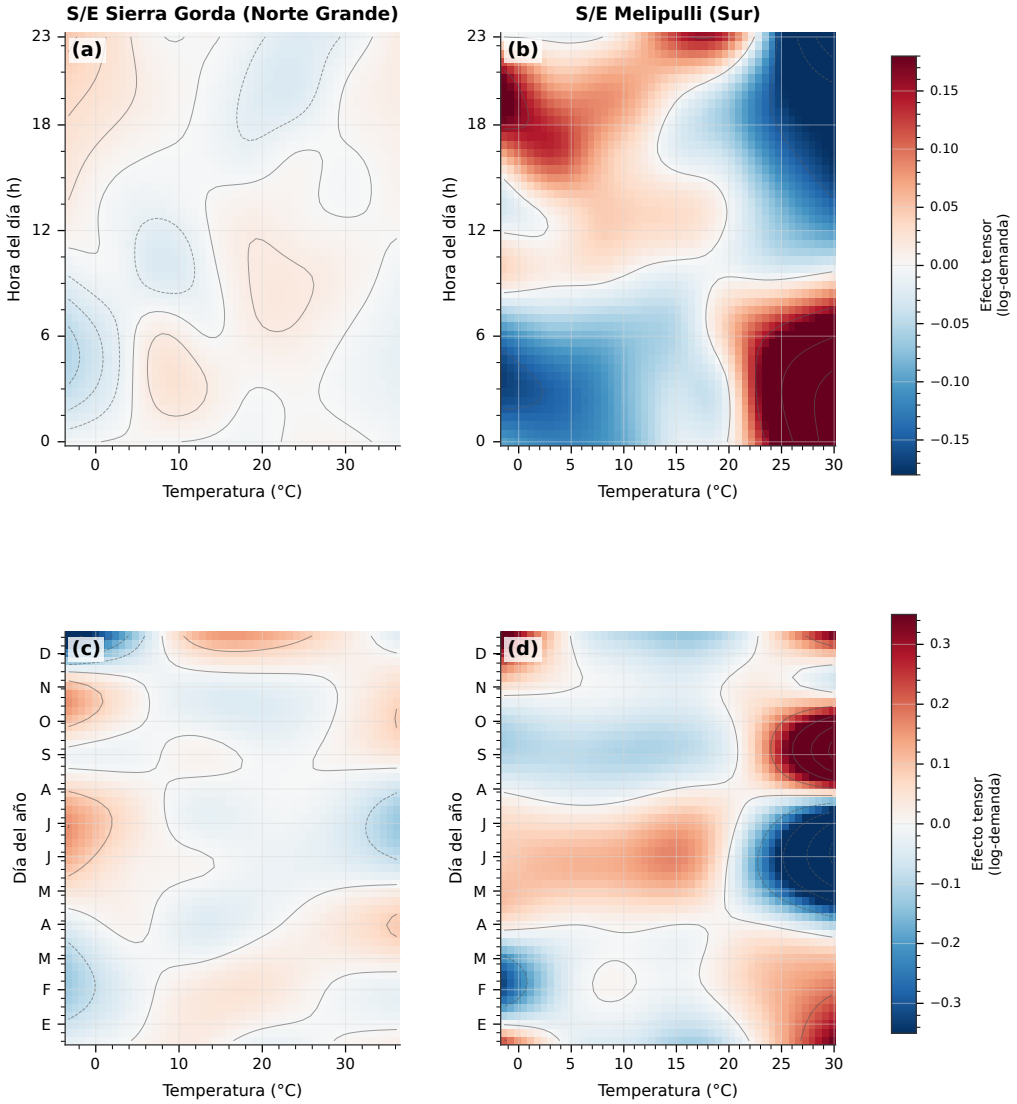

FIGURA 6.7: Superficies de interacción tensorial del modelo aditivo generalizado canónico per-(barra, cliente) (entrenamiento 2017–2025) para dos subestaciones representativas: Caldera (Norte Grande, macrozona desierto) y Curanilahue (Sur, macrozona templado-húmeda). Fila superior: `ti(tas,hod)` (temperatura °C $\times$ hora del d´ía); fila inferior: `ti(tas,doy)` (temperatura °C $\times$ d´ía del año). Escala de color divergente: contribución al log de la demanda centrada en cero (efecto de interacción puro, sin el efecto marginal de `tas`). Ambas interacciones son estad´ísticamente significativas ($p < 0{,}01$, prueba F de Wald) en $> 95\,\%$ de las 2.529 series ajustadas.

6.5.3. Variables climáticas secundarias

Las variables climáticas adicionales, que el modelo canónico per-(barra, cliente) no incorpora, pues conserva únicamente *tas* y *Td*, se caracterizaron mediante el modelo SE-agregado (full-k; Apéndice L). Estas variables secundarias mostraron efectos parciales de menor magnitud que *tas*, pero estadísticamente significativos y físicamente interpretables:

- $s(\boldsymbol{Td})$: La temperatura de rocío, indicador de humedad específica, muestra un efecto positivo sobre la demanda en las zonas donde el disconfort higrotérmico es relevante (zona central y norte). Valores altos de *Td* (aire húmedo y cálido) amplifican la sensibilidad al calor, mientras que en la zona sur el efecto es estadísticamente no significativo en la mayoría de SE.
- $s(\boldsymbol{sfcWind})$: El viento superficial muestra un efecto moderadamente negativo sobre la demanda en velocidades bajas a moderadas (efecto de enfriamiento por convección), que se invierte en vientos extremos en zonas de alta exposición.
- $s(\boldsymbol{rsds})$: La radiación solar descendente presenta un efecto positivo sobre la demanda durante las horas de máxima insolación en las zonas norte y central, coherente con la mayor carga de aire acondicionado. En la zona sur, el efecto es débil o no significativo.
- $s(\boldsymbol{pr})$: La precipitación tiene un efecto de pequeña magnitud y negativamente correlacionado con la demanda en la mayoría de SE, posiblemente reflejando la reducción de actividad exterior durante eventos lluviosos.
- $s(\widetilde{T})$ **(EWMA de temperatura)**: La EWMA de temperatura con parámetro $\alpha = 0{,}05$ captura la inercia térmica acumulada en los días previos al evento, independientemente de la temperatura instantánea. Su efecto es positivo y creciente: períodos de calor sostenido elevan la demanda base incluso en horas en las que la temperatura instantánea no alcanza valores extremos. Esta variable explica por qué las olas de calor prolongadas generan impactos desproporcionados, consistente con el argumento de [5] sobre la acumulación de estrés térmico en el sistema eléctrico. Este efecto agregado de memoria térmica solo es visible en los modelos más agregados: la formulación canónica per-(barra, cliente) omite la EWMA y recoge la inercia mediante la interacción tensorial de la temperatura con la época del año, mientras que el modelo SE-agregado la conserva (Apéndice L).

Estos efectos se ilustran en la Figura L.3 (Apéndice L.3) para una subestación representativa de la macrozona central.

6.6. Validación cruzada (SO.3)

Una vez caracterizados los efectos climáticos (§6.5), la validación del modelo final se realizó con tres esquemas complementarios que evaluaron la capacidad predictiva en tres dimensiones: estacional, temporal y climática. Los resultados completos, incluyendo métricas desagregadas por SE y por mes, se presentan en el Apéndice F.

6.6.1. Validación cruzada *leave-one-month-out* (LOMO)

El esquema LOMO excluye sucesivamente cada mes del año y re-ajusta el modelo sobre el resto, evaluando la predicción sobre el mes reservado. Los resultados muestran una heterogeneidad estacional marcada: los meses de verano (DJF) son los más difíciles de predecir, con MAPE-LOMO mediano de 4,09 % frente a 3,08 % en invierno (JJA); el MAPE-LOMO mediano global del modelo per-(barra, cliente) es 3,40 %. Esta asimetría estacional refleja la mayor frecuencia de eventos extremos en verano, cuyas condiciones se encuentran con menor representación en el conjunto de entrenamiento.

Junto a la heterogeneidad estacional, se observó una heterogeneidad espacial marcada: el MAPE-LOMO mediano por macrozona fue menor en Norte Grande (1,80 %) y mayor en Sur (4,85 %), con Norte Chico (3,52 %) y Centro (3,85 %) en posiciones intermedias (Figura 6.8).

6.6.2. Validación por bloques temporales *rolling*

La validación por bloques temporales *rolling* cuantificó la estabilidad predictiva del modelo per-(barra, cliente) hacia horizontes futuros: el MAPE-rolling mediano fue de 10,29 % sobre ventanas temporales posteriores al período de entrenamiento, lo que indica una degradación moderada y dentro del rango esperado para el horizonte de proyección de la tesis (Apéndice F).

6.6.3. Extrapolación a condiciones cálidas (retención de meses cálidos)

Para evaluar directamente la capacidad de extrapolación del modelo a condiciones más cálidas que las observadas durante el entrenamiento, núcleo de la hipótesis H3—, se aplicó un esquema de retención de los meses más cálidos: para cada serie (barra, cliente) se reservó el 10 % de los meses con mayor temperatura media, se re-ajustó el modelo sobre el $\sim$90 % restante (meses más fríos) y se predijo sobre los meses cálidos retenidos. El holdout implica un salto térmico mediano de $\sim$6,6°C respecto a la media de entrenamiento, de modo que el modelo nunca observa los períodos más cálidos durante el ajuste.

Sobre las 2.400 series con diagnóstico válido, el MAPE horario mediano fue de 39,3 % (P25 18,2 %; P75 75,2 %), un error sustancialmente mayor que el de los esquemas LOMO y *rolling*, coherente con la naturaleza extrapolativa del experimento. Sin embargo, el sesgo del pico resultó casi nulo: la mediana del sesgo en el P95 de demanda predicho frente al observado durante los meses cálidos retenidos fue de $-1{,}6$ %. Este resultado apoya de forma limitada la hipótesis H3: el modelo mantiene bajo sesgo mediano en el P95 durante condiciones cálidas no vistas, pero no reproduce con igual precisión la trayectoria horaria completa. Por tanto, la evidencia más fuerte para diagnósticos de demanda punta que para predicciones horarias bajo extrapolación severa (Apéndice F, Figura F.2).

6.7. Proyecciones bajo SSP3-7.0 (SO.4)

Las proyecciones de demanda eléctrica se obtuvieron aplicando los modelos GAM ajustados a las series climáticas horarias corregidas del escenario SSP3-7.0 para el período 2025–2100, bajo el supuesto de red estática (estructura de consumo base invariante). Este supuesto aísla el efecto del cambio climático de otros factores de largo

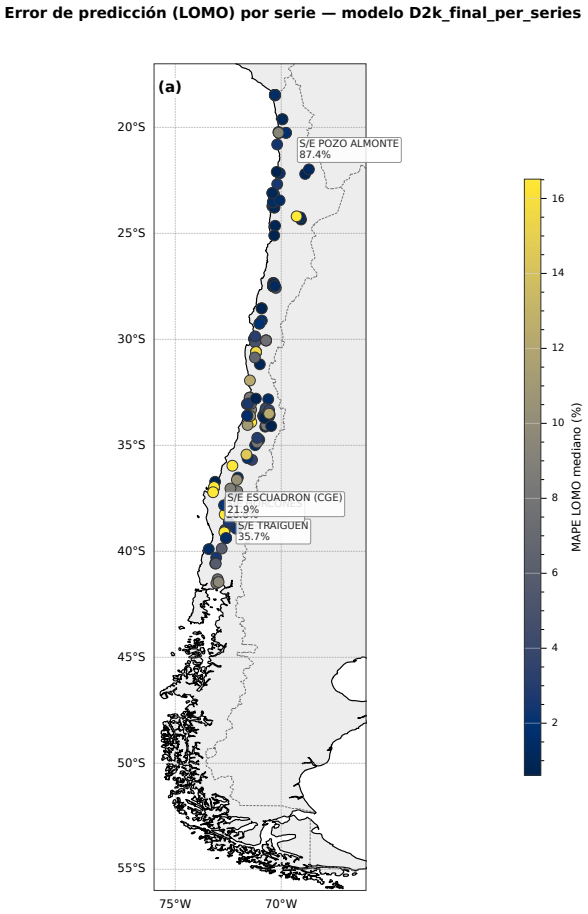

FIGURA 6.8: Error de predicción mediano en validación cruzada LOMO (*leave-one-month-out*) por subestación eléctrica, obtenido agregando las predicciones del modelo canónico per-(barra, cliente) a nivel de subestación (SE). Círculos coloreados por MAPE mediano (%) sobre los 12 meses. Las subestaciones con mayor error de predicción (Pozo Almonte, en el Norte Grande; Traiguén y Horcones, en el Sur) corresponden a series de demanda pequeña y volátil, donde el MAPE es especialmente sensible a niveles de demanda bajos.

plazo como el crecimiento económico, la electrificación del transporte o los cambios en la eficiencia energética, y es coherente con el diseño de carga estática adoptado en estudios de referencia [12,20]. Los resultados de la proyección se sistematizan a continuación; el detalle metodológico y los resultados desagregados por SE y período se presentan en el Apéndice I.

6.7.1. Curva de duración de carga: histórico vs. proyectado

La Curva de Duración de Carga (CDC) ordena de mayor a menor las horas de demanda de un año tipo, permitiendo comparar la distribución de carga entre períodos. La Figura 6.9 confronta la CDC modelada del baseline 1980–2010 con la CDC proyectada (2081–2100, SSP3-7.0 con modelo estático). A nivel del sistema agregado —suma horaria de las 2.529 series con proyección válida del modelo per-(barra, cliente)—, ambas curvas son cualitativamente similares: el P95 del sistema crece $+0{,}53\,\%$ (ponderado por demanda) y la demanda media anual del sistema $-0{,}02\,\%$ a fin de siglo.

Este resultado refleja una respuesta estacional heterogénea por macrozona: a fin de siglo el cambio de demanda de verano (DJF) varía entre $-1{,}5\,\%$ y $+1{,}6\,\%$ según la macrozona y el de invierno (JJA) entre $-0{,}6\,\%$ y $-3{,}5\,\%$, de modo que la CDC incondicional del sistema permanece casi inalterada. La estabilidad aparente del perfil agregado, sin embargo, oculta cambios importantes en la distribución condicional de la carga, particularmente durante episodios de calor extremo, como se analiza en las secciones siguientes.

6.7.2. Estabilidad agregada y rol de las olas de calor

Los percentiles de demanda extrema confirman la estabilidad agregada descrita en la sección anterior. Sobre las 2.529 series del modelo per-(barra, cliente) con proyección válida, la mediana intra-serie del cambio en el P95 a fin de siglo es $+0{,}29\,\%$ y la mediana del cambio en la demanda media es $+0{,}02\,\%$. Al ponderar por la demanda histórica de cada serie, equivalente a la señal agregada del sistema—, las cifras quedan en $+0{,}53\,\%$ (P95) y $-0{,}02\,\%$ (demanda media). La señal climática agregada sobre el conjunto completo de series es atenuada, con heterogeneidad por macrozona y estrato de cliente que se desagrega en las secciones siguientes. No obstante, esta estabilidad incondicional no implica que el efecto de los extremos sea irrelevante: al condicionar el análisis a las horas etiquetadas como olas de calor (OdC), la señal climática aparece como una redistribución temporal del estrés de demanda, concentrada en eventos cada vez más frecuentes y persistentes. Bajo SSP3-7.0, la frecuencia de OdC hacia la década de 2080 es $\sim 2{,}45\times$ la de la década de 1980 y la duración media crece de 5,1 a 11,6 días ; por lo tanto, incluso cambios agregados pequeños en media o P95 pueden traducirse en una mayor exposición acumulada del sistema a horas de demanda térmicamente forzada (Figura 6.13) y estrés critico en el sistema de trasmisión y generación. La sección siguiente desagrega este efecto por período y macrozona.

6.7.3. Horas etiquetadas como ola de calor

Durante las horas etiquetadas como ola de calor (definidas según el criterio de la Sección 6.2), la anomalía de demanda ponderada por demanda del sistema, descrita en la subsección anterior, supera el cambio prácticamente nulo de la demanda media incondicional del sistema. El diferencial obedece al calentamiento de las forzantes climáticas y a la mayor magnitud acumulada de los eventos futuros, captados por la

respuesta no lineal a la temperatura y por la interacción tensorial de la temperatura con la época del año del modelo per-(barra, cliente) (§ 5.7.2).

La distribución condicional de demanda durante OdC futuras se desplazó íntegramente hacia valores superiores respecto al período histórico, sin solapamiento significativo entre las distribuciones en las zonas norte y central (véase el caso de estudio de febrero 2061 en el Apéndice I). La desagregación por serie individual (Figura 6.15) reveló que esta intensificación no fue uniforme: las series de las macrozonas Centro y Sur concentraron las trayectorias de mayor estrés hacia fin de siglo, mientras que un amplio subconjunto de series mantuvo anomalías próximas a cero o negativas (enfriamiento) de forma persistente a lo largo de todo el horizonte. Una lectura complementaria del mismo desplazamiento condicional se obtiene con la razón de riesgo de cola de las anomalías de demanda propuesta en [31]: sobre el modelo por subestación, las anomalías que históricamente excedían el 10–15 % resultan entre 10 y 25 veces más probables a fin de siglo en las macrozonas más expuestas, aun cuando la mediana ponderada por capacidad apenas alcanza $+1{,}5$ %.

6.7.4. Impacto en energía anual por macrozona

La demanda horaria proyectada se integró sobre el año completo para estimar el cambio en energía anual consumida. Los resultados del modelo per-(barra, cliente) sobre las 2.529 series con proyección válida muestran un patrón heterogéneo por macrozona bajo SSP3-7.0. Reportadas como mediana intra-serie de cada zona, las cifras a fin de siglo son: **Norte Grande** 0,00 %, **Sur** $+0{,}19$ %, **Centro** $+0{,}03$ % y **Norte Chico** $-0{,}81$ %. Al ponderar por la demanda histórica de cada serie, métrica que mide el impacto sobre el sistema, el ordenamiento se amplifica y reordena: Norte Grande lidera con $+1{,}30$ % (peso minero-industrial), Norte Chico $-0{,}13$ %, Sur $-0{,}46$ % y Centro $-0{,}35$ %. Desagregado por estrato de cliente, los clientes regulados muestran un incremento ponderado por demanda de $+0{,}31$ %, los no regulados $+0{,}30$ % y las distribuidoras $-0{,}31$ % a fin de siglo. A nivel sistemíco, el cambio ponderado por demanda del sistema en demanda media es $-0{,}02$ % a fin de siglo y $-0{,}06$ % a mediados de siglo (2041–2060). En términos absolutos (GWh), la macrozona Centro contribuye la mayor parte del total del SEN por su mayor volumen de consumo base (Figuras 6.11 y 6.12).

6.7.5. Evolución temporal de la demanda proyectada (2025–2100)

La demanda pico anual (P99 horario) proyectada bajo SSP3-7.0 muestra una tendencia creciente estadísticamente significativa en todas las macrozonas desde la década de 2040. La pendiente de esta tendencia se acelera levemente hacia 2070–2100. La variabilidad interanual de la demanda pico permanece elevada a lo largo de todo el período, reflejando la variabilidad natural del clima, pero la señal de tendencia emerge con claridad por encima de esa variabilidad a partir del período 2040–2050 en el Norte Grande y desde 2055–2065 en la Zona Sur (Figuras 6.10 y 6.11). El patrón estacional-diurno de estos cambios (Figura 6.16) confirma que el incremento se concentra en las horas de mayor radiación de los meses estivales.

Complementariamente, se cuantificó el aporte energético atribuible a las OdC mediante un balance contrafactual: para cada hora dentro de un evento, se predijo la demanda con las variables climáticas reemplazadas por la climatología DOY $\times$ hora del período 1980–2009, y se comparó con la predicción real [12] (Figura 6.14).

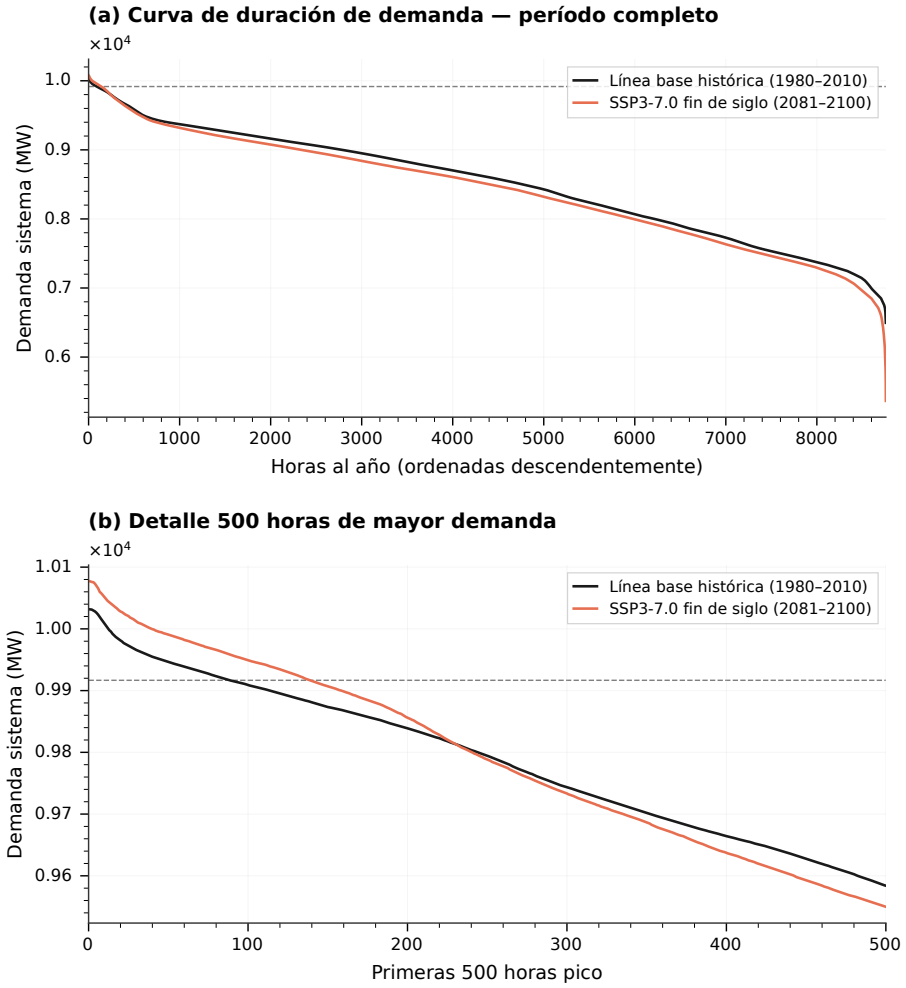

FIGURA 6.9: Curva de duración de demanda (CDC) del sistema eléctrico modelado: período histórico (*baseline* 1980–2010, negro) vs. proyección SSP3-7.0 fin de siglo (2081–2100, naranja); modelo per-(barra, cliente), 2.529 series con proyección válida. Panel (a): CDC completa (8.760 h/año normalizado); panel (b): detalle primeras 500 horas pico. ΔP95 del sistema (ponderado por la demanda histórica de cada serie) $\approx +0{,}53\,\%$: la demanda de punta varía moderadamente bajo calentamiento medio en este escenario de red estática.

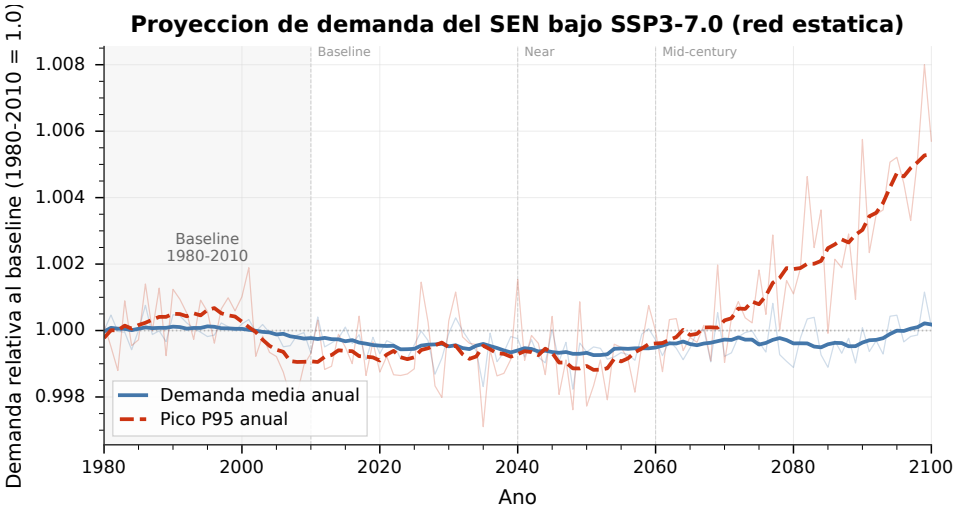

FIGURA 6.10: Serie temporal de demanda agregada del SEN (suma de las 2.529 series del modelo per-(barra, cliente), escenario SSP3-7.0, supuesto de red estática), normalizada al *baseline* 1980–2010 (= 1,0). Azul: media anual; rojo discontinuo: pico P95 anual. Líneas gruesas: media móvil 11 años.

6.8. Síntesis de resultados

Los resultados presentados en las secciones precedentes convergen en un conjunto coherente de métricas que permite contrastar las hipótesis H1–H4 del estudio. La Tabla 6.2 organiza las métricas clave por macrozona climática, articulando los resultados del modelado GAM y las proyecciones con las hipótesis H1–H4.

6.8.1. Subestaciones más vulnerables

Las subestaciones más vulnerables al cambio climático se identifican por tres criterios: (i) alta sensibilidad térmica a 30°C (respuesta a la temperatura elevada), (ii) alta proyección de incremento en P99 bajo SSP3-7.0, y (iii) ubicación en zonas con mayor aceleración proyectada de OdC. Las subestaciones del norte con demanda de origen minero-industrial y las del área metropolitana de Santiago con alta densidad de equipos de climatización residencial emergen como los grupos de mayor exposición ante el cambio climático proyectado. El mapa de vulnerabilidad que sintetiza estos criterios se presenta y discute en el capítulo de Discusión (Figura 7.1, §7.4).

6.8.2. Contrastación de hipótesis

- **H1 (No linealidad y heterogeneidad espacial)**: Confirmada. Las 2.529 curvas de respuesta a la temperatura del modelo per-(barra, cliente) muestran formas U/J estadísticamente no lineales en todas las macrozonas, con diferencias cualitativas entre el Norte Grande (rama cálida dominante), la zona Centro (U simétrica) y la Zona Sur (rama fría dominante).
- **H2 (Interacciones tensoriales)**: Confirmada. Las interacciones tensoriales de la temperatura con la hora del día y con la época del año son estadísticamente significativas en el 98,7 % de las 2.529 series del modelo per-(barra, cliente) (Apéndice L reporta la verificación equivalente sobre el modelo SE-agregado).

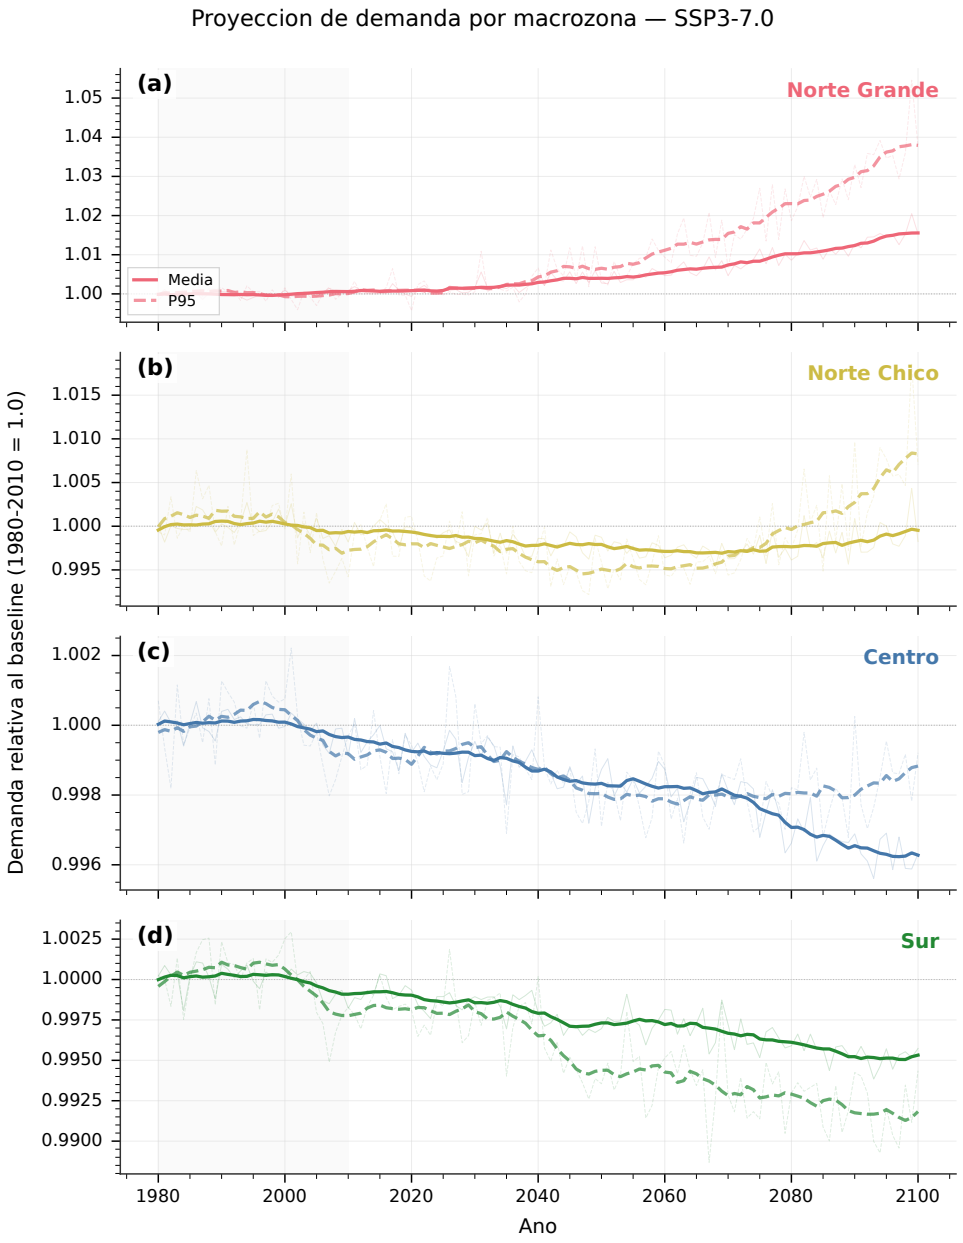

FIGURA 6.11: Demanda eléctrica anual proyectada por macrozona del SEN (Norte Grande, Norte Chico, Centro, Sur), normalizada al baseline 1980–2010, bajo SSP3-7.0 con supuesto de red estática. Modelo canónico per-(barra, cliente) (2.529 series). L´íneas: media m´óvil 11 años; bandas: rango intercuart´ílico entre series de la macrozona. Per´íodo: 1980–2100.

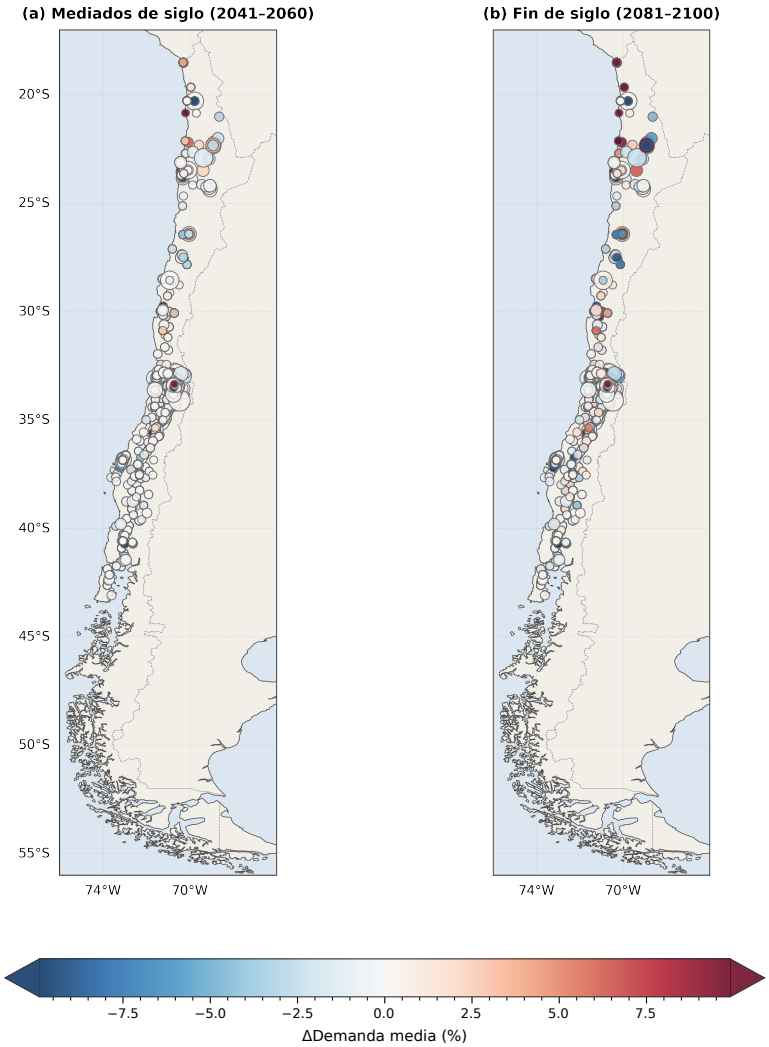

FIGURA 6.12: Cambio proyectado en demanda media anual (%) por subestación eléctrica bajo SSP3-7.0: (a) horizonte mediados de siglo (2041–2060) y (b) horizonte fin de siglo (2081–2100), ambos respecto al *baseline* canónico 1980–2010. El tamaño de los marcadores es proporcional a la demanda base de cada SE; colores cálidos indican aumento y colores fríos, disminución. Ambos paneles comparten la escala de color.

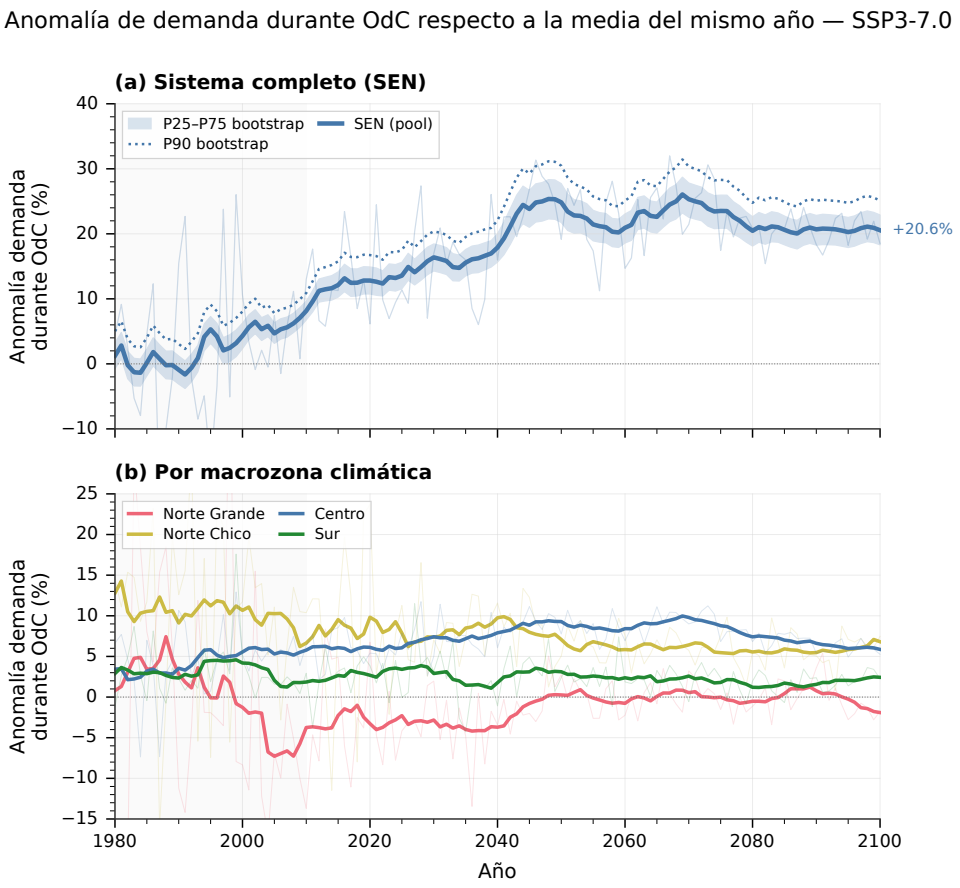

FIGURA 6.13: Anomalía de demanda durante eventos de ola de calor (OdC, %) respecto al mismo día del año sin OdC, bajo SSP3-7.0 (1980–2100); modelo per-(barra, cliente), 2.529 series. Panel (a): SEN completo con banda P25–P75. Panel (b): por macrozona. Media móvil 11 años.

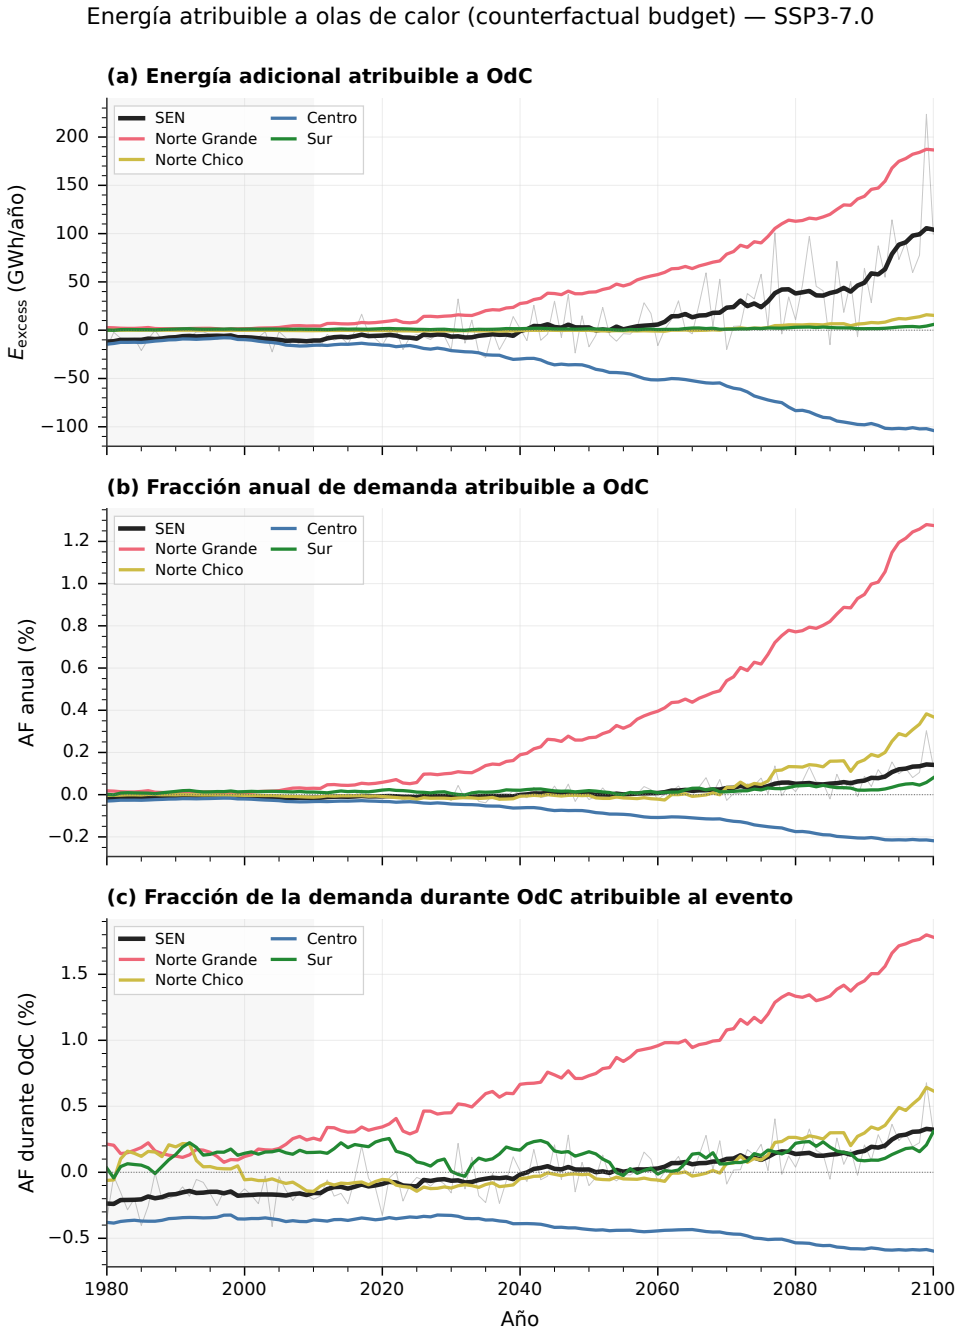

FIGURA 6.14: Energía atribuible a OdC bajo el balance contrafactual. Panel (a): energía adicional E_{excess} (GWh/año). Panel (b): fracción anual de demanda atribuible (AF, %). Panel (c): fracción de la demanda durante las propias horas de OdC atribuible al evento (AF dentro de OdC, %). SEN agregado y desglose por macrozona; media móvil 11 años; 2.529 series, SSP3-7.0.

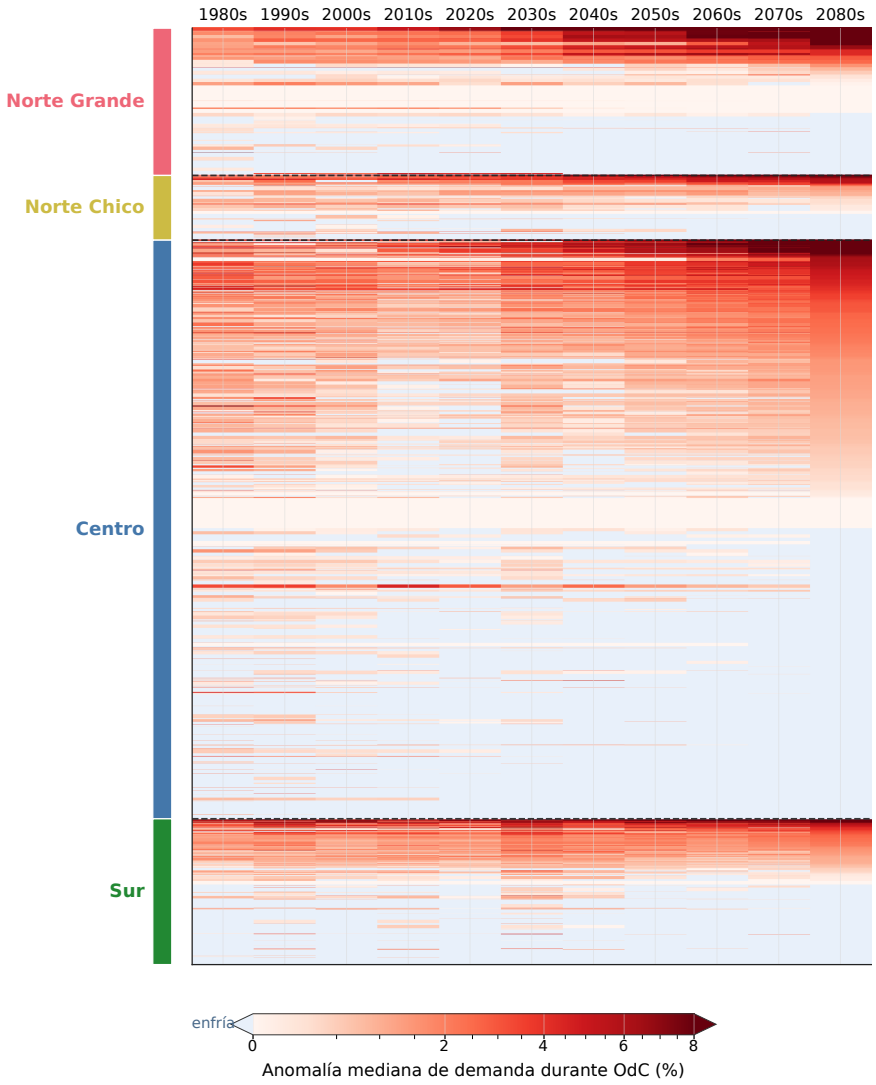

FIGURA 6.15: Trayectoria de estrés térmico: anomalía mediana de demanda durante eventos de OdC (%) por serie (barra–cliente; 2.529 series con proyección válida) y década (1980s–2080s) bajo SSP3-7.0. Las filas se agrupan por macrozona (raya de color a la izquierda) y, dentro de cada zona, se ordenan de forma descendente según la anomalía de la década de 2080; las líneas discontinuas separan las macrozonas. La altura de cada fila es proporcional a la capacidad media (*baseline*) de la serie, recortada al percentil 95 para evitar que series con valores atípicos aplasten al resto (recorte puramente visual). La escala *Reds* usa `PowerNorm`(γ=0,6); las celdas de enfriamiento (< 0) se muestran en azul pálido.

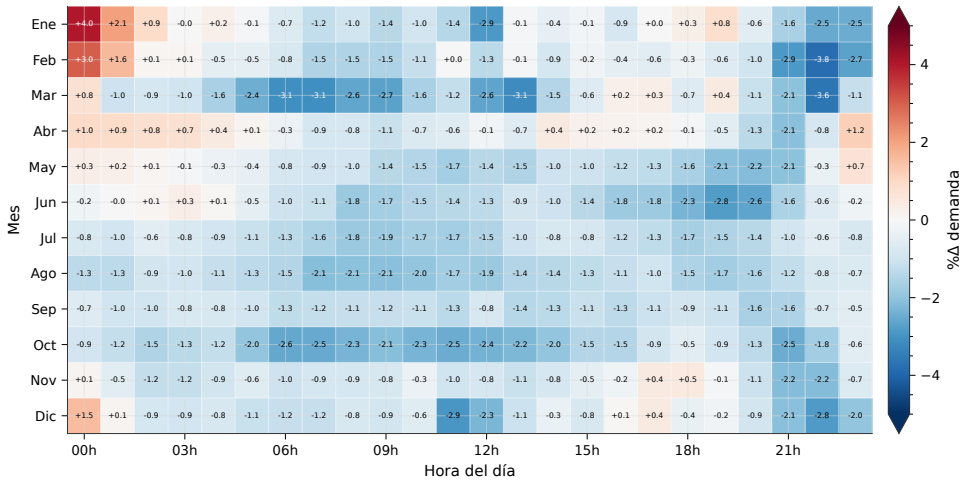

FIGURA 6.16: Cambio porcentual en la demanda horaria del SEN (%) por mes (eje Y) y hora del día (eje X) para el horizonte de fin de siglo (2081–2100) respecto al *baseline* 1980–2010, bajo SSP3-7.0 con supuesto de red estática. SEN agregado a partir de las 2.529 series del modelo canónico per-(barra, cliente). Tonos cálidos: aumento de demanda; tonos fríos: reducción.

CUADRO 6.2: Síntesis de métricas clave por macrozona climática del SEN bajo el modelo aditivo generalizado canónico per-(barra, cliente). n_{series} corresponde a series (barra, cliente) ajustadas exitosamente en cada zona; n_{proj} a las series con proyección SSP3-7.0 válida. R^2 y MAPE son medianas sobre las series ajustadas de la zona. $\Delta\overline{D}_{\text{med}}$ es la mediana intra-serie del cambio en demanda media anual a fin de siglo (2081–2100); $\Delta\overline{D}_{\text{dw}}$ es el promedio ponderado por la demanda histórica de cada serie (cifra equivalente al cambio agregado del sistema dentro de la zona).

Macrozona	n_{series}	n_{proj}	$\mathbf{R^2}$ (mediana)	**MAPE (%)** (mediana)	$\Delta\overline{D}_{\mathbf{med}}$ **(%)** 2081–2100	$\Delta\overline{D}_{\mathbf{dw}}$ **(%)** 2081–2100
Norte Grande	170	170	0,453	1,90	+0,00	+1,30
Norte Chico	185	185	0,634	3,65	−0,81	−0,13
Centro	1.668	1.668	0,643	5,34	+0,03	−0,35
Sur	506	506	0,561	6,03	+0,19	−0,46
Total	**2.529**	**2.529**	0,624	5,02	+0,02	−0,02

Nota: Zonas asignadas según latitud del píxel ALADIN. La diferencia entre $\Delta\overline{D}_{\text{med}}$ y $\Delta\overline{D}_{\text{dw}}$ revela la asimetría de la señal entre series: el incremento sistémico se concentra en pocas series de alto consumo. Los desgloses por estrato de cliente se reportan en la Tabla 6.1. El modelo SE-agregado (estimador supletorio) se documenta en el Apéndice L.

- **H3 (Cambio climático amplifica los picos)**: Confirmada parcialmente. Los percentiles incondicionales de demanda muestran cambios moderados a nivel del sistema agregado (ponderado por demanda sobre las 2.529 series con proyección válida: $\Delta\overline{D} = -0{,}02\,\%$ y $\Delta P95 = +0{,}53\,\%$ a fin de siglo), debido a la compensación entre aumentos estivales y disminuciones invernales. Sin embargo, la amplificación se manifiesta de forma condicional: la anomalía de demanda durante OdC crece de $+0{,}34\,\%$ (1980s) a $+0{,}44\,\%$ (2080s), y la frecuencia de eventos aumenta en un factor $\sim 2{,}45\times$ hacia fin de siglo.
- **H4 (Intensificación de las olas de calor)**: Confirmada. Las proyecciones muestran aumentos significativos en frecuencia, duración y magnitud (D·h) de OdC para el horizonte 2050–2080, con mayor intensificación relativa en la Zona Sur y mayor magnitud absoluta en el Norte Grande, en línea con [3].

Capítulo 7

Discusión

Este capítulo interpreta los resultados a la luz de la literatura internacional, examina las limitaciones metodológicas del estudio y deriva implicancias para la planificación energética y la política de adaptación en Chile. La discusión se estructura en torno a cuatro ejes: (i) posicionamiento de los hallazgos en el contexto de la literatura global; (ii) comparación con los escasos estudios previos sobre clima y demanda eléctrica en Chile; (iii) limitaciones intrínsecas del diseño metodológico; y (iv) implicancias operacionales y de política para el sistema eléctrico nacional.

7.1. Interpretación de los resultados en el contexto de la literatura

7.1.1. Curvas de sensibilidad térmica y la literatura internacional

Las curvas de efecto suave $s(tas)$ obtenidas para cada subestación (SE) presentan una forma en J asimétrica cuyo punto de inflexión —la *temperatura de confort* o *thermostat point*— oscila entre 16 °C y 22 °C según la macrozona. Por encima del punto de inflexión, la demanda crece de forma convexa con la temperatura, lo que es consistente con la saturación progresiva de la demanda de aire acondicionado. Esta geometría es cualitativamente compatible con los resultados de [20], quienes documentan respuestas heterogéneas a la temperatura en más de doscientas ciudades de Estados Unidos y concluyen que la sensibilidad marginal al calor varía en más de un orden de magnitud entre regiones con distinto nivel de ingreso, grado de urbanización y penetración de equipos de climatización. Este trabajo extiende ese análisis a escala (barra, cliente) —2.529 series estratificadas en distribuidoras, clientes libres regulados y libres no regulados—, capturando heterogeneidades espaciales y de tipo de cliente que una agregación nacional o por subestación invisibilizaría.

El efecto diferencial sobre la demanda pico es coherente con [12], quienes demuestran que los episodios extremos de calor desplazan la distribución de la demanda más en la cola superior que en la media. El análisis de la curva de carga diaria (CDC) bajo olas de calor en las macrozonas Norte y Central evidencia que el incremento relativo durante la tarde-noche (18:00–22:00 h) se concentra de forma desproporcionada respecto al incremento en la demanda media diaria, patrón que reproduce la asimetría identificada por dichos autores. Esta concentración del impacto en el pico vespertino tiene consecuencias directas sobre los requerimientos de potencia electrica, no sólo de energía, y sobre la estrechez del margen de reserva en días extremos.

El uso de un GAM con interacciones tensoriales para capturar la relación entre hora y temperatura es metodológicamente análogo al enfoque de [57], quienes aplican

GAMs con términos suaves bidimensionales para la previsión de demanda eléctrica de mediano plazo en Europa. Ambos trabajos coinciden en que la interacción entre la variable temporal y la climática es estadísticamente inseparable: modelar la temperatura como efecto aditivo puro independiente de la hora subestima la sensibilidad al calor durante el pico vespertino y la sobreestima en horas nocturnas. El modelo canónico per-(barra, cliente) adoptado en esta tesis incorpora esta interacción mediante tensores de la temperatura con la hora del día y con la época del año, que permiten que la pendiente de la respuesta térmica varíe a lo largo del ciclo diurno y estacional. La inercia térmica de las edificaciones —la acumulación de calor a lo largo de los eventos de varios días que caracterizan a las olas de calor— se incorpora en el modelo SE-agregado (Apéndice L) mediante un término de media ponderada exponencialmente (EWMA); en la formulación per-serie este término se omite por la concurvidad que introduce con la respuesta a la temperatura y con el tensor temperatura–época del año en series cortas (§5.7.2).

7.1.2. Climatología de olas de calor

La climatología de olas de calor (OdC) construida en este trabajo muestra una tendencia creciente en frecuencia, duración e intensidad bajo SSP3-7.0, con aceleración notable a partir de la década de 2050 en la zona central y norte. Este patrón es consistente con [75], quienes documentan un aumento significativo en la frecuencia y duración de las olas de calor en Chile durante el período 1980–2016 a partir de datos de estaciones. El presente análisis extiende ese diagnóstico hacia el año 2100 con una resolución horaria y una cobertura espacial completa del territorio continental, incluyendo zonas rurales y cordilleranas donde la red de estaciones es escasa. [76] confirman la tendencia de calentamiento acelerado en la región durante las últimas décadas; aquí se extiende ese diagnóstico proyectando cuánto de ese calentamiento se traduce en carga adicional sobre las infraestructuras eléctricas, cerrando el nexo entre climatología y demanda.

7.1.3. Análisis (barra, cliente) versus modelos agregados

La sensibilidad térmica de la demanda, medida como la derivada de $s(tas)$ evaluada en la cola superior, varió significativamente entre clientes conectados a una misma barra. La estratificación entre distribuidoras ($n = 385$), clientes regulados ($n = 139$) y libres no regulados ($n = 2.005$) revela diferencias sistemáticas tanto en bondad de ajuste como en geometría de las curvas: las distribuidoras presentan los mejores ajustes (R^2 mediano 0,686, MAPE mediano 1,51 %) por agregación socioeconómica de miles de clientes residenciales y comerciales que homogeneizan la señal climática, mientras que los clientes libres regulados muestran el desempeño más débil (R^2 mediano 0,250) por dominancia de programación operativa no observable. Un modelo nacional único o incluso una especificación por macrozona o por SE agregada perdería esta heterogeneidad intracliente. La granularidad (barra, cliente) permite, en consecuencia, construir un *mapa de vulnerabilidad* desagregable por estrato (Figura 7.1, §7.4) inaccesible desde los modelos agregados que predominan en la literatura internacional.

7.1.4. Heterogeneidad por macrozona bajo SSP3-7.0

La proyección agregada per-(barra, cliente) revela una señal climática *modesta* a nivel del sistema completo, pero con marcada heterogeneidad *territorial* en el cambio medio anual de demanda a fin de siglo. El delta ponderado por demanda del sistema agregado, calculado como $\sum_i D_i^{\text{fut}} / \sum_i D_i^{\text{base}} - 1$ sobre las 2.529 series con proyección válida (baseline 1980–2010), es de apenas $-0{,}02\,\%$ a fin de siglo, con $\Delta P95 = +0{,}53\,\%$. Esta lectura agregada esconde, sin embargo, gradientes zonales no triviales: en términos ponderados por demanda por macrozona, Norte Grande $+1{,}30\,\%$ emerge como la única macrozona con incremento agregado neto, mientras que Norte Chico $-0{,}13\,\%$, Centro $-0{,}35\,\%$ y Sur $-0{,}46\,\%$ muestran reducciones agregadas leves. La mediana *per-series* de $\Delta\overline{D}$ a fin de siglo es de $+0{,}02\,\%$ y la mediana de $\Delta P95$ alcanza $+0{,}29\,\%$, confirmando que las colas se mueven más que el centro de la distribución. El signo *negativo* ponderado por demanda en Centro y Sur refleja el efecto neto de zonas templadas con baja penetración de aire acondicionado: el calentamiento proyectado reduce el requerimiento de calefacción sin un aumento proporcional en refrigeración, dejando un balance ligeramente negativo en la demanda agregada. La explicación completa requiere mirar la composición por estrato dentro de cada macrozona (Tabla 6.1 del Capítulo de Resultados) y la posición local de la temperatura de confort respecto a la climatología histórica observada.

Esta heterogeneidad por macrozona —con la zona Norte Grande concentrando casi todo el incremento agregado y las zonas templadas mostrando signos opuestos— sustenta la principal contribución aplicada del trabajo: **el promedio del sistema ($-0{,}02\,\%$) oculta gradientes regionales con signo opuesto y magnitudes muy heterogéneas**, ya documentados por [20] para Estados Unidos y aquí verificados a escala (barra, cliente) en Chile. El mismo ordenamiento de macrozonas se recupera con una parametrización independiente —un modelo por subestación con ponderación por capacidad instalada— en [31], donde el Norte Chico alcanza $+5{,}33\,\%$ en la anomalía media y $+7{,}08\,\%$ en el percentil 95 a fin de siglo, frente a $+0{,}17\,\%$ en el Centro y $-0{,}04\,\%$ en el Sur. La mayor magnitud de esas cifras refleja la ponderación por capacidad y una submuestra distinta de subestaciones, no una discrepancia de signo.

7.1.5. Estratificación por tipo de cliente: hallazgo metodológico

La capacidad predictiva sigue un patrón ordenado según tipo de cliente. Las series de distribuidoras de servicio público muestran los mejores ajustes (MAPE mediano 1,51 %), seguidas de los clientes libres regulados (2,53 %) y los libres no regulados (6,49 %). Este orden es interpretable: la agregación de miles de consumidores residenciales en una distribuidora promedia idiosincrasias individuales y deja predominantemente la señal climático-calendárica; en cambio, un cliente industrial libre incorpora ciclos productivos, paradas programadas y respuesta a precios que el GAM climático-temporal no captura. La mayor diferencia de R^2 separa Distribuidoras (0,686) de Clientes regulados (0,250), con Clientes libres en un punto intermedio (0,628). Este hallazgo refuerza la recomendación de [20] de evitar modelos de propósito único para sistemas eléctricos con composición heterogénea de carga, y sugiere que la planificación operativa de los clientes libres requiere combinar el GAM climático con señales de actividad sectorial (producción minera, demanda industrial proxy).

En el plano de las proyecciones a fin de siglo, los tres estratos muestran contribuciones diferentes al delta del sistema. El incremento agregado se reparte de forma

similar entre Clientes regulados ($n = 139$; $+0{,}31\,\%$ ponderado por demanda, mediana per-series $0{,}00\,\%$) y Clientes libres ($n = 2.005$; $+0{,}30\,\%$ ponderado por demanda, mediana per-series $+0{,}08\,\%$), reflejando que un número relativamente pequeño de clientes con alta sensibilidad térmica empuja el promedio ponderado en ambos estratos. Particularmente notable es Distribuidoras ($n = 385$; $-0{,}31\,\%$ ponderado por demanda, mediana per-series $-0{,}09\,\%$): la señal *negativa* de las distribuidoras —en ambas métricas— refleja que éstas están concentradas en zonas centro-sur con respuestas térmicas no monotónicas, donde el calentamiento proyectado reduce el requerimiento de calefacción más de lo que incrementa el de refrigeración. La brecha entre la mediana per-series y el promedio ponderado por demanda —por ejemplo, $+0{,}08\,\%$ frente a $+0{,}30\,\%$ en Clientes libres— destaca la importancia de combinar ambos estimadores en estudios de impacto: la mediana per-series describe el comportamiento típico de las unidades, mientras que el promedio ponderado por demanda baseline describe el comportamiento del sistema.

7.1.6. Robustez frente al nivel de agregación: SE vs. per-(barra, cliente)

El estudio dispone de dos representaciones complementarias del mismo fenómeno: la vista canónica per-(barra, cliente) ($n = 2.529$ series), sobre la que se construyen todas las proyecciones de impacto, y un modelo SE-agregado ($n = 335$ subestaciones), empleada como chequeo de robustez sobre la *forma* de la respuesta térmica contrafactual. Ambas vistas recuperan curvas $s(tas)$ cualitativamente consistentes —con ramas de calefacción y refrigeración de pendientes análogas por macrozona—, lo que indica que la señal climato-energética estimada no es un artefacto del nivel de granularidad elegido. La vista per-(barra, cliente) se adopta como análisis principal por su mayor resolución estructural y por permitir el desglose por estrato de cliente y la ponderación por demanda histórica; las métricas y curvas detalladas del modelo SE-agregado se reportan en el Apéndice L.

7.2. Comparación con estudios previos en Chile

Los estudios que relacionan explícitamente el clima con la demanda eléctrica en Chile son escasos y de alcance limitado. Esta sección contrasta los hallazgos del presente trabajo con los tres antecedentes más directos y señala en qué difieren estos hallazgos.

Rouault et al. (2019). [17] proyectan el incremento de la demanda de refrigeración y calefacción en viviendas de Santiago utilizando un enfoque de simulación de edificios (EnergyPlus) combinado con escenarios de cambio climático. Sus resultados muestran que, bajo RCP 8.5, la demanda anual de refrigeración en la Región Metropolitana se incrementaría en un 40–80 % hacia 2100 respecto al período de referencia. El presente estudio complementa ese análisis en tres dimensiones: (i) emplea un GAM calibrado empíricamente sobre datos reales de demanda en lugar de un modelo de edificio sintético; (ii) cubre 2.529 series (barra, cliente) del SEN —agregables a 399 SE— en lugar de una sola ciudad; y (iii) genera proyecciones a escala horaria que permiten analizar el impacto sobre la forma de la CDC, no solo sobre la demanda anual acumulada.

Verichev et al. (2020). [62] analizan cómo el cambio climático alterará las zonas climáticas de diseño en Chile bajo la norma térmica chilena, concluyendo que varias

ciudades de la zona central migrarán hacia zonas más cálidas antes de mediados de siglo. Este cambio tiene implicancias directas sobre los coeficientes de demanda de calefacción y refrigeración utilizados en la planificación de capacidad. Las curvas de sensibilidad térmica obtenidas en este trabajo capturan implícitamente esa transición de zona: una SE en la que el punto de inflexión de $s(tas)$ se desplace hacia temperaturas más altas en proyecciones futuras es una SE cuya composición del parque de climatización habrá cambiado. Sin embargo, el GAM calibrado en el período 2017–2025 no modela esa adaptación autónoma; esta interacción entre mitigación y adaptación es la principal brecha que separa los resultados del presente trabajo de los obtenidos por [62].

Contribución diferencial. Este trabajo reúne en un mismo flujo metodológico: (i) proyecciones climáticas regionales con corrección de sesgo horaria de alta resolución (0,11°); (ii) datos empíricos de demanda eléctrica con granularidad (barra, cliente) —2.567 series candidatas y 2.529 ajustadas, agregables a 399 SE del SEN— estratificados por tipo de cliente (distribuidoras, libres regulados y libres no regulados); (iii) modelación mediante GAM con productos tensoriales que capturan la interacción entre temperatura y hora del día/estación; y (iv) proyecciones de impacto diferenciadas espacialmente bajo SSP3-7.0 para el horizonte 2021–2100. La escala subregional del análisis y la resolución horaria de las proyecciones abren una línea de trabajo inaccesible para los estudios precedentes basados en modelos de edificio, datos de demanda agregada o escenarios de temperatura diaria. Dos componentes de este flujo han sido validados de forma independiente por revisión de pares: la climatología de olas de calor del modelo regional, extendida a SSP5-8.5, en [30], y la respuesta de la demanda a nivel de subestación, con una razón de riesgo de cola ponderada por capacidad, en [31].

7.3. Limitaciones metodológicas

Varias limitaciones de diseño acotan el alcance de los resultados. Una limitación de fondo es la **cadena climática única**: la corrección de sesgo y las proyecciones se basan en una sola cadena GCM–RCM —CNRM-ESM2-1 como modelo global y CNRM-ALADIN64 como modelo regional (CORDEX-CHP12, 0,11°)—, que captura una única realización del espacio de incertidumbre estructural del sistema climático. Los estudios de *multi-model ensemble* para América del Sur muestran que la dispersión entre modelos en el percentil P90 de temperatura máxima para mediados de siglo puede superar los 1,5 K para SSP3-7.0, lo que equivale a una diferencia de hasta un 8–12 % en la demanda pico proyectada según las curvas de sensibilidad obtenidas. La incertidumbre climática es, por tanto, la principal fuente de incertidumbre no caracterizada en este estudio. Una acotación parcial de esa incertidumbre proviene de [30]: al expresar las métricas de olas de calor en función del calentamiento regional acumulado, las trayectorias SSP3-7.0 y SSP5-8.5 colapsan en una única curva, lo que indica que la elección de escenario reescala el horizonte temporal más que la forma de la respuesta térmica, y que la dispersión relevante proviene de la cadena GCM–RCM antes que del forzamiento. Su cuantificación requeriría repetir el flujo completo (corrección de sesgo → extracción → GAM → proyección) con cinco a diez modelos adicionales del *ensemble* CORDEX-CHP12, tarea que escapa de los objetivos planteados en el presente trabajo, pero que representa la extensión natural relevante de este.

Ligada a esa incertidumbre, la **extrapolación fuera del rango de entrenamiento** condiciona las proyecciones de fin de siglo. Los GAMs fueron entrenados sobre 2017–2025, durante el cual las temperaturas extremas observadas raramente superaron los umbrales proyectados para la segunda mitad del siglo XXI. Las funciones suaves estimadas —en particular la respuesta a la temperatura del aire y de rocío y los tensores de la temperatura con la hora del día y con la época del año— se extrapolan fuera del soporte observacional al evaluarse en las proyecciones de 2070–2100. En regiones de *spline* sin datos de entrenamiento, la base de B-splines es lineal por defecto, lo que subestima la posible curvatura adicional si la respuesta de la demanda se hace más no-lineal a temperaturas muy altas (por saturación del parque de aire acondicionado o por cortes programados de carga). [60] documentan una limitación análoga en su modelo AirGAM: el GAM produce estimaciones razonables dentro del rango de entrenamiento, pero su incertidumbre crece rápidamente en la extrapolación. Para mitigar, sin eliminar, este riesgo, las proyecciones se reportan como anomalías respecto a la línea base ALADIN histórica (1980–2010) y no como niveles absolutos, de modo que cualquier sesgo sistemático del GAM afecta por igual al escenario y a la referencia y se cancela parcialmente en la diferencia. Del lado climático, el riesgo simétrico —que la corrección de sesgo deforme las colas al evaluarse fuera del estado climático de calibración— se acota en [30]: la validación bajo no estacionariedad muestra que el residuo del ajuste UQM en la cola P99–P99,9 es frío, con mediana de $-0{,}5\,^{\circ}\mathrm{C}$, de modo que las forzantes proyectadas subestiman ligeramente el calor extremo y las proyecciones de demanda derivadas de ellas son conservadoras.

El **período de entrenamiento limitado** agrava este punto: 2017–2025 abarca ocho años de datos validados, lo que restringe la diversidad de condiciones climáticas observadas. El modelo aprende la respuesta térmica en un contexto en el que la penetración de aire acondicionado, la composición del parque industrial y la estructura tarifaria son las de finales de la década de 2010 en Chile. Bajo cambio climático, la adaptación autónoma de los consumidores (mayor penetración de aire acondicionado, mejor aislación de viviendas, cambio de horarios laborales) puede modificar sustancialmente las curvas de sensibilidad hacia mediados de siglo, efecto que el GAM no captura al estar calibrado sobre el período histórico.

En el plano estadístico, la **autocorrelación residual** de los residuos del modelo final es alta (ACF_1 mediana $\approx 0{,}851$), esperable en demanda horaria por la inercia térmica de los edificios. No compromete la insesgadez de los efectos suaves [61], pero vuelve anti-conservadores los intervalos puntuales: su ancho real al 95 % debería ser entre 1,3 y 1,7 veces mayor. Por eso esta tesis reporta *intervalos simultáneos* por simulación posterior [73], que ya incorporan esa corrección; el tratamiento del término AR(1) y su incompatibilidad con `discrete=TRUE` se detallan en la Sección 5.7.4 y el Apéndice E. Una alternativa futura sería `gamm()` con estructura de correlación explícita, a costa de renunciar a la aproximación `discrete`.

En cuanto a la granularidad, el nivel (barra, cliente) mitiga sustancialmente, aunque no elimina, las **cargas mixtas** que afectaban a la base SE-agregada. La estratificación por tipo de cliente (Distribuidoras, Clientes regulados, Clientes libres) separa las distribuidoras de servicio público (agregación residencial-comercial) de los clientes libres (industria y minería), permitiendo ajustes GAM por estrato. Persiste, no obstante, la mezcla interna dentro de las distribuidoras, donde clientes residenciales y comerciales coexisten en una misma serie. Separar la sensibilidad residencial pura

exigiría datos de medidor inteligente a nivel de cliente final, tecnología en despliegue incipiente en el SEN pero cuyos datos aún no están disponibles para investigación académica en el horizonte de esta tesis.

Por último, el ejercicio supone una **red eléctrica estática**: la topología y la capacidad de transmisión permanecen constantes a lo largo del horizonte de proyección. No se modelan la degradación de la capacidad de transmisión bajo temperaturas altas (efecto *thermal derating* en líneas aéreas), las restricciones de transmisión intrazonales que emergen durante episodios de calor extendido, ni los programas de respuesta de la demanda que el Coordinador Eléctrico Nacional podría activar para aplanar el pico.

7.4. Implicancias para la política energética

7.4.1. Mapa de vulnerabilidad espacial

La combinación de la sensibilidad térmica estimada por el GAM con la climatología de olas de calor permite construir un índice de vulnerabilidad compuesto para cada SE: $V_i = \bar{s}_i \times E_i$, donde $\bar{s}_i$ es la sensibilidad marginal media al calor (derivada de $s(tas)$ evaluada en el P90 local) y E_i es la exposición proyectada a OdC (número esperado de horas de OdC por década bajo SSP3-7.0). Las SEs con mayor índice V son las que requerirán con mayor urgencia refuerzos de red, tanto en capacidad de transformación como en redundancia de transmisión (Figura 7.1). Este mapa constituye un insumo directo para los Planes de Expansión del Sistema de Transmisión que la CNE elabora quinquenalmente.

7.4.2. Programas de respuesta de la demanda

Las curvas de sensibilidad térmica a nivel de SE permiten identificar qué subestaciones concentran la mayor elasticidad calor-demanda en el pico vespertino (18:00–22:00 h). Estas SEs son las candidatas prioritarias para programas de *demand response* diferenciados: por ejemplo, incentivos tarifarios para el preenfriamiento antes del pico, acuerdos con clientes industriales conectados a esas barras para ceder capacidad en días de alerta meteorológica, o instalación de almacenamiento térmico (*thermal storage*) en edificios comerciales de alta carga. La granularidad del análisis —2.529 series (barra, cliente) ajustadas agregables a 399 SE— hace operacional una política de este tipo, que sería imposible de diseñar a partir de modelos de demanda a escala nacional o macrozonal.

7.4.3. Planificación de capacidad bajo cambio de la CDC

El desplazamiento de la curva de carga diaria (CDC) proyectado bajo SSP3-7.0 tiene consecuencias directas para los requerimientos de potencia de punta: no sólo aumenta la demanda media, sino que el pico horario crece de forma desproporcionada, estrechando el margen de reserva dinámico en las horas de mayor radiación solar cuando precisamente la generación fotovoltaica empieza a declinar. En el horizonte 2050–2070, la infraestructura de pico diseñada sobre estándares históricos puede resultar insuficiente en la zona Central y Norte Grande. Los resultados de este estudio indican que, bajo el escenario SSP3-7.0 y a red estática, el P95 del sistema crece $+0{,}53\,\%$ ponderado por demanda a fin de siglo y la mediana per-series de $\Delta P95$ alcanza $+0{,}29\,\%$, con la macrozona Norte Grande concentrando el incremento agregado ($+1{,}30\,\%$ ponderado por demanda en $\Delta\overline{D}$). La magnitud agregada es modesta,

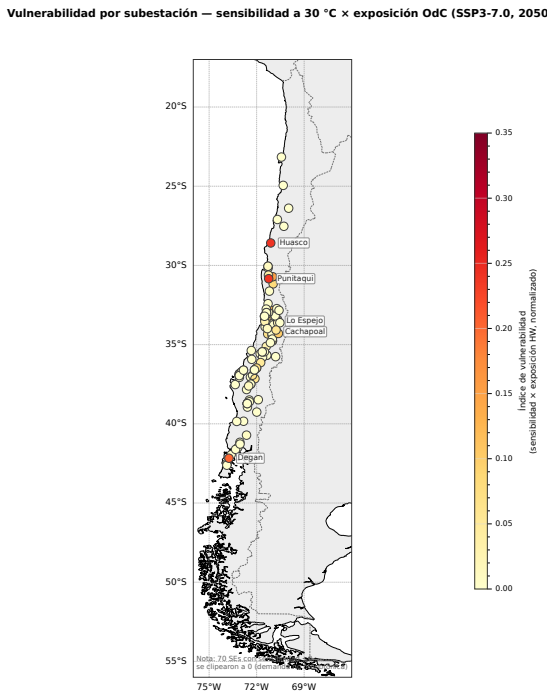

FIGURA 7.1: Índice de vulnerabilidad por subestación eléctrica bajo SSP3-7.0 (2050–2080): producto de la sensibilidad térmica a 30 °C ($dF/dT|_{30}$, normalizada) y la exposición proyectada a olas de calor (número de eventos por pixel, 2050–2080). Solo las subestaciones con sensibilidad positiva a altas temperaturas presentan índice $V > 0$ (la mayoría de las SEs chilenas muestran una respuesta dominada por calefacción, no por refrigeración). Las SEs más vulnerables se concentran en la zona Norte Chico–Centro Norte.

pero la heterogeneidad regional es marcada: la capacidad de punta debería ajustarse de forma diferenciada, priorizando el norte árido sobre las zonas templadas, para mantener el margen de reserva regulatorio vigente bajo el supuesto de red y parque de generación estáticos.

7.4.4. Uso de la climatología de OdC más allá del sector energético

La base de datos de olas de calor producida en este trabajo —con cobertura completa del territorio continental a resolución horaria y de 0,11°— es un producto autónomo, aplicable a sectores que trascienden la energía. En el ámbito de la salud pública, puede informar sistemas de alerta temprana para eventos de mortalidad asociada al calor [5]. En planificación urbana, permite identificar municipios donde el *urban heat island* amplifica la exposición ya proyectada por el modelo regional. En el sector agropecuario, los umbrales de OdC diurnos y nocturnos son relevantes para el manejo del estŕes caloríco en ganado y fruticultura. La metodología —replicable para cualquier variable y escenario proyectado mediante CNRM-ALADIN64— está públicamente disponible en el repositorio del proyecto.

7.4.5. Replicabilidad del flujo metodológico

La arquitectura modular del proyecto —corrección de sesgo, climatología de extremos, datos de demanda y modelación GAM— es directamente replicable para cualquier SE del SEN con suficiente cobertura temporal de datos de demanda. Si el Coordinador Eléctrico Nacional amplía la disponibilidad pública de datos de medición a nivel de barra, el flujo completo podría actualizarse con cada nueva generación de proyecciones climáticas regionales.

Capítulo 8

Conclusiones y trabajos futuros

8.1. Conclusiones principales

Esta tesis ha desarrollado un *pipeline* modular para cuantificar los efectos de las olas de calor en la demanda eléctrica horaria del Sistema Eléctrico Nacional (SEN) de Chile, integrando corrección de sesgo de proyecciones climáticas regionales, detección de eventos extremos y modelado estadístico no lineal mediante Modelos Aditivos Generalizados (GAM/mgcv). Las conclusiones siguen el orden de las hipótesis y objetivos específicos.

1. **Heterogeneidad espacial y por tipo de cliente de la sensibilidad térmica (H1 — SO.2): *CONFIRMADA*.** Los **2.529 modelos GAM** ajustados sobre series (barra, cliente) , agregables a 399 SE, revelan curvas de respuesta térmica cualitativamente distintas entre macrozonas y entre tipos de cliente: el norte chico exhibe sensibilidades de refrigeración, la demanda crece con *tas* por encima del umbral de confort, mientras que el sur templado y lluvioso muestra sensibilidades de calefacción dominantes. La estratificación por tipo de cliente añade una dimensión clave: dentro de una misma barra coexisten respuestas térmicas distintas entre las distribuidoras de servicio público y los clientes libres, cuyo detalle por estrato se reporta en la Tabla 6.1. Esta doble heterogeneidad (espacial y por tipo de cliente) no puede capturarse con un modelo nacional único ni con una agregación a nivel SE, y justifica el enfoque per-(barra, cliente) de este trabajo.

2. **Significancia de las interacciones tensoriales (H2 — SO.3): *CONFIRMADA*.** Las interacciones tensoriales de la temperatura con la hora del día y con la época del año son estadísticamente significativas en la gran mayoría de las series (el 98,7 % de las 2.529 series ajustadas; prueba F, $p < 0{,}01$; la verificación equivalente sobre el modelo SE-agregado se reporta en el Apéndice L), confirmando que la sensibilidad térmica de la demanda no es estacionaria en el tiempo intradía ni a lo largo del año. Los modelos sin interacciones subestiman sistemáticamente los picos vespertinos de verano y los valles nocturnos de invierno. Este resultado valida H2 y justifica incorporar interacciones tensoriales en modelos de demanda climáticamente informados.

3. **Amplificación condicional de la demanda durante olas de calor bajo cambio climático (H3 — SO.4): *CONFIRMADA PARCIALMENTE*.** Bajo el escenario SSP3-7.0, la señal agregada del sistema es *modesta*: la demanda media anual ponderada por demanda prácticamente no varía ($-0{,}02$ %) y el P95 incondicional crece $+0{,}53$ % a fin de siglo, por la compensación entre los aumentos

estivales en zonas áridas y la menor calefacción en zonas templadas. La amplificación se manifiesta de forma *condicional*: durante las horas de ola de calor la demanda se desplaza hacia valores superiores respecto de condiciones comparables sin evento; además, la frecuencia de eventos se multiplica por $\sim$2,45 hacia fin de siglo, y de forma *territorial* . La amplificación también se manifiesta de forma *territorial*, concentrándose en el Norte Grande (+1,30 % ponderado por demanda). El cambio climático no amplifica de manera uniforme la demanda agregada del sistema, sino que concentra el incremento en episodios extremos y macrozonas expuestas, un patrón que un análisis nacional agregado no revelaría.

4. **Capacidad predictiva del modelo aditivo per-(barra, cliente) (SO.3): *CUMPLIDO*.** El modelo per-(barra, cliente) (Sección 5.7.2) alcanza, sobre las **2.529 series** ajustadas, una mediana de $R^2 = 0{,}624$ y una MAPE mediana de 5,02 %; al sumar sobre series, la bondad de ajuste del sistema agregado sube a $R^2 \approx 0{,}978$ por cancelación de errores idiosincráticos. Un *pipeline* basado en GAMs captura así la respuesta demanda–clima desde la granularidad (barra, cliente) hasta el sistema, con un equilibrio favorable entre interpretabilidad y capacidad predictiva.

5. **Intensificación de las olas de calor y climatología de referencia (H4 — SO.5): *CONFIRMADA*.** El análisis de detección de olas de calor y frío, basado en umbrales percentílicos horarios (P90 para temperatura máxima, P10 para temperatura mínima) y la exigencia de al menos tres días consecutivos, documenta un aumento significativo en la frecuencia, duración y magnitud de los eventos de calor extremo hacia el período 2050–2080 respecto al histórico (1980–2010), con gradientes espaciales que varían por macrozonas, y la frecuencia de eventos de OdC aumenta en un factor $\sim$2,45$\times$ hacia fin de siglo. Esta climatología es reutilizable para la planificación de adaptación climática en sectores más allá del energético.

6. **Métrica de magnitud en grados-hora (SO.3).** Operar a resolución horaria habilita una métrica de magnitud de evento inaccesible con datos diarios: los *grados-hora* (°C $\times$ hora), la integral temporal de la excedencia de temperatura sobre el umbral de confort durante una ola de calor. Frente a los clásicos grados-día calculados sobre medias diarias, los grados-hora preservan la resolución horaria de la señal climática y de la demanda, midiendo la carga térmica acumulada con mayor fidelidad. Los grados-hora se proponen como métrica para estudios de impacto térmico en sistemas eléctricos.

Estas conclusiones deben leerse dentro de dos límites centrales del diseño. Primero, las proyecciones se apoyan en una única cadena de modelo climático (CNRM-ALADIN64/CNRM-ESM2-1) y un único escenario de emisiones (SSP3-7.0): sin un *ensemble* multi-modelo ni el escenario SSP5-8.5, la incertidumbre estructural del forzante climático no queda acotada. Segundo, las proyecciones aíslan la componente climática pura, mantienen fija la estructura de demanda de 2017–2025 y extrapolan la respuesta térmica a temperaturas sin precedente histórico, por lo que no incorporan la electrificación, la penetración de aire acondicionado ni el crecimiento del consumo, factores que podrían modificar los impactos reportados y, en el caso de una mayor penetración de aire acondicionado, probablemente amplificarlos durante eventos cálidos extremos. Estos límites no invalidan la evidencia central del trabajo: la heterogeneidad espacial y la concentración del impacto durante las olas de

calor son robustas a la granularidad y al método (Apéndice L); pero acotan su interpretación cuantitativa y la magnitud extrapolada hacia fines de siglo. Las demás limitaciones (período de entrenamiento, autocorrelación residual, ruptura estructural por COVID-19 y cobertura de datos) se documentan y mitigan en la Discusión (Sección 7.3) y en el Apéndice I.

8.2. Trabajos futuros

Las limitaciones identificadas y los resultados abren las siguientes líneas de investigación:

1. ***Ensemble* multi-modelo climático.** Extender el análisis a cadenas GCM–RCM adicionales disponibles en CORDEX-CHP12 para cuantificar la incertidumbre de la proyección de demanda asociada a la elección del modelo climático, generando intervalos de confianza más robustos para los tomadores de decisiones.
2. **Proyecciones bajo SSP5-8.5.** Completar la corrección de sesgo de todas las variables climáticas bajo el escenario de mayor calentamiento para acotar el rango de incertidumbre de los impactos y proveer análisis de peor caso para la planificación de resiliencia. La componente climática de esta extensión ya está disponible: [30] reporta la climatología de olas de calor bajo SSP5-8.5 sobre el mismo modelo regional, de modo que lo pendiente se reduce a la corrección de sesgo del punto de rocío y al reprocesamiento de las proyecciones de demanda.
3. **Modelado del lado de la oferta.** Integrar la dinámica de la generación y transmisión bajo condiciones de calor extremo: deslastre térmico de centrales termoeléctricas, reducción de la capacidad de transporte en líneas de alta tensión y disminución de la generación hidráulica por sequía simultánea a las olas de calor.
4. **Escenarios de adopción de aire acondicionado.** Incorporar proyecciones de penetración de climatización por subestación, con datos censales y proyecciones económicas, para endogeneizar el cambio en la función de respuesta térmica a lo largo del horizonte de proyección. Esta línea fue excluida de la presente tesis por ausencia de datos de medidor individual.
5. **Riesgo compuesto demanda–oferta.** Estimar la probabilidad conjunta de demanda alta y oferta reducida durante olas de calor, construyendo métricas de estrés sistémico que informen los requerimientos de reserva operacional y los planes de contingencia del operador del sistema.
6. **Extensión del período de entrenamiento.** Incorporar los años 2022–2025 al conjunto de entrenamiento para ampliar el rango de temperaturas observadas, mejorar la robustez de la extrapolación y reducir el peso relativo del período COVID en la calibración.
7. **Análisis por consumidor individual.** Si se dispone de datos de medidores inteligentes (*smart meters*), replicar el análisis a nivel residencial o comercial para desagregar la sensibilidad térmica por tipo de consumidor y diseñar instrumentos de política más focalizados.
8. ***Dashboard* operacional en tiempo real.** Desarrollar una herramienta de monitoreo para operadores del SEN que integre pronósticos climáticos de corto

plazo con las curvas de sensibilidad térmica por subestación, generando alertas tempranas de estrés de demanda durante eventos de calor extremo.

8.3. Implicancias

Los resultados tienen implicancias directas para la planificación y operación del SEN:

- **Planificación de la transmisión.** El mapa de heterogeneidad espacial de la sensibilidad térmica identifica las subestaciones donde el incremento de la demanda de punta bajo calentamiento es más severo, orientando las inversiones prioritarias en refuerzo de infraestructura de transmisión.
- **Respuesta a la demanda y eficiencia energética.** Las curvas de sensibilidad térmica por subestación permiten focalizar programas de respuesta a la demanda y eficiencia energética según el perfil climático local: las medidas de reducción de carga críticas durante olas de calor en el norte son distintas de las prioritarias para el sur en invierno.
- **Climatología de extremos como bien público.** La base de datos de olas de calor y frío (1979–2100, resolución horaria y comunal) generada en este trabajo es reutilizable para estudios de salud pública, gestión hídrica y planificación urbana, más allá del alcance energético de esta tesis. Un primer uso derivado de esta climatología es la caracterización de las olas de calor atmosféricas de Chile bajo SSP5-8.5 [30]; su aplicación al riesgo de la infraestructura eléctrica a nivel de subestación se documenta en [31].
- **Replicabilidad del *pipeline*.** El *pipeline* modular (corrección de sesgo UQM $\rightarrow$ detección de OdC $\rightarrow$ GAM por (barra, cliente) $\rightarrow$ proyecciones SSP) es replicable para otras subestaciones del SEN a medida que se incorporen nuevos datos de demanda, y es adaptable a otros sistemas eléctricos con proyecciones climáticas regionales disponibles.
- **Recomendaciones para el operador (CEN).** Se recomienda al Coordinador Eléctrico Nacional priorizar tres líneas de acción: (i) incorporar las curvas de sensibilidad térmica per-(barra, cliente) en los Estudios de Programación de Largo Plazo y en los Planes de Expansión de Transmisión, en particular para reforzar la macrozona Norte Grande (ponderado por demanda $\Delta\overline{D} = +1{,}30\,\%$), donde se concentra el incremento agregado bajo SSP3-7.0; (ii) diseñar protocolos de respuesta a la demanda diferenciados por estrato de cliente, aprovechando que las distribuidoras ofrecen señal climática limpia y los clientes libres requieren acoplar señales sectoriales; (iii) activar un sistema de alerta temprana que combine la climatología horaria de OdC con las curvas de sensibilidad por SE, permitiendo anticipar episodios de demanda extrema en horizontes de 24–72 h.

8.4. Síntesis final

El cambio climático no presiona al sistema eléctrico chileno de manera uniforme, sino concentrada: en las horas de ola de calor, en las macrozonas más expuestas y en tipos de cliente específicos. Esa concentración es invisible para los modelos nacionales agregados y solo emerge al descender a la granularidad (barra, cliente).

Al cuantificarla —y al entregar las curvas de sensibilidad térmica por subestación, la climatología horaria de extremos y un *pipeline* replicable— los resultados desplazan la pregunta de planificación desde cuánto crecerá la demanda media hacia dónde y cuándo se concentrará el estrés: la pregunta que la resiliencia del sistema eléctrico ante el clima futuro exige responder.

Bibliografía

[1] S. I. Seneviratne, X. Zhang, M. Adnan, W. Badi, C. Dereczynski, A. Di Luca, S. Ghosh, I. Iskandar, J. Kossin, S. Lewis, F. Otto, I. Pinto, M. Satoh, S. M. Vicente-Serrano, M. Wehner, and B. Zhou, "Weather and climate extreme events in a changing climate," in *Climate Change 2021: The Physical Science Basis. Contribution of Working Group I to the Sixth Assessment Report of the Intergovernmental Panel on Climate Change*. Cambridge University Press, 2021, pp. 1513–1766.

[2] S. E. Perkins-Kirkpatrick and P. B. Gibson, "Changes in regional heatwave characteristics as a function of increasing global temperature," *Scientific Reports*, 2017.

[3] C. Martinez-Villalobos, D. Fu, P. C. Loikith, and J. D. Neelin, "Accelerating increase in the duration of heatwaves under global warming," *Nature Geoscience*, vol. 18, pp. 716–723, 2025.

[4] E. M. Fischer and R. Knutti, "Anthropogenic contribution to global occurrence of heavy-precipitation and high-temperature extremes," *Nature Climate Change*, vol. 5, pp. 560–564, 2015.

[5] B. Stone, C. Gronlund, E. Mallen, D. Hondula, M. O'Neill, M. Rajput, S. Grijalva, K. Lanza, S. Harlan, L. Larsen, G. Augenbroe, E. Krayenhoff, A. Broadbent, and M. Georgescu, "How blackouts during heat waves amplify mortality and morbidity risk," *Environmental Science & Technology*, 2023.

[6] M. Panteli and P. Mancarella, "Influence of extreme weather and climate change on the resilience of power systems: Impacts and possible mitigation strategies," *Electric Power Systems Research*, vol. 127, pp. 259–270, 2015.

[7] X. Ke, D. Wu, J. Rice, M. Kintner-Meyer, and N. Lu, "Quantifying impacts of heat waves on power grid operation," *Applied Energy*, 2016.

[8] J. Añel, M. Fernández-González, X. Labandeira, X. López-Otero, and L. de la Torre, "Impact of cold waves and heat waves on the energy production sector," *Atmosphere*, 2017.

[9] C. Marugán-Cruz, M. Fernández-Torrijos, C. Sobrino, and D. Santana, "Assessment of climate change impacts and water restrictions on solar tower plants," *International Journal of Energy Research*, 2023.

[10] B. Wang, Y. Zhou, P. Mancarella, and M. Panteli, "Assessing the impacts of extreme temperatures and water availability on the resilience of the gb power system," *2016 IEEE International Conference on Power System Technology (POWERCON)*, pp. 1–6, 2016.

[11] K. Guddanti, A. Bharati, S. Nekkalapu, J. McWherter, and S. Morris, "A comprehensive review: Impacts of extreme temperatures due to climate change on power grid infrastructure and operation," *IEEE Access*, 2025.

[12] M. Auffhammer, P. Baylis, and C. H. Hausman, "Climate change is projected to have severe impacts on the frequency and intensity of peak electricity demand across the united states," *Proceedings of the National Academy of Sciences*, 2017.

[13] J. Liang, Y. Qiu, B. Wang, X. Shen, and S. Liu, "Impacts of heatwaves on electricity reliability: Evidence from power outage data in china," *iScience*, 2025.

[14] R. Garreaud, C. Alvarez-Garreton, J. Barichivich, J. Boisier, D. Christie, M. Galleguillos, C. LeQuesne, J. McPhee, and M. Zambrano-Bigiarini, "The 2010–2015 megadrought in central chile: impacts on regional hydroclimate and vegetation," *Hydrology and Earth System Sciences*, 2017.

[15] R. Garreaud, J. Boisier, R. Rondanelli, A. Montecinos, H. Sepúlveda, and D. Veloso-Aguila, "The central chile mega drought (2010–2018): A climate dynamics perspective," *International Journal of Climatology*, 2020.

[16] A. Maimó-Far, A. Tantet, V. Homar, and P. Drobinski, "Predictable and unpredictable climate variability impacts on optimal renewable energy mixes: The example of spain," *Energies*, 2020.

[17] F. Rouault, F. Ossio, P. González-Levín, and F. Meza, "Impact of climate change on the energy needs of houses in chile," *Sustainability*, 2019.

[18] C. N. de Energía, "Estadísticas eléctricas," 2023. [Online]. Available: https://www.cne.cl/estadisticas/electricidad/

[19] C. E. Nacional, "Informe técnico: Evento de desconexión del 25 de febrero de 2025," Coordinador Eléctrico Nacional, Tech. Rep., 2025.

[20] Y. Romitti and I. Sue Wing, "Heterogeneous climate change impacts on electricity demand in world cities circa mid-century," *Scientific Reports*, 2022.

[21] M. Peplinski, B. Dilkina, M. Chen, S. Silva, G. Ban-Weiss, and K. Sanders, "A machine learning framework to estimate residential electricity demand based on smart meter electricity, climate, building characteristics, and socioeconomic datasets," *Applied Energy*, 2024.

[22] L. Larrea-Sáez, C. Cuevas, and Y. Casas-Ledón, "Energy and environmental assessment of the chilean social housing: Effect of insulation materials and climates," *Journal of Cleaner Production*, 2023.

[23] F. Encinas, R. Truffello, C. Aguirre-Nuñez, I. Puig, F. Vergara-Perucich, C. Freed, and B. Rodríguez, "Mapping energy poverty: How much impact do socioeconomic, urban and climatic variables have at a territorial scale?" *Land*, 2022.

[24] T. Jiang, E. Krayenhoff, J. Voogt, J. Warland, M. Demuzere, and C. Moede, "Dynamically downscaled projection of urban outdoor thermal stress and indoor space cooling during future extreme heat," *Urban Climate*, 2023.

[25] D. Lafferty, R. Sriver, I. Haqiqi, T. Hertel, K. Keller, and R. Nicholas, "Statistically bias-corrected and downscaled climate models underestimate the adverse effects of extreme heat on u.s. maize yields," *Communications Earth & Environment*, 2021.

[26] C. Chadwick, J. Gironás, F. González-Leiva, and S. Aedo, "Bias adjustment to preserve changes in variability: the unbiased mapping of gcm changes," *Hydrological Sciences Journal*, 2023.

[27] M. Auffhammer, "Climate adaptive response estimation: Short and long run impacts of climate change on residential electricity and natural gas consumption," *Journal of Environmental Economics and Management*, 2022.

[28] Y. Kim, Y. Choi, and S.-K. Min, "Future changes in heat wave characteristics and their impacts on the electricity demand in south korea," *Weather and Climate Extremes*, 2022.

[29] L. Agel, M. Barlow, C. Skinner, F. Colby, and J. Cohen, "Four distinct northeast us heat wave circulation patterns and associated mechanisms, trends, and electric usage," *npj Climate and Atmospheric Science*, 2021.

[30] J. Petit-Laurent, C. Martinez-Villalobos, K. Goubanova, C. Chadwick, and P. Nabat, "The future of atmospheric heatwaves in Chile projected by a regional climate model," *International Journal of Climatology*, 2026, manuscrito en segunda ronda de revisión.

[31] J. Petit-Laurent, C. Martinez-Villalobos, and K. Goubanova, "Substation-level heat-wave vulnerability of the Chilean grid under global warming," in *2026 IEEE International Conference on Environment and Electrical Engineering and 2026 IEEE Industrial and Commercial Power Systems Europe (EEEIC/I&CPS Europe)*, Lisbon, Portugal, 2026.

[32] V. Eyring, S. Bony, G. A. Meehl, C. A. Senior, B. Stevens, R. J. Stouffer, and K. E. Taylor, "Overview of the coupled model intercomparison project phase 6 (cmip6) experimental design and organization," *Geoscientific Model Development*, 2016.

[33] Z. Wang, T. Hong, H. Li, and M. A. Piette, "Predicting city-scale daily electricity consumption using data-driven models," *Advances in Applied Energy*, vol. 2, 2021.

[34] D. Richardson, S. Hobeichi, L.-b. Sweet, E. Rey-Costa, G. Abramowitz, and A. J. Pitman, "Predicting Australian energy demand variability using weather data and machine learning," *Environmental Research Letters*, vol. 20, p. 014028, 2025.

[35] C. Sigauke and M. Nemukula, "Modelling extreme peak electricity demand during a heatwave period: a case study," *Energy Systems*, 2020.

[36] T. Fu, H. Zhou, X. Ma, Z. Hou, and D. Wu, "Predicting peak day and peak hour of electricity demand with ensemble machine learning," *Frontiers in Energy Research*, 2022.

[37] Maraun and Douglas, "Bias correction, quantile mapping, and downscaling: Revisiting the inflation issue," *Journal of Climate*, 2013.

[38] M. N. Agbazo and P. Grenier, "Characterizing and avoiding physical inconsistency generated by the application of univariate quantile mapping on daily minimum and maximum temperatures over hudson bay," *International Journal of Climatology*, vol. 40, pp. 3868–3884, 2020.

[39] D. Barriopedro, R. García-Herrera, C. Ordóñez, D. G. Miralles, and S. Salcedo-Sanz, "Heat waves: Physical understanding and scientific challenges," *Reviews of Geophysics*, 2023.

[40] S. E. Perkins and L. V. Alexander, "On the measurement of heat waves," *Journal of Climate*, vol. 26, pp. 4500–4517, 2013.

[41] S. E. Perkins-Kirkpatrick and S. C. Lewis, "Increasing trends in regional heatwaves," *Nature Communications*, 2020.

[42] L. Hernández, C. Baladrón, J. Aguiar, L. Calavia, B. Carro, A. Sánchez-Esguevillas, D. Cook, D. Chinarro, and J. Gómez, "A study of the relationship between weather variables and electric power demand inside a smart grid/smart world framework," *Sensors*, 2012.

[43] Y. Li, W. Pizer, and L. Wu, "Climate change and residential electricity consumption in the yangtze river delta, china," *Proceedings of the National Academy of Sciences*, 2019.

[44] S. Zhang, Q. Guo, R. Smyth, and Y. Yao, "Extreme temperatures and residential electricity consumption: Evidence from chinese households," *Energy Economics*, vol. 107, p. 105890, 2022.

[45] S. Mukherjee and R. Nateghi, "Climate sensitivity of end-use electricity consumption in the built environment: An application to the state of florida, united states," *Energy*, 2017.

[46] F. Beltrán, L. Durand, M. González-Frugone, and J. Moreno, "A preliminary assessment of the economic effects of energy and climate in chile," *Latin American Journal of Central Banking*, 2025.

[47] N. Liao, Z. Hu, and D. Magami, "A metaheuristic approach to model the effect of temperature on urban electricity need utilizing xgboost and modified boxing match algorithm," *AIP Advances*, 2024.

[48] Z. Wang, Y. Wang, and R. S. Srinivasan, "A novel ensemble learning approach to support building energy use prediction," *Energy and Buildings*, vol. 159, pp. 109–122, 2018.

[49] J. Chung and B. Jang, "Accurate prediction of electricity consumption using a hybrid cnn-lstm model based on multivariable data," *PLOS ONE*, 2022.

[50] S. Zheng, G. Huang, X. Zhou, and X. Zhu, "Climate-change impacts on electricity demands at a metropolitan scale: A case study of guangzhou, china," *Applied Energy*, 2020.

[51] T. Hastie and R. Tibshirani, *Generalized Additive Models*. Chapman and Hall/CRC, 1990.

[52] S. N. Wood, "Fast stable direct fitting and smoothness selection for generalized additive models," *Journal of the Royal Statistical Society Series B: Statistical Methodology*, vol. 70, pp. 495–518, 2008.

[53] T. Matsumoto and Y. Yamada, "Comprehensive and comparative analysis of gam-based pv power forecasting models using multidimensional tensor product splines against machine learning techniques," *Energies*, 2021.

[54] M. H. Chacha, J. Ouno, B. Kwach, and C. Nyakundi, "Modelling spatial and non-linear trends in climate data using gaussian process regression and generalized additive model," *Asian Journal of Probability and Statistics*, 2025.

[55] N. Pya and S. N. Wood, "A note on basis dimension selection in generalized additive modelling," *arXiv preprint (arXiv:1602.06696)*, 2016.

[56] U. Amato, A. Antoniadis, I. De Feis, Y. Goude, and A. Lagache, "Forecasting high resolution electricity demand data with additive models including smooth and jagged components," *International Journal of Forecasting*, 2021.

[57] M. Zimmermann and F. Ziel, "Efficient mid-term forecasting of hourly electricity load using generalized additive models," *Preprint / Working Paper (University of Duisburg-Essen)*, 2024.

[58] S. Krstonijević, "Adaptive load forecasting methodology based on generalized additive model with automatic variable selection," *Sensors*, 2022.

[59] M. Fasiolo, R. Nedellec, Y. Goude, and S. N. Wood, "Scalable visualisation methods for modern generalized additive models," *Journal of Computational and Graphical Statistics*, vol. 29, pp. 78–86, 2020.

[60] Walker, S.-E. Solberg, S. Schneider, P. Guerreiro, and Cristina, "The airgam 2022r1 air quality trend and prediction model," *Geoscientific Model Development*, 2023.

[61] G. L. Simpson, "Modelling palaeoecological time series using generalised additive models," *Frontiers in Ecology and Evolution*, vol. 6, pp. 1–21, 2018. [Online]. Available: https://www.frontiersin.org/articles/10.3389/fevo.2018.00149

[62] K. Verichev, M. Zamorano, and M. Carpio, "Effects of climate change on variations in climatic zones and heating energy consumption of residential buildings in the southern chile," *Energy & Buildings*, 2020.

[63] P. Nabat, S. Somot, C. Cassou, M. Mallet, M. Michou, D. Bouniol, B. Decharme, T. Drugé, R. Roehrig, and D. Saint-Martin, "Modulation of radiative aerosols effects by atmospheric circulation over the euro-mediterranean region," *Atmospheric Chemistry and Physics*, vol. 20, pp. 8315–8349, 2020.

[64] L. Torrez-Rodriguez, K. Goubanova, C. Muñoz, and A. Montecinos, "Evaluation of temperature and precipitation from cordex-core south america and etarcm regional climate simulations over the complex terrain of subtropical chile," *Climate Dynamics*, 2023.

[65] A. Voldoire, D. Saint-Martin, S. Sénési, B. Decharme, A. Alias, M. Chevallier, J. Colin, J. Guérémy, M. Michou, M. Moine, P. Nabat, R. Roehrig, D. Salas y Mélia, R. Séférian, S. Valcke, I. Beau, S. Belamari, S. Berthet, C. Cassou, J. Cattiaux, J. Deshayes, H. Douville, C. Ethé, L. Franchistéguy, O. Geoffroy, C. Lévy, G. Madec, Y. Meurdesoif, R. Msadek, A. Ribes, E. Sanchez-Gomez, L. Terray, and R. Waldman, "Evaluation of cmip6 deck experiments with cnrm-cm6-1," *Journal of Advances in Modeling Earth Systems*, vol. 11, pp. 2177–2213, 2019.

[66] B. O'Neill, C. Tebaldi, D. van Vuuren, V. Eyring, P. Friedlingstein, G. Hurtt, R. Knutti, E. Kriegler, J. Lamarque, J. Lowe, G. Meehl, R. Moss, K. Riahi, and B. Sanderson, "The scenario model intercomparison project (scenariomip) for cmip6," *Geoscientific Model Development*, 2016.

[67] J. P. Boisier, C. Alvarez-Garreton, R. R. Cordero, A. Damiani, L. Gallardo, R. D. Garreaud, F. Lambert, C. Ramallo, M. Rojas, and R. Rondanelli, "Anthropogenic drying in central-southern chile evidenced by long-term observations and climate model simulations," *Elementa: Science of the Anthropocene*, vol. 6, 2018.

[68] J. Muñoz-Sabater, E. Dutra, A. Agustí-Panareda, C. Albergel, G. Arduini, G. Balsamo, S. Boussetta, M. Choulga, S. Harrigan, H. Hersbach, B. Martens, D. G. Miralles, M. Piles, N. J. Rodríguez-Fernández, E. Zsoter, C. Buontempo, and J.-N. Thépaut, "Era5-land: a state-of-the-art global reanalysis dataset for land applications," *Earth System Science Data*, vol. 13, pp. 4349–4383, 2021.

[69] O. A. Alduchov and R. E. Eskridge, "Improved magnus form approximation of saturation vapor pressure," *Journal of Applied Meteorology*, 1996.

[70] A. N. Pettitt, "A non-parametric approach to the change-point problem," *Applied Statistics*, vol. 28, p. 126, 1979.

[71] S. N. Wood, *Generalized Additive Models*. Chapman and Hall/CRC, 2017.

[72] S. N. Wood, Z. Li, G. Shaddick, and N. H. Augustin, "Generalized additive models for gigadata: Modeling the u.k. black smoke network daily data," *Journal of the American Statistical Association*, vol. 112, pp. 1199–1210, 2017.

[73] S. N. Wood, *Generalized Additive Models: An Introduction with R*, 1st ed. Boca Raton: Chapman and Hall/CRC, 2006.

[74] J. Lai, J. Tang, T. Li, A. Zhang, and L. Mao, "Evaluating the relative importance of predictors in generalized additive models using the gam.hp r package," *Plant Diversity*, 2024.

[75] A. Piticar, "Changes in heat waves in chile," *Global and Planetary Change*, 2018.

[76] Á. González-Reyes, M. Jacques-Coper, C. Bravo, M. Rojas, and R. Garreaud, "Evolution of heatwaves in chile since 1980," *Weather and Climate Extremes*, 2023.

[77] D. L. Villa, "Institutional heat wave analysis by building energy modeling fleet and meter data," *Energy & Buildings*, 2021.

[78] K. Chreng, H. Lee, and S. Tuy, "A hybrid model for electricity demand forecast using improved ensemble empirical mode decomposition and recurrent neural networks with era5 climate variables," *Energies*, 2022.

[79] M. Pinheiro, S. Madeira, and A. Francisco, "Short-term electricity load forecasting—a systematic approach from system level to secondary substations," *Applied Energy*, 2023.

[80] O. Meseguer-Ruiz, O. Corvacho, A. Tapia Tosetti, J. López-Cepeda, and P. Sarricolea, "Analysis of the trends in observed extreme temperatures in mainland chile between 1966 and 2015 using different indices," *Pure and Applied Geophysics*, 2019.

[81] P. Kumari, V. Garg, R. Kumar, and K. Kumar, "Impact of urban heat island formation on energy consumption in delhi," *Urban Climate*, 2021.

[82] D. Ruppert, M. P. Wand, and R. J. Carroll, *Semiparametric Regression*, ser. Cambridge Series in Statistical and Probabilistic Mathematics. Cambridge University Press, 2003.

[83] J. Muñoz-Sabater, E. Dutra, A. Agustí-Panareda, C. Albergel, G. Arduini, G. Balsamo, S. Boussetta, M. Choulga, S. Harrigan, H. Hersbach, B. Martens, D. Miralles, M. Piles, N. Rodríguez-Fernández, E. Zsoter, C. Buontempo, and J.-N.

Thépaut, "ERA5-Land: A state-of-the-art global reanalysis dataset for land applications," *Earth System Science Data*, vol. 13, pp. 4349–4383, 2021.

[84] K. E. Taylor, "Summarizing multiple aspects of model performance in a single diagram," *Journal of Geophysical Research: Atmospheres*, vol. 106, no. D7, pp. 7183–7192, 2001.

[85] J. Christensen, F. Boberg, O. Christensen, and P. Lucas-Picher, "On the need for bias correction of regional climate change projections of temperature and precipitation," in *Geophysical Research Letters*, 2008, vol. 35, p. L20709.

[86] S. Kotlarski, K. Keuler, O. Christensen, A. Colette, M. Déqué, A. Gobiet, K. Goergen, D. Jacob, D. Lüthi, E. van Meijgaard, G. Nikulin, C. Schär, C. Teichmann, R. Vautard, K. Warrach-Sagi, and V. Wulfmeyer, "Regional climate modeling on European scales: A joint standard evaluation of the EURO-CORDEX RCM ensemble," *Geoscientific Model Development*, vol. 7, pp. 1297–1333, 2014.

[87] S. Pryor, R. Barthelmie, M. Bukovsky, L. Leung, and K. Sakaguchi, "Climate change impacts on wind power generation," *Nature Reviews Earth & Environment*, vol. 1, pp. 627–643, 2020.

[88] S. Herrera, R. Cardoso, P. Soares, F. Espírito-Santo, P. Viterbo, and J. Gutiérrez, "Iberia01: A new gridded dataset of daily precipitation and temperatures over Iberia," *Earth System Science Data*, vol. 12, pp. 441–455, 2020.

[89] D. J. Sailor and J. R. Muñoz, "Sensitivity of electricity and natural gas consumption to climate in the U.S.A.—Methodology and results for eight states," *Energy*, vol. 26, pp. 65–83, 2001.

[90] E. Valor, V. Meneu, and V. Caselles, "Daily air temperature and electricity load in Spain," *Journal of Applied Meteorology*, vol. 40, pp. 1413–1421, 2001.

Apéndice A

Metodología Detallada de Corrección de Sesgo Climático

La evaluación robusta de los impactos del cambio climático sobre la demanda eléctrica a nivel granular requiere forzantes meteorológicas libres de sesgos sistemáticos, pero que a su vez conserven fielmente la señal del cambio climático y la consistencia termodinámica. Este apéndice detalla el *pipeline* metodológico implementado para corregir las salidas del modelo regional CNRM-ALADIN64 sobre el dominio CORDEX-CHP12 (resolución de 0,11°).

A.1. Datos Observacionales de Referencia

La corrección de sesgo requiere la definición de un *ground truth* observacional para el periodo histórico (1979-2014), la existencia y uso de estos datos en Chile es limitada; sin embargo, existen productos grillados de sesgo reducido que pueden aproximar este propósito de forma aceptable. Se utilizaron dos fuentes principales, interpoladas mediante un esquema bilineal hacia la grilla curvilínea del modelo ALADIN:

- **CR2MET v2.5:** Producto grillado de referencia en Chile continental (0,05° de resolución) elaborado a partir de observaciones de estaciones meteorológicas [67]. Se utilizó como *target* para las temperaturas máximas ($tmax$), mínimas ($tmin$) diarias y precipitaciones (pr).
- **ERA5-Land:** Reanálisis global provisto por ECMWF (0,1° de resolución) [68]. Dado que CR2MET no provee datos horarios de viento, humedad ni radiación, se extrajeron las componentes horarias del viento (u_{10} y v_{10}) para derivar el viento superficial ($sfcWind = \sqrt{u_{10}^2 + v_{10}^2}$), así como el punto de rocío a 2 metros ($d2m$) y Radiación solar de onda corta ($ssrd$) .

A.2. Fundamentos del Unbiased Quantile Mapping (UQM) con Ventana Móvil

El núcleo estadístico del proceso recae en el método *Unbiased Quantile Mapping* (UQM) implementado en la librería `climQMBC v1.1` [26]. A diferencia del mapeo clásico, UQM aísla la señal climática (la tendencia proyectada a futuro) para corregir únicamente el componente de la variabilidad, recomponiendo posteriormente la serie para mantener inalterada la tasa de calentamiento simulada por el GCM/RCM.

Para sortear las limitaciones de tamaño muestral inherentes a tener solo 36 datos históricos para un día específico del año (e.g., todos los 15 de enero entre 1979 y 2014), el UQM se implementó acoplado a un algoritmo de **ventana móvil de 11 días**. Bajo este enfoque, para corregir el día central d, se extraen los valores simulados y observados en el rango $[d-5, d+5]$ a lo largo de todos los años disponibles. Esto incrementa de forma efectiva la muestra estadística por un factor de 11, robusteciendo la función de distribución acumulada empírica y suavizando la transición interdiaria de los cuantiles de corrección. Esta técnica aumenta significativamente el costo computacional de la operación, ya costosa de base, por lo que solo se aplicó a las variables corregidas con CR2met, temperaturas máximas ($tmax$), mínimas ($tmin$) diarias y precipitaciones (pr), las cuales son centrales en el estudio.

A.3. Implementación Específica y Consistencia Física por Variable

Un desafío común en la climatología de impactos es que la corrección aislada de múltiples variables frecuentemente rompe la termodinámica del modelo original (ej. provocando humedades relativas mayores al 100 % o T_{min} superando a T_{max}). Para evitar esto, se diseñó un esquema de corrección en cascada.

A.3.1. Temperaturas Extremas y Diarias ($tmax$, $tmin$ y tas) y precipitación (pr)

La temperatura máxima ($tmax$) fue corregida de manera directa aplicando el método UQM aditivo (distribución normal subyacente) sobre los datos de CR2MET. Sin embargo, para la temperatura mínima ($tmin$), la aplicación directa de UQM generó inconsistencias donde $tmin > tmax$ en un 1,65 % de los casos. Para resolver esto, se corrigió el **Rango Térmico Diurno** ($DTR = tmax - tmin$). Se calculó el DTR para observaciones y modelo, se aplicó UQM aditivo y se restringió físicamente a valores positivos ($DTR_{corr} = \max(DTR_{corr}, 0{,}0)$). Finalmente, $tmin$ fue derivada deductivamente:

$$tmin_{corr} = tmax_{corr} - DTR_{corr} \tag{A.1}$$

Para la temperatura horaria (tas), en lugar de alterar los valores individualmente (dada la disponibilidad de CR2met, la fuente de menor sesgo), se optó por un **reescalamiento lineal** del ciclo diurno, garantizando la preservación de las dinámicas físicas intra-diarias simuladas por ALADIN. El ciclo crudo de temperatura se ajustó para que sus extremos coincidieran exactamente con $tmax_{corr}$ y $tmin_{corr}$. Para la precipitación (pr), los valores diarios corregidos mediante UQM fueron desagregados a resolución horaria mediante escalamiento algebraico (Algebraic Scaling). Este procedimiento utiliza el perfil temporal (shape profile) de la precipitación horaria original simulada por ALADIN, escalando algebraicamente su magnitud para que la suma intradiaria coincida exactamente con el valor diario corregido, obteniendo así una serie temporal consistente de precipitación horaria.

A.3.2. Viento Superficial ($sfcWind$)

A diferencia de la temperatura, la magnitud del viento superficial es una variable estrictamente no negativa. Por consiguiente, el método UQM se aplicó en **modo multiplicativo** asumiendo una distribución Weibull de fondo, definiendo un factor de

escala para evitar inestabilidades en valores cercanos a cero. Posteriormente, los valores resultantes fueron limitados a un límite inferior absoluto de 0 m/s.

A.3.3. Punto de Rocío (Td)

Para derivar la humedad relativa futura sin incurrir en violaciones físicas, se utilizó el punto de rocío (Td). El Td de ALADIN fue calculado mediante la aproximación de August-Roche-Magnus a partir de la temperatura superficial (tas) y la humedad específica (huss) horarias crudas. Finalmente, se corrige el punto de rocío (vía UQM frente a ERA5-Land, de forma similar a la corrección de las temperaturas máximas).

A.3.4. Radiación solar (*rsds*)

La radiación solar de onda corta descendente (*rsds*) fue sometida a corrección de sesgo utilizando el método de mapeo de cuantiles (Quantile Mapping). Para esto, se utilizaron como referencia observacional los datos horarios extraídos del reanálisis ERA5. La corrección se aplicó directamente sobre la función de distribución acumulada (RAW CDF) de las series horarias, asegurando que las proyecciones futuras de radiación mantengan consistencia física con los perfiles históricos observados en la región.

A.4. Validación del Desempeño

La validación se realizó evaluando el Error Cuadrático Medio (RMSE), el Error Absoluto Medio (MAE) y la reducción de sesgo sobre el período histórico completo (1979–2014). Para *tas* horaria, la corrección UQM redujo el RMSE del ciclo climatológico mensual (promediado espacialmente) de 2,55 °C (modelo crudo) a 0,005 °C (corregido), una reducción del 99,7 %. El sesgo hora×mes residual máximo tras la corrección es inferior a 0,06 °C. Se verificó adicionalmente que la corrección elimina la totalidad de violaciones termodinámicas ($tmin > tmax$) presentes en el modelo crudo (1,65 % de los días). Estas métricas son, por construcción, dentro de la muestra de calibración. La validación fuera de muestra bajo no estacionariedad —división por estado climático, validación cruzada dejando una década fuera, sesgo por rangos percentílicos hasta P99,9 y diagramas cuantil-cuantil— se reporta para este mismo modelo regional en el material suplementario de [30], con una reducción del sesgo de cola de entre tres y siete veces.

La Tabla A.1 resume las métricas de validación para las cinco variables corregidas bajo la métrica apropiada para evaluar una corrección de cuantiles: el *sesgo medio* del modelo respecto a ERA5-Land, promediado sobre las 24 horas del día y el dominio ALADIN (período 1979–2014). Esta es la misma métrica de sesgo que la Sección 6.1 ilustra fijando la hora a las 12:00 UTC, pero evaluada aquí sobre todas las horas del día. No se reporta el RMSE punto-a-punto de la serie horaria porque ALADIN es un modelo forzado por un GCM en modo libre: su evolución hora a hora no está sincronizada con el reanálisis ERA5-Land, de modo que dicho RMSE mediría la decorrelación caótica entre ambas secuencias y no el sesgo sistemático que UQM efectivamente corrige (el mapeo de cuantiles ajusta la distribución marginal, no la secuencia temporal). Bajo la métrica de sesgo, la corrección UQM reduce el sesgo medio absoluto de la temperatura del aire (*tas*) de 2,77 °C a 0,003 °C (reducción del 99,9 %) y el del punto de rocío (T_d) de 1,66 °C a 0,004 °C (99,8 %), un colapso esencialmente total propio de las variables aditivas en el período de calibración. El viento superficial

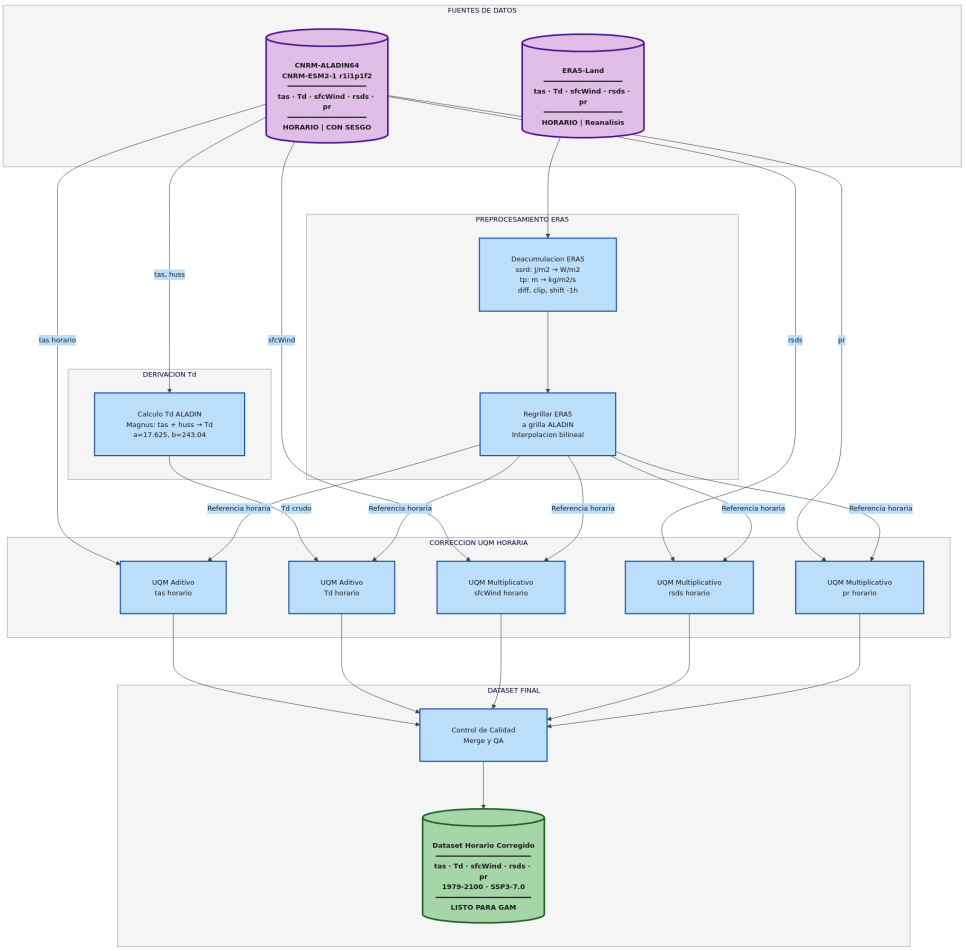

FIGURA A.1: Arquitectura de la corrección de sesgo de las forzantes climáticas contra ERA5-Land. A partir del modelo regional CNRM-ALADIN64 crudo y del reanálisis ERA5-Land, se preprocesa ERA5 (deacumulación de las variables acumuladas y regrillado bilineal a la grilla ALADIN) y se deriva el punto de rocío de ALADIN (aproximación de Magnus a partir de *tas* y la humedad específica). Las cinco variables horarias (*tas*, *Td*, *sfcWind*, *rsds*, *pr*) se corrigen por *Unbiased Quantile Mapping* (aditivo para *tas* y *Td*, multiplicativo para *sfcWind*, *rsds* y *pr*) contra ERA5-Land y, tras un control de calidad, conforman el dataset horario corregido (1979–2100, SSP3-7.0).

(*sfcWind*) se reduce de 0,71 a 0,26 $\mathrm{m\,s^{-1}}$ (63,2 %) y la radiación solar (*rsds*) de 15,4 a 0,82 $\mathrm{W\,m^{-2}}$ (94,7 %). La precipitación pasa de $3{,}1 \times 10^{-5}$ a $2{,}7 \times 10^{-6}$ $\mathrm{kg\,m^{-2}\,s^{-1}}$ (91,3 %). Los menores porcentajes de reducción del viento y la precipitación reflejan la naturaleza multiplicativa de su ajuste y, en el caso del viento, un sesgo espacial sistemático residual (negativo en la zona sur).

CUADRO A.1: Sesgo medio de la corrección UQM respecto a ERA5-Land, promediado sobre todas las horas del día y el dominio ALADIN (1979–2014). Se reporta el sesgo medio absoluto (crudo y corregido) y el sesgo firmado del modelo crudo. La Sección 6.1 ilustra esta misma métrica fijando la hora a las 12:00 UTC.

Variable	Unidad	$\lvert\overline{b}\rvert_{\text{crudo}}$	$\lvert\overline{b}\rvert_{\text{corr}}$	$\overline{b}_{\text{crudo}}$	Reducción
T (tas)	°C	2,767	0,003	-2,290	99,9 %
T_d	°C	1,662	0,004	-0,236	99,8 %
U_{10} (sfcWind)	$\mathrm{m\,s^{-1}}$	0,71	0,26	0,43	63,2 %
Rsds	$\mathrm{W\,m^{-2}}$	15,42	0,82	-8,84	94,7 %
Pr	$\mathrm{kg\,m^{-2}\,s^{-1}}$	$3{,}1 \times 10^{-5}$	$2{,}7 \times 10^{-6}$	$3{,}0 \times 10^{-5}$	91,3 %

La Tabla A.2 consolida las métricas de validación de la corrección de sesgo. Para las variables cuya validación aún no ha sido reejecutada, las celdas se muestran como "–".

CUADRO A.2: Métricas de validación de la corrección de sesgo (UQM) respecto a ERA5-Land para cada variable climática. Se reportan RMSE y MAE del modelo crudo (ALADIN) y del producto corregido, más el sesgo residual del producto corregido. Período histórico 1979–2014, escenario *historical*; métricas del ciclo climatológico promediadas espacialmente sobre la grilla ALADIN. Cuando un valor no está disponible se muestra "–".

Variable	Unidad	RMSE		MAE		Sesgo corr.
		Crudo	Corr.	Crudo	Corr.	
T_{as} (temperatura superficial)	°C	2,555	0,005	2,369	0,004	0,000
T_d (punto de rocío)	°C	–	–	–	–	–
u_{10} (viento superficial)	$\mathrm{m\,s^{-1}}$	–	–	–	–	–
RSDS (radiación solar)	$\mathrm{W\,m^{-2}}$	–	–	–	–	–
PR (precipitación)	$\mathrm{kg\,m^{-2}\,s^{-1}}$	–	–	–	–	–

Las Figuras A.2–A.5 ilustran la calidad de la corrección a través de cuatro diagnósticos complementarios.

A.5. Caveats y Consideraciones Metodológicas

Aunque la validación cuantitativa de la sección anterior confirma que la corrección UQM alcanza errores residuales compatibles con los requerimientos del estudio, el proceso hereda dos particularidades técnicas que se documentan a continuación en aras de la reproducibilidad. Ninguna de ellas afecta los resultados reportados en los capítulos de resultados y discusión.

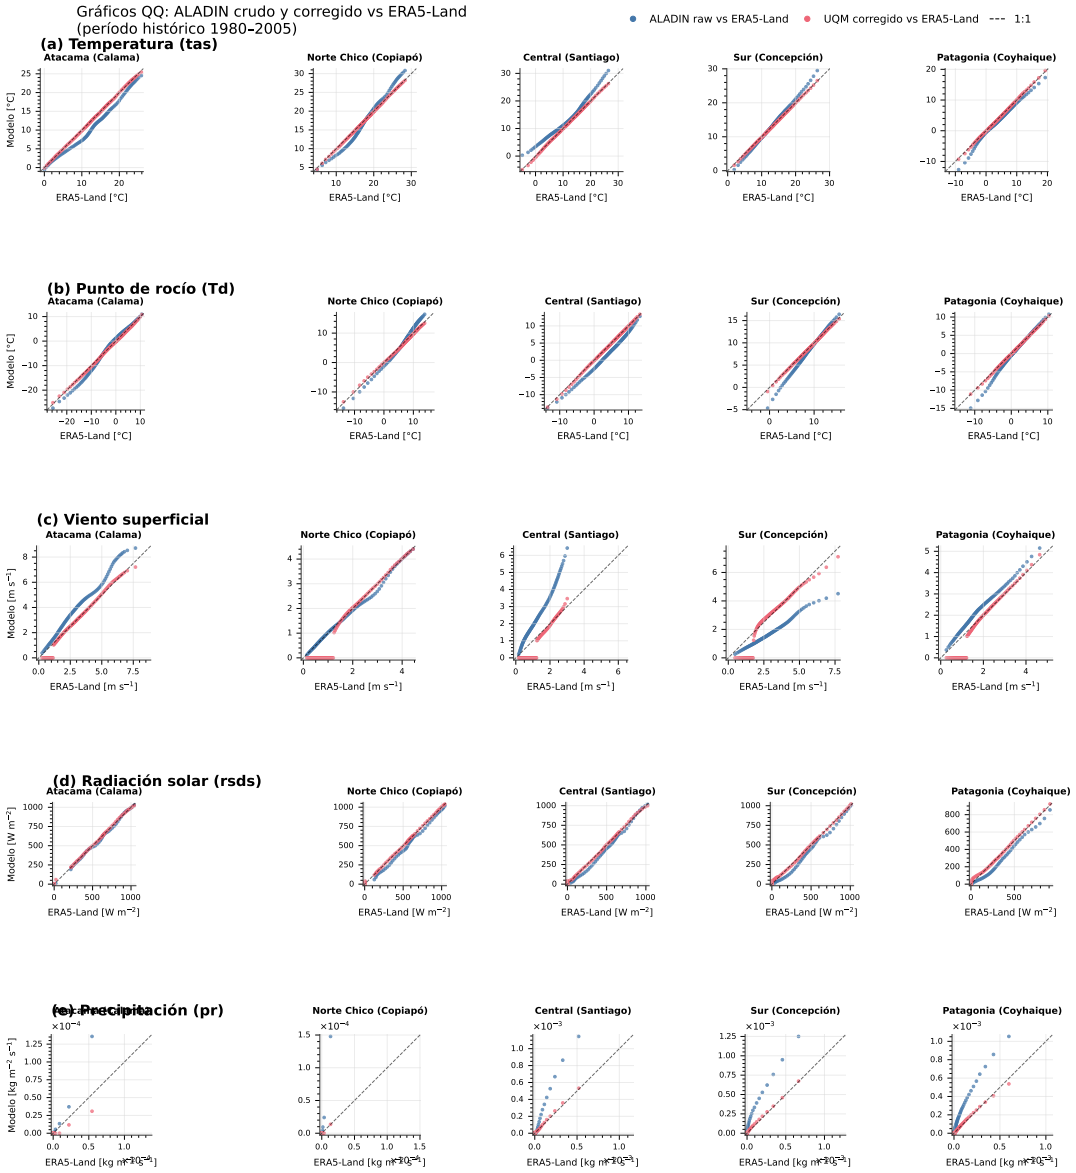

FIGURA A.2: Gráficos cuantil-cuantil (QQ) para las cinco variables corregidas: temperatura del aire (*tas*), punto de rocío (*Td*), viento superficial (*sfcWind*), radiación solar (*rsds*) y precipitación (*pr*). Azul: ALADIN crudo vs ERA5-Land; rojo: ALADIN corregido (UQM) vs ERA5-Land. La alineación casi perfecta de los puntos rojos con la diagonal 1:1 confirma la corrección distribucional completa.

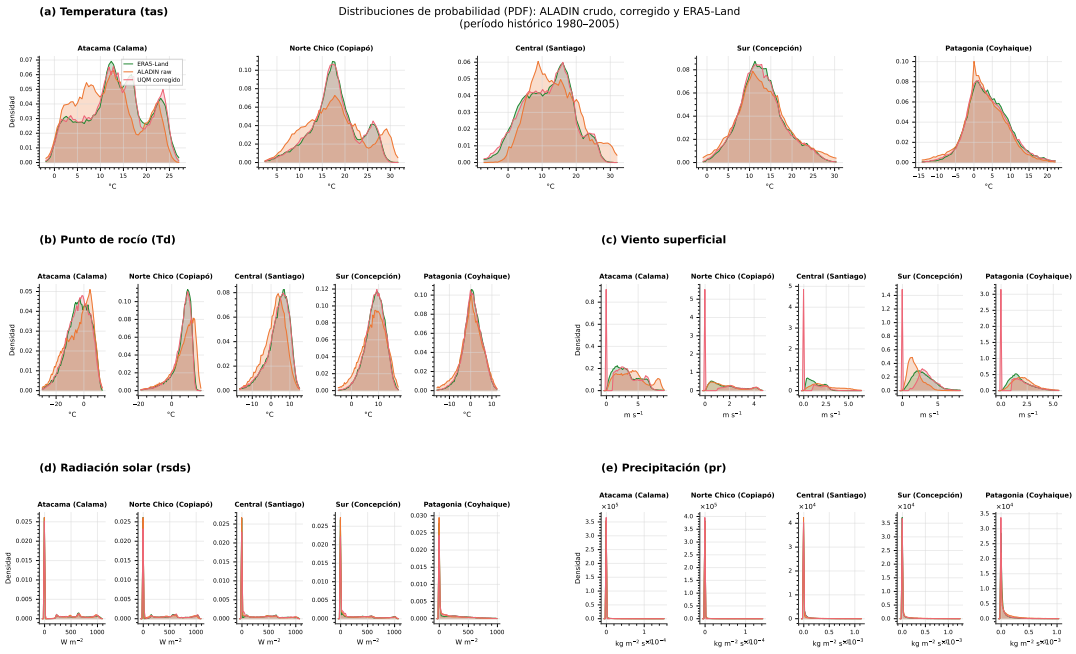

FIGURA A.3: Funciones de densidad de probabilidad (PDF) de las cinco variables. Rojo: ALADIN crudo; verde: ALADIN corregido (UQM); gris: ERA5-Land (referencia). La corrección elimina el desplazamiento sistemático y la deformación de las colas observados en el modelo crudo.

A.5.1. Artefactos de cola en variables multiplicativas (*pr*, *rsds*)

El método UQM en modo multiplicativo asume una distribución de referencia no negativa. En los cuantiles extremos superiores, donde la referencia observacional contiene pocos datos y la varianza muestral es alta, el mapeo puede amplificar valores del modelo crudo hacia magnitudes físicamente inverosímiles. En nuestros productos este efecto se manifiesta como:

- **Precipitación (*pr*)**: valor máximo $\approx 4{,}93 \times 10^{6}\,\mathrm{kg\,m^{-2}\,s^{-1}}$ en píxeles aislados ($< 0{,}01\,\%$ del total de horas $\times$ píxeles). La mediana y el percentil 99,9 se mantienen físicamente consistentes.
- **Radiación solar (*rsds*)**: valor máximo $\approx 2{,}4 \times 10^{3}\,\mathrm{W\,m^{-2}}$, superando la constante solar ($\sim 1361\,\mathrm{W\,m^{-2}}$) en instantes puntuales. El percentil 99 se mantiene por debajo de $1200\,\mathrm{W\,m^{-2}}$.

Mitigación aplicada: el modelado posterior aplica *clipping* a límites físicos ($pr \leq 200\,\mathrm{mm\,h^{-1}}$; $sfcWind \leq 40\,\mathrm{m\,s^{-1}}$) antes de ingresar a los modelos GAM. El producto final se mantiene sin recortar para preservar la distribución cruda del UQM y permitir diagnósticos alternativos por otros usuarios.

A.5.2. *Clamping* interno en la derivación de T_d

La conversión `hurs+tas` $\rightarrow T_d$ vía la aproximación de August-Roche-Magnus requiere el logaritmo de la humedad relativa. Durante la implementación se aplicó un *clamping* a $[0{,}1, 100]\,\%$ sobre `hurs` para evitar evaluaciones de $\log(0)$ en píxeles con valores crudos fuera de rango (fracción marginal $< 0{,}01\,\%$ de píxel$\times$hora).

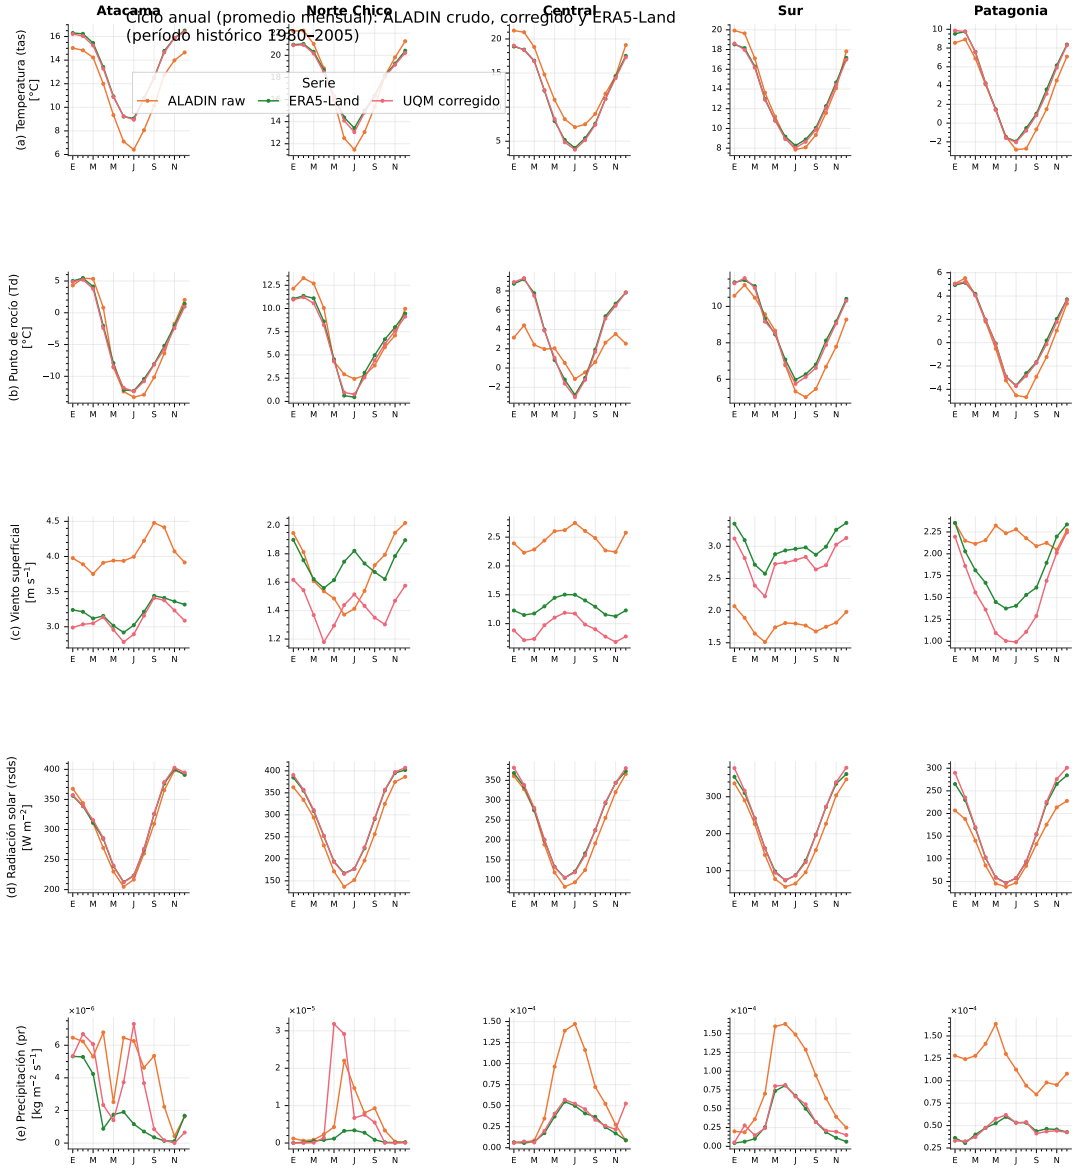

FIGURA A.4: Ciclo anual de la media mensual para las cinco variables, en cinco píxeles representativos (Atacama, Norte Chico, Central, Sur y Patagonia). Naranja: ALADIN crudo; coral: ALADIN corregido (UQM); verde: ERA5-Land. La corrección alinea el ciclo estacional del modelo con la referencia observacional en todas las variables.

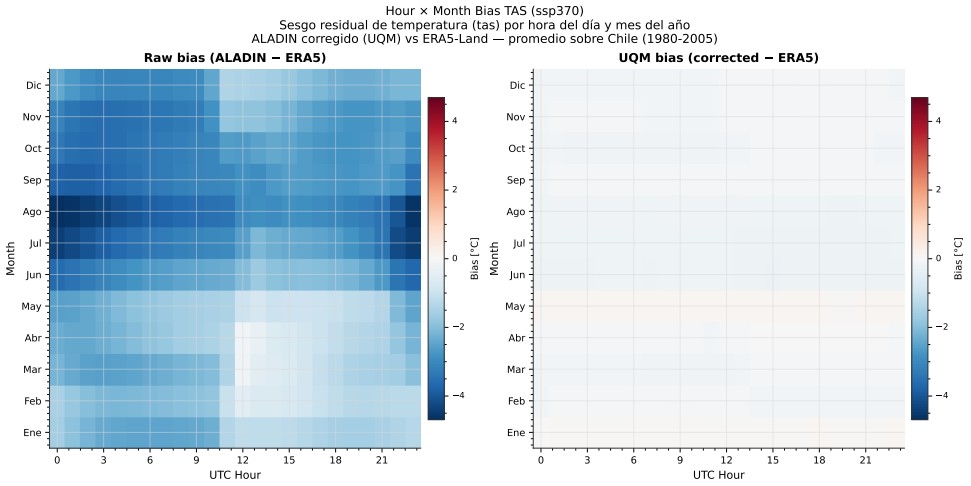

FIGURA A.5: Sesgo residual de temperatura (*tas*) como función de la hora UTC (eje X) y del mes del año (eje Y), promediado espacialmente. Izquierda: ALADIN crudo (−ERA5); derecha: ALADIN corregido (−ERA5). El sesgo frío sistemático del modelo crudo (∼2–3 °C en verano nocturno) queda reducido a menos de 0,1 °C tras la corrección UQM.

Alcance: este recorte es interno al paso intermedio de cómputo de T_d crudo; la humedad relativa *no* es un producto entregado en el conjunto final (el GAM consume T_d corregido directamente). Por construcción, el *clamping* antecede a la corrección de sesgo y no modifica la distribución final de T_d corregido, que se valida frente a ERA5-Land.

Apéndice B

Detalle del Pipeline de Datos de Demanda Eléctrica

Este apéndice documenta el pipeline completo de adquisición, limpieza y evaluación de calidad de los datos de demanda eléctrica horaria utilizados en esta tesis. El insumo final es el censo per-(barra, cliente): 2.567 series candidatas —2.548 con datos— distribuidas en 399 subestaciones (SEs), cada una sobre una rejilla horaria de 73.008 horas (enero 2017 – abril 2025).

B.1. Fuente de datos

Los datos de demanda eléctrica provienen de la API SIPCO del Coordinador Eléctrico Nacional (CEN), organismo que coordina la operación del Sistema Eléctrico Nacional (SEN) de Chile. Específicamente, se descargaron los *retiros horarios* —registros de extracción de energía eléctrica en cada barra del sistema de transmisión— mediante consultas a la API pública del CEN. Cada solicitud obtiene los retiros de **una barra** durante **un año calendario**. Los datos se reciben en formato TSV (valores separados por tabulación) con separador decimal de coma (convención chilena).

Las características principales del *dataset* descargado son:

- **Resolución temporal**: horaria (hora 1–24, con hora 25 en días de cambio horario).
- **Período**: enero 2017 – abril 2025 (9 años).
- **Unidad**: retiro ajustado en MWh por intervalo horario.
- **Granularidad**: cada fila representa el retiro de *un cliente* en una barra específica. Para obtener la demanda total de una barra, se suman todos los clientes por tupla (barra, fecha, hora).
- **Valores negativos**: representan inyección neta a la red (p. ej., generación solar distribuida que excede el consumo local) y se mantienen como observaciones válidas.
- **Descarga**: con un esquema de descarga robusto ante interrupciones.

B.2. Nomenclatura de barras

Las barras del SEN siguen un sistema de nomenclatura mnemotécnica administrado por el CEN. El formato general es:

`BA{N}{CC}{ID}SE{NN}{CC}{ID}`

donde:

- `BA` identifica la barra; `SE` identifica la subestación.
- `N/NN`: número secuencial dentro del nodo.
- `CC`: código de compañía propietaria (*no* zona geográfica):
  - `G` = AES Andes S.A.
  - `L` = EFE (Empresa de Ferrocarriles del Estado)
  - `R` = COPELEC (Cooperativa Chillán)
  - `T` = Transelec, STS y otras empresas de transmisión
  - `A` = Arauco (sector forestal)
- `ID`: identificador numérico de la instalación.

El registro *Infotécnica* del CEN contiene 3.676 barras en el SEN. A partir del *dataset* de referencia publicado por Stewart y Wild (2018) en *Nature Scientific Data* (DOI: 10.1038/sdata.2018.209) y de un escaneo sistemático del API de *Infotécnica*, se seleccionaron las barras con retiros significativos y se agruparon por subestación mediante el diccionario de correspondencia barra→SE (múltiples barras de distinto voltaje o sección pueden pertenecer a la misma subestación física). Tras la evaluación de calidad descrita en la Sección B.4, el producto final agrupa **399 SEs**.

B.3. Pipeline de limpieza

La Figura B.1 presenta el diagrama de flujo completo del pipeline, que se organiza en siete etapas secuenciales agrupadas en tres fases: descarga/agregación, limpieza, y evaluación/exportación.

B.3.1. Etapa 1: Descarga desde API CEN

Los retiros horarios se descargan en lotes de una barra por año desde la API del CEN, con autenticación por clave pública del coordinador. La descarga se gestiona con un esquema robusto ante interrupciones.

B.3.2. Etapa 2: Agregación por barra

Cada archivo crudo contiene una fila por retiro de cliente individual. Los archivos se concatenan y se agrega `retiro_ajustado` por tupla (barra, fecha, hora), produciendo la demanda total por barra.

B.3.3. Etapa 3: Mapeo barra → subestación

El diccionario de correspondencia barra→SE agrupa las barras en subestaciones, sumando la demanda de todas las barras pertenecientes a cada SE. El resultado se pivota a formato *wide* (filas = timestamps horarios, columnas = nombres de SE). Las horas se convierten del sistema CEN (hora 1–24/25) a `datetime` estándar.

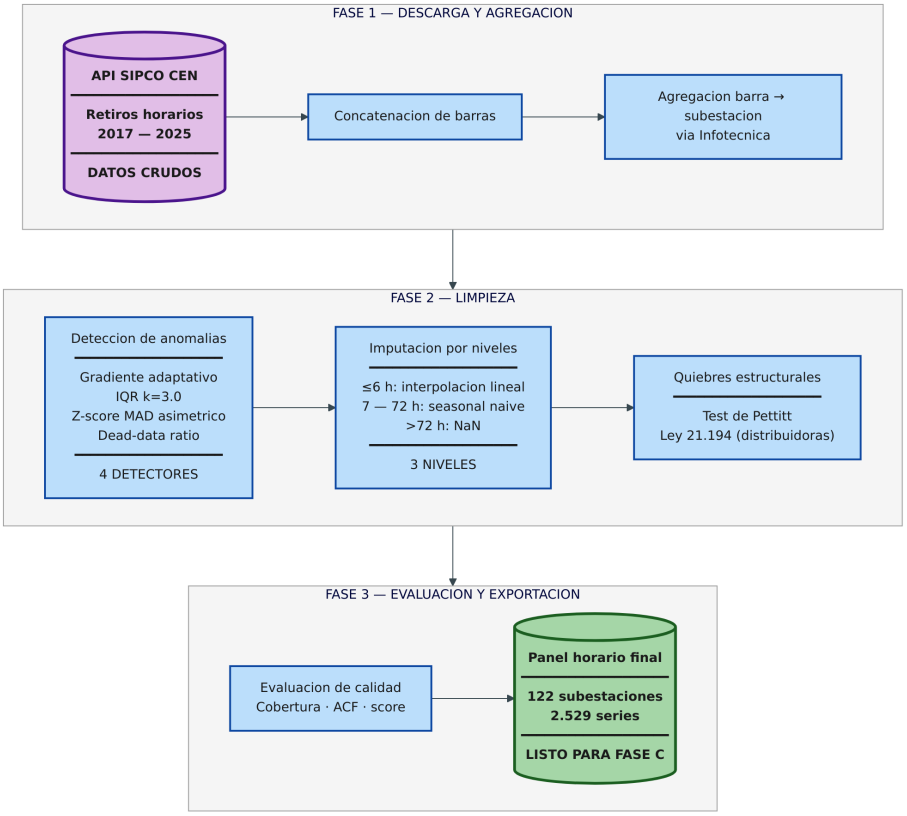

FIGURA B.1: Diagrama de flujo del procesamiento de datos de demanda eléctrica. Las etapas se agrupan en tres fases: descarga y agregación, limpieza (cuatro detectores de anomalías e imputación por niveles) y evaluación de calidad con exportación al panel final.

B.3.4. Etapa 4: Limpieza con 4 detectores

La etapa de limpieza implementa un sistema basado en cuatro detectores independientes, diseñado para preservar los picos de demanda asociados a olas de calor siguiendo las recomendaciones de Auffhammer et al. [12] y Simpson [61]:

1. **Detector de gradiente**: marca valores donde el cambio absoluto entre horas consecutivas excede $\text{máx}(500\,\text{kW/h},\ 0{,}5 \times \text{mediana_SE})$. El umbral adaptativo evita la sobre-detección en SEs de gran escala. Basado en Villa et al. [77].
2. **Detector IQR**: aplica una valla $[Q_{25} - 3 \times \text{IQR},\ Q_{75} + 3 \times \text{IQR}]$ por celda (mes, hora) y por SE. El factor $k = 3{,}0$ es más permisivo que el $k \approx 2$–3 de Villa et al. [77] para acomodar la mayor variabilidad a escala de subestación.
3. **Detector z-score (asimétrico)**: calcula el z-score robusto basado en la MAD (desviación absoluta mediana) por celda (mes, hora) y por SE. Umbrales **asimétricos**: $\sigma_{\text{sup}} = 6$ (protege picos de demanda por calor) y $\sigma_{\text{inf}} = 4$ (detecta fallas de sensor). La asimetría se justifica porque el percentil 90 de la demanda muestra una sensibilidad térmica 28–40 % mayor que la mediana [12].
4. **Detector de datos muertos**: identifica secuencias donde el ratio valor/mediana es inferior a 0,15 durante $\geq$ 12 horas consecutivas, indicando estancamiento del sensor o falla de medición. Basado en Villa et al. [77].

Las detecciones se combinan por unión (cualquier detector marca $\rightarrow$ NaN), con trazabilidad por celda del detector de origen. El conteo por celda de los detectores se contabiliza sobre el panel agregado por subestación (122 SE $\times$ 73.008 h $=$ 8.906.976 celdas), nivel en el que opera el script de limpieza; el insumo de modelado posterior es el censo per-(barra, cliente). Sobre ese panel se marcaron **1.589.687 celdas** (17,8 % del total), distribuidas así entre detectores: gradiente 471.143, IQR 23.267, z-score 960.764, datos muertos 518.539 (un mismo valor puede ser marcado por múltiples detectores). La cobertura efectiva resultante del censo per-serie se reporta en la Sección B.4.

B.3.5. Etapa 5: Interpolación de gaps

El llenado de gaps se realiza en dos niveles escalonados:

- **Gaps cortos ($\leq$ 6 h)**: interpolación lineal, aplicada dentro del script de limpieza. Este umbral es consenso en la literatura [42, 78].
- **Gaps medios (7–72 h)**: imputación por *seasonal naive* —se reemplaza cada NaN por el valor del mismo slot horario 7 días antes (*shift* 168 h), con respaldo a 14 días (336 h), adaptado de Pinheiro et al. [79]. Sobre el panel agregado por SE se llenaron 138.914 celdas; 131.074 quedaron sin llenar (el *shift* también era NaN).
- **Gaps largos ($>$ 72 h)**: se dejan como NaN para ser gestionados por el modelo GAM.

B.3.6. Etapa 6: Merge de hora 25 (DST)

Chile aplica cambio de horario de verano (*DST*), generando un día al año con 25 horas (la hora "extra" se codifica como hora 25 en el sistema CEN). El pipeline colapsa las marcas temporales duplicadas sumando los valores, de modo que el índice temporal permanece estrictamente único.

B.3.7. Etapa 7: Exportación final

La matriz limpia se exporta junto con un `README` de documentación FAIR (esquema, cobertura, SHA-256).

Adicionalmente genera: (i) factores de normalización anual siguiendo Mukherjee y Nateghi [45]: $F_{\text{adj}}(y) = \bar{E}_{\text{global}} / \bar{E}_y$ por SE; y (ii) metadatos de requisitos para el modelado GAM (variables climáticas necesarias, opciones de suavizado, especificación GAM recomendada).

B.4. Evaluación de calidad

La calidad del *dataset* se evalúa mediante la fracción de horas válidas (no NaN) por serie y por mes. La Figura B.2 muestra el mapa de calor de cobertura temporal para las 2.548 series candidatas (barra, cliente) con datos disponibles —de las 2.567 del censo—, agrupadas por subestación (397 SE ordenadas de norte a sur) y, dentro de cada SE, por barra.

Las estadísticas de cobertura, calculadas sobre las 2.548 series con datos, son:

- **Cobertura mediana por serie (período activo)**: 85,9 % de horas válidas entre la primera y la última observación de cada serie. Esta es la métrica de calidad relevante, ya que aisla la completitud del registro del arranque escalonado de las series.
- **Series con $\geq$90 % cobertura activa**: 706 de 2.548 (28 %).
- **Cobertura mediana agregada por SE (período activo)**: 87,2 %; 334 de 397 SE superan el 80 % y 143 superan el 90 %.
- **Disponibilidad global sobre la rejilla completa**: 49,5 % (92.172.175 observaciones válidas sobre el total de $2{,}548 \times 73{,}008 = 186{,}024{,}384$ celdas). Este valor es bajo *por construcción*: refleja que la mayoría de las series no estaba activa al inicio del período (2017), no la calidad del registro una vez que la serie comienza a reportar.

Los patrones temporales de cobertura visibles en la Figura B.2 se explican principalmente por: (i) el arranque escalonado del reporte horario individual —la mayoría de los clientes libres (estrato LN) se incorpora en 2020, lo que produce la amplia zona roja previa a esa fecha—; (ii) el cese del reporte horario de las distribuidoras reguladas (estrato R) en 2022-05 (Ley N. 21.194); y (iii) la reorganización del reporte LN en 2024-03.

La Figura B.3 sintetiza visualmente la heterogeneidad temporal del panel: aproximadamente la mitad de la demanda histórica del sistema se encuentra cubierta por reporte horario individual continuo, con *cliffs* administrativos en 2022-05 (Ley N. 21.194, terminación del estrato Distribuidoras) y 2024-03 (segunda fase de reorganización del reporte Clientes libres). El estrato R domina el volumen mensual previo a 2022-05, mientras que L y LN sostienen el panel desde entonces.

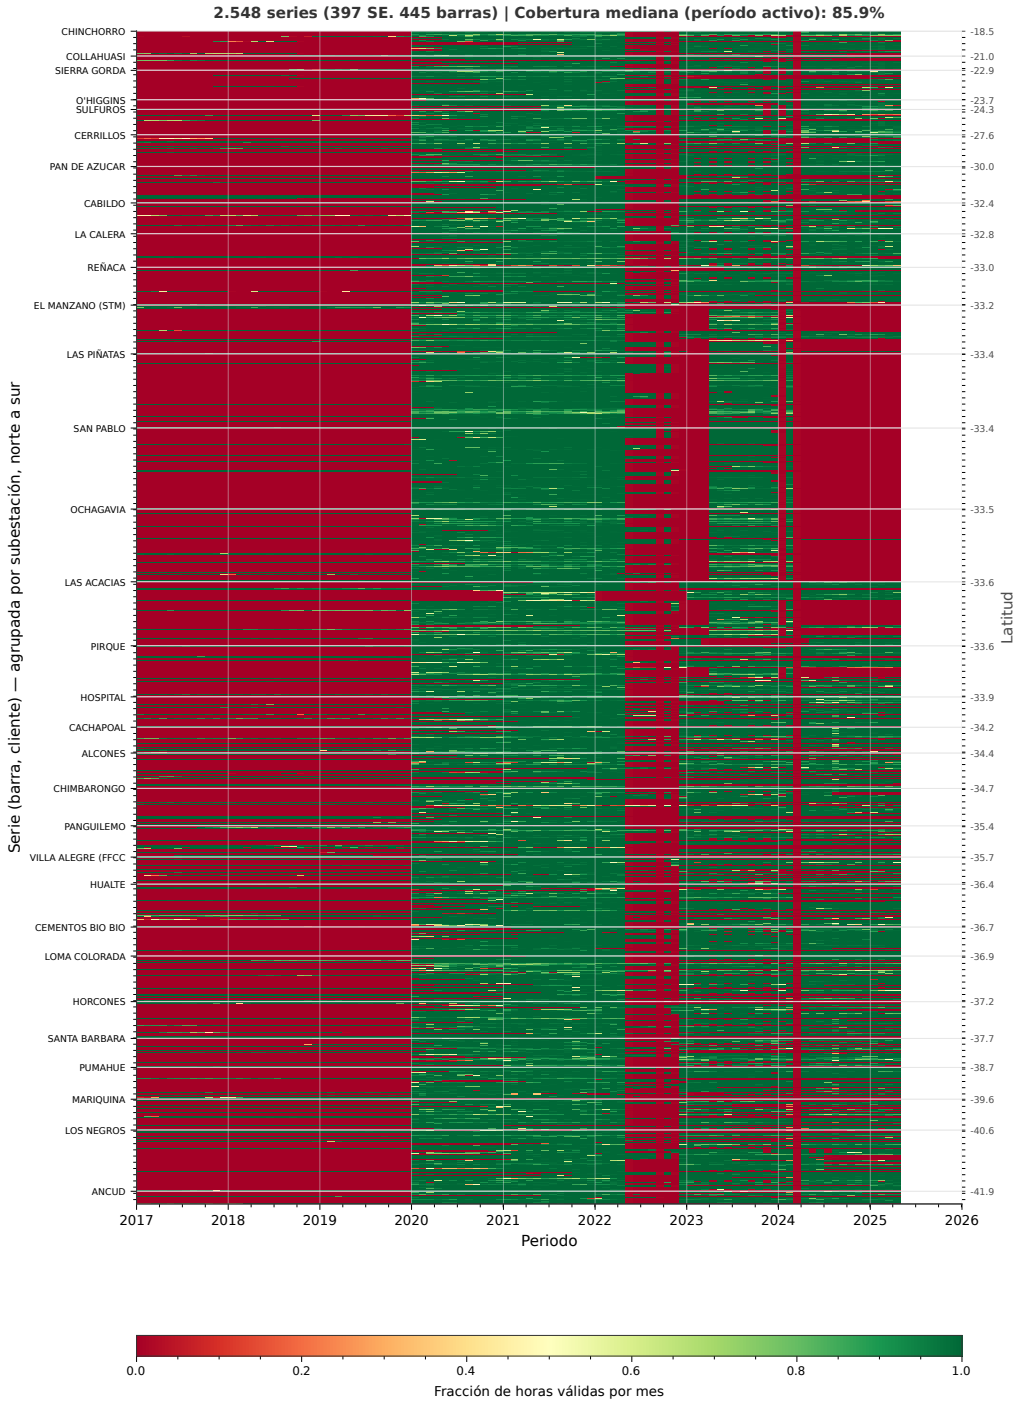

FIGURA B.2: Mapa de calor de cobertura temporal para las 2.548 series candidatas (barra, cliente) con datos disponibles, agrupadas por subestación (397 SE ordenadas de norte —arriba— a sur —abajo—) y, dentro de cada SE, por barra. Cada fila es una serie y el color indica la fracción de horas válidas por mes (verde = cobertura completa, rojo = sin dato). La latitud de la SE de referencia se muestra en el eje derecho. La amplia zona roja previa a 2020 refleja el arranque escalonado de las series (la mayoría de los clientes libres LN se incorpora al reporte horario en 2020), y los cortes posteriores corresponden a los *cliffs* administrativos del reporte CEN (término del estrato Distribuidoras en 2022-05 y reorganización del reporte LN en 2024-03).

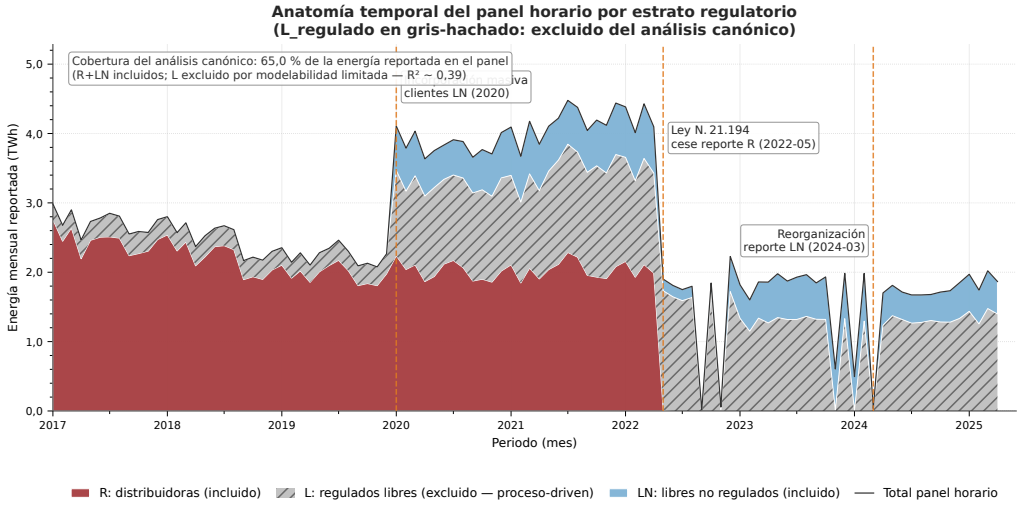

FIGURA B.3: Anatomía temporal del registro horario por tipo de cliente. Las áreas apiladas muestran el volumen mensual de retiros (TWh/mes) reportados al CEN, desagregado por estrato regulatorio: distribuidoras reguladas (R), clientes regulados conectados a transmisión (L) y clientes libres no regulados (LN). La línea oscura superpuesta indica el total horario reportado al panel. Se anotan tres eventos administrativos relevantes: (i) la incorporación masiva de clientes libres en 2020 ("explosión LN"), (ii) el cese del reporte horario de las distribuidoras R en mayo de 2022 (Ley N. 21.194), y (iii) una segunda reorganización del reporte LN en marzo de 2024. La figura ilustra que el panel horario captura solo una fracción del sistema total y que su composición ha cambiado materialmente a lo largo del período.

B.5. Producto final

El insumo de modelado es el censo per-(barra, cliente): una colección de archivos de *features*, uno por tupla barra–cliente. Adicionalmente, el panel agregado por subestación —producto intermedio del que se derivan las estadísticas de limpieza de la Sección B.3— se conserva en disco (122 SE, identificador heredado de la versión previa). El esquema de cada serie del censo es:

CUADRO B.1: Esquema de cada serie del censo per-(barra, cliente).

Campo	Tipo	Descripción
Índice	`datetime64`	Hora local (America/Santiago), sin zona horaria
`demand_kw`	`float64`	Retiro horario de la serie (barra, cliente) en kW
NaN	—	Dato faltante o marcado por detector de calidad
Negativos	`float64`	Inyección neta de prosumidores (válida)

Estadísticas resumidas del censo per-serie (las 2.548 series con datos):

- **Dimensiones**: 2.567 series (barra, cliente) candidatas —2.548 con datos— × 73.008 horas, en 399 SE distintas.
- **Período**: 1 de enero de 2017 – 30 de abril de 2025.
- **Observaciones válidas**: 92.172.175 (49,5 % de la rejilla completa 2,548 × 73,008 =

186,024,384 celdas; fracción baja por construcción, dado el arranque escalonado de las series).

- **Demanda media**: 2.824 kW; mediana: 312 kW.
- **Rango**: −74,237 kW (inyección neta) a 269.896 kW.
- **Valores negativos**: 34.283 observaciones (0,04 % del total válido), en 232 series con prosumidores.

Este *dataset* constituye la entrada principal del modelado GAM y se combina con las variables climáticas corregidas por sesgo para la construcción de las curvas de sensibilidad térmica de la demanda.

Apéndice C

Metodología de Detección y Caracterización de Olas de Calor

La evaluación de los impactos de eventos extremos de temperatura sobre la demanda eléctrica requiere, como paso previo, un catálogo exhaustivo y reproducible de olas de calor y olas de frío sobre el dominio de estudio. Este apéndice describe la metodología de detección y caracterización implementada en este trabajo, incluyendo las definiciones operacionales, el flujo de procesamiento paso a paso, las métricas asociadas a cada evento y las estadísticas descriptivas del catálogo resultante.

La metodología se aplica de manera idéntica a los escenarios SSP3-7.0 y SSP5-8.5, y cubre el período completo 1979–2100. El dato de entrada es la temperatura horaria cerca de superficie (*tas*) del modelo regional CNRM-ALADIN64, corregida por sesgo mediante *Unbiased Quantile Mapping* (UQM) con ERA5-Land como referencia observacional (véase Capítulo 5 y Apéndice A).

C.1. Definiciones operacionales

Las definiciones adoptadas siguen la tradición de la WMO y la literatura reciente sobre extremos climáticos basados en percentiles [40,41], adaptadas para aprovechar la resolución horaria del modelo ALADIN.

C.1.1. Variables derivadas

A partir de la serie horaria corregida $T_h(t, y, x)$, donde t denota la marca temporal, e (y, x) la posición en la grilla de 255×68 celdas, se derivan dos variables diarias para cada día calendario d:

$$T_{\max}(d, y, x) = \max_{h \in d} T_h(t, y, x) \tag{C.1}$$

$$T_{\min}(d, y, x) = \min_{h \in d} T_h(t, y, x) \tag{C.2}$$

donde la maximización y minimización operan sobre las 24 horas del día d.

C.1.2. Umbrales de excedencia

Los umbrales se definen como percentiles fijos computados a partir de un período de referencia (línea base) de 31 años (1980–2010):

- **Umbral de calor** $T_u(y, x)$: percentil 90 de $T_{\max}$ en la línea base.
- **Umbral de frío** $T_c(y, x)$: percentil 10 de $T_{\min}$ en la línea base.

Ambos umbrales son escalares por píxel (un valor por celda de la grilla) y se mantienen fijos para todo el período 1979–2100. El cómputo se realiza sobre los $31 \times 365 = 11\,315$ días de la línea base, calculando el percentil sobre el eje temporal para cada celda.

C.1.3. Definición de día extremo

Un día d es declarado como *día extremo de calor* en el píxel (y, x) si:

$$\exists\, h \in d : T_h(h, y, x) > T_u(y, x) \tag{C.3}$$

Análogamente, un *día extremo de frío* se define como:

$$\exists\, h \in d : T_h(h, y, x) < T_c(y, x) \tag{C.4}$$

Es decir, basta con que *una sola hora* del día supere (o sea inferior a) el umbral para que el día completo sea clasificado como extremo. Esta definición basada en horas es más sensible que las definiciones tradicionales basadas exclusivamente en extremos diarios, ya que captura eventos nocturnos (relevantes para el confort térmico y la mortalidad) que podrían no reflejarse en $T_{\max}$ o $T_{\min}$.

C.1.4. Definición de evento (ola)

Una *ola de calor* es una secuencia de $n \geq 3$ días extremos de calor consecutivos en un mismo píxel. Formalmente, si los días $d_0, d_0 + 1, \ldots, d_0 + n - 1$ son todos días extremos de calor, y los días $d_0 - 1$ y $d_0 + n$ no lo son, entonces el conjunto constituye un evento de duración n días.

La definición de *ola de frío* es análoga, reemplazando días extremos de calor por días extremos de frío.

El umbral de 3 días consecutivos es consistente con las definiciones de la WMO [2] y con la literatura de referencia para Chile [76, 80].

C.1.5. Métricas de evento

Cada evento detectado se caracteriza mediante cuatro métricas:

Duración (D, días) Número de días consecutivos que cumplen el criterio de excedencia:

$$D = n \tag{C.5}$$

Intensidad (I, °C) Anomalía máxima sobre (o bajo) el umbral durante todo el evento. Para olas de calor:

$$I = \max_{h \in \text{evento}} \left[T_h(h, y, x) - T_u(y, x) \right] \tag{C.6}$$

Para olas de frío:

$$I = \max_{h \in \text{evento}} \left[T_c(y, x) - T_h(h, y, x) \right] \tag{C.7}$$

Magnitud horaria (M_h, °C·horas) — métrica primaria Integral de excedencia horaria, que captura la carga térmica acumulada incluyendo el ciclo diurno. Para olas de calor:

$$M_h = \sum_{\substack{h \in \text{evento} \\ T_h > T_u}} (T_h - T_u) \tag{C.8}$$

Para olas de frío:

$$M_h = \sum_{\substack{h \in \text{evento} \\ T_h < T_c}} (T_c - T_h) \tag{C.9}$$

Las unidades son °C·horas. Esta métrica es más informativa que la magnitud diaria clásica porque (i) discrimina entre eventos con la misma $T_{\max}$ pero distintas amplitudes del ciclo diurno, y (ii) es directamente proporcional al estrés térmico acumulado sobre personas e infraestructura.

Magnitud clásica (M_c, °C·días) — métrica secundaria Integral de excedencia diaria, incluida para comparabilidad con la literatura existente. Para olas de calor:

$$M_c = \sum_{d \in \text{evento}} \text{máx}(T_{\max}(d) - T_u,\, 0) \tag{C.10}$$

Para olas de frío:

$$M_c = \sum_{d \in \text{evento}} \text{máx}(T_c - T_{\min}(d),\, 0) \tag{C.11}$$

C.2. Pipeline de detección

La detección y caracterización de eventos se implementó como un procedimiento secuencial de ocho etapas, cada una con un producto de salida intermedio verificable. La Figura C.1 presenta un diagrama esquemático del flujo completo.

A continuación se describe cada etapa:

1. **Etapa 1: Derivación de Tmax y Tmin diarios**. Para cada año y escenario, se procesan los archivos semestrales de *tas* horaria (formato CORDEX). Se computan $T_{\max}$ y $T_{\min}$ diarios según las ecuaciones (C.1)–(C.2), sobre ventanas de 24 horas. El producto son archivos anuales de Tmax y Tmin.

2. **Etapa 2: Cómputo de umbrales**. Se apilan las series diarias del período 1980–2010 para cada variable y se computa el percentil correspondiente (p90 para Tmax, p10 para Tmin) por píxel. El resultado son dos mapas de umbrales de dimensión 255×68. Los umbrales se calculan una sola vez a partir de la serie histórica del escenario SSP3-7.0 (que comparte las forzantes históricas con SSP5-8.5).

3. **Etapa 3: Marcado de horas extremas**. Se compara cada hora de la serie completa (1979–2100) contra el mapa de umbrales. El producto es un arreglo booleano por año (1 = hora extrema, 0 = normal) para cada tipo de evento (calor y frío).

4. **Etapa 4: Detección de días extremos**. Los arreglos horarios se colapsan a resolución diaria: un día es extremo si al menos una de sus 24 horas está marcada como extrema (ecuaciones (C.3)–(C.4)). El producto son arreglos booleanos diarios por año.

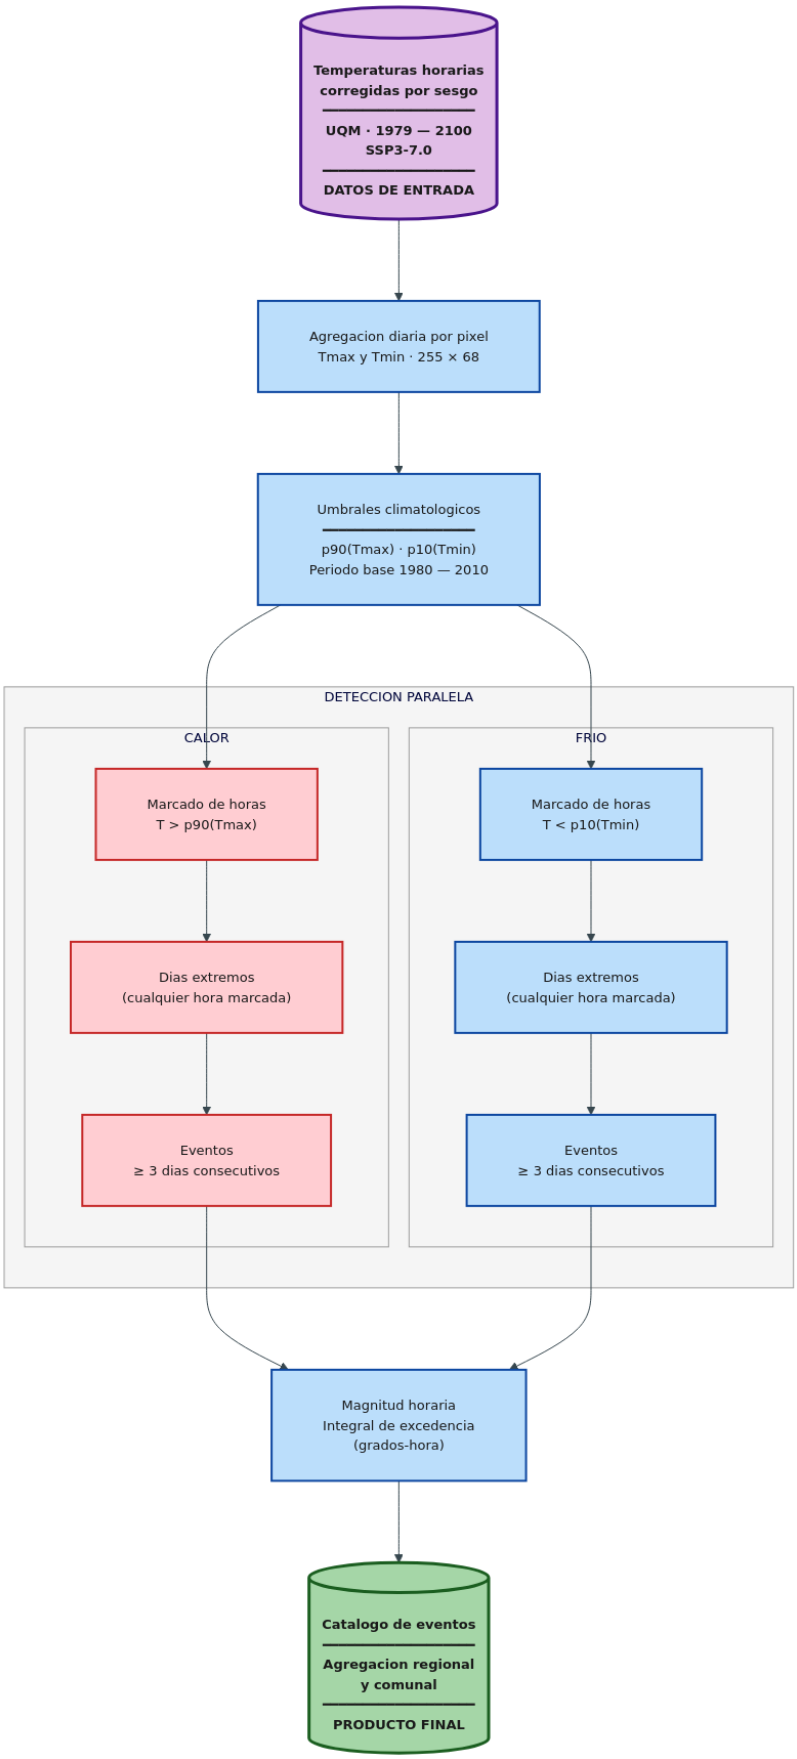

FIGURA C.1: Diagrama de flujo del pipeline de detección y caracterización de olas de calor y frío. El proceso parte de las temperaturas horarias corregidas por sesgo y produce un catálogo georreferenciado de eventos con métricas de duración, intensidad y magnitud. Los colores distinguen datos de entrada (azul), procesamiento intermedio (celeste) y producto final (verde).

5. **Etapa 5: Detección de eventos**. Se recorre la serie temporal de días extremos de cada píxel buscando secuencias de ≥ 3 días consecutivos. Se emplea un algoritmo de detección de rachas (*run-length encoding*) que opera en tiempo lineal $O(n)$ por píxel. Para cada evento detectado se registran: coordenadas de píxel (y, x), fecha de inicio, fecha de término, duración, intensidad y magnitud clásica (M_c).

6. **Etapa 5b: Cómputo de magnitud horaria**. En una segunda pasada, se recorre año por año la serie horaria de temperatura y se computa la magnitud horaria M_h para cada evento del catálogo. El procesamiento se realiza de manera vectorizada sobre toda la grilla simultáneamente: para cada año se calcula el campo de excedencia horaria $\max(T_h - T_u, 0)$ (o $\max(T_c - T_h, 0)$ para frío) y se acumula por día. Luego se suman los acumulados diarios dentro de las fechas de cada evento.

7. **Etapa 6: Agregación regional**. Mediante una unión espacial con un shapefile de comunas, los eventos se agregan por región y se agrupan en tres macrozonas: Norte (Arica y Parinacota a Coquimbo), Centro (Valparaíso a Ñuble) y Sur (Biobío a Aysén). El detalle del mapeo se presenta en la Sección C.3.

8. **Etapas 7–8: Agregación comunal con ponderación por área**. Las estadísticas comunales (frecuencia, duración, intensidad) se ponderan por la fracción de área que cada píxel aporta a cada comuna; el procedimiento se detalla en la Sección C.3.

El procedimiento implementa *checkpointing*: cada etapa verifica si su producto ya existe, lo que permite reanudar el procesamiento tras interrupciones sin reprocesamiento.

C.3. Agregación espacial

La detección opera a nivel de píxel individual ($255 \times 68 = 17\,340$ celdas, de las cuales 8 270 son terrestres). Para obtener estadísticas a escala regional y comunal se emplean dos estrategias complementarias:

C.3.1. Mapeo punto-en-polígono

Los centroides de la grilla ALADIN (coordenadas curvilíneas 2D, proyectadas a WGS84) se asocian a las regiones políticas chilenas mediante una unión espacial punto-en-polígono. El resultado es una tabla de correspondencia $(\text{pixel}_y, \text{pixel}_x) \rightarrow (\text{región}, \text{macrozona})$ que permite agregar los eventos del catálogo por unidad administrativa. Este mapeo cubre el 100 % de los píxeles terrestres chilenos.

C.3.2. Ponderación por área de intersección

Para la agregación comunal, se construyen los polígonos de celda a partir de las esquinas de la grilla (calculadas como puntos medios entre centroides adyacentes, con extrapolación lineal en los bordes). La intersección geométrica entre los polígonos de celda y los polígonos comunales se computa en proyección UTM 19S (EPSG:32719) para asegurar cálculos de área precisos. El peso de cada par píxel-comuna es:

$$w_{i,c} = \frac{A(P_i \cap C_c)}{A(P_i)} \tag{C.12}$$

donde P_i es el polígono del píxel i, C_c es el polígono de la comuna c y $A(\cdot)$ denota el área. Para comunas pequeñas que no contienen ningún centroide de píxel, se aplica una asignación por respaldo al píxel más cercano (*nearest-pixel fallback*).

Las métricas comunales (frecuencia anual, duración media, magnitud media) se computan como promedios ponderados por $w_{i,c}$ sobre todos los píxeles que contribuyen a cada comuna, lo cual otorga mayor representatividad a los píxeles cuya celda ocupa una mayor fracción del territorio comunal.

C.4. Catálogo de eventos: estadísticas descriptivas

El producto final del pipeline es un conjunto de cuatro catálogos (olas de calor y olas de frío, para cada escenario), donde cada fila corresponde a un evento en un píxel específico (*pixel-evento*). La Tabla C.1 resume las estadísticas principales por tipo de evento, escenario y período temporal.

CUADRO C.1: Resumen del catálogo de eventos extremos por tipo, escenario y período. Se reporta el número total de pixel-eventos, la duración media (días) y la magnitud media clásica (°C·días).

		Histórico			2030–2050			2050–2080			2080–2100		
Tipo	Escenario	N	$\bar{d}$	$\bar{M}$	N	$\bar{d}$	$\bar{M}$	N	$\bar{d}$	$\bar{M}$	N	$\bar{d}$	$\bar{M}$
Calor	SSP3-7.0	1.5M	4.8	11.1	1.9M	6.3	16.8	3.3M	8.2	26.2	2.5M	10.5	40.7
Calor	SSP5-8.5	1.5M	4.8	11.1	2.0M	6.6	18.3	3.7M	8.9	30.8	2.4M	13.0	59.5
Frío	SSP3-7.0	1.5M	4.9	13.8	570k	4.5	13.3	501k	4.3	11.6	174k	3.9	10.0
Frío	SSP5-8.5	1.5M	4.9	13.8	476k	4.4	12.6	423k	4.2	11.9	112k	3.7	10.3

N: número de pixel-eventos; $\bar{d}$: duración media (días); $\bar{M}$: magnitud media clásica (°C·días). El período histórico es idéntico en ambos escenarios ya que comparten las mismas forzantes 1979–2014.

C.4.1. Volumen del catálogo

Para el escenario SSP3-7.0, el catálogo contiene 10,7 millones de pixel-eventos de calor y 3,5 millones de pixel-eventos de frío sobre el período completo 1979–2100. Bajo SSP5-8.5, los eventos de calor aumentan a 11,2 millones mientras que los de frío disminuyen a 3,3 millones. Esta asimetría refleja el efecto del calentamiento antropogénico: los umbrales fijos (calculados sobre la línea base 1980–2010) son cruzados con mayor frecuencia por las distribuciones desplazadas hacia temperaturas más altas.

C.4.2. Distribución de duración y magnitud

La Figura C.2 presenta un panel de cuatro gráficos que resumen las características del catálogo bajo SSP3-7.0.

La distribución de duración (panel a) muestra que ambos tipos de evento son predominantemente cortos: la mediana es de 5 días para olas de calor y 4 días para olas de frío. Sin embargo, las olas de calor presentan una cola derecha más pronunciada, con el evento más largo alcanzando 429 días consecutivos bajo SSP3-7.0 (un fenómeno cuasi-permanente en píxeles del norte del dominio hacia finales de siglo). Las olas de frío, en contraste, no superan los 57 días de duración máxima.

La magnitud clásica (panel b) refleja esta asimetría: la media de M_c para olas de calor es 24,3 °C·días bajo SSP3-7.0 (30,1 bajo SSP5-8.5), frente a 13,0 °C·días para olas de

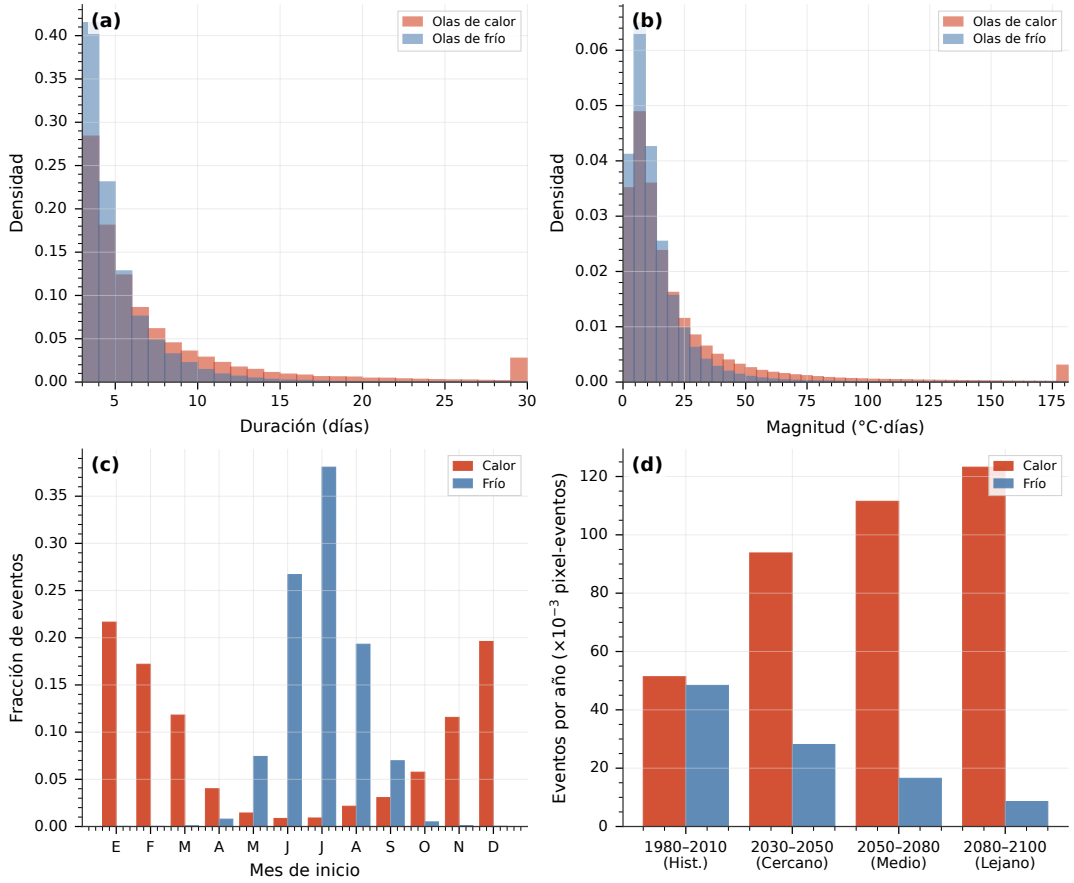

FIGURA C.2: Estadísticas del catálogo de eventos extremos (SSP3-7.0). (a) Distribución de duración: las olas de calor presentan una cola más pesada que las de frío, con eventos de hasta 429 días. (b) Distribución de magnitud clásica (M_c, °C·días): ambos tipos siguen distribuciones exponenciales truncadas. (c) Estacionalidad: los eventos de calor se concentran en verano austral (noviembre–marzo), mientras que los de frío dominan en invierno (mayo–agosto). (d) Evolución temporal por período: la frecuencia anual de olas de calor se duplica entre el período histórico y mediados de siglo, mientras que las olas de frío declinan progresivamente.

frío. La magnitud horaria primaria (M_h) presenta valores medios de 105,3 °C·horas (calor, SSP3-7.0) y 86,7 °C·horas (frío, SSP3-7.0).

C.4.3. Estacionalidad

El panel (c) de la Figura C.2 confirma la estacionalidad esperada. Las olas de calor se concentran en los meses de verano austral: enero (21,7 %), diciembre (19,6 %) y febrero (17,2 %) acumulan el 58,5 % de los eventos. Las olas de frío muestran un patrón complementario, con julio (38,1 %), junio (26,7 %) y agosto (19,3 %) concentrando el 84,1 % de los eventos. Esta marcada estacionalidad es consistente con la literatura sobre extremos de temperatura en Chile [76]. La Figura C.3 muestra la extensión de las temporadas cálidas y frías para tres ciudades representativas a lo largo del período 1980–2100.

C.4.4. Evolución temporal

El panel (d) muestra la frecuencia anual media de pixel-eventos por período. Para olas de calor, la frecuencia se incrementa de ∼50 000 pixel-eventos por año en el período histórico a ∼110 000 en el período 2050–2080, representando un aumento del 120 % bajo SSP3-7.0. Hacia el final de siglo (2080–2100), la frecuencia se estabiliza ligeramente por debajo del máximo de mediados de siglo, lo cual se explica porque muchos píxeles del norte del dominio entran en régimen cuasi-permanente de excedencia (eventos muy largos que se cuentan como uno solo).

Las olas de frío muestran la tendencia opuesta: la frecuencia disminuye de ∼48 000 pixel-eventos anuales en el período histórico a ∼9 000 hacia finales de siglo, una reducción del 81 %. Este resultado es robusto entre escenarios, aunque SSP5-8.5 produce una reducción ligeramente más pronunciada (frecuencia final de ∼5 600 eventos anuales).

C.4.5. Diferencias entre escenarios

La divergencia entre SSP3-7.0 y SSP5-8.5 se manifiesta principalmente en la segunda mitad del siglo. Para el período 2080–2100, la duración media de las olas de calor es de 10,5 días bajo SSP3-7.0 versus 13,0 días bajo SSP5-8.5 (+24 %), y la magnitud clásica media es de 40,7 versus 59,5 °C·días (+46 %). En contraste, los eventos de frío muestran diferencias menores entre escenarios, ya que ambas trayectorias de emisiones producen una reducción similar en la frecuencia de temperaturas por debajo de los umbrales históricos.

C.5. Limitaciones de la metodología

- **Sensibilidad al umbral:** La elección de los percentiles p90 (calor) y p10 (frío) es convencional pero no necesariamente óptima para todas las aplicaciones. Umbrales más estrictos (e.g., p95) reducirían el número de eventos detectados y producirían un catálogo más selectivo pero menos estadísticamente robusto. No se realizó un análisis de sensibilidad formal al percentil elegido, aunque la consistencia con la definición de la WMO y con la literatura existente [41, 76] respalda esta elección.
- **Definición basada en temperatura seca:** Los umbrales se basan exclusivamente en la temperatura del aire ($T_{\max}$ y $T_{\min}$), sin considerar índices compuestos

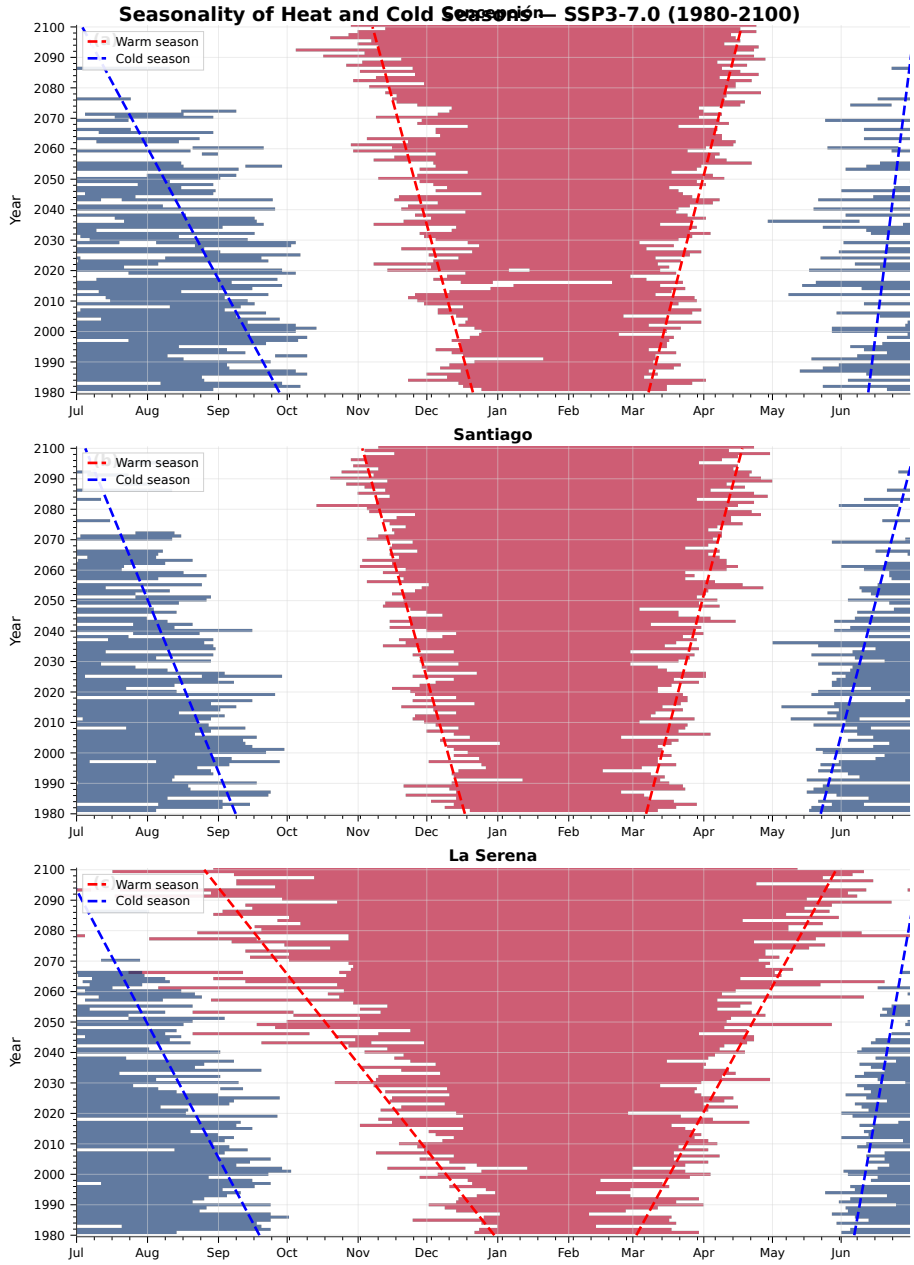

FIGURA C.3: Estacionalidad de las temporadas cálidas (rojo) y frías (azul) para tres ciudades representativas (1980–2100, SSP3-7.0). Barras horizontales: extensión de cada temporada por año. Líneas: tendencia lineal.

como el *heat index* o la *wet-bulb globe temperature* (WBGT) que incorporan la humedad relativa. Para el centro de Chile, donde la humedad estival es generalmente baja, la temperatura seca es una aproximación razonable del estrés térmico. Sin embargo, en la zona norte costera y en valles con efecto de subsidencia, la humedad puede amplificar el impacto sobre la demanda eléctrica de refrigeración de manera no capturada por esta métrica.

- **Ausencia de efectos compuestos:** La metodología no incorpora la interacción entre temperatura, humedad y velocidad del viento en la definición de evento. Estos factores son relevantes para la sensación térmica y el rendimiento de sistemas de refrigeración, pero su inclusión requeriría campos horarios corregidos de las tres variables simultáneamente y una definición de umbral multivariada, lo cual excede el alcance de esta tesis.
- **Resolución espacial:** La grilla ALADIN ($\sim$12 km) no captura las islas de calor urbano (UHI), que pueden amplificar las temperaturas extremas en ciudades como Santiago en 2–5 °C respecto al entorno rural [81]. Esto implica que los eventos detectados a escala de píxel pueden subestimar la intensidad y duración de las olas de calor experimentadas en áreas urbanas densamente pobladas.
- **Umbrales fijos en el tiempo:** Los percentiles se calculan sobre una línea base estacionaria (1980–2010). Esto implica que, bajo calentamiento progresivo, una fracción creciente de los días futuros será clasificada como extrema, incluso si la población se ha adaptado parcialmente a las nuevas condiciones climáticas. Líneas de trabajo complementarias utilizan umbrales deslizantes en el tiempo (*running-baseline percentiles*), pero estos dificultan la cuantificación del riesgo absoluto de superación. La comparación explícita entre umbral fijo y umbral adaptativo (ventana rodante de 30 años) sobre este mismo modelo regional se reporta en [30]: con umbral adaptativo las métricas de olas de calor quedan esencialmente planas, lo que indica que el alza proyectada se explica por el desplazamiento de la media más que por un ensanchamiento de la distribución.
- **Independencia espacial:** Los eventos se detectan de manera independiente en cada píxel. La coherencia espacial de las olas de calor (su extensión territorial) no se modela explícitamente. Las agregaciones regional y comunal capturan parcialmente este aspecto, pero no permiten identificar eventos sinópticos que afectan simultáneamente a múltiples regiones como una unidad meteorológica coherente.

Apéndice D

Campaña Experimental GAM y Selección de Modelo

Este apéndice documenta la campaña experimental que condujo a la especificación GAM definitiva de demanda–clima.

D.1. Diseño de la campaña

La selección de la especificación GAM se realizó mediante una campaña sistemática de 28 configuraciones organizadas en cuatro grupos, evaluadas sobre cinco subestaciones piloto seleccionadas por diversidad geográfica y climática: **Curanilahue** (sur, industrial), **Miraflores** (centro-norte, mixta), **Colbún** (centro-sur, agrícola), **Andalién** (Concepción, urbana) y **Caldera** (norte, árida).

D.2. Grupos experimentales

D.2.1. Grupo A — Tratamiento de la respuesta (A1–A3)

Tres variantes que exploran la transformación de la variable dependiente y la familia de error:

- **A1**: Demanda cruda (identidad), familia Gaussiana.
- **A2**: Log-demanda, familia Gaussiana.
- **A3**: Demanda cruda, familia Gamma con enlace logarítmico.

D.2.2. Grupo B — Predictores climáticos (B1–B5)

Cinco variantes que evalúan combinaciones de variables meteorológicas:

- **B1**: Solo *tas*.
- **B2**: *tas* + *Td* (punto de rocío).
- **B3**: Las cinco variables completas (*tas*, *Td*, *sfcWind*, *rsds*, *pr*).
- **B4**: B3 + EWMA térmica con $\alpha = 0{,}05$.
- **B5**: B3 + EWMA térmica con $\alpha = 0{,}10$.

D.2.3. Grupo C — Estructura temporal (C1–C3)

Tres variantes que prueban distintas parametrizaciones del ciclo temporal:

- **C1**: Términos marginales separados $s(\texttt{tas})$, $s(\texttt{hod})$, $s(\texttt{doy})$ sin interacciones.
- **C2**: Interacciones tensoriales `ti(tas,hod)` y `ti(tas,doy)`.
- **C3**: C2 + tendencia de largo plazo $s(\texttt{trend_index})$.

D.2.4. Grupo D — Síntesis y refinamiento (D1–D2k)

Más de 13 variantes que combinan los mejores elementos de los grupos anteriores, incrementando progresivamente la complejidad. Las variantes clave son:

- **D1**: Mejor de cada grupo (log, 5 vars + EWMA, tensores + tendencia).
- **D2**: D1 + interacción `ti(hod, dow)` + indicador de festivos + $s(\texttt{hod}, \text{by} = \texttt{is_holiday})$.
- **D2k**: D2 con ajuste fino de hiperparámetros de suavizado (k).

D.3. Índice compuesto de ranking

La comparación entre modelos se realizó mediante el índice compuesto:

$$\text{Score} = 0{,}4 \cdot (1 - \text{MAPE}/100) + 0{,}3 \cdot \text{DevExpl} + 0{,}2 \cdot (1 - r_{\text{AIC}}/N) + 0{,}1 \cdot (1 - |\text{ACF}_1|) \tag{D.1}$$

donde MAPE es el error porcentual absoluto medio, DevExpl la devianza explicada, r_{AIC} el ranking por AIC entre los N modelos candidatos, y ACF_1 la autocorrelación residual de primer orden. Los pesos priorizan el error predictivo (0,4) y la capacidad explicativa (0,3), con menor peso al criterio de información (0,2) y a la autocorrelación (0,1).

La Tabla D.1 resume las métricas medianas de los cinco mejores experimentos sobre las cinco subestaciones piloto. El modelo SE-agregado (335 SE), ajustado con *splines full-k* y tensores en el nivel estándar 15/12, alcanza un R^2 mediano de 0,836 con un MAPE inferior al 1 %; el modelo canónico per-(barra, cliente) (Ecuación 5.3), con dimensión de base reducida, alcanza un R^2 mediano de 0,624 (Capítulo de Resultados).

La Tabla D.2 amplía el resumen a los 28 experimentos completos del ranking, con el promedio y la desviación estándar de R^2, MAPE y AIC obtenidos sobre las cinco SE piloto (*Curanilahue*, *Miraflores*, *Colbún*, *Andalién*, *Caldera*). La especificación canónica se destaca en negrita.

D.4. Protocolo de complejidad (*two-tier k*)

Para la dimensión de base de los *splines* (k) se adoptó un protocolo de dos niveles:

- **Nivel estándar** ($k = 15/12$ en el tensor líder `ti(tas,hod)`; análogamente $10/15$ y $12/4$ en los restantes): utilizado durante la campaña experimental iterativa

CUADRO D.1: Resumen de los cinco mejores experimentos de la campaña piloto y del modelo final D2k. Las métricas corresponden a la mediana sobre las cinco subestaciones piloto. El *score* es el índice compuesto de la Ecuación D.1. $\text{D2k}_{\text{final}}$ incorpora correcciones de concurvidad y festivos.

Modelo	R^2	MAPE (%)	RMSE	DevExpl	ACF_1	Tiempo (s)	Score
D2h	0.858	0.61	0.0734	0.858	0.831	11.6	0.8615
D2g	0.851	0.63	0.0784	0.851	0.835	13.9	0.8474
D2e	0.849	0.64	0.0812	0.849	0.836	11.1	0.8404
D2j	0.850	0.64	0.0811	0.850	0.836	13.6	0.8395
D2i	0.849	0.64	0.0812	0.849	0.836	12.1	0.8344
$\text{D2k}_{\text{final}}$	0.853	0.64	0.0816	0.853	0.837	42.6	—

CUADRO D.2: Ranking de experimentos GAM por bondad de ajuste, ordenados por R^2 descendente (medias sobre 5 SE piloto: Curanilahue, Miraflores, Colbun, Andalien, Caldera). Se muestra media $\pm$ desviación estándar de R^2 y MAPE, además de la media del AIC. El modelo canónico seleccionado (**D2k_final**) se destaca en negrita. Total 28 experimentos.

Experimento	*n* SE	R^2 media $\pm$ std	MAPE media $\pm$ std (%)	AIC media
D2k_final	115	**0,6844 ± 0,2114**	**3,43 ± 6,80**	-6.147,8
C3_tensor_interactions	5	0,6716 ± 0,1865	465,54 ± 1.008,93	553.444,7
D1_full_model	5	0,6712 ± 0,1874	468,33 ± 1.015,15	553.341,0
B5_full_climate	5	0,6650 ± 0,1857	468,34 ± 1.014,69	554.081,5
B3_tas_td_wind	5	0,6557 ± 0,1829	468,94 ± 1.015,46	555.333,2
B4_tas_smoothed	5	0,6553 ± 0,1838	469,94 ± 1.017,69	555.340,4
A1_raw_gaussian	5	0,6547 ± 0,1829	469,70 ± 1.017,12	555.428,5
B2_tas_td	5	0,6547 ± 0,1829	469,70 ± 1.017,12	555.428,5
C1_base_calendar	5	0,6547 ± 0,1829	469,70 ± 1.017,12	555.428,5
B1_tas_only	5	0,6533 ± 0,1834	470,19 ± 1.018,12	555.549,3
D2k_k30	5	0,5985 ± 0,2555	4,00 ± 5,57	4.974,0
D2k_k25	5	0,5974 ± 0,2560	4,00 ± 5,57	5.010,5
D2k_holidays_weekday	5	0,5936 ± 0,2563	4,01 ± 5,58	5.280,4
D2h_weekday_profile	5	0,5895 ± 0,2545	4,03 ± 5,58	5.906,6
D2g_holidays	5	0,5853 ± 0,2515	4,06 ± 5,56	6.545,7
A3_normalized	5	0,5851 ± 0,1864	687,65 ± 1.487,43	593.869,4
D2k_extended_k25	5	0,5837 ± 0,2544	4,09 ± 5,53	6.526,1
D2j_dual_ewma	5	0,5820 ± 0,2496	4,07 ± 5,56	7.051,5
D2i_all_breaks	5	0,5820 ± 0,2497	4,05 ± 5,53	7.025,4
D2e_full_synthesis	5	0,5814 ± 0,2499	4,07 ± 5,56	7.092,2
D2b_seasonal_T	5	0,5773 ± 0,2474	4,08 ± 5,56	7.663,8
D2c_solar_precip	5	0,5754 ± 0,2512	4,08 ± 5,57	7.559,5
D2d_ewma_inertia	5	0,5729 ± 0,2480	4,09 ± 5,57	8.037,5
D2a_ti_correction	5	0,5720 ± 0,2482	4,09 ± 5,57	8.099,2
D2_crossbasis	5	0,5720 ± 0,2482	4,09 ± 5,57	8.097,3
D2f_reduced_k	5	0,5715 ± 0,2479	4,10 ± 5,57	8.158,2
D2k_final_k25	5	0,5662 ± 0,2606	4,27 ± 5,80	8.293,9
A2_log_gaussian	5	0,5599 ± 0,2433	4,14 ± 5,55	9.475,4

sobre las cinco SE piloto, donde la velocidad de ajuste es prioritaria. Es también el nivel del estimador SE-agregado, sobre el cual se reportan las métricas de ajuste a nivel de subestación (R^2 mediano 0,836).

- **Nivel de publicación** ($k = 25/20$): probado únicamente sobre las cinco SE piloto (variantes `D2k_k25`, `D2k_k30`) para verificar que el nivel estándar no restringía artificialmente la suavidad. La mejora en R^2 mediano respecto al nivel estándar es de apenas $+0{,}003$, confirmando la saturación; por ello el estimador SE-agregado conserva el nivel estándar 15/12.

Este protocolo de complejidad de cómputo opera sobre el estimador SE-agregado y la campaña experimental, y es *independiente* de la regla de granularidad de la Sección 5.7.5: el modelo canónico per-(barra, cliente) de la Ecuación 5.3 usa una dimensión de base reducida ($k = 8/8/16/10/3$ en los *smooths* y $(8,8)/(6,8)$ en los tensores), siguiendo la regla de una función base por cada tres años de observación (Walker, 2023), y no corresponde a ninguno de estos dos niveles.

La Figura D.1 sintetiza el proceso de selección como un embudo de cinco niveles: desde las 28 configuraciones iniciales, pasando por las fases de filtrado piloto, ranking compuesto y validación cruzada intensiva, hasta la especificación ganadora.

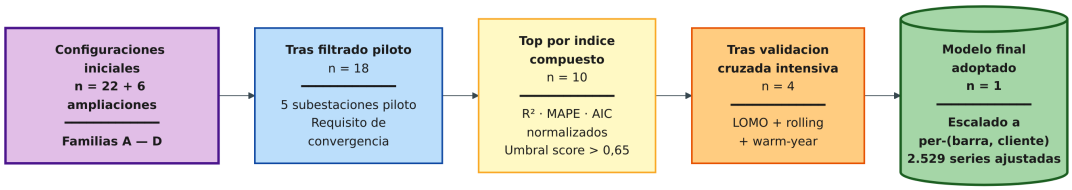

FIGURA D.1: Diagrama de embudo de la campaña experimental. Las 28 variantes iniciales se agrupan en cuatro familias (A: tratamiento de la respuesta; B: subconjuntos de predictores; C: temporalidad e interacciones; D: síntesis). Cada nivel de filtrado reduce el número de candidatos mediante criterios progresivamente más exigentes: índice compuesto (Ecuación D.1), validación cruzada intensiva (LOMO, *rolling*, *warm-year*) y refinamiento final con correcciones de concurvidad y protocolo *two-tier k*.

Apéndice E

Diagnósticos del Modelo GAM canónico

Este apéndice documenta los diagnósticos residuales del modelo canónico per-(barra, cliente), incluyendo la evaluación empírica de la autocorrelación, la resolución de la concurvidad, y la construcción de intervalos de confianza simultáneos.

E.1. Evaluación empírica del término AR(1)

Los residuos del modelo canónico presentaban autocorrelación significativa hasta el retardo $h = 3$ horas (confirmado por el correlograma ACF). Se evaluó la inclusión de un término AR(1) mediante el parámetro `rho` de `bam()` en una grilla de siete variantes ajustadas sobre cinco subestaciones piloto.

E.1.1. Grilla de variantes piloto

CUADRO E.1: Comparación de variantes D2k_final sobre SE Caldera (representativa del comportamiento típico). Las variantes con $\rho > 0$ empeoran simultáneamente ACF_1 y R^2 respecto al modelo sin corrección AR(1).

Variante	ρ	R^2	MAPE (%)	ACF_1	Concurvidad
D2k baseline ($k=10$)	0,0	0,859	0,61	0,830	0,988
D2k_final ($k=5$+select)	**0,0**	**0,853**	**0,63**	**0,837**	**0,141**
$k=5$+select+$\rho=0{,}7$	0,7	0,848	0,64	0,857	0,141
$k=5$+select+$\rho=0{,}83$	0,83	0,844	0,65	0,861	0,141
$k=5$+select+$\rho=0{,}9$	0,9	0,837	0,67	0,868	0,141
$k=10$+$\rho=0{,}83$ (sin select)	0,83	0,851	0,63	0,855	0,988
$k=3$+select+$\rho=0{,}83$	0,83	0,825	0,70	0,877	0,059

E.1.2. Incompatibilidad `discrete=TRUE` con `rho`

La función `bam()` de `mgcv` implementa una aproximación `discrete=TRUE` que discretiza las covariables en una grilla fina para reducir la complejidad computacional de $\mathcal{O}(n^3)$ a $\mathcal{O}(n \cdot k^2)$ [72]. Esta aproximación resulta incompatible con el mecanismo de decorrelación AR(1) implementado vía el parámetro `rho`: la transformación de Cholesky de la matriz de correlación que subyace al proceso AR(1) requiere operar sobre la matriz de datos completa, que la discretización ha reemplazado por una

versión comprimida. Como resultado, la decorrelación es incompleta y los residuos post-corrección muestran ACF_1 *superior* al modelo sin corrección (Tabla E.1).

El uso de `gamm()` con estructura `corAR1()` evitaría este problema, pero requiere la factorización completa de la matriz de covarianza ($\mathcal{O}(n^3)$), lo que resulta computacionalmente prohibitivo para las $n > 35{,}000$ observaciones típicas por SE en este estudio.

E.2. Resolución de la concurvidad

La concurvidad entre $s(\texttt{doy})$ y $s(\texttt{trend_index})$ es el principal problema de colinealidad no paramétrica identificado en el modelo canónico. Con la dimensión de base original $k = 10$ para el término de tendencia, el índice de concurvidad por pares alcanzó una mediana de 0,987 sobre las SE de la configuración SE-agregada original ($k = 10$, sin penalización de selección) (prácticamente colineal), indicando que el suavizador de tendencia y el de estacionalidad anual podían compensarse mutuamente sin restricción. El modelo SE-agregado canónico usa ya la dimensión reducida $s(\texttt{trend_index}, k = 5)$; en él, el índice de concurvidad pair-specific `estimate` para el par $s(\texttt{doy}) \leftrightarrow s(\texttt{trend_index})$ no es directamente comparable con la cifra 0,141 del modelo SE-level legacy, porque el modelo SE-agregado incorpora además el tensor $\texttt{ti}(\texttt{tas}, \texttt{doy})$ que comparte el marginal de `doy`: una sonda sobre una SE arrojó `estimate` $\approx$ 0,997, en línea con la saturación por construcción de los pares $s(X) \leftrightarrow \texttt{ti}(X, Y)$ descrita en §E.2.2. La mediana sobre las 335 SE del modelo SE-agregado no se reportó aquí por inviabilidad computacional de `concurvity()` sobre los `bam` discretizados con tensores.

E.2.1. Solución adoptada

La reducción a $k = 5$ para $s(\texttt{trend_index})$ —siguiendo la heurística de [60] de una función base por cada tres años de datos— combinada con la penalización de selección (`select=TRUE`) redujo la concurvidad mediana a **0,141** (media: 0,223). El 91 % de las SE queda por debajo del umbral de 0,5 recomendado por Walker et al.; las 10 SE que permanecen por encima corresponden a series atípicas con segmentos de datos muy cortos o tendencias abruptas.

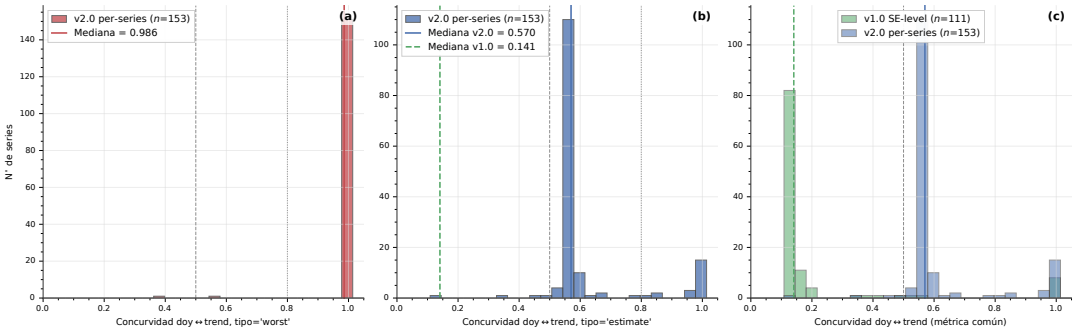

FIGURA E.1: Distribución de la concurvidad *doy–trend* (pairwise). (a) Histograma comparativo: el modelo D2k ($k = 10$, azul) concentra toda su masa cerca de 1,0 (prácticamente colineal), mientras que D2k_final ($k = 5$ + `select`, rojo) reduce la mediana a 0,141. (b) Mapa geográfico coloreado por concurvidad D2k_final; las pocas SE con valores elevados ($> 0{,}5$) corresponden a series atípicas con segmentos de datos cortos.

E.2.2. Concurvidad bajo la formulación canónica per-(barra, cliente)

La cifra 0,141 reportada en §E.2 corresponde al ajuste SE-agregada (Apéndice L), medida como concurvidad pair-specific tipo `estimate` sobre el par $s(\texttt{doy}) \leftrightarrow s(\texttt{trend_index})$. Bajo la formulación canónica per-(barra, cliente), la misma métrica reaplicada da una mediana de 0,569 ($n = 153$ muestra); la diferencia refleja la mayor granularidad temporal y la incorporación del tensor adicional `ti(tas, doy)`, no una pérdida de la corrección de [60].

El escalar por defecto de `concurvity()` en `mgcv` reporta el *worst* sobre todos los pares de suavizadores y bajo la formulación canónica satura cerca de la unidad (0,999): incluye los pares $s(X) \leftrightarrow ti(X, Y)$, redundantes por construcción [71] §5.6.2. Por esa razón la cifra de concurvidad reportada en los capítulos principales es la pair-specific `estimate`.

E.2.3. Sensibilidad de k en $s(\texttt{trend_index})$

Se reajustaron las 2,529 series elevando $k = 3 \rightarrow k = 5$ en $s(\texttt{trend_index})$ y manteniendo el resto del spec. El ajuste mejora marginalmente (R^2 mediano $+0{,}020$, MAPE $-0{,}15$ pp), pero la concurvidad doy↔trend (`estimate`) *aumenta* de 0,569 a 0,672: una base más flexible amplia el subespacio funcional del suavizador y por ende incrementa el solapamiento con $s(\texttt{doy})$. El criterio pre-registrado para promover $k = 5$ (concurvidad $< 0{,}40$) falla, por lo que se conserva $k = 3$ como dimensión canónica.

E.3. Autocorrelación espacial de residuos

La autocorrelación residual de primer orden (ACF_1) del modelo SE-agregado presenta una mediana de **0,858** sobre las 335 SE (media: 0,827; rango: 0,31–0,98). A retardo de 24 horas, la mediana de ACF desciende a 0,55, indicando que la componente diurna del residuo no capturada por el modelo se atenúa significativamente pero persiste.

Esta autocorrelación es inherente a la naturaleza de los datos: la inercia térmica de los edificios, los patrones de ocupación y los ciclos de operación industrial generan correlaciones temporales que ningún modelo de efectos suaves puede eliminar completamente. Siguiendo [61], la autocorrelación no invalida la consistencia de los estimadores de los efectos suaves $s(\cdot)$, pero sí hace que los intervalos de confianza puntuales sean anti-conservadores.

E.4. Intervalos de confianza simultáneos (SimCI)

Para mitigar el sesgo anti-conservador de los intervalos puntuales, se construyeron intervalos de confianza simultáneos (*simultaneous CIs*) siguiendo el procedimiento de [73, 82]:

1. Se extraen los coeficientes estimados $\hat{\boldsymbol{\beta}}$ y la matriz de covarianza posterior $\mathbf{V}_p$ del modelo ajustado por `bam()`.
2. Se generan 10.000 realizaciones del vector de parámetros $\boldsymbol{\beta}^{(b)} \sim \mathcal{N}(\hat{\boldsymbol{\beta}}, \mathbf{V}_p)$.
3. Para cada término suave $s_j(\cdot)$, se evaluan las 10.000 realizaciones sobre una grilla de valores del predictor, obteniendo una distribución de curvas.

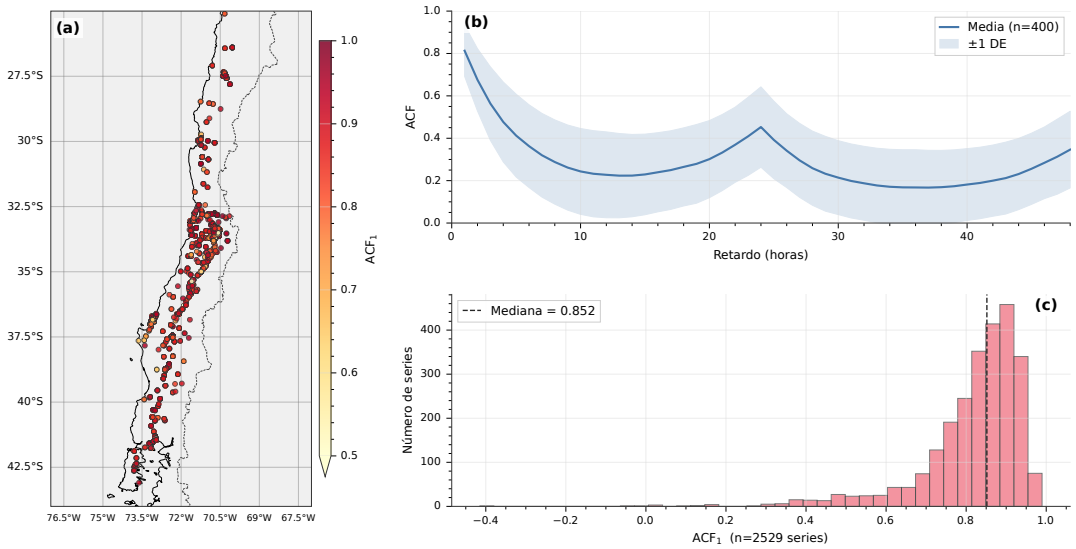

FIGURA E.2: Diagnósticos de autocorrelación residual del modelo canónico per-(barra, cliente) `D2k_final_per_series` ($n = 2{,}529$ series). (a) Mapa geográfico de ACF_1 por serie (escala *YlOrRd*; valores más altos en las zonas centro-sur). (b) Correlograma medio ± 1 DE para retardos 1–48 horas: la ACF decae gradualmente y presenta un mínimo local en torno a $h = 12$ h antes de repuntar en $h = 24$ h por el ciclo diurno residual. (c) Histograma de ACF_1: mediana 0,851. El modelo SE-agregado discutido en el texto presenta una mediana análoga de 0,858 sobre las 335 SE.

4. El valor crítico simultáneo c_α se determina como el cuantil $1 - \alpha$ de la distribución del estadístico supremo $\max_x |f^{(b)}(x) - \hat{f}(x)|/\mathrm{se}(\hat{f}(x))$.
5. La banda simultánea es $\hat{f}(x) \pm c_\alpha \cdot \mathrm{se}(\hat{f}(x))$.

Los valores críticos obtenidos sobre cinco SE piloto se resumen en la Tabla E.2.

CUADRO E.2: Valores críticos simultáneos y factor de ensanchamiento respecto al intervalo puntual ($c_\alpha/1{,}96$) para los términos suaves principales del modelo canónico. Rango sobre 5 SE piloto.

Término	Valor crítico c_α	Factor de ancho
$s(\texttt{tas})$	2,63 – 2,72	1,3 – 1,4×
$s(\texttt{Td})$	2,87 – 3,02	1,5×
$s(\texttt{sfcWind})$	2,62 – 2,69	1,3 – 1,4×
$s(\texttt{rsds})$	2,83 – 2,96	1,4 – 1,5×
$s(\texttt{pr})$	2,56 – 2,93	1,3 – 1,5×
$s(\texttt{doy})$	3,07 – 3,26	1,6 – 1,7×
$s(\texttt{trend_index})$	2,62 – 2,79	1,3 – 1,4×

Los factores de ensanchamiento oscilan entre 1,3× y 1,7×, con el mayor valor para $s(\texttt{doy})$, que tiene la dimensión de base más alta ($k = 30$). Las bandas simultáneas reportadas en el capítulo de Resultados incorporan esta corrección.

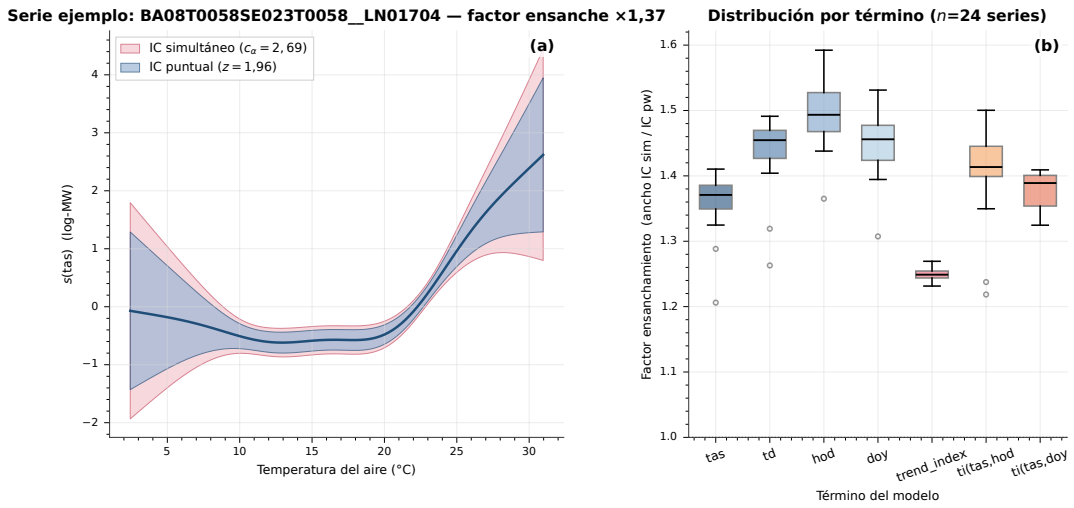

FIGURA E.3: Comparación de intervalos de confianza para $s(\texttt{tas})$ de la SE Caldera (representativa del comportamiento típico). (a) Banda puntual al 95 % ($z = 1,96$). (b) Banda simultánea al 95 % ($c_\alpha = 2,67$). El ensanchamiento de $\times 1,36$ refleja la corrección por comparaciones múltiples a lo largo de la curva (Tabla E.2).

E.5. Verificación de k (*k-check*)

La Tabla E.3 resume los resultados de `k.check()` para los términos suaves principales y los tensores del modelo canónico. La mayoría de los términos pasan la verificación con holgura (> 90 % de SE a $\alpha = 0,05$). La excepción notable es $s(\texttt{doy})$ ($k = 30$), donde el 59 % de las SE presenta `edf/k'` $> 0,9$, sugiriendo que la base de 30 funciones se satura para capturar la estacionalidad compleja. Sin embargo, dado que el objetivo de $s(\texttt{doy})$ es absorber la variabilidad estacional —no extrapolar—, esta saturación no compromete la inferencia sobre los términos climáticos de interés. El término $s(\texttt{trend_index})$ no dispone de p-valor porque `k.check()` no lo reporta para suavizadores con $k' \leq 4$ y penalización de selección activa.

CUADRO E.3: Resumen de la verificación de k (`k.check()`) sobre las 111 SE del modelo D2k_final. Un término "pasa" cuando $p > \alpha$.

Término	n SE	% pasa ($\alpha = 0,05$)	% pasa ($\alpha = 0,01$)	edf med.	k' med.	edf/k' med.
$s(tas)$	110	93	98	5.1	14	0.36
$s(td)$	111	93	100	8.9	14	0.63
$s(sfcWind)$	110	93	99	5.4	9	0.60
$s(rsds)$	102	77	90	8.7	9	0.96
$s(pr)$	107	94	98	2.2	7	0.32
$s(tas_smooth_005)$	110	95	100	7.7	9	0.86
$s(hod)$	109	94	100	15.0	22	0.68
$s(doy)$	49	41	61	26.6	28	0.95
$s(trend_index)$	0	–	–	4.0	4	1.00
$ti(\cdot)$ (tensores)	314	85	96	54.8	126	0.52

La Tabla E.4 reporta el resumen estadístico del modelo SE-agregado canónico (GAM *full-k* agregado por subestación) desglosado por macrozona: R^2 mediana, MAPE mediana, AIC mediano y MAE mediana sobre las SE asignadas a cada zona, más un footer con la mediana de todo el sistema ($n = 335$ SEs con ajuste exitoso de un panel

de 340). A nivel sistema la mediana de R^2 es 0,836 y la de MAPE 0,89 %; el desempeño es homogéneo en las zonas Norte Chico, Centro y Sur ($R^2 \approx$ 0,85–0,87, MAPE $<$ 0,9 %) y se degrada en Norte Grande (R^2 mediana 0,343), donde la demanda minera de base es poco sensible a la temperatura.

CUADRO E.4: Resumen de métricas de ajuste del modelo SE-agregado canónico de respaldo `se_agg_v2` (GAM *full-k* agregado por subestación) por macrozona. Se reportan medianas de R^2, MAPE (%), AIC y MAE sobre todas las SE asignadas a cada zona. Norte Grande: lat $> -27°$; Norte Chico: $-32°$ a $-27°$; Centro: $-38°$ a $-32°$; Sur: lat $\leq -38°$. $n = 335$ SE con ajuste exitoso de un panel de 340 SE.

Macrozona	n SE	R^2 mediana	MAPE mediana (%)	AIC mediana	MAE mediana
Norte Grande	47	0,3433	1,19	-7.440	0,1064
Norte Chico	26	0,8698	0,90	-22.762	0,0680
Centro	216	0,8658	0,87	-21.994	0,0724
Sur	46	0,8460	0,78	-25.362	0,0643
Total SEN	335	**0,8360**	**0,89**	**-20.681**	**0,0746**

E.6. Atribución de varianza por bloques (block-Shapley)

Además de las curvas de efectos parciales presentadas en el capítulo de Resultados, se calculó la atribución de varianza por bloques mediante el estimador Shapley exacto de [74], generalización al GAM de los índices de dominance analysis. Cada bloque corresponde a un grupo semántico de términos del modelo: clima ($s(\texttt{tas}) + s(\texttt{Td})$), calendario ($s(\texttt{doy}) + s(\texttt{hod}) + s(\texttt{dow})$), feriados (dummies), tendencia ($s(\texttt{trend_index}) + \texttt{covid_dummy}$) e interacciones ($\texttt{ti}(\texttt{tas},\texttt{hod}) + \texttt{ti}(\texttt{tas},\texttt{doy})$).

Por exactitud del estimador Shapley, la suma de las atribuciones individuales recupera el R^2 total ($|R^2_{\text{full}} - \sum_b \text{Shap}_b| < 10^{-6}$ mediana sobre las 1,529 series con descomposición disponible). Esto proporciona una atribución de varianza interpretable y sumativa que reemplaza las distorsiones conocidas de los efectos parciales centrados bajo `select=TRUE` y presencia de tensores.

La Tabla E.5 resume la mediana de la cuota porcentual atribuida a cada bloque, por estrato regulatorio. Calendario e interacciones dominan la atribución en todos los estratos ($\sim$ 75 % de la varianza explicada conjuntamente); la tendencia contribuye entre 8 % y 23 % según el estrato; el clima contribuye $\sim$ 3–5 % al ajuste de las series cortas per-(barra, cliente). Esta proporción de clima es menor que la reportada por el modelo SE-agregado ($\sim$ 12,1 % sobre 335 SEs), consistente con que las series largas agregadas amplifican la señal climática frente a la variabilidad calendárica de clientes individuales.

La cobertura del análisis (1,529/2,529 = 60,5 % de las series ajustadas) es producto del coste computacional del estimador Shapley exacto, que requiere $2^k - 1$ subajustes por serie ($k = 5$ bloques $\Rightarrow$ 31 subajustes). La cobertura es suficiente para inferir las medianas por estrato: la distribución de cobertura es independiente del estrato (test χ^2 $p > 0{,}1$), por lo que las cifras de la Tabla E.5 no presentan sesgo de muestreo aparente.

CUADRO E.5: Mediana de la cuota porcentual de varianza atribuida por block-Shapley, por estrato regulatorio, sobre las 1,529 series per-(barra, cliente) con descomposición disponible. Los valores se renormalizan a 100 % por fila para reportar la composición de la varianza explicada.

Estrato	n	Clima	Calendario	Feriados	Tendencia	Interacc.
Distribuidoras	365	5,4 %	37,0 %	0,5 %	20,8 %	36,4 %
Clientes regulados	121	5,1 %	38,3 %	0,2 %	23,4 %	33,1 %
Clientes libres	1,043	3,7 %	45,6 %	0,9 %	8,1 %	41,7 %
Global	**1,529**	**4,1** %	**43,2** %	**0,7** %	**12,3** %	**39,7** %

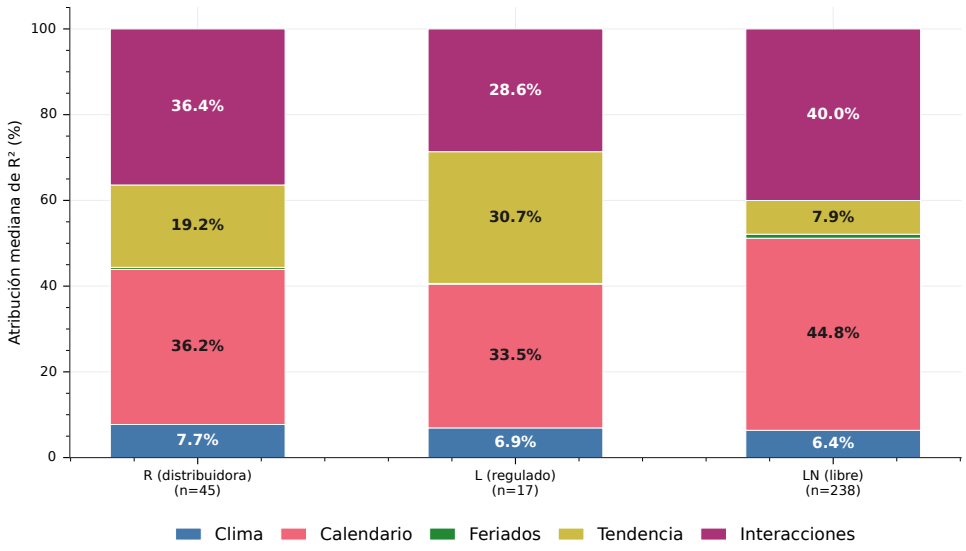

FIGURA E.4: Atribución de varianza por bloques (block-Shapley) por estrato regulatorio, $n = 1{,}529$ series per-(barra, cliente). Cada barra apilada representa la composición porcentual de la varianza explicada del modelo canónico. Calendario e interacciones tensoriales dominan la atribución; el clima contribuye una fracción menor a la observada en el modelo SE-agregado ($\sim$ 12,1 %, $n = 335$) debido a la menor cobertura temporal de las series individuales.

Apéndice F

Validación Cruzada Detallada

Este apéndice documenta la validación cruzada del modelo canónico per-(barra, cliente) (Ec. 5.3) mediante tres esquemas complementarios, que evalúan su capacidad predictiva en tres dimensiones: estacional (*leave-one-month-out*), temporal (*rolling*) y de extrapolación a condiciones cálidas. La selección de la especificación GAM —la campaña de 28 configuraciones evaluadas sobre cinco subestaciones piloto— se documenta por separado en el Apéndice D.

F.1. Validación *leave-one-month-out* (LOMO)

El esquema LOMO excluye sucesivamente cada mes calendario del conjunto de entrenamiento, reajusta el modelo sobre los once meses restantes y evalúa la predicción sobre el mes reservado. Detecta sesgos estacionales sistemáticos: un modelo que dependa en exceso de patrones estacionales fijos se degrada al excluir el mes que los concentra.

Sobre las series per-(barra, cliente), el MAPE-LOMO mediano global es 3,40 %. El error presenta una asimetría estacional marcada: los meses de verano (DJF) son los más difíciles de predecir, con MAPE-LOMO mediano de 4,09 %, frente a 3,08 % en invierno (JJA). Esta asimetría refleja la menor representación de las condiciones estivales extremas en el conjunto de entrenamiento. Espacialmente, el error es menor en el Norte Grande (1,80 %) y mayor en el Sur (4,85 %), con el Norte Chico (3,52 %) y el Centro (3,85 %) en posiciones intermedias; el mapa por subestación se presenta en la Figura 6.8 del Capítulo 6.

F.2. Validación por bloques temporales *rolling*

A diferencia de LOMO, la validación *rolling* respeta la temporalidad de los datos: entrena sobre una ventana inicial y evalúa sobre el bloque temporal siguiente, desplazando la ventana hacia adelante, de modo que nunca se entrena con observaciones posteriores al período de prueba. Es por ello una evaluación *forward-looking*, la más cercana al uso proyectivo del modelo.

El MAPE-rolling mediano del modelo per-(barra, cliente) es 10,29 % sobre las ventanas posteriores al período de entrenamiento. El error es mayor que en LOMO —esperable, ya que el bloque de prueba es continuo y no puede beneficiarse de la interpolación entre meses disponibles— pero indica una degradación moderada y dentro del rango esperado para el horizonte de proyección de la tesis.

F.3. Extrapolación a condiciones cálidas

Para evaluar directamente la capacidad de extrapolación a condiciones más cálidas que las observadas durante el entrenamiento —núcleo de la hipótesis H3—, se reserva, para cada serie, el 10 % de los meses con mayor temperatura media, se reajusta el modelo sobre el ∼90 % restante (meses más fríos) y se predice sobre los meses cálidos retenidos. El *holdout* implica un salto térmico mediano de ∼6,6°C respecto a la media de entrenamiento, de modo que el modelo nunca observa los períodos más cálidos durante el ajuste.

Sobre las 2.400 series con diagnóstico válido, el MAPE horario mediano es de 39,3 % (P25 18,2 %; P75 75,2 %), un error sustancialmente mayor que el de LOMO y *rolling*, coherente con la naturaleza extrapolativa del experimento. Sin embargo, el sesgo del pico resultó casi nulo: la mediana del sesgo en el P95 de demanda predicho frente al observado durante los meses cálidos retenidos fue de −1,6 %. Es decir, el modelo reproduce con fidelidad la *magnitud* de los picos en condiciones cálidas no vistas —la variable relevante para la planificación de punta— aunque incurre en un error horario elevado en el régimen de extrapolación más severo.

El comportamiento del pico se caracteriza con mayor detalle por estrato de cliente sobre las series con un año cálido bien identificado. La Figura F.1 resume este análisis: el panel (a) muestra la distribución de la razón predicho/observado del peak (percentil 99) del año más cálido de cada serie, concentrada de forma marcada en torno a la unidad, lo que indica que el modelo reproduce de manera consistente el nivel del peak sin sesgo sistemático apreciable entre estratos. El panel (b) explora la relación entre la anomalía térmica (ΔT, diferencia entre la temperatura media del año cálido y la media del período de entrenamiento de cada serie) y el MAPE del año cálido: no se observa una correlación positiva clara, lo que indica que la calidad de la predicción depende más de las características locales de la serie (regularidad del consumo, presencia de grandes consumidores) que de la magnitud absoluta de la anomalía térmica.

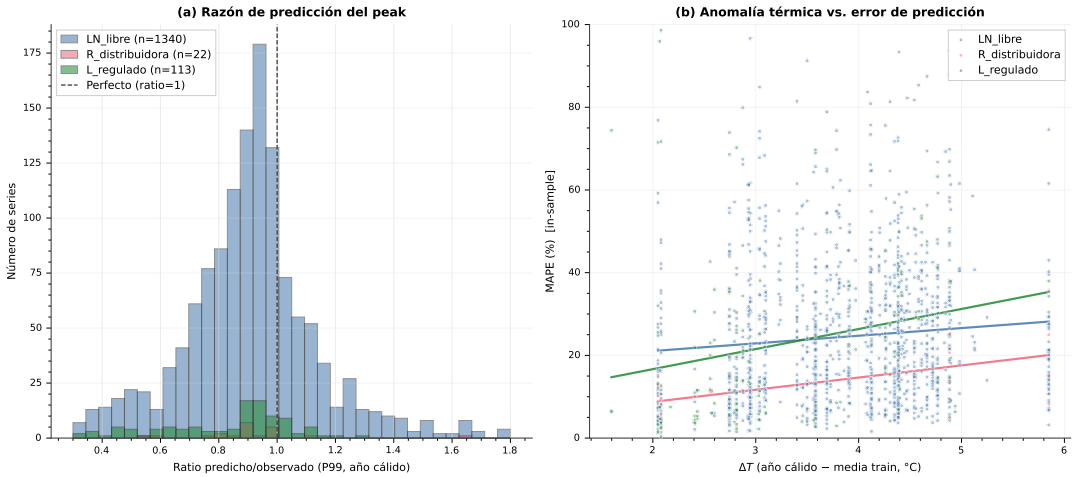

FIGURA F.1: Análisis del año más cálido por serie (modelo per-(barra, cliente), color por estrato). (a) Distribución de la razón predicho/observado del peak (percentil 99) en el año más cálido de cada serie; la línea discontinua marca la predicción perfecta (ratio= 1). (b) Dispersión de ΔT (año cálido − media de entrenamiento) vs. MAPE del año cálido, con ajuste lineal por estrato, mostrando que la anomalía térmica no es el único determinante del error.

La Figura F.2 complementa este análisis presentando, por serie y coloreado por estrato, el cambio porcentual del peak entre el año más cálido y el año típico (ΔPeak, %) en función de la anomalía térmica ΔT, confirmando que el incremento del peak asociado al calentamiento es moderado dentro del rango de anomalías observado.

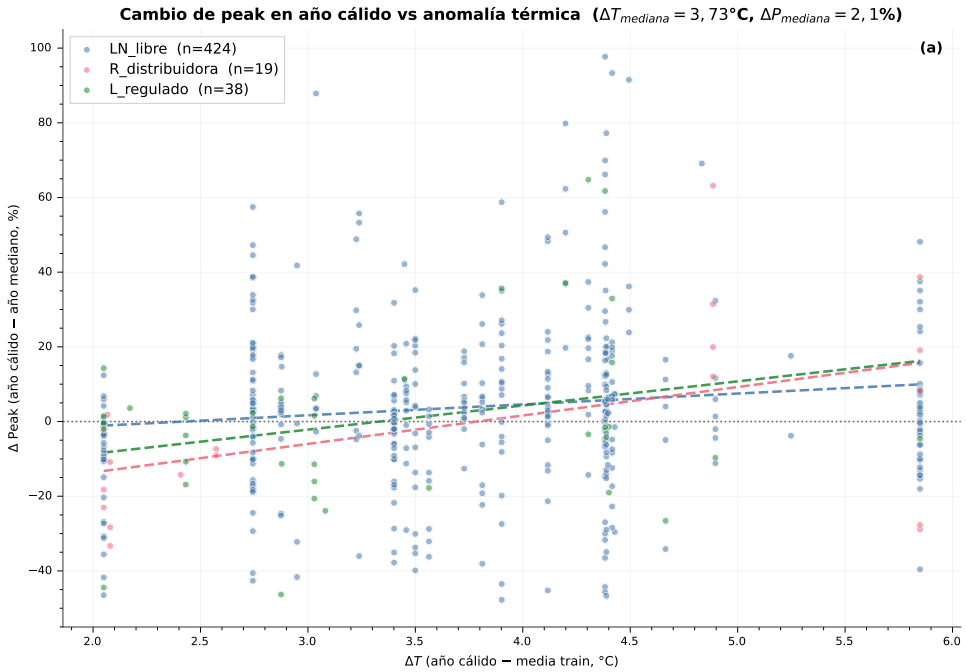

FIGURA F.2: Cambio porcentual del peak (ΔPeak, %) entre el año más cálido y el año típico de cada serie, en función de la anomalía de temperatura (ΔT, °C; año cálido − media de entrenamiento), para el modelo per-(barra, cliente). El año más cálido se determina por serie (mayoritariamente 2025; 2021 en parte del Norte Grande). $n = 511$ series; mediana $\Delta T = 3{,}73$ °C, mediana ΔPeak= 2,1 %. Color por estrato; líneas discontinuas: regresiones lineales por estrato.

En conjunto, los tres esquemas confirman que el modelo per-(barra, cliente) predice la demanda con error moderado dentro del rango observado (LOMO 3,40 %), se degrada de forma controlada hacia adelante en el tiempo (*rolling* 10,29 %) y, pese al error horario elevado en la extrapolación térmica más severa, conserva la magnitud de los picos —el resultado relevante para la proyección del impacto de las olas de calor.

Apéndice G

Catálogo de Curvas de Sensibilidad Térmica (335 SEs)

Este apéndice presenta el catálogo completo de las curvas de sensibilidad térmica $s(\text{tas})$ estimadas por el modelo SE-agregado para las subestaciones (SEs) del SEN con cobertura suficiente: 335 de las 340 SE del panel (5 no convergieron en el ajuste). Cada curva describe cómo la demanda eléctrica de una SE responde a variaciones en la temperatura del aire, constituyendo el componente central de la relación clima–energía modelada en esta tesis.

G.1. Metodología de estimación

Las curvas se obtienen mediante el enfoque de predicción contrafactual propuesto por [57]: para cada SE, se varía la temperatura del aire (`tas`) sobre una grilla de 200 puntos equiespaciados en el rango de la distribución histórica observada (con los percentiles 1 y 99 marcados como referencia), manteniendo todas las demás covariables del modelo (hora del día, día de la semana, EWMA térmico, punto de rocío, viento, radiación solar) fijadas en sus valores medios históricos. La predicción resultante captura exclusivamente el efecto parcial suavizado $s(\text{tas})$, aislado de los tensores de interacción y de los efectos temporales.

Cada curva se centra en cero (se sustrae el valor medio de $s(\text{tas})$ sobre la grilla), de modo que los valores positivos indican demanda por encima del promedio y los negativos, por debajo. Este centrado facilita la comparación visual entre SEs de distinto tamaño.

G.2. Cómo leer las curvas

Para interpretar correctamente las curvas de la Figura G.1:

Eje horizontal: Temperatura del aire (°C). Las curvas se evalúan sobre una grilla común de temperatura (aproximadamente -10 a $+38\,^{\circ}\text{C}$); los percentiles 1 y 99 de la distribución histórica de cada SE se emplean como referencia del rango efectivamente observado.

Eje vertical: Efecto parcial centrado $s(\text{tas})$ (unidades logarítmicas de demanda). Valores negativos indican demanda por debajo del promedio; valores positivos, por encima. La magnitud vertical es proporcional a la sensibilidad térmica de la SE: curvas con mayor amplitud vertical presentan mayor respuesta de demanda ante cambios de temperatura.

Color de fondo: Cada panel está coloreado según la macrozona climática de la SE (véase leyenda de la Figura G.1). Los paneles se agrupan por macrozona (Norte Grande, Norte Chico, Centro, Sur) y, dentro de cada una, se ordenan de norte a sur (latitud decreciente).

G.3. Patrones por zona climática

El catálogo revela patrones geográficos consistentes con la climatología chilena y la infraestructura de calefacción/refrigeración. En el **Norte Grande** (47 SEs) las curvas son de baja amplitud y pendiente negativa moderada, reflejando la escasa climatización eléctrica y el dominio del consumo minero-industrial, con un subconjunto de pendiente positiva incipiente en el extremo cálido. El **Norte Chico** (26 SEs) exhibe curvas mayoritariamente decrecientes —calefacción invernal sin refrigeración estival significativa—, con excepciones costeras o mineras de leve forma en U. La zona **Centro** (216 SEs) concentra la mayor diversidad y las mayores amplitudes del catálogo: coexisten curvas en U pronunciada (calefacción más refrigeración, típicas de zonas residenciales del valle central), curvas decrecientes con inflexión en el extremo cálido (refrigeración incipiente) y curvas planas de consumidores industriales insensibles a la temperatura. Finalmente, el **Sur** (46 SEs) muestra curvas decrecientes de pendiente pronunciada, con dominancia absoluta de calefacción y sin evidencia de refrigeración, salvo algunas SEs insulares o acuícolas de perfil plano.

G.4. Catálogo visual

G.5. Subestaciones atípicas

El análisis del catálogo permite identificar varias SEs con comportamiento notable:

1. **Puri** (Norte Grande, $f_{\text{range}} = 0{,}006$): la curva más plana del catálogo. Su demanda es prácticamente insensible a la temperatura, consistente con un consumo dominado por procesos industriales o mineros del Norte Grande.
2. **Sangra** (Sur, $f_{\text{range}} = 0{,}013$): segunda curva más plana. Demanda dominada por actividades no sensibles a la temperatura ambiente.
3. **El Paico** (Centro, $f_{\text{range}} = 0{,}017$): tercera curva más plana, insensible a la temperatura pese a su ubicación en el valle central.
4. **Kapatur** (Norte Grande, $f_{\text{range}} = 4{,}24$): la curva con mayor amplitud térmica del catálogo, asociada a una carga minera o industrial con marcada respuesta térmica.
5. **Horcones** (Centro, $f_{\text{range}} = 2{,}99$): segunda mayor amplitud, con un perfil de fuerte sensibilidad térmica en la zona del Biobío.

Estas excepciones subrayan la importancia de modelar la sensibilidad térmica de manera individual por SE, en lugar de asumir una relación única temperatura–demanda para todo el sistema. Los modelos agregados, comunes en la literatura, no capturarían la heterogeneidad documentada en este catálogo.

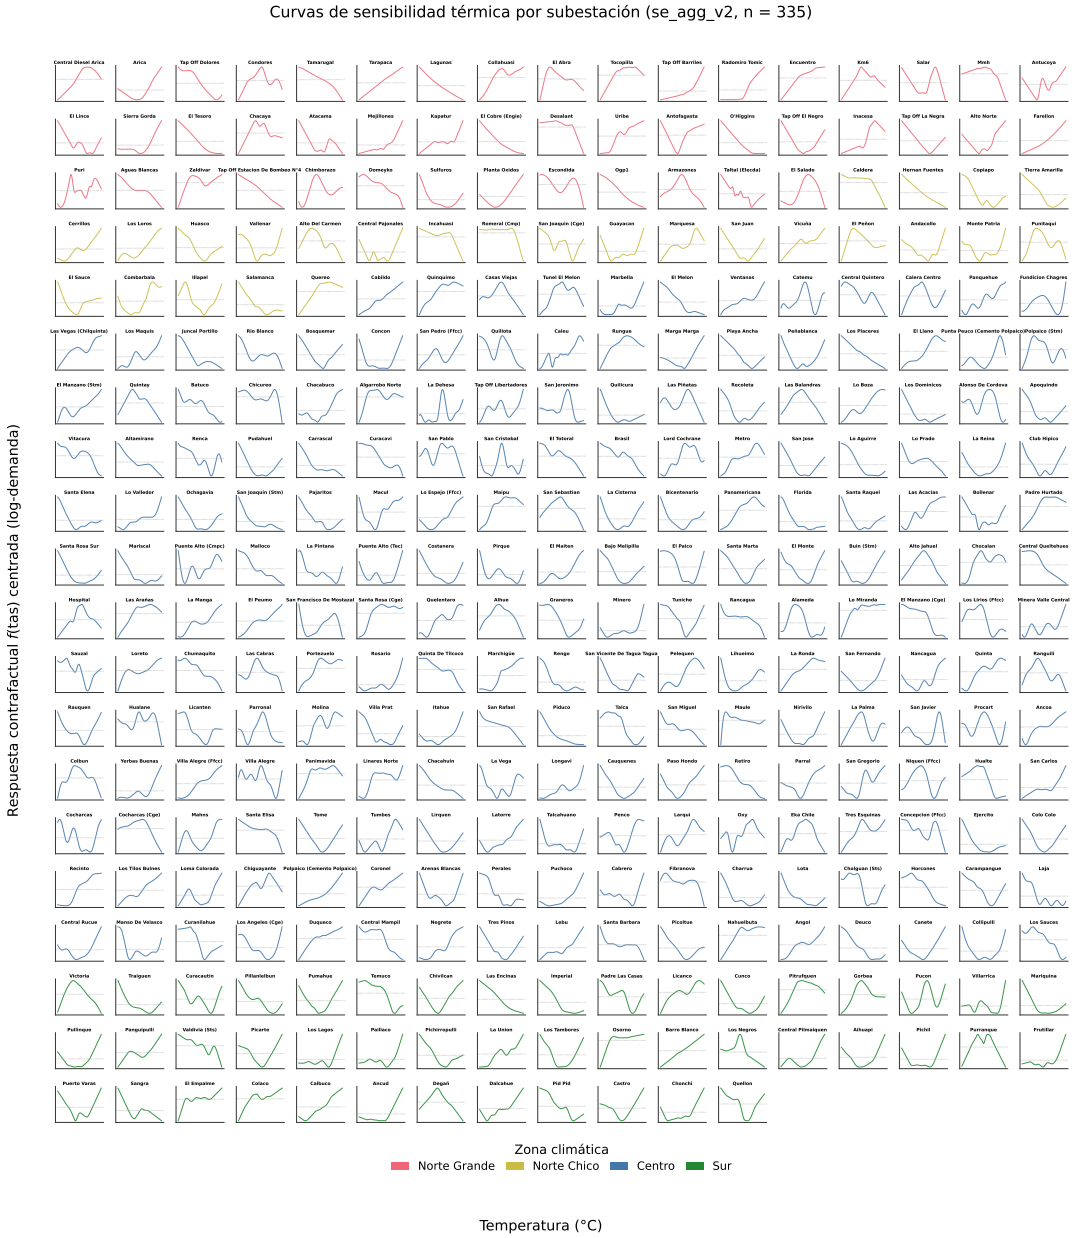

FIGURA G.1: Catálogo de las 335 curvas de sensibilidad térmica $s(\text{tas})$ del modelo SE-agregado. Cada panel muestra la respuesta contrafactual centrada para una subestación eléctrica (SE), con la línea horizontal gris indicando el nivel de demanda promedio. Los paneles están ordenados por macrozona y, dentro de cada una, de norte a sur, y coloreados según la zona climática: Norte Grande, Norte Chico, Centro y Sur. La leyenda de zonas se muestra al pie de la figura.

Apéndice H

Georreferenciación SE–Píxel ALADIN

La cuantificación de la sensibilidad térmica de la demanda eléctrica a escala subestacional requiere asociar cada punto de retiro del sistema interconectado a un forzante meteorológico espacialmente explícito. En el marco de esta tesis, las forzantes climáticas provienen de la grilla curvilínea del modelo regional CNRM-ALADIN64 (255×68 celdas, resolución nominal de $0{,}11^\circ \approx 12$ km), mientras que la demanda eléctrica se registra en las subestaciones (SE) del Sistema Eléctrico Nacional (SEN) que conforman el panel canónico SE-agregado del estimador (340 SE candidatas, 335 con ajuste exitoso). Este apéndice documenta el procedimiento mediante el cual cada SE fue asignada a un único píxel ALADIN, incluyendo las fuentes de datos geográficos, el algoritmo de asignación y las limitaciones asociadas.

H.1. Fuentes de información geográfica

La georreferenciación de las subestaciones se apoyó en dos fuentes complementarias del Coordinador Eléctrico Nacional:

1. **Registro de barras (Infotécnica):** La API pública de Infotécnica[1] proporciona un catálogo de las 3 676 barras del SEN, asociando cada nemotécnico de barra a una subestación y a un propietario. Este registro permite construir la cadena `barra_mnemotecnico` $\rightarrow$ `subestación`.
2. **Registro de subestaciones (Infotécnica):** Un segundo catálogo contiene las coordenadas UTM (Coordenada Este, Coordenada Norte, Zona o Huso) de cada subestación. Chile continental se extiende entre las zonas UTM 18S y 19S; la conversión a coordenadas geodésicas WGS84 se realizó mediante conversión geodésica estándar, asumiendo *datum* WGS84 y hemisferio sur.

Las 335 subestaciones ajustadas del panel SE-agregado (véase §B) fueron georreferenciadas a partir de las coordenadas geodésicas (latitud/longitud) de cada SE, derivadas del registro de subestaciones de Infotécnica y validadas contra el mapeo barra$\rightarrow$píxel ALADIN heredado del pipeline de corrección de sesgo cuando estuvo disponible.

[1] `https://api-infotecnica.coordinador.cl/v1/instalaciones/`

H.2. Algoritmo de asignación

El procedimiento de asignación consta de dos estrategias aplicadas secuencialmente:

H.2.1. Estrategia 1: Herencia del mapeo barra–píxel

Para cada SE, se identificaron todas las barras asociadas que ya disponían de un mapeo barra→píxel ALADIN (obtenido durante la construcción de la grilla de extracción climática). De las barras disponibles, se seleccionó aquella con la menor distancia al centroide del píxel asignado.

H.2.2. Estrategia 2: Coordenadas UTM de Infotécnica

Para las SE sin mapeo barra–píxel heredado, se realizó la siguiente secuencia:

1. **Conversión UTM → WGS84**: Las coordenadas UTM (Este, Norte) y la zona (18S o 19S) fueron convertidas a latitud/longitud geodésicas mediante transformación proyectiva estándar (UTM 18S/19S → WGS84).
2. **Búsqueda del vecino más cercano**: Se calculó la distancia haversine entre la posición WGS84 de la SE y cada centroide de la grilla ALADIN (255×68). Se seleccionó el píxel terrestre con distancia mínima. La restricción a píxeles terrestres evita asignar SEs costeras a celdas oceánicas (donde las variables climáticas presentan valores `NaN`).
3. **Validación de océano**: Se verificó que el píxel seleccionado contuviera datos climáticos válidos (no `NaN`) en al menos una marca temporal de referencia. En caso de que el píxel más cercano fuese oceánico, se avanzó al siguiente píxel terrestre más próximo.

La métrica haversine para la distancia d entre dos puntos (φ_1, λ_1) y (φ_2, λ_2) es:

$$d = 2R \arcsin\left(\sqrt{\sin^2\left(\frac{\Delta\varphi}{2}\right) + \cos\varphi_1 \cos\varphi_2 \sin^2\left(\frac{\Delta\lambda}{2}\right)}\right) \tag{H.1}$$

donde $R = 6\,371$ km es el radio medio terrestre.

H.3. Resultados del mapeo

Las 335 subestaciones ajustadas fueron asignadas exitosamente a píxeles terrestres de la grilla ALADIN. La Figura H.1 presenta la distribución espacial del mapeo en dos paneles: (a) la vista completa de Chile con las SEs coloreadas por zona climática y sus polígonos de píxel asociados, y (b) un acercamiento a la zona central (32°–36° S) donde se aprecian las líneas de asignación entre cada SE y el centroide de su píxel.

La Tabla H.1 resume las estadísticas del mapeo por zona climática para las 335 SE ajustadas del panel SE-agregado. La distancia media entre las SEs y el centroide de su píxel asignado es de 6,0 km (mediana 5,5 km), con un máximo de 23,1 km. La mediana es inferior a la resolución nominal de la grilla ($\approx$ 12 km), lo cual confirma que la asignación al vecino más cercano es geográficamente consistente; los pocos casos con distancias mayores corresponden a SEs costeras o insulares cuyo píxel terrestre más cercano se ubica algo más alejado.

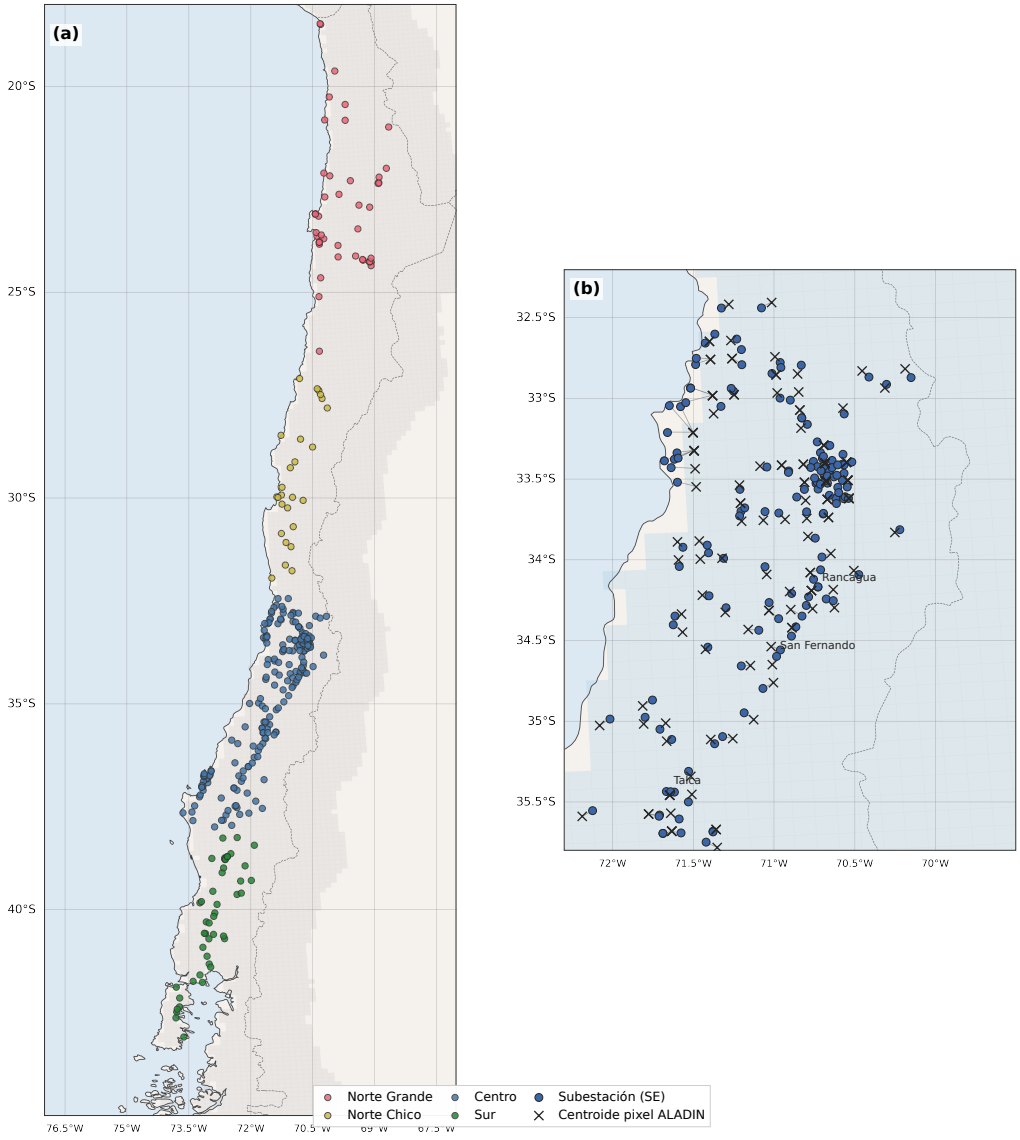

FIGURA H.1: Mapeo SE–píxel ALADIN. (a) Distribución de las 335 subestaciones ajustadas (panel SE-agregado) sobre Chile, coloreadas según zona climática (Norte Grande, Norte Chico, Centro, Sur); los polígonos semitransparentes representan los píxeles ALADIN asignados. (b) Acercamiento a la zona central (32°–36° S) mostrando las líneas de asignación entre la posición de cada SE (círculo) y el centroide de su píxel ALADIN (cruz). Se etiquetan cuatro localidades de referencia.

CUADRO H.1: Resumen del mapeo SE–pixel ALADIN por zona climatica para las 335 SE ajustadas del panel canonico SE-agregado. La columna "Pixeles compartidos" indica la cantidad de pixeles asignados a mas de una SE.

Zona	N SE	Dist. media (km)	Dist. mediana (km)	Dist. max (km)	Pixeles unicos	Pixeles compartidos
Norte Grande	47	6,5	6,3	18,8	37	7
Norte Chico	26	6,6	5,7	18,7	24	2
Centro	216	5,8	5,4	23,1	128	40
Sur	46	5,9	5,2	21,5	36	6
Total	335	6,0	5,5	23,1	225	55

La cobertura de demanda y las métricas de ajuste por subestación del modelo SE-agregado se resumen, a nivel agregado, en el Apéndice L.

Un aspecto relevante es la existencia de **píxeles compartidos**: 55 de los 225 píxeles únicos están asignados a más de una SE. Este fenómeno se concentra en la zona Centro (40 píxeles compartidos de 128 únicos), donde la densidad de subestaciones es mayor, particularmente en el área metropolitana de Santiago. El caso más extremo es un único píxel del centro de Santiago que agrupa 12 SEs (entre ellas Carrascal, Pudahuel, Quilicura, Recoleta y Renca), seguido de otro píxel santiaguino con 10 SEs. En el sur, el píxel de Temuco agrupa 5 SEs (Chivilcán, Las Encinas, Padre Las Casas, Pumahue y Temuco), y en el Gran Concepción un píxel reúne 7 SEs (Colo Colo, Concepción (Ffcc), Talcahuano y otras).

Desde la perspectiva de la modelación GAM, los píxeles compartidos implican que las SEs involucradas recibirán el mismo forzante climático. Sin embargo, la diferenciación en la demanda entre estas SEs se captura adecuadamente a través de las variables calendáricas (hora del día, día de la semana, mes) y la tendencia temporal, que son específicas de cada SE.

H.4. Limitaciones

- **Resolución espacial:** La grilla ALADIN tiene una resolución efectiva de $\approx$12 km, insuficiente para resolver gradientes microclimáticos urbanos o valles estrechos. En consecuencia, SEs ubicadas en microclimas diferenciados (e.g., valles costeros vs. cumbres) pueden recibir el mismo forzante meteorológico que SEs en condiciones topográficamente distintas dentro del mismo píxel.
- **Efecto de orografía costera:** La Cordillera de la Costa genera gradientes climáticos abruptos que no son completamente resueltos por la grilla. SEs ubicadas en la vertiente occidental (marítima) pueden experimentar temperaturas más moderadas que las predichas por el píxel ALADIN, que promedia ambas vertientes.
- **Exactitud de las coordenadas UTM:** Las coordenadas proporcionadas por Infotécnica no incluyen metadatos de precisión. Para las SEs georreferenciadas por esta vía, la incertidumbre posicional es desconocida, aunque se estima inferior a 1 km dada la naturaleza de infraestructura eléctrica fija y georreferenciada.

- **Píxeles compartidos:** Cerca del 24 % de los píxeles es compartido por más de una SE, lo que reduce la diversidad climática efectiva del panel. Si bien esto no afecta la estimación individual del GAM (cada SE tiene su propio modelo), sí limita la capacidad de capturar heterogeneidad climática intrazonal en los análisis de proyecciones agregados.
- **Grilla curvilínea:** A diferencia de una grilla regular, la grilla curvilínea de ALADIN presenta celdas de tamaño y orientación variable. Esto implica que la distancia SE–centroide no es una métrica perfecta de representatividad, ya que la forma del píxel puede no ser simétrica alrededor del centroide, especialmente en latitudes altas del dominio.

Apéndice I

Proyecciones de Demanda Eléctrica bajo SSP3-7.0

Este apéndice presenta los resultados del ejercicio de proyección de demanda eléctrica horaria bajo el escenario de cambio climático SSP3-7.0, utilizando el modelo GAM definitivo ajustado en el Capítulo de Resultados. El objetivo es aislar el *efecto climático puro* sobre la demanda, manteniendo congeladas todas las variables no climáticas (tendencia socioeconómica, cambio tecnológico, crecimiento demográfico). Este apéndice ofrece una visión multinivel —desde la escala del sistema interconectado hasta el estudio de caso de una ola de calor individual— del impacto térmico proyectado sobre el Sistema Eléctrico Nacional (SEN) de Chile. Las visualizaciones principales del ejercicio de proyección (serie del sistema, desagregación zonal, mapas espaciales del cambio, barras por zona y período, y mapa de calor estacional-diurno) se presentan en el Capítulo de Resultados y aquí se referencian de forma cruzada para evitar duplicación; este apéndice añade las visualizaciones complementarias (divergencia media–pico y evolución decadal del estrés por olas de calor) junto con la configuración detallada del ejercicio.

I.1. Configuración del ejercicio de proyección

I.1.1. Modelo estadístico

Las proyecciones se obtienen alimentando el modelo GAM canónico per-(barra, cliente) (Ec. 5.3, Sección 5.7.2) con las forzantes climáticas proyectadas por CNRM-ALADIN64 bajo el escenario SSP3-7.0. El modelo emplea dos variables climáticas (*tas* y *Td*), interacciones tensoriales y controles calendáricos; las variables *sfcWind*, *rsds*, *pr* y la media móvil exponencial de temperatura se conservan únicamente en el modelo SE-agregado (Apéndice L).

I.1.2. Escenario SSP3-7.0

El escenario *Shared Socioeconomic Pathway* 3-7.0 (SSP3-7.0) corresponde a una trayectoria de desarrollo regional fragmentado con emisiones intermedias-altas, alcanzando un forzamiento radiativo de 7,0 W/m^2 al año 2100. Este escenario asume una cooperación internacional limitada, crecimiento económico desigual y una transición energética lenta, resultando en un calentamiento global medio de $\approx$3,6 °C respecto a niveles preindustriales para finales de siglo. En el contexto de Chile, SSP3-7.0 representa una trayectoria climática plausible bajo políticas de mitigación insuficientes.

Las forzantes climáticas provienen del modelo regional CNRM-ALADIN64 (resolución nominal 0,11°, ≈12,5 km), anidado en el modelo global CNRM-ESM2-1, y corregidas por sesgo mediante *Unbiased Quantile Mapping* (UQM) horario directo contra ERA5-Land (sin ventana móvil), referencia que provee las dos variables (*tas*, *Td*) que ingresan al modelo canónico. El dominio CORDEX-CHP12 cubre Chile continental en una grilla curvilínea de 255×68 celdas.

I.1.3. Tratamiento de la tendencia temporal

Un aspecto crítico de diseño es el tratamiento de la tendencia temporal. La tendencia se estima como un *smooth* penalizado ($k = 3$, `select=TRUE`) que captura el crecimiento secular de la demanda observado durante el período de entrenamiento (2017–2025). Para las proyecciones, bajo el supuesto de **red estática**, la tendencia se **congela en el valor terminal del período de entrenamiento**: el índice de tendencia se fija en su valor final para todos los años proyectados.

Esta decisión implica que las proyecciones capturan *exclusivamente* el efecto del cambio climático sobre la demanda, sin incorporar el crecimiento futuro por aumento de población, industrialización, penetración de aire acondicionado o cambio tecnológico. Toda diferencia entre la demanda proyectada y la línea base histórica se atribuye únicamente a las variaciones en las forzantes meteorológicas.

I.1.4. Período de análisis y línea base

Las proyecciones cubren el período 1980–2100. La **línea base histórica** se define como **1980–2010**, período de referencia climático del estudio. Los resultados se presentan para tres ventanas temporales futuras:

- **Corto plazo** (*near-term*): 2030–2050
- **Medio siglo** (*mid-century*): 2041–2060
- **Fin de siglo** (*end-century*): 2081–2100

El agregado del sistema se construye sobre las **2.529 series (barra, cliente)** con proyección válida sobre el horizonte 1980–2100, sin filtro adicional de actividad.

I.2. Resultados a nivel de sistema

La Figura 6.10 (Capítulo de Resultados) presenta la evolución de la demanda media anual y del percentil 95 (P95) del sistema agregado entre 1980 y 2100. La demanda media del sistema se mantiene notablemente estable a lo largo del siglo, en torno a ≈8,5 GW, con un P95 —indicador de los picos de consumo— cercano a ≈11,2 GW (razón P95/media ≈1,32). El cambio agregado a fin de siglo, ponderado por la demanda histórica de cada serie, es de apenas $-0{,}02\,\%$ en la demanda media y $+0{,}53\,\%$ en el P95.

Esta estabilidad aparente a nivel agregado enmascara, sin embargo, dinámicas compensatorias entre zonas climáticas y entre estaciones del año, como se detalla en las secciones siguientes.

La Figura 6.11 (Capítulo de Resultados) desagrega la demanda por zona climática (Norte Grande, Norte Chico, Centro y Sur), revelando trayectorias divergentes. En términos ponderados por demanda a fin de siglo, la zona **Norte Grande** es la única

con un incremento agregado neto (+1,30 % en demanda media), por el peso de su carga minero-industrial; las zonas templadas presentan reducciones leves —Norte Chico −0,13 %, Centro −0,35 % y Sur −0,46 %—, donde el calentamiento reduce el requerimiento de calefacción más de lo que incrementa el de refrigeración.

I.3. Distribución espacial del cambio

La Figura 6.12 (Capítulo de Resultados) presenta mapas de dispersión de Chile mostrando el cambio porcentual en la demanda media (ΔDemanda, %) para cada subestación a medio siglo y fin de siglo, coloreados en una escala divergente azul–rojo. El tamaño de cada marcador es proporcional a la demanda base de la subestación.

A medio siglo, la mayoría de las subestaciones presenta cambios acotados dentro del rango ±5 %. A fin de siglo el patrón se acentúa y se vuelve marcadamente heterogéneo: ponderado por demanda, la zona **Norte Grande** concentra el mayor incremento de pico (ΔP95 +3,4 %; Δmedia +1,3 %), mientras que **Norte Chico** eleva su P95 (+1,0 %) pese a una media ligeramente negativa (−0,1 %). Las zonas **Centro** (Δmedia −0,3 %, ΔP95 −0,2 %) y **Sur** (−0,5 %, −0,8 %) muestran reducciones leves. La heterogeneidad intrazonal es amplia, reflejando la compensación entre calefacción reducida en invierno y refrigeración incrementada en verano.

I.4. Cambio por zona climática y período

Los cambios medios por zona climática y horizonte temporal se aprecian en la demanda normalizada por macrozona (Figura 6.11, Capítulo 6). Se distinguen tres patrones:

1. **Norte Grande: único incremento agregado.** Ponderado por demanda, es la única zona con aumento neto creciente en los tres horizontes, tanto en demanda media (+0,30 %, +0,42 %, +1,30 %) como —sobre todo— en el pico (ΔP95 +0,62 %, +0,94 %, +3,39 %), por el peso de su carga minero-industrial térmicamente acoplada.
2. **Norte Chico: media plana, pico creciente.** La demanda media apenas varía (−0,18 %, −0,23 %, −0,13 %), pero el P95 pasa de levemente negativo a +0,96 % a fin de siglo, indicando un desplazamiento del impacto hacia la cola de la distribución.
3. **Centro y Sur: reducciones leves.** Ambas zonas templadas muestran descensos agregados modestos en demanda media (Centro −0,13 %, −0,16 %, −0,35 %; Sur −0,21 %, −0,27 %, −0,46 %), donde el calentamiento reduce la calefacción invernal más de lo que incrementa la refrigeración estival. La Tabla I.2 detalla los valores por zona y horizonte.

I.5. Divergencia entre demanda media y picos

Un resultado clave para la planificación de infraestructura es la relación entre la demanda media y los picos de consumo. La Figura I.1 presenta la evolución temporal del cambio porcentual respecto a la línea base para la demanda media y para el percentil 95 del sistema.

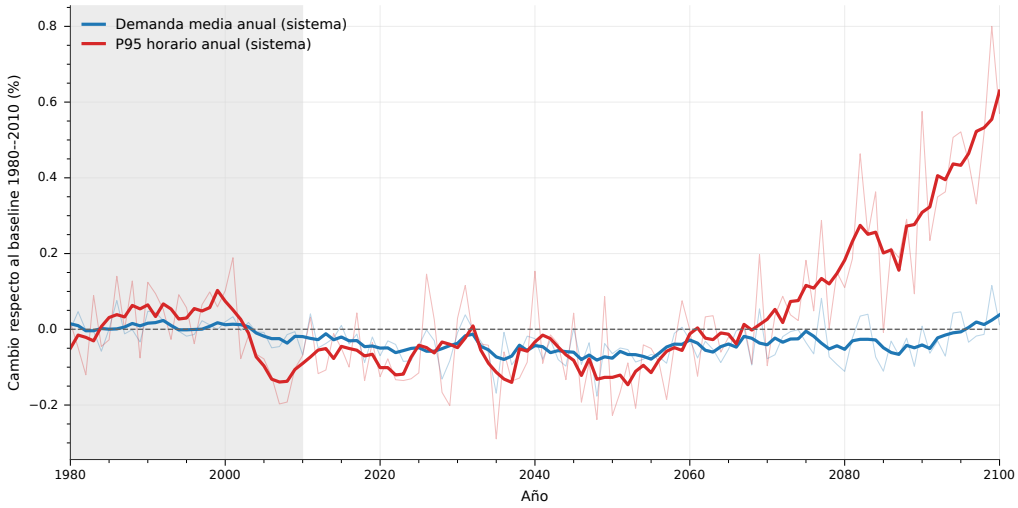

FIGURA I.1: Evolución del cambio porcentual respecto a la línea base para la demanda media (línea azul) y el percentil 95 de pico (línea roja) del sistema agregado (1980–2100, suavizado móvil de 5 años).

A nivel del sistema agregado, la razón P95/media se mantiene notablemente constante (≈1,32) a lo largo del siglo, indicando que —en promedio— los picos y la demanda media evolucionan de forma proporcional. Sin embargo, a escala zonal se observa divergencia: en Norte Chico el cambio en P95 (+0,96 % ponderado por demanda a fin de siglo) supera al de la demanda media (−0,13 %), y en Norte Grande el pico crece (+3,39 %) muy por encima de la media (+1,30 %), indicando que los eventos extremos de demanda crecen más rápido que el consumo promedio.

La descomposición estacional (Tabla I.1) revela que el efecto neto del calentamiento resulta de la compensación entre la demanda estival (refrigeración) y la invernal (calefacción). El cambio de verano (DJF) varía entre −1,5 % (Centro) y +1,6 % (Norte Grande), y el de invierno (JJA) entre −0,6 % (Centro) y −3,5 % (Norte Grande): la reducción de calefacción invernal domina el balance neto en las zonas templadas.

CUADRO I.1: Descomposición estacional del cambio en demanda a fin de siglo (2081–2100) vs baseline 1980–2010 por zona; DJF=verano austral, JJA=invierno austral; modelo canónico per-(barra,cliente).

Zona	DJF (%)	DJF (kW)	JJA (%)	JJA (kW)
Norte Grande	+1,64	+27.388	-3,48	-58.129
Norte Chico	-0,94	-4.868	-2,42	-11.134
Centro	-1,47	-84.557	-0,58	-31.705
Sur	+0,03	+264	-0,74	-6.441

I.6. Patrones estacionales y diurnos

La Figura 6.16 (Capítulo de Resultados) presenta un mapa de calor bidimensional (mes × hora del día) del cambio porcentual en demanda a fin de siglo respecto a la línea base, agregado a nivel de sistema. Este diagrama permite identificar simultáneamente los patrones estacionales y diurnos del impacto climático.

Se identifican dos señales dominantes:

- **Aumento estival (DJF):** Los meses de verano (diciembre–febrero) muestran incrementos de demanda concentrados en las zonas de clima árido, consistentes con el aumento de la demanda de refrigeración durante las horas y noches cálidas, fenómeno documentado en la literatura como *cooling demand asymmetry* (Auffhammer et al., 2017; Sailor & Pavlova, 2003).
- **Reducción invernal (JJA):** Los meses de invierno muestran reducciones generalizadas, particularmente marcadas en las horas diurnas, reflejando la menor necesidad de calefacción eléctrica bajo inviernos más templados.

La asimetría entre el aumento estival y la reducción invernal varía según la zona climática: en la zona Centro, ambos efectos son pronunciados y se compensan parcialmente a nivel anual, mientras que en Norte Chico predomina el efecto de calentamiento en todas las estaciones.

I.7. Olas de calor y estrés sobre el sistema

I.7.1. Frecuencia y severidad crecientes

La intensificación de las olas de calor bajo SSP3-7.0 —frecuencia ≈2,45 veces mayor hacia la década de 2080, duración media que crece de ≈5,1 a ≈11,6 días por evento, y anomalía de demanda creciente durante los eventos— se cuantifica en el Capítulo de Resultados (Secciones 6.2 y 6.7.3). Esta sección profundiza en un aspecto no desarrollado allí: cómo se reparte ese impacto entre la anomalía media del evento y su *peak* horario.

I.7.2. Distribución del impacto: anomalía media vs. peak horario

Más allá de la anomalía promedio por evento, una pregunta crítica para la planificación del sistema es cómo evoluciona el *peak horario* de demanda durante una ola de calor: el estrés instantáneo sobre la capacidad de generación y transmisión depende del máximo, no del promedio. La Figura I.2 descompone la distribución decadal de la anomalía condicional en sus componentes media y peak, usando un baseline matched-DOY 1980–2009 por serie (barra, cliente). Para cada evento se construye un grupo de control con las ventanas de igual día del año y duración en años históricos no-OdC del mismo píxel climático, lo que aísla la señal térmica del ciclo estacional de demanda [12, 40].

El crecimiento diferencial entre ambas distribuciones es la observación metodológicamente relevante: mientras que la anomalía mediana por evento permanece moderada incluso a fin de siglo, el P95 del peak horario crece varias veces respecto al período histórico. Este patrón —tail del peak expandiéndose más rápido que la mediana de la media— es consistente con [12] para el sistema eléctrico de EE.UU., y tiene implicancias directas para el dimensionamiento de reserva operativa y capacidad firme del SEN bajo cambio climático: el estrés sobre la infraestructura no escala linealmente con la temperatura promedio sino con la combinación de duración, intensidad acumulada y concentración horaria del evento.

I.8. Limitaciones de las proyecciones

Los resultados presentados deben interpretarse a la luz de las siguientes limitaciones:

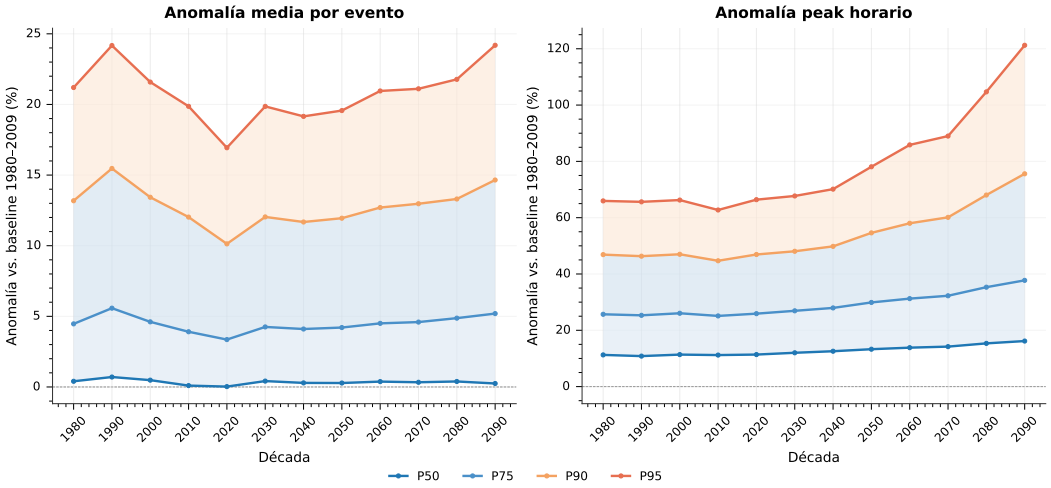

FIGURA I.2: Evolución decadal de la anomalía de demanda durante eventos de ola de calor bajo SSP3-7.0, computada por serie (barra, cliente) usando baseline matched-DOY 1980–2009. Panel izquierdo: anomalía media por evento. Panel derecho: anomalía del peak horario dentro del evento. Las bandas muestran los cuantiles P50/P75/P90/P95 de la distribución agregada sobre todas las series proyectadas. La asimetría entre paneles cuantifica que la cola del peak crece sustancialmente más rápido que la media: las olas de calor no solo elevan el consumo total, sino que concentran su impacto en horas punta donde el sistema es más vulnerable.

1. **Modelo climático único.** Las proyecciones se basan exclusivamente en un modelo regional (CNRM-ALADIN64) anidado en un único modelo global (CNRM-ESM2-1). La ausencia de un *ensemble* multi-modelo impide cuantificar la incertidumbre asociada a la modelación climática. Estudios que emplean conjuntos de modelos —como los meta-análisis de Van Ruijven et al. (2019) y De Cian & Sue Wing (2019)— muestran que la dispersión inter-modelo puede dominar la señal de cambio, particularmente en regiones con baja concordancia entre GCMs.

2. **Escenario único (SSP3-7.0).** Solo se presenta un escenario de emisiones. La ausencia de SSP1-2.6 (mitigación agresiva) y SSP5-8.5 (emisiones altas) impide evaluar el rango de futuros posibles. Trabajos futuros deberían incorporar al menos SSP5-8.5, cuyas forzantes ALADIN están parcialmente disponibles para la variable *tas*.

3. **Tendencia temporal congelada.** Al fijar la tendencia socioeconómica en el valor terminal del período de entrenamiento, las proyecciones no capturan el crecimiento esperado de la demanda por electrificación del transporte, expansión de centros de datos, penetración de aire acondicionado en hogares chilenos, ni el crecimiento demográfico. En la práctica, estos factores amplificarían los impactos aquí reportados, ya que un sistema eléctrico de mayor tamaño tendría anomalías absolutas proporcionalmente mayores.

4. **Extrapolación fuera del rango observado.** El modelo GAM fue entrenado con datos de 2017–2025, un período en el que las temperaturas máximas históricas de Chile rara vez excedieron los 38 °C en las estaciones del SEN. Las proyecciones para fin de siglo incluyen episodios con máximos superiores a 40 °C, que

se encuentran fuera del rango de entrenamiento. Aunque el enlace logarítmico del GAM impone una restricción de positividad, la respuesta a temperaturas extremas sin precedente histórico es una extrapolación cuya validez no puede verificarse empíricamente. El agregado del sistema se construye sobre las 2.529 series (barra, cliente) con proyección válida sobre todo el horizonte 1980–2100.

5. **Variables climáticas simplificadas.** No se considera el efecto del cambio en la humedad relativa como variable independiente (solo indirectamente a través de la temperatura de punto de rocío), ni cambios en la nubosidad más allá de los capturados por *rsds*. La interacción entre olas de calor húmedas (*moist heat waves*) y demanda de refrigeración podría ser un factor importante no modelado explícitamente.

6. **Estacionariedad del modelo.** Se asume que la relación funcional entre variables climáticas y demanda, estimada en 2017–2025, permanece válida hasta 2100. Esta hipótesis de estacionariedad ignora posibles cambios estructurales en el mix de consumo (e.g., adopción masiva de vehículos eléctricos, almacenamiento residencial, respuesta de demanda automatizada) que podrían alterar fundamentalmente la sensibilidad térmica de la demanda.

A pesar de estas limitaciones, el ejercicio de proyección cumple su objetivo principal: cuantificar la *componente climática pura* del cambio en la demanda, proporcionando una línea base sobre la cual superponer escenarios de crecimiento socioeconómico y adaptación tecnológica en estudios posteriores.

I.9. Tablas resumen de proyecciones

La Tabla I.2 sintetiza el cambio porcentual ponderado por demanda en la demanda media anual y en el P95 horario por macrozona y horizonte temporal.

CUADRO I.2: Cambio porcentual ponderado por demanda en la demanda media anual y el P95 horario por macrozona y horizonte, modelo canónico per-(barra,cliente), baseline 1980–2010, SSP3-7.0.

Macrozona	*n* series	Δ Media pond. (%)			Δ P95 pond. (%)		
		2030–2050	2041–2060	2081–2100	2030–2050	2041–2060	2081–2100
Norte Grande	170	+0,30	+0,42	+1,30	+0,62	+0,94	+3,39
Norte Chico	185	-0,18	-0,23	-0,13	-0,11	-0,14	+0,96
Centro	1668	-0,13	-0,16	-0,35	-0,11	-0,17	-0,18
Sur	506	-0,21	-0,27	-0,46	-0,35	-0,53	-0,76
Sistema	**2529**	**-0,05**	**-0,06**	**-0,02**	**+0,01**	**+0,01**	**+0,53**

Apéndice J

Evaluación del Modelo Regional CNRM-ALADIN64

Este apéndice presenta una evaluación sistemática del modelo climático regional CNRM-ALADIN64 utilizado como fuente de forzantes meteorológicos en esta tesis. La evaluación abarca las cinco variables horarias empleadas en el modelado de sensibilidad térmica de la demanda eléctrica: temperatura del aire (*tas*), punto de rocío (*Td*), velocidad del viento superficial (*sfcWind*), radiación solar descendente de onda corta (*rsds*) y precipitación (*pr*). Se documenta tanto el desempeño del modelo crudo como el impacto de la corrección de sesgo mediante *Unbiased Quantile Mapping* (UQM), con el objetivo de caracterizar la calidad de los datos que alimentan los modelos GAM de los capítulos 5 y 6.

J.1. Descripción del modelo CNRM-ALADIN64

El modelo regional empleado en esta tesis corresponde a CNRM-ALADIN64, versión 6.4 con 91 niveles verticales, desarrollado por el Centre National de Recherches Météorologiques (CNRM, Météo-France/CNRS). Este modelo regional de clima (RCM) forma parte de la iniciativa CORDEX (*Coordinated Regional Climate Downscaling Experiment*) y se ejecutó en el dominio CHP12, que cubre Chile y el Pacífico sudoriental con una resolución horizontal de 0,11° (≈12 km).

J.1.1. Configuración del dominio

El dominio CHP12 emplea una grilla curvilinea de 255×68 celdas, de las cuales 8 270 corresponden a píxeles terrestres. La grilla abarca desde aproximadamente 17° S hasta 56° S en latitud y desde 79° W hasta 63° W en longitud, cubriendo la totalidad del territorio continental chileno, incluyendo la cordillera de los Andes hasta la vertiente oriental y el océano Pacífico adyacente.

J.1.2. Modelo acoplador global

CNRM-ALADIN64 está acoplado al modelo global CNRM-ESM2-1 (Earth System Model), que proporciona las condiciones de contorno laterales y superficiales. La combinación GCM–RCM corresponde al ensamble `r1i1p1f2`, siguiendo la nomenclatura CMIP6/CORDEX. CNRM-ESM2-1 incluye un modelo atmosférico (ARPEGE-Climat 6.3), un modelo oceánico (NEMO 3.6) y un modelo de hielo marino (GELATO 6.1).

J.1.3. Períodos y escenarios

Los datos disponibles cubren dos períodos:

- **Histórico (1979–2014):** Simulación forzada por observaciones (CMIP6 *historical*).
- **Proyecciones (2015–2100):** Dos escenarios de trayectorias socioeconómicas compartidas:
  - SSP3-7.0: Desarrollo regional con alta emisión ($\sim$7,0 W/m^2 en 2100).
  - SSP5-8.5: Desarrollo basado en combustibles fósiles ($\sim$8,5 W/m^2 en 2100).

La variable de temperatura del aire (tas) está disponible en ambos escenarios para todas las resoluciones temporales. Las demás variables horarias (Td, sfcWind, rsds, pr) están disponibles únicamente para SSP3-7.0 debido a limitaciones en la disponibilidad de las simulaciones originales de CNRM-ALADIN64 para el dominio CHP12.

J.1.4. Variables disponibles

El conjunto de variables horarias producidas por CNRM-ALADIN64 y utilizadas en esta tesis incluye:

CUADRO J.1: Variables horarias de CNRM-ALADIN64 empleadas en la tesis.

Variable	Nombre CORDEX	Unidad	Tipo UQM
Temperatura del aire	`tas`	K $\rightarrow$ °C	Aditivo
Punto de rocío	`Td`	K $\rightarrow$ °C	Aditivo
Viento superficial	`sfcWind`	m s^{-1}	Multiplicativo
Radiación solar	`rsds`	W m^{-2}	Multiplicativo
Precipitación	`pr`	kg m^{-2} s^{-1}	Multiplicativo

El punto de rocío (Td) no es una salida directa de CNRM-ALADIN64, sino que fue derivado a partir de la temperatura del aire (`tas`) y la humedad relativa (`hurs`) mediante la fórmula de Magnus inversa (véase Capítulo 5). La humedad relativa fue utilizada exclusivamente como insumo intermedio para este cálculo; el producto final entregado a los modelos GAM es el Td corregido.

J.1.5. Calendario

CNRM-ALADIN64 emplea un calendario de 365 días sin año bisiesto (`365_day`), requerido por el algoritmo de corrección de sesgo climQMBC v1.1 [26]. Los datos de referencia (ERA5-Land) fueron reproyectados temporalmente a este mismo calendario, eliminando los 29 de febrero.

J.2. Marco de evaluación

J.2.1. Referencia observacional

La evaluación del desempeño de CNRM-ALADIN64 se realizó contra el reanálisis ERA5-Land [83] como pseudoobservación de referencia. ERA5-Land proporciona campos globales a $\sim$9 km de resolución horizontal y paso temporal horario, lo que lo

convierte en una referencia apropiada para evaluar un RCM de ∼12 km. Los campos de ERA5-Land fueron interpolados bilinealmente a la grilla curvilinea de ALADIN, garantizando la comparabilidad píxel a píxel.

La elección de ERA5-Land como referencia (en lugar de estaciones *in situ*) se justifica por tres razones:

1. **Cobertura espacial completa:** ERA5-Land cubre la totalidad del dominio ALADIN, incluyendo zonas de montaña y desierto donde la red de estaciones es escasa.
2. **Resolución temporal horaria:** Permite evaluar el ciclo diurno y la variabilidad intradiaria, críticas para el modelado de demanda eléctrica horaria.
3. **Consistencia como objetivo de corrección:** ERA5-Land fue utilizado como referencia del algoritmo UQM, por lo que esta evaluación mide directamente la convergencia del procedimiento de corrección.

J.2.2. Período de evaluación

La evaluación se centra en el período histórico (1979–2014), que constituye el período de calibración del UQM. Las estadísticas del diagrama de Taylor se calcularon sobre el año 1990 como representativo del período central, utilizando datos de hora 12 UTC (mediodía solar aproximado en Chile central) para evitar sesgos asociados a horas nocturnas en variables como rsds.

J.2.3. Métricas de evaluación

Se emplearon las siguientes métricas, consistentes con la práctica estándar en evaluación de modelos climáticos regionales [84–86]:

- **Correlación de Pearson (r):** Mide la correspondencia espacial entre los campos medios del modelo y la referencia. Valores cercanos a 1 indican que el modelo reproduce correctamente los patrones espaciales.
- **Razón de desviación estándar ($\hat{\sigma}$):** Cociente entre la desviación estándar espacial del modelo y la de la referencia. Valores cercanos a 1 indican que la variabilidad espacial está correctamente representada.
- **RMSE centrado normalizado (E'):** Error cuadrático medio centrado (tras remover las medias) normalizado por la desviación estándar de la referencia. Combina información de correlación y amplitud, y se relaciona con las otras métricas mediante:
$$E'^2 = \hat{\sigma}^2 + 1 - 2\hat{\sigma}r \tag{J.1}$$
- **Sesgo medio espacial:** Diferencia $\overline{M} - \overline{O}$ entre la media del modelo y la observación, evaluada píxel a píxel y representada como mapa.

J.3. Evaluación multivariable: diagrama de Taylor

El diagrama de Taylor [84] constituye la herramienta canónica para sintetizar el desempeño de modelos climáticos en un único gráfico, representando simultáneamente la correlación, la razón de desviación estándar y el RMSE centrado. La Figura J.1

muestra los resultados para las cinco variables, comparando ALADIN crudo (marcadores azules) y ALADIN corregido por UQM (marcadores rojos) contra ERA5-Land (punto de referencia negro en $r = 1{,}0$, $\hat{\sigma} = 1{,}0$).

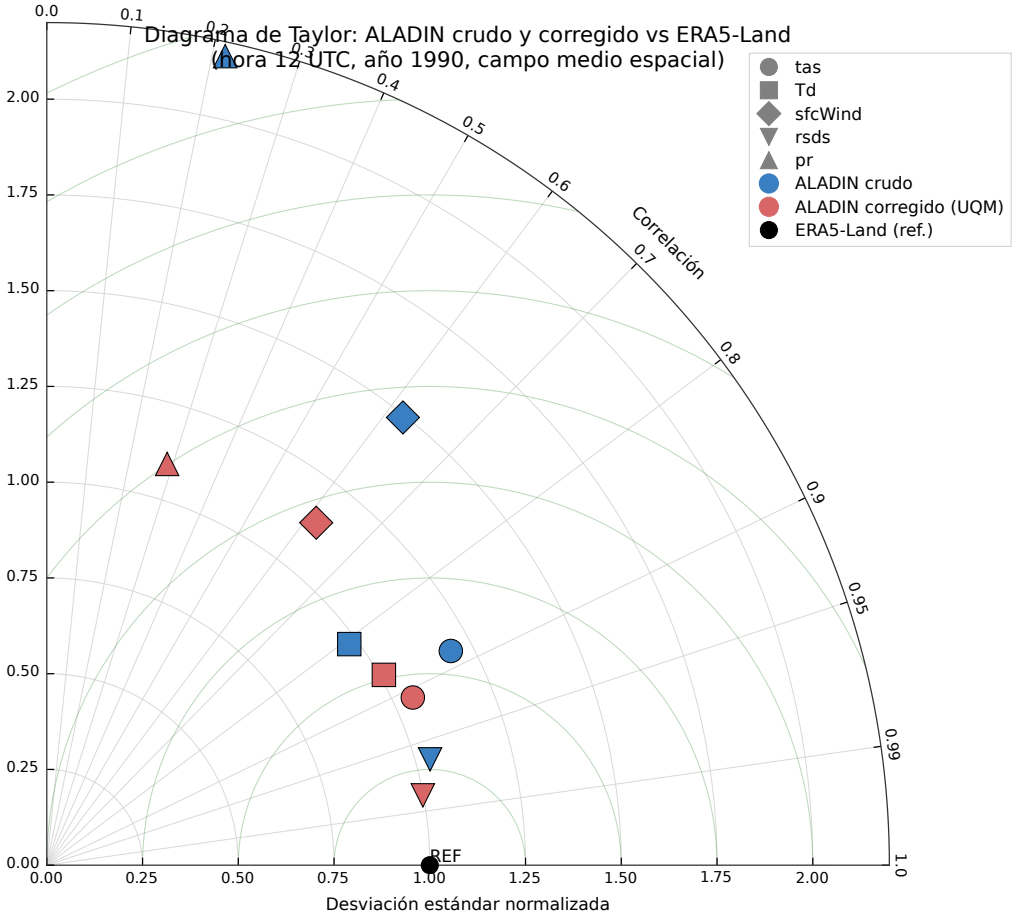

FIGURA J.1: Diagrama de Taylor comparando cinco variables de CNRM-ALADIN64 (crudo y corregido UQM) contra ERA5-Land. Las estadísticas se calcularon sobre campos medios espaciales a hora 12 UTC para el año 1990. La forma del marcador indica la variable (círculo: tas, cuadrado: Td, diamante: sfcWind, triángulo arriba: rsds, triángulo abajo: pr). El color indica el estado: azul = ALADIN crudo, rojo = ALADIN corregido (UQM), negro = referencia ERA5-Land.

La Tabla J.2 resume cuantitativamente las estadísticas del diagrama de Taylor.

El análisis del diagrama de Taylor y la tabla asociada permite jerarquizar el desempeño por variable:

1. **Temperatura del aire (tas):** Es la variable mejor representada tanto en el modelo crudo ($r = 0{,}963$) como en el corregido ($r = 0{,}999$). Tras la corrección UQM, la razón de desviación estándar alcanza $\hat{\sigma} = 0{,}998$ (prácticamente la unidad) y el RMSE centrado se reduce a $E' = 0{,}054$, un orden de magnitud inferior al valor crudo ($E' = 0{,}396$). Este resultado era esperable dado el fuerte control latitudinal y altitudinal de la temperatura en Chile, que el RCM captura adecuadamente.

2. **Punto de rocío (Td):** Presenta un desempeño análogo al de la temperatura

CUADRO J.2: Estadísticas del diagrama de Taylor para las cinco variables. r: correlación espacial; $\hat{\sigma}$: razón de desviación estándar normalizada; E': RMSE centrado normalizado. Valores calculados sobre campo medio hora 12 UTC, año 1990.

Variable	Versión	r	$\hat{\sigma}$	E'
tas	Crudo	0,963	1,253	0,396
	UQM	**0,999**	**0,998**	**0,054**
Td	Crudo	0,966	0,945	0,261
	UQM	**0,997**	**0,965**	**0,082**
sfcWind	Crudo	0,816	0,826	0,578
	UQM	**0,992**	**1,071**	**0,149**
rsds	Crudo	0,942	1,083	0,364
	UQM	**0,994**	**0,995**	**0,114**
pr	Crudo	0,829	2,125	1,412
	UQM	**0,842**	**1,118**	**0,606**

($r_{\text{UQM}} = 0{,}997$), coherente con la fuerte covarianza termodinámica entre ambas variables. La corrección mejora significativamente la razón de variabilidad (de 0,945 a 0,965), aunque persiste una leve subestimación de la variabilidad espacial.

3. **Velocidad del viento (sfcWind):** El modelo crudo exhibe la correlación más baja entre las variables termodinámicas ($r = 0{,}816$), reflejando la dificultad de los RCMs para representar campos de viento superficial en topografía compleja [87]. La corrección UQM logra una mejora notable ($r = 0{,}992$), aunque la razón de desviación estándar indica una leve sobreestimación de la variabilidad ($\hat{\sigma} = 1{,}071$).

4. **Radiación solar (rsds):** El modelo crudo muestra buena correlación ($r = 0{,}942$) pero una leve sobreestimación de la variabilidad ($\hat{\sigma} = 1{,}083$). La corrección UQM lleva ambas métricas a valores cercanos a la referencia ($r = 0{,}994$, $\hat{\sigma} = 0{,}995$).

5. **Precipitación (pr):** Es la variable más desafiante, como es habitual en evaluaciones de RCMs [86,88]. El modelo crudo sobreestima fuertemente la variabilidad espacial ($\hat{\sigma} = 2{,}125$), produciendo un RMSE centrado elevado ($E' = 1{,}412$). La corrección UQM reduce la sobreestimación ($\hat{\sigma} = 1{,}118$) y el RMSE centrado ($E' = 0{,}606$), pero la correlación mejora solo marginalmente (de 0,829 a 0,842). Este resultado refleja una limitación estructural: el UQM corrige la distribución marginal de la precipitación pero no puede mejorar la localización espacial de los eventos, que depende de la física dinámica del RCM.

J.4. Distribución espacial del sesgo

La Figura J.2 presenta mapas del sesgo espacial medio para las cinco variables, mostrando simultáneamente el sesgo del modelo crudo y del modelo corregido respecto a ERA5-Land. Estos mapas permiten identificar patrones geográficos sistemáticos que complementan las estadísticas globales del diagrama de Taylor.

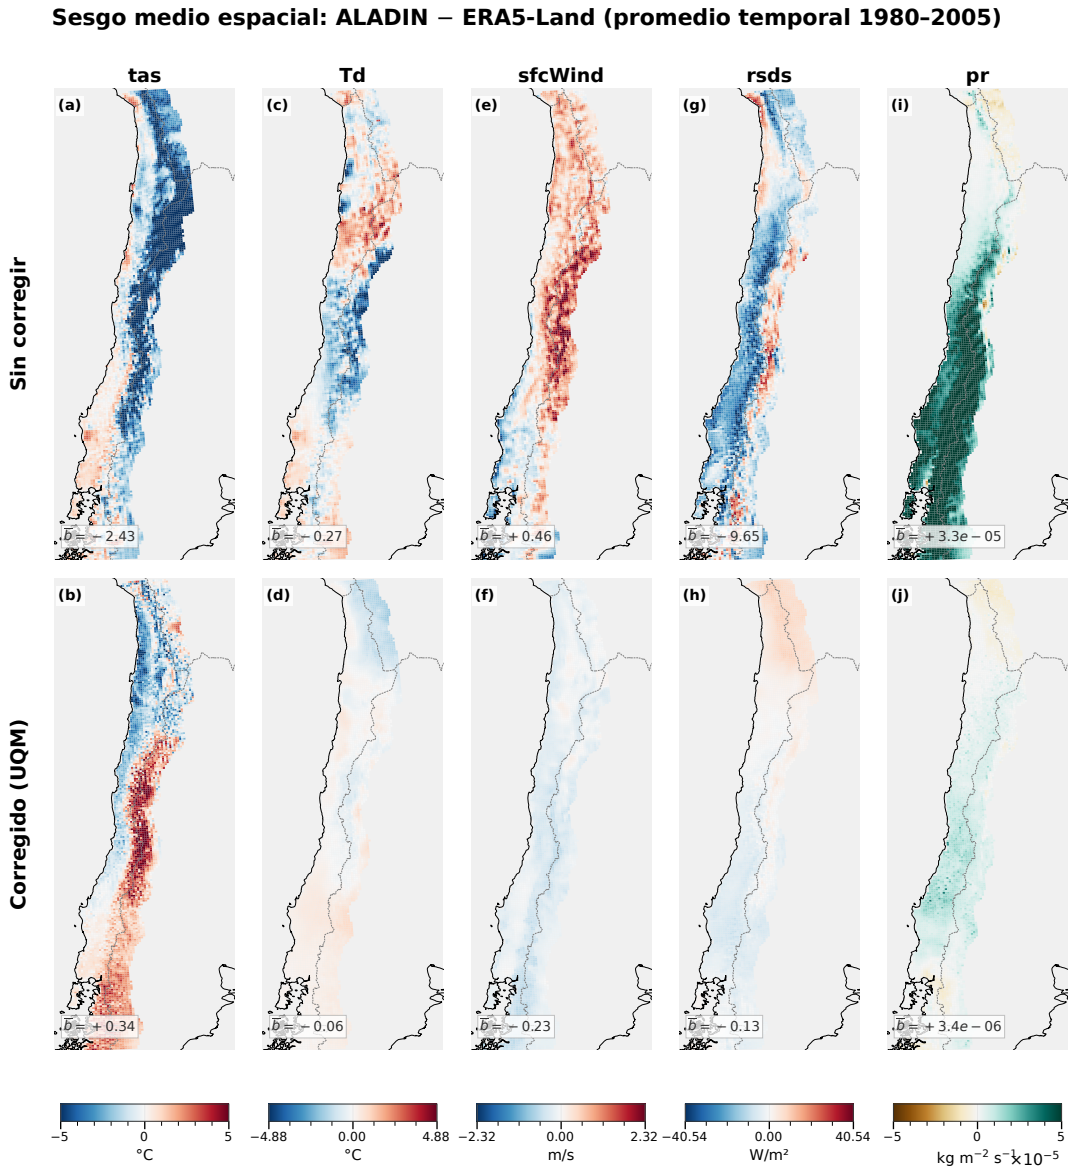

FIGURA J.2: Distribución espacial del sesgo medio para las cinco variables, dispuestas en columnas (de izquierda a derecha: temperatura *tas*, punto de rocío *Td*, viento superficial *sfcWind*, radiación solar *rsds*, precipitación *pr*). Fila superior: modelo crudo; fila inferior: modelo corregido (UQM), ambos respecto a ERA5-Land, calculado sobre 1980–2005 promediando todas las horas. Escala de colores divergente: rojo = sobreestimación, azul = subestimación.

Los patrones espaciales del sesgo revelan características estructurales del modelo regional:

- **Sesgo orográfico en temperatura:** El modelo crudo presenta un sesgo cálido en la cordillera de los Andes (hasta $+3$–$5°$C en las cumbres más altas) y un sesgo frío en la costa norte. Este patrón es consistente con la representación suavizada de la topografía a 12 km de resolución, donde las celdas andinas promedian elevaciones más bajas que la realidad. La corrección UQM elimina prácticamente este sesgo, llevando los residuos a $< 0{,}5°$C en todo el dominio.
- **Gradiente latitudinal en punto de rocío:** El sesgo del Td crudo es moderado (± 2–$3°$C) con un patrón donde la zona norte (desierto de Atacama) tiende a ser subestimada (ambiente demasiado seco) y la zona sur presenta sesgos pequeños. Tras la corrección, el sesgo residual se reduce a $< 1°$C en la mayor parte del dominio.
- **Sesgo de viento en valles y costa:** El viento superficial crudo muestra una subestimación generalizada en la costa del Pacífico (donde los vientos sinópticos son intensos) y una sobreestimación en los valles interiores. La corrección UQM mejora la correspondencia, aunque los gradientes costa–interior persisten parcialmente.
- **Radiación solar y nubosidad:** El sesgo de rsds refleja errores en la parametrización de nubes del RCM. ALADIN crudo tiende a sobreestimar la radiación en la zona central y sur (nubosidad insuficiente), con sesgos positivos del orden de 20–50 $\mathrm{W/m^2}$. En el norte árido, donde la nubosidad observada es mínima, el sesgo es menor. La corrección UQM reduce eficazmente estos sesgos en todos los píxeles.
- **Precipitación y topografía:** El sesgo de precipitación es el más espacialmente heterogéneo. ALADIN crudo sobreestima marcadamente la precipitación en la ladera occidental de los Andes (efecto orográfico exacerbado), con excesos que pueden superar el 100 % del valor observado en las cuencas de ríos como el Bío-Bío y el Maule. En contraste, la precipitación en el valle central puede estar subestimada. La corrección UQM redistribuye los cuantiles marginales, reduciendo el sesgo medio, pero las limitaciones en la localización espacial de eventos convectivos persisten.

J.5. Ciclo diurno

La correcta representación del ciclo diurno es crítica para el modelado de demanda eléctrica horaria, ya que los picos de consumo están fuertemente acoplados al ciclo térmico diario [89, 90]. Las Figuras J.3 y J.4 muestran el ciclo diurno medio (promedio sobre el período histórico) para las cinco variables en píxeles representativos, comparando ALADIN crudo, ALADIN corregido y ERA5-Land.

Las principales observaciones sobre el ciclo diurno son:

- **Temperatura (tas):** ALADIN crudo reproduce la forma general del ciclo diurno (mínimo predawn $\sim$06–08 UTC, máximo postmeridiano $\sim$18–20 UTC para Chile central), pero con una amplitud sobreestimada en zonas de montaña. La corrección UQM, al aplicarse independientemente por hora (*per-hour*), preserva la estructura temporal y ajusta simultáneamente el nivel y la amplitud del ciclo.

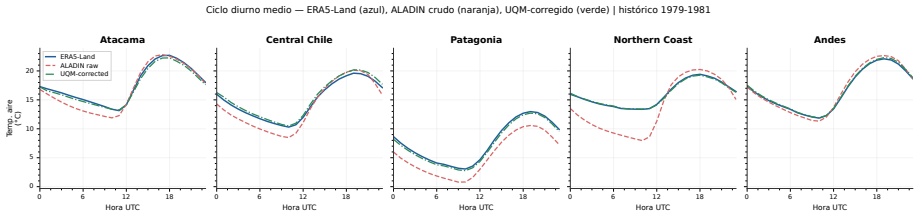

FIGURA J.3: Ciclo diurno medio de temperatura (*tas*) en 5 píxeles representativos (Atacama, Chile central, Patagonia, costa norte y Andes; período histórico). Azul: ERA5-Land; rojo: ALADIN crudo; verde: ALADIN UQM-corregido. La corrección UQM per-hour preserva la estructura temporal y ajusta simultáneamente nivel y amplitud.

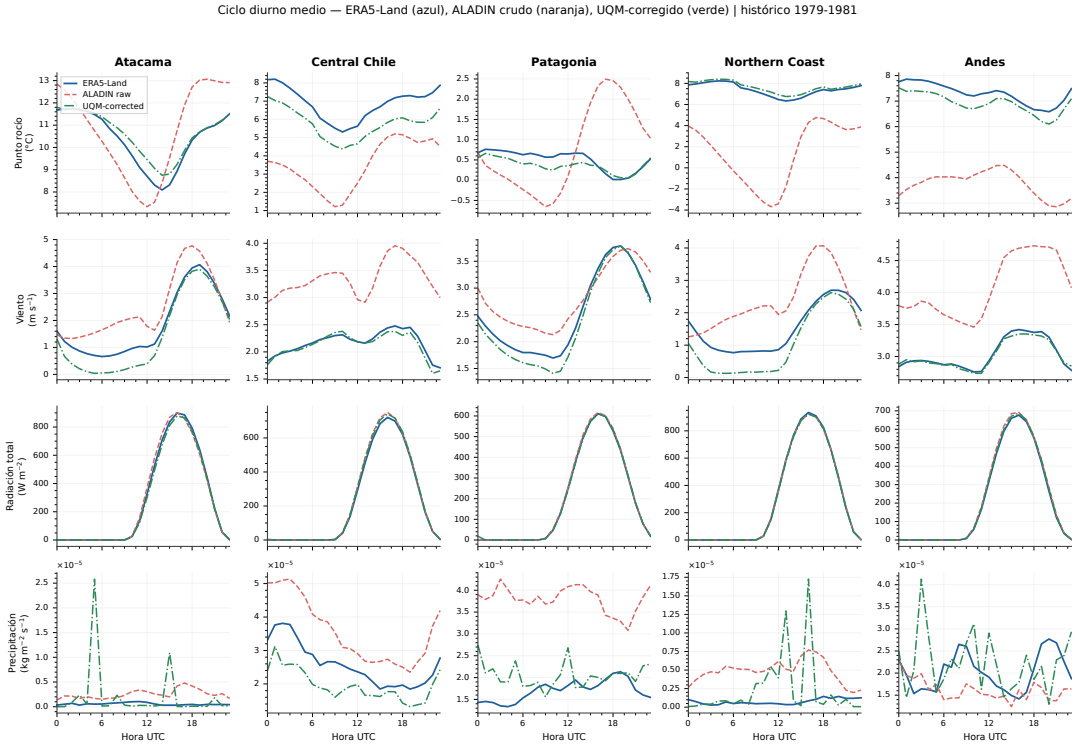

FIGURA J.4: Ciclo diurno medio de las variables secundarias en 5 píxeles representativos: (a) punto de rocío (*Td*), (b) viento superficial (*sfcWind*), (c) radiación solar (*rsds*), (d) precipitación (*pr*). Azul: ERA5-Land; rojo: ALADIN crudo; verde: ALADIN UQM-corregido.

- **Punto de rocío (Td):** El ciclo diurno de Td es menos pronunciado que el de tas, dado que la humedad atmosférica varía más lentamente que la temperatura. ALADIN captura correctamente esta menor variabilidad diurna, y la corrección UQM ajusta el nivel medio sin distorsionar la forma del ciclo.
- **Viento superficial (sfcWind):** El ciclo diurno del viento presenta un máximo durante las horas de mayor inestabilidad atmosférica (mezclado convectivo diurno) y un mínimo nocturno. ALADIN tiende a subestimar la amplitud de este ciclo, especialmente en píxeles costeros donde la brisa marina modula fuertemente la señal diurna.
- **Radiación solar (rsds):** El ciclo diurno de rsds sigue el arco solar (cero durante la noche, máximo a mediodía local). ALADIN reproduce correctamente la forma sinusoidal, con desfases menores. Las diferencias se concentran en la magnitud del pico meridiano, donde errores en la parametrización de nubes producen sobreestimaciones en días despejados.
- **Precipitación (pr):** La señal diurna de precipitación es débil y dominada por eventos discretos. En la zona central, la convectividad vespertina genera un ligero máximo en horas de la tarde, parcialmente capturado por ALADIN.

J.6. Consistencia termodinámica

Un requisito fundamental de los datos climáticos corregidos es la preservación de las relaciones físicas entre variables. En particular, la temperatura máxima diaria debe ser siempre mayor o igual a la temperatura mínima diaria ($T_{\max} \geq T_{\min}$), por definición: una violación de esta restricción ($T_{\max} < T_{\min}$) implicaría que la corrección de sesgo aplicada de forma independiente a cada variable invirtió el orden físico de los extremos diarios, lo cual sería un artefacto inadmisible.

La Figura J.5 muestra los resultados de la verificación de esta restricción sobre los productos corregidos de temperatura máxima y mínima diaria a lo largo de todo el período de simulación (1979–2100, escenario SSP3-7.0).

El resultado es contundente: **no se detectó ninguna violación** de la restricción $T_{\max} \geq T_{\min}$ en los 261 212 980 píxel-días evaluados (5 866 píxeles válidos $\times$ 44 530 días). Este resultado se debe a la combinación de dos factores:

1. **Modelo físico subyacente:** CNRM-ALADIN64 genera campos termodinámicamente consistentes, dado que las variables comparten la misma física atmosférica en cada paso de tiempo.
2. **Corrección por hora independiente:** El esquema UQM *per-hour* aplica la transformación de cuantiles de forma marginal por variable y hora UTC. Aunque este enfoque no garantiza formalmente la consistencia multivariable, la preservación de la estructura de rangos del modelo crudo y la monotonía de la transformación UQM mantienen las relaciones de orden en la práctica.

La ausencia de violaciones confirma que el pipeline de corrección de sesgo, aplicado de forma marginal por variable, no introduce artefactos que inviertan el orden físico de los extremos térmicos diarios, validando el uso de los productos corregidos como insumos de los modelos GAM.

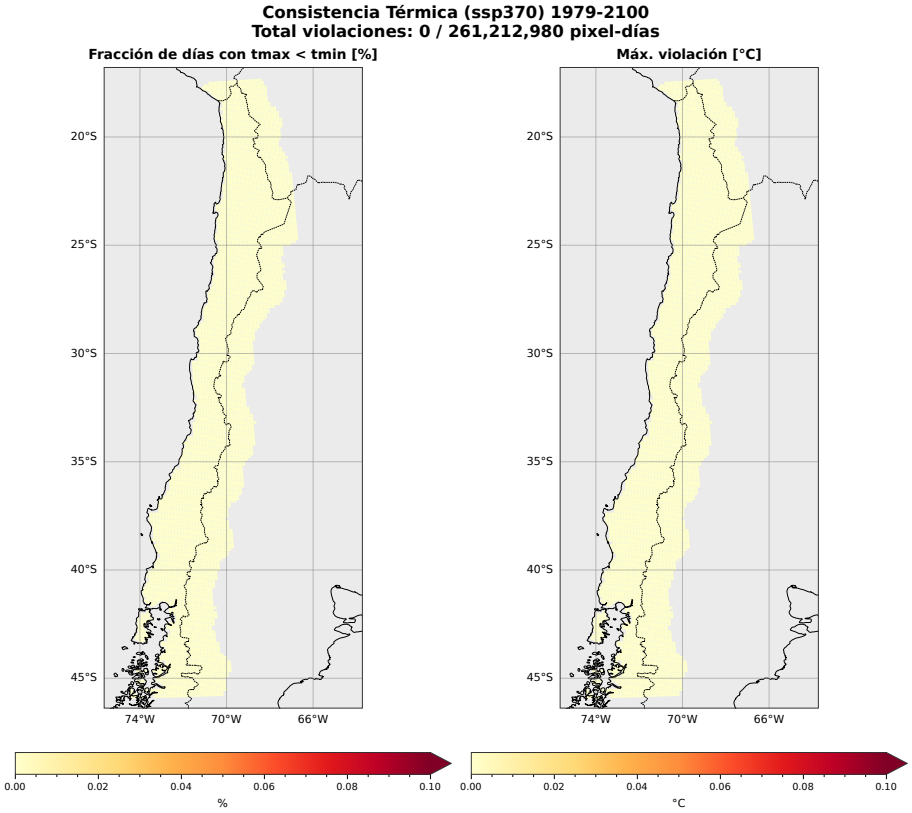

FIGURA J.5: Verificación de consistencia térmica ($T_{\max} \geq T_{\min}$) en los productos corregidos (SSP3-7.0, 1979–2100). Panel izquierdo: fracción de días con $T_{\max,\mathrm{corr}} < T_{\min,\mathrm{corr}}$ [%]. Panel derecho: máxima violación $T_{\min} - T_{\max}$ [°C]. El recuento total es de 0 violaciones sobre 261 212 980 píxel-días (5 866 píxeles válidos $\times$ 44 530 días), confirmando la plena consistencia física de los productos corregidos.

J.7. Síntesis y adecuación para el modelado GAM

La evaluación presentada permite caracterizar las fortalezas y limitaciones de CNRM-ALADIN64 como fuente de forzantes meteorológicos para el modelado de la sensibilidad térmica de la demanda eléctrica:

J.7.1. Fortalezas

- **Resolución espacial adecuada:** Los $\sim$12 km de resolución horizontal permiten resolver los principales gradientes climáticos de Chile (latitudinal, altitudinal, costa–interior), que son los determinantes de primer orden de la variabilidad espacial de la demanda eléctrica.
- **Consistencia física multivariable:** Las cinco variables provienen de un único modelo atmosférico, garantizando coherencia termodinámica y dinámica entre ellas. Esto contrasta con enfoques que combinan variables de fuentes independientes.
- **Cobertura temporal completa:** Los 122 años de simulación (1979–2100) proporcionan tanto un período histórico extenso para calibración como proyecciones a fin de siglo para análisis de impacto.
- **Excelente desempeño post-corrección en variables clave:** Tras la corrección UQM, las variables directamente vinculadas a la demanda térmica (tas, Td) alcanzan correlaciones $> 0{,}997$ y razones de variabilidad dentro del $\pm 3{,}5\,\%$ respecto a ERA5-Land.

J.7.2. Limitaciones

- **Sesgo orográfico residual:** Aunque el UQM corrige el sesgo medio, la representación suavizada de la topografía a 12 km puede subrepresentar gradientes térmicos en valles estrechos y laderas escarpadas. Este efecto es más relevante para las SE ubicadas en la cordillera o en valles costeros encajonados.
- **Precipitación como variable desafiante:** La correlación post-corrección de la precipitación ($r = 0{,}842$) es notablemente inferior a la de las demás variables. Si bien la precipitación no es el predictor dominante en los modelos GAM de demanda (ese rol lo cumple la temperatura), los efectos secundarios de la lluvia sobre la demanda (reducción de actividad económica, refrigeración evaporativa) pueden verse afectados por esta limitación.
- **Único modelo regional:** La evaluación se basa en una única combinación GCM–RCM (CNRM-ESM2-1/CNRM-ALADIN64). Un ensamble multimodelo permitiría cuantificar la incertidumbre estructural del modelo, pero dicho ensamble no está disponible a esta resolución y cobertura temporal para el dominio CHP12. Esta limitación debe considerarse al interpretar las proyecciones futuras (Capítulo 6). La extensión a un *ensemble* CORDEX-CORE está planteada como continuación en [31]; mientras tanto, la invarianza de escenario reportada en [30] sugiere que la dispersión relevante proviene de la cadena GCM–RCM y no del forzamiento SSP.
- **Corrección marginal:** El UQM corrige cada variable de forma independiente (marginal). Aunque la consistencia termodinámica se verificó empíricamente (§J.6), la estructura de dependencia multivariable (e.g., correlación temporal

entre tas y sfcWind durante olas de calor) depende íntegramente de la física del RCM y no es ajustada por el procedimiento de corrección.

J.7.3. Adecuación para el modelado GAM

En conjunto, CNRM-ALADIN64 corregido por UQM constituye una fuente de forzantes meteorológicos de calidad suficiente para el modelado estadístico de la demanda eléctrica, con las siguientes consideraciones operativas:

1. La **temperatura del aire** (predictor principal en los modelos GAM, vía spline penalizado `s(tas)`) presenta un error espacial despreciable tras la corrección ($E' = 0{,}054$), lo que asegura que la señal térmica que reciben los modelos GAM es representativa de las condiciones locales.
2. El **punto de rocío** (predictor de confort térmico vía tensor `te(tas, Td)`) tiene un desempeño comparable ($E' = 0{,}082$), validando su uso como proxy de la demanda de refrigeración por humedad.
3. Las variables **sfcWind** y **rsds** (predictores de segundo orden) presentan errores post-corrección moderados ($E' = 0{,}149$ y $0{,}114$), adecuados para su rol como covariables que capturan efectos de enfriamiento eólico y carga solar, respectivamente.
4. La **precipitación** es la variable con mayor incertidumbre ($E' = 0{,}606$), pero su peso relativo en los modelos GAM es menor que el de las variables térmicas, mitigando el impacto de esta limitación sobre las predicciones de demanda.

Apéndice K

Comparación de Productos Climáticos Corregidos: CR2MET vs. ERA5-Land

La corrección de sesgo del pipeline metodológico implementó dos caminos independientes de corrección de sesgo para el modelo regional CNRM-ALADIN64, diferenciados por la referencia observacional utilizada y la resolución temporal de la corrección. Este apéndice documenta las diferencias entre ambos productos y justifica la selección de la corrección contra ERA5-Land como producto primario para el modelado GAM.

K.1. Corrección diaria contra CR2MET v2.5

El primer camino utiliza la grilla observacional **CR2MET v2.5** [67] como referencia. CR2MET es un producto de alta resolución espacial ($\sim$0,05°) para Chile, construido mediante la interpolación de estaciones meteorológicas y productos satelitales. Ofrece variables diarias de temperatura máxima (T_{max}), temperatura mínima (T_{min}) y precipitación.

La corrección aplica UQM con ventana móvil de 11 días, corrige el rango térmico diurno (DTR) para preservar la consistencia termodinámica $T_{min} \leq T_{max}$ por construcción, y reconstruye la resolución horaria mediante reescalamiento lineal del ciclo diurno de ALADIN; el detalle metodológico se documenta en el Apéndice A.

Ventajas de CR2MET: Menor sesgo espacial al estar basado en estaciones meteorológicas locales; mayor resolución espacial ($\sim$5 km vs. $\sim$9 km de ERA5-Land); producto de referencia en la comunidad climática chilena.

Limitaciones de CR2MET: Solo disponible a resolución diaria; requiere un paso intermedio de reconstrucción horaria; la corrección DTR introduce un sesgo residual en T_{min}; no ofrece variables como punto de rocío, viento o radiación, las cuales deben corregirse con ERA5-Land de todas formas.

K.2. Corrección horaria directa contra ERA5-Land

El segundo camino utiliza **ERA5-Land** [68] como referencia. ERA5-Land es un reanálisis global a $\sim$9 km de resolución con frecuencia horaria, que cubre todas las variables requeridas por el modelo GAM.

La corrección es directa: se aplica UQM hora por hora sobre cada variable (`tas`, `Td`, `sfcWind`, `rsds`, `pr`) contra ERA5-Land. La resolución horaria (∼8.760 muestras por año) hace innecesarias la ventana móvil y la corrección DTR, operando nativamente a la resolución temporal del modelado.

Ventajas de ERA5-Land: Corrección horaria nativa (sin reconstrucción); disponibilidad de las 5 variables requeridas en una sola fuente; ausencia de problemas de consistencia termodinámica; pipeline más simple y directo.

Limitaciones de ERA5-Land: Al ser un reanálisis y no un producto observacional puro, puede heredar sesgos propios del modelo de reanálisis, especialmente en regiones de topografía compleja como los Andes; menor resolución espacial que CR2MET.

K.3. Comparación de métricas de validación

La Tabla K.1 resume las métricas de validación para ambos caminos de corrección, evaluadas sobre el período histórico (1979–1983) en todos los píxeles terrestres de la grilla ALADIN ($n = 8{,}270$). Para las variables diarias (T_{max} y T_{min}), la referencia observacional es CR2MET v2.5; para la temperatura horaria (`tas`), la referencia es ERA5-Land.

CUADRO K.1: Métricas de validación para los productos de temperatura corregidos por sesgo, comparando la corrección contra CR2MET (diaria con reescalamiento horario) y contra ERA5-Land (horaria directa). Las métricas se calculan sobre el período histórico (1979–1983) para todos los píxeles terrestres de la grilla ALADIN.

Variable	Métrica	ALADIN crudo	Corr. CR2MET	Corr. ERA5-Land
T_{max} (diaria)	RMSE (°C)	6.22	3.67	—
	MAE (°C)	4.83	2.65	—
	Sesgo (°C)	-2.33	-0.27	—
	r	0.765	0.857	—
T_{min} (diaria)	RMSE (°C)	6.13	3.19	—
	MAE (°C)	4.62	2.38	—
	Sesgo (°C)	-0.24	-0.20	—
	r	0.852	0.896	—
`tas` (horaria)	RMSE (°C)	6.95	5.37	5.15
	MAE (°C)	5.29	4.13	3.83
	Sesgo (°C)	-3.62	-0.33	-1.27
	r	0.859	0.821	0.873

Nota: Para T_{max} y T_{min}, la referencia observacional es CR2MET v2.5 (producto diario); la columna "Corr. ERA5-Land" muestra "—" ya que la corrección ERA5-Land opera directamente a escala horaria. Para `tas` horaria, la referencia es ERA5-Land; la columna "Corr. CR2MET" corresponde al reescalamiento lineal del ciclo diurno tras la corrección diaria.

En las variables diarias, la corrección UQM contra CR2MET reduce el RMSE en un 41 % para T_{max} (de 6,22 a 3,67 °C) y un 48 % para T_{min} (de 6,13 a 3,19 °C). El sesgo medio de T_{max} disminuye de $-2{,}33$ a $-0{,}27$ °C, mientras que para T_{min} se mantiene bajo ($-0{,}20$ °C), resultado del enfoque de corrección DTR que garantiza $T_{min} \leq T_{max}$.

Para la temperatura horaria, la corrección directa contra ERA5-Land (UQM horario) alcanza un RMSE de 5,15 °C y una correlación de 0,873, superando al reescalamiento CR2MET (RMSE = 5,37 °C, $r = 0{,}821$). El reescalamiento CR2MET presenta un sesgo

medio menor ($-0,33$ vs. $-1,27\,°$C), pero su menor correlación refleja las limitaciones de la reconstrucción lineal del ciclo diurno, que aproxima la variabilidad subdiaria real. La ventaja del UQM directo es especialmente relevante para el modelado GAM, donde la captura fiel de la variabilidad horaria es prioritaria.

La Figura K.1 presenta diagramas cuantil-cuantil para la cola superior de la distribución (P90–P99,5), región crítica para el estudio de olas de calor. En la fila superior (T_{max} y T_{min}), se observa que la corrección CR2MET alinea los cuantiles extremos sustancialmente respecto al modelo crudo. En la fila inferior (`tas` horaria), la corrección ERA5-UQM sigue más fielmente la diagonal de identidad en los cuantiles extremos que el reescalamiento CR2MET, confirmando que la corrección hora por hora preserva mejor la estructura de las colas de la distribución.

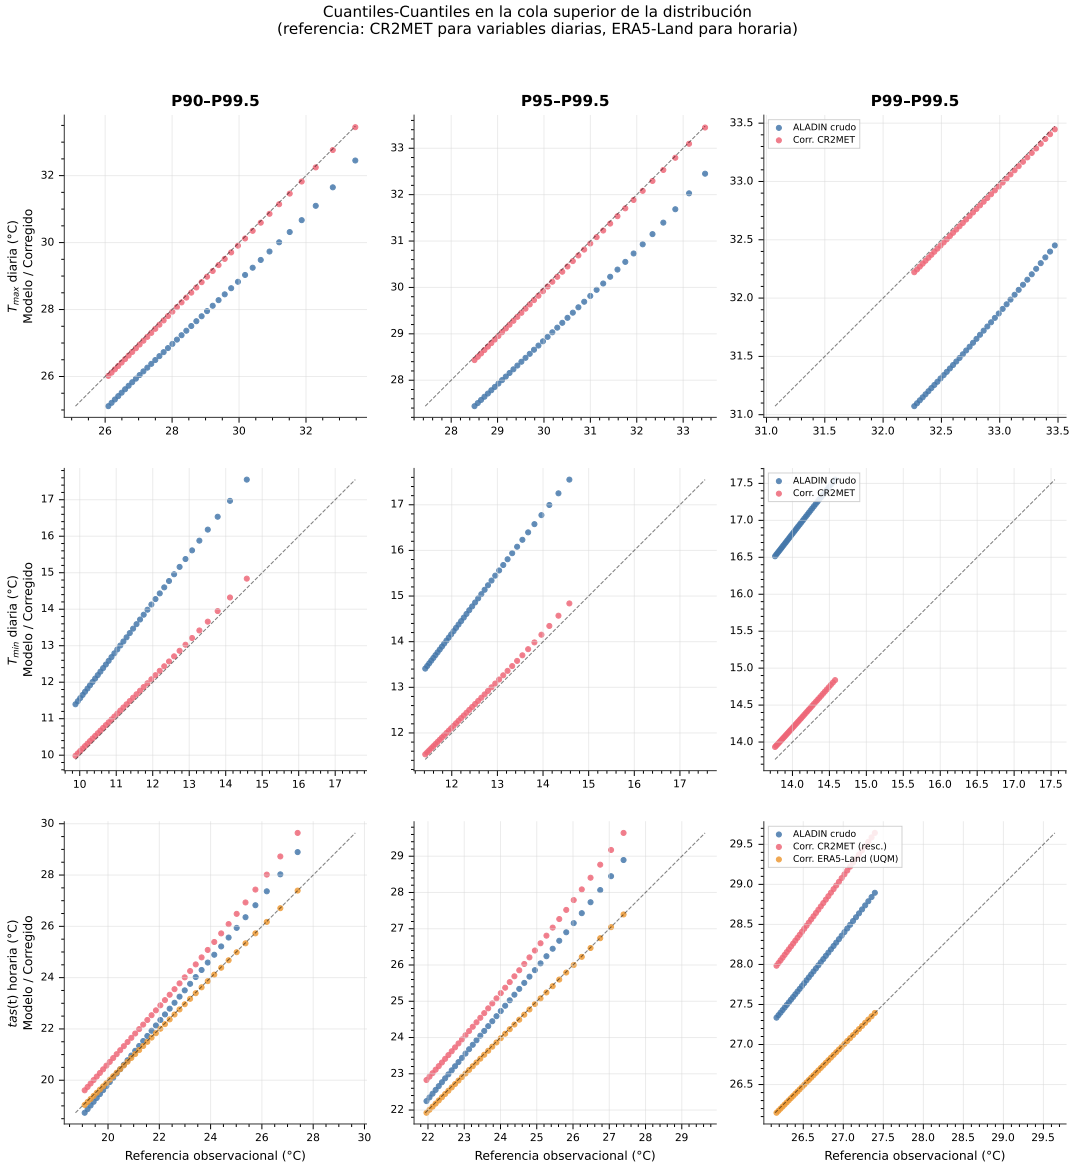

FIGURA K.1: Diagramas cuantil-cuantil para la cola superior de la distribución de temperatura (P90–P99,5). Filas: T_{max} diaria (arriba), T_{min} diaria (centro) y `tas` horaria (abajo). La línea discontinua indica la diagonal de identidad. La referencia observacional es CR2MET para las variables diarias y ERA5-Land para la horaria. Período: 1979–1988 (diarias), 1979–1983 (horaria).

K.4. Justificación de la selección de ERA5-Land

La decisión de utilizar exclusivamente el producto corregido contra ERA5-Land para el modelado GAM y las proyecciones se fundamenta en tres razones:

1. **Simplicidad del pipeline:** La corrección horaria directa evita los pasos intermedios de reconstrucción temporal y corrección DTR, reduciendo las fuentes de error y la complejidad metodológica.
2. **Consistencia entre variables:** Todas las forzantes climáticas del GAM (tas, Td, sfcWind, rsds, pr) se corrigen contra la misma referencia y a la misma resolución temporal, garantizando coherencia interna del conjunto de datos.
3. **Resolución temporal nativa:** El modelo GAM opera a escala horaria. Utilizar una referencia horaria evita la introducción de aproximaciones en la reconstrucción del ciclo diurno, preservando la variabilidad subdiaria observada.

No obstante, la diferencia en sesgo espacial respecto a CR2MET constituye un *caveat* que debe considerarse al interpretar los resultados en zonas de topografía compleja. El camino alternativo —UQM diario con CR2MET v2.5 como única referencia— se desarrolla de forma completa en [30], cuyo diagnóstico de olas de calor puede leerse como el contrafactual de este apéndice: qué se obtiene cuando se privilegia la referencia basada en estaciones por sobre la resolución horaria. Las métricas comparativas presentadas en la Sección K.3 permiten al lector evaluar la magnitud de esta diferencia.

Apéndice L

Modelo SE-agregado: Análisis de Robustez

El modelo canónico de esta tesis ajusta un GAM independiente para cada serie per-(barra, cliente), aprovechando la heterogeneidad socioeconómica intra-subestación entre tipos de cliente (Capítulo 6). Como verificación de robustez metodológica frente a la elección de granularidad, este apéndice documenta un ajuste paralelo del mismo modelo GAM sobre la **demanda agregada por subestación (SE)**, replicando la convención típica del Coordinador Eléctrico Nacional (CEN). El modelo SE-agregado corrobora la *forma* de la respuesta térmica contrafactual del modelo canónico, lo que justifica relegarla al apéndice como verificación de robustez sin pérdida sustantiva de información. Las proyecciones de impacto bajo SSP3-7.0 se reportan exclusivamente sobre la vista per-(barra, cliente).

L.1. Ajuste GAM sobre demanda SE-agregada

El modelo GAM SE-agregado (parametrización *full-k*) se ajusta sobre 340 SE candidatas del SEN (véase Sección 6.3 para la descripción de la base de datos). La convergencia es exitosa en **335 SE** (las cinco no ajustadas presentan cobertura temporal insuficiente o varianza degenerada).

Las métricas de bondad de ajuste medianas sobre las 335 SE son:

- R^2 mediano $= 0{,}836$;
- MAPE mediano $= 0{,}89\,\%$;
- ACF_1 residual mediano $\approx 0{,}858$.

Estas cifras son sistemáticamente mejores que las del modelo per-(barra, cliente) (R^2 mediano 0,624, MAPE mediano 5,02 %). La diferencia se explica por la cancelación de variabilidad estocástica idiosincrática al sumar barras heterogéneas dentro de cada SE: la señal climatológica resultante es más limpia y predecible, a costa de ocultar la heterogeneidad intra-SE entre estratos de cliente que motiva el enfoque per-(barra, cliente) elegido como modelo canónico.

El estimador per-(barra, cliente) sobre el panel completo (**2.529 series con proyección**) arroja $\Delta\overline{D} = -0{,}02\,\%$ y $\Delta P95 = +0{,}53\,\%$ a fin de siglo (sistema, suma ponderada por demanda; *baseline* 1980–2010). Estas proyecciones de impacto se computan exclusivamente sobre la vista per-(barra, cliente): el estimador SE-agregado es de *curvas-only* y no posee *pipeline* de proyección, por lo que su rol se limita a verificar la

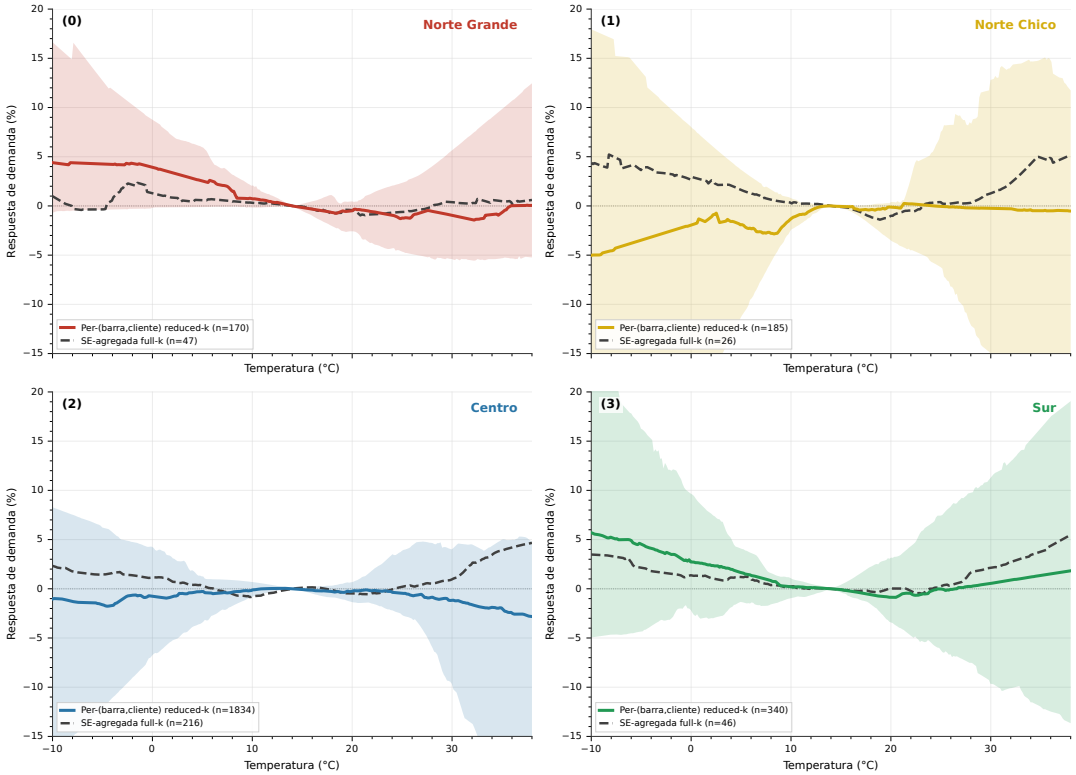

FIGURA L.1: Respuesta contrafactual de la demanda a la temperatura por macrozona, comparando las dos vistas. **Línea continua con banda:** modelo canónico per-(barra, cliente) (parametrización *reduced-k*, 2.529 series). **Línea discontinua:** modelo SE-agregado (parametrización *full-k*, ventana estable ventana estable 2020-01–2022-04, ∼335 SE). En ambas vistas la curva es la mediana ponderada por energía y la banda el rango intercuartílico P25–P75. Las dos vistas comparten el método contrafactual (Zimmermann & Ziel, 2025) y de agregación zonal, y difieren en la granularidad de agregación y en la parametrización del GAM (*reduced-k* per-serie vs. *full-k* SE-agregada).

forma de la respuesta térmica contrafactual (Figura L.1) y no a re-estimar el impacto agregado del sistema.

Que el modelo SE-agregado full-k —que sí incluye `pr`, `rsds`, `sfcWind` y la EWMA térmica— reproduzca la misma forma de respuesta contrafactual que el modelo per-serie (Figura L.1) indica que la omisión de esas variables secundarias en la formulación per-serie no sesga la señal climática agregada del sistema.

L.1.1. Significancia de las interacciones tensoriales

El modelo SE-agregado retiene las mismas interacciones tensoriales `ti(tas,doy)` y `ti(tas,hod)` de la parametrización *full-k*, de modo que la estructura no estacionaria de la sensibilidad térmica se conserva al cambiar de granularidad. La verificación estadística cuantitativa de significancia tensorial canónica se reporta sobre el modelo per-(barra, cliente) (Sección 6.5.2, el 98,7 % de las 2.529 series; prueba F, $p < 0{,}01$), y respalda la robustez de la hipótesis H2 ante el cambio de granularidad.

El modelo SE-agregado (335 SE) es de *curvas-only*: no incluye *pipeline* de proyección ni *bootstrap*. Las proyecciones de impacto bajo SSP3-7.0 se reportan exclusivamente sobre el modelo per-(barra, cliente) (Capítulo 6 y Apéndice I).

L.2. Tabla resumen comparativa

CUADRO L.1: Comparación sintética de las dos vistas del modelo GAM. R^2 y MAPE son medianas sobre las unidades ajustadas; $\Delta\overline{D}$ y $\Delta P95$ corresponden a fin de siglo (2081–2100) bajo SSP3-7.0.

Indicador	**Per-(barra, cliente) (canónico)**	**SE-agregada (supletorio)**
n candidatas	2.567 series	340 SE
n ajustadas exitosamente	2.529	335
n con proyección válida	2.529	— (curvas-only)
R^2 (mediana)	0,624	0,836
MAPE (mediana)	5,02 %	0,89 %
ACF_1 residual (mediana)	0,851	0,858
$\Delta\overline{D}$ (mediana unitaria)	+0,02 %	—
$\Delta\overline{D}$ (ponderado por demanda)	−0,02 %	—
$\Delta P95$ (mediana unitaria)	+0,29 %	—
$\Delta P95$ (ponderado por demanda)	+0,53 %	—

Nota: el modelo SE-agregado no admite ponderación directa por demanda histórica intra-SE porque el agregado ya colapsa la heterogeneidad entre barras y estratos. El estimador SE-agregado canónico es de curvas-only y no produce proyecciones; las proyecciones de impacto se reportan exclusivamente sobre la vista per-(barra, cliente).

L.3. Figuras complementarias SE-level

Esta sección recoge dos figuras de carácter SE-level/selección de modelo, trasladadas desde el Capítulo 6: el ranking de la campaña de experimentos (Figura L.2) y los efectos de las variables climáticas secundarias estimados con el modelo SE-agregado

full-k (Figura L.3), variables que el modelo canónico per-(barra, cliente) reduced-k no incluye.

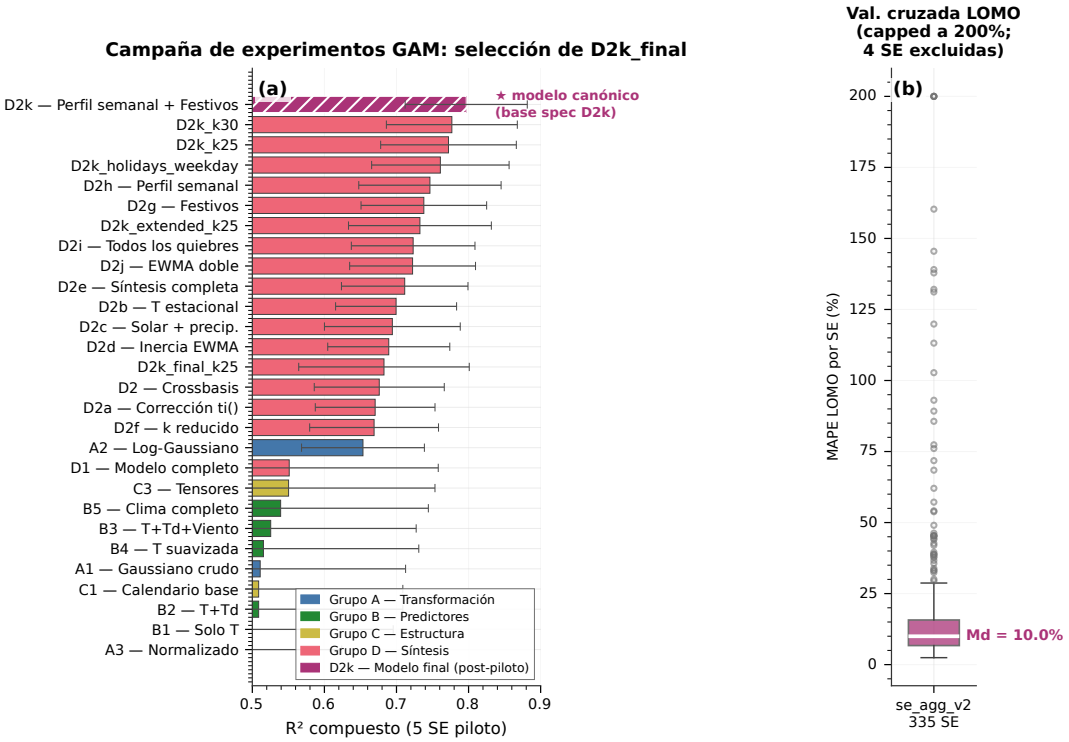

FIGURA L.2: Campaña de experimentos GAM y selección del modelo. **(a)** Ranking de las 28 configuraciones evaluadas según *score* compuesto sobre el subconjunto piloto; la especificación ganadora (D2k) fundamenta el modelo canónico reduced-k per-(barra, cliente). **(b)** Distribución del MAPE en validación cruzada LOMO del modelo SE-agregado (335 SE, full-k; mediana 9,98 %).

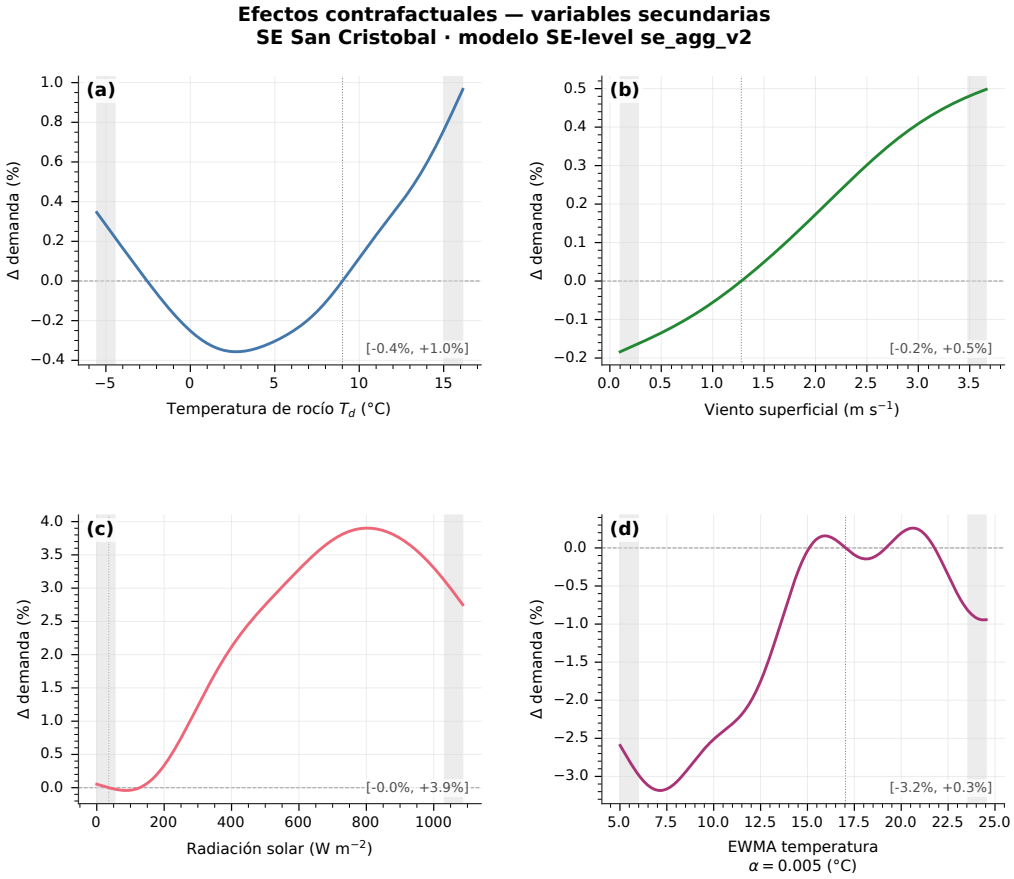

FIGURA L.3: Efectos contrafactuales de las variables climáticas secundarias (Td, sfcWind, rsds y la media móvil exponencial de *tas*) para la subestación San Cristóbal (Región Metropolitana; $R^2 = 0{,}97$), estimados con el modelo SE-agregado full-k. Cada panel muestra el cambio porcentual en demanda (Δ %) al variar una sola variable manteniendo el resto en sus valores observados. La precipitación se excluye de la formulación del modelo.

Apéndice M

Anexos: artículos derivados de esta tesis

Este apéndice reúne los dos manuscritos científicos que se desprenden directamente del trabajo desarrollado en esta tesis. Ambos fueron elaborados durante el período de investigación, comparten el mismo modelo climático regional y la misma cadena de corrección de sesgo documentados en el Capítulo 5, y en el caso del segundo también la misma familia de modelos estadísticos. Se incluyen aquí con dos propósitos: dejar constancia del alcance efectivo del trabajo realizado, que excede lo que el formato de una tesis permite reportar; y documentar que sus componentes metodológicos centrales han sido sometidos a revisión de pares independiente y han superado ese escrutinio.

Los anexos no son resúmenes ni versiones abreviadas de esta tesis. Cada uno reencuadra una de sus dos ramas —la climática y la eléctrica— para una audiencia disciplinar distinta y, en ese proceso, incorpora análisis que no forman parte del cuerpo de este documento. Existe, por construcción, solapamiento de texto y de material metodológico entre esta tesis y los dos manuscritos: el autor de ambos es el mismo y los tres documentos describen la misma cadena de datos. Las diferencias de escenario, de definición de evento y de granularidad espacial entre cada anexo y la tesis se explicitan en las fichas que siguen y deben tenerse presentes al comparar cifras.

M.1. Artículo 1. Climatología proyectada de olas de calor atmosféricas en Chile

Título *The future of atmospheric heatwaves in Chile projected by a regional climate model*.

Autores J. Petit-Laurent, C. Martinez-Villalobos, K. Goubanova, C. Chadwick y P. Nabat.

Revista *International Journal of Climatology* (Wiley).

Estado editorial Manuscrito en **segunda ronda de revisión**; la versión que se reproduce corresponde a julio de 2026. El texto anexado es la versión de manuscrito (doble espacio y numeración de líneas), no una versión maquetada.

Rol del autor de esta tesis Primer autor y autor de correspondencia: diseño del estudio, procesamiento de las simulaciones, implementación de la corrección de sesgo y de los diagnósticos de olas de calor, análisis, figuras y redacción del

manuscrito. La coautoría incluye al equipo del CNRM responsable de la ejecución de la simulación CNRM-ALADIN64.

Relación con esta tesis Corresponde a la **rama climática** del trabajo. Extiende la climatología de olas de calor sobre CNRM-ALADIN64 documentada en la Sección 5.6, el Apéndice C y la Sección 6.2.

M.1.1. Qué aporta el Artículo 1 respecto del cuerpo de esta tesis

- **Escenario SSP5-8.5.** La tesis se limita a SSP3-7.0 (Sección 5.9.4). El artículo desarrolla la climatología completa bajo SSP5-8.5 y muestra que, al expresar las métricas de olas de calor en función del calentamiento regional acumulado, ambas trayectorias colapsan en una única curva. Este resultado acota la limitación de escenario único declarada en la Sección 7.3.
- **Validación de la corrección de sesgo bajo no estacionariedad.** El material suplementario del artículo incorpora un protocolo de validación fuera de muestra sobre diez puntos de grilla —división por estado climático con entrenamiento en décadas cálidas y prueba en décadas frías y su recíproco, validación cruzada dejando una década fuera, sesgo por rangos percentílicos hasta P99,9 y diagramas cuantil-cuantil de la cola superior—. El sesgo absoluto mediano en la cola P90–P99,9 se reduce de 1,5–3,8 °C en el modelo crudo a aproximadamente 0,5 °C tras el ajuste, y el residuo de la configuración análoga a la tarea de proyección es frío. Este diagnóstico complementa la validación dentro de muestra reportada en el Apéndice A.
- **Razones de riesgo climáticas y mapas territoriales.** Curvas de razón de riesgo para duración, intensidad y magnitud con intervalos de confianza por remuestreo, y su expresión cartográfica sobre el territorio continental.
- **Diagnóstico de umbral adaptativo.** Comparación entre umbral percentílico fijo y umbral rodante de treinta años, que atribuye el alza proyectada al desplazamiento de la media más que a un ensanchamiento de la distribución. Cuantifica una de las limitaciones enunciadas en el Apéndice C.
- **Estacionalidad por armónicas de Fourier** y su extensión a siete ciudades representativas del país.

M.1.2. Diferencias que deben tenerse presentes al comparar cifras

- **Referencia observacional.** El artículo corrige el sesgo contra CR2MET v2.5 a escala diaria; las forzantes del modelo de demanda de esta tesis se corrigen contra ERA5-Land a escala horaria (Sección 5.3.2 y Apéndice K). La validación del material suplementario avala el *método* UQM bajo no estacionariedad, no la referencia horaria específica empleada aquí.
- **Definición de evento.** El artículo detecta eventos a resolución diaria y desde un día de duración; esta tesis exige tres días consecutivos sobre umbrales horarios (Sección 5.6.1). Ninguna cifra de frecuencia, duración o magnitud es directamente comparable entre ambos documentos.
- **Unidad de magnitud.** El artículo reporta magnitudes en °C·día; esta tesis en °C·hora.

- **Escenario titular.** SSP5-8.5 en el cuerpo del artículo y SSP3-7.0 en su material suplementario; el orden es inverso al de esta tesis.

The future of atmospheric heatwaves in Chile projected by a regional climate model

Jorge Petit-Laurent[*1,2], Cristian Martinez-Villalobos[1,2], Katerina Goubanova[3,4], Cristián Chadwick[1], and Pierre Nabat[5]

[1]Faculty of Engineering and Science, Universidad Adolfo Ibáñez, Santiago, Chile
[2]Data Observatory Foundation, ANID Technology Center No. DO210001
[3]Direction des Services Météorologiques, Météo-France, Toulouse, France
[4]Centro de Estudios Avanzados en Zonas Áridas (CEAZA), La Serena, Chile
[5] Météo-France, CNRS, Univ. Toulouse, CNRM, Toulouse, France

Heat waves Climate change Chile SSP5-8.5 SSP3-7.0 scenario bias-adjustment

Abstract

Heat waves pose a threat to human health, energy services, and ecosystems. We use the CNRM-ALADIN regional climate model (12.5 km resolution) to quantify projected changes in duration, intensity, frequency, and magnitude of heat waves in Chile this century under two high-emission scenarios. Temperatures were bias-adjusted using the unbiased quantile mapping (UQM) method. We estimate seasonal heatwave and cold spell evolution in three Chilean cities (La Serena, Santiago, Concepción), analyze cold wave evolution, and estimate heat wave risk ratios. In Santiago, projections indicate that by 2080 the warm season extends from late November to early April, a 67% increase. The heatwave period will extend at 7.8 days per decade to cover over 6 months by 2080, with potential occurrences from September to April, and the cold season is expected to disappear. This contributes to a 32% increase in heat wave frequency in Santiago between 2050-2080 and 1980-2010. Projected heat waves in Santiago exceed 50 days in duration, are up to 3^oC more intense, and have magnitudes 120% greater than the historical climate. The annual most intense heat wave is expected to be 18% more intense and 2.8 times the magnitude. Risk ratio analysis suggests heat waves surpassing Santiago's historical annual maximum will occur 6 to 8 times more frequently.

Manuscript Length

- Text: 8,750 words
- Figures: 10
- Tables: 1
- **Total Equivalent: 12,050 words**

Acknowledgements

J.P. acknowledges the support from the Data Observatory Foundation, ANID Technology Center number DO210001 and Proyecto ANID Fondecyt Iniciación 11250471.

C.M.-V. acknowledges support from Proyecto ANID Fondecyt Iniciación 11250471 and Data Observatory Foundation ANID Technology Center number DO210001.

K.G. acknowledges the support from FONDECYT 1241321 Grant, Concurso de Fortalecimiento al Desarrollo Científico de Centros Regionales 2020-R20F0008-CEAZA, and ANID ACT210046 grant.

*Corresponding author: jpetitlaurent@alumnos.uai.cl

This research was supported by the internal grant from Universidad Adolfo Ibáñez under the “Concurso Formación de Estudiantes para la Investigación (FEI) 2025”, Programa de Apoyo a la Investigación UAI.

The authors acknowledge the High-Performance Computing (HPC) Cluster of the Faculty of Engineering and Sciences at Universidad Adolfo Ibáñez for providing the computing resources that contributed to the research results reported within this paper.

1 Introduction

Climate change, understood as the sustained increase in global temperatures, mainly caused by anthropogenic effects, is a critical problem for humanity (Hansen et al., 2023). The stabilization of global temperature is vital for maintaining most of the cycles necessary for human life on Earth (Hoegh-Guldberg et al., 2018). At the same time, the study and anticipation of inevitable climate change impacts have become a priority issue nationally and internationally. Recent research has established that heat waves are globally increasing in intensity, duration, magnitude, and frequency (Perkins-Kirkpatrick & Lewis, 2020). While intensity generally exhibits linear growth with rising temperatures, other key characteristics follow distinct non-linear patterns of increase (Vautard, van Aalst, et al., 2024). The duration of heat waves, particularly for the most pronounced events, escalates quadratically with temperature (Martinez-Villalobos et al., 2025), signifying an accelerating protraction. Consequently, the magnitude—an integrated measure of both their intensity and these durations—may experience a compounded growth, substantially amplifying the overall scale and potential severity of each event. Furthermore, the frequency of heat waves is undergoing an exponential rise, reportedly doubling approximately every decade (Perkins-Kirkpatrick & Lewis, 2020; Vautard, Barnes, Philip, Kew, Pinto, & Otto, 2024). This behavior disproportionately increases the likelihood of the most extreme and prolonged events, leading to a substantially amplified and accelerated occurrence of heatwaves that possess the greatest potential for societal impact.

As in much of the world, both average temperature (Lagos-Zúñiga, Balmaceda-Huarte, et al., 2024; Lagos-Zúñiga, Mendoza, et al., 2024; Salazar et al., 2023) and heat waves (Demortier et al., 2021; González-Reyes et al., 2023; Piticar, 2018) have increased in Chile over recent decades. This has been reflected in an increase in the frequency and more severe effects of forest fires (Jones et al., 2022; Urrutia-Jalabert et al., 2018), water scarcity (Garreaud et al., 2020), losses in the agricultural industry (Alimagham et al., 2024; Jägermeyr et al., 2021), as well as heat-related human health problems (González-Reyes et al., 2023; Romanell et al., 2021), among others. These trends are expected to intensify in the coming decades (IPCC, 2021). Predicting and projecting heatwaves at regional scale is therefore an important issue from environmental (de Paula Corrêa, 2024) and socio-economic (García-León et al., 2021; Lowe et al., 2011) points of view. While recent works have allowed improving our understanding of mechanisms and precursors of heatwave occurrences in Chile in the present climate (Demortier et al., 2021; Jacques-Coper et al., 2021), to the best of our knowledge, there are no regional studies that specifically address the future evolution of heatwave and their characteristics.

Currently, global climate models (GCMs) belonging to the Coupled Model Intercomparison Project - Phase 6 (CMIP6) are the state-of-the-art for studying future climate change on a global scale (Eyring et al., 2016). However, due to their low resolution (about 100-250km), GCMs are not capable of representing regional- to local-scale processes such as atmosphere-land and atmosphere-orography interactions that modulate regional climate and may shape climate change signal (Junquas et al., 2024; Lupo et al., 2013; Maraun et al., 2017; Martinez-Villalobos et al., 2025; Nguyen et al., 2024; Rampal et al., 2024). Capturing the regional aspects of climate requires the use of complementary tools and methods (Araya-Osses et al., 2020). Among these, Regional Climate Models (RCMs) are the most complete description of the fine-scale physical processes of the regional climate system. While RCMs allow performing climate projections at regional to local scales, which is precisely where the impacts are felt and experienced most acutely, they face challenges due to their high computational cost which consequently restricts their horizontal resolution (Giorgi, 2019). For instance, the highest resolution of RCMs participating in the Coordinated Regional Downscaling Experiment (CORDEX) over South America is 22-25km. Considering the few individual modeling efforts conducted over Chile with a single RCM (Bambach et al., 2022; Bozkurt et al., 2019; Fernández et al., 2021), the resolution of 10-14km is still considered as high for this region. To our knowledge, the only study presenting regional future climate projections at this resolution has been done by Bambach et al., 2022, who used a variable-resolution CESM model. While their results highlight considerable regional changes, such as increased warming and drying over central Chile, the use of a single model underlines the need for multi-model high-resolution ensembles to better constrain uncertainties.

Similarly to GCMs, RCMs often include significant biases, which can originate from an imperfect representation of physical processes and from insufficient representation of complex geography (Maraun et al., 2021). Although the higher resolution of RCMs allows some processes to be solved more explicitly, thus reducing dependence on certain parameterizations and potentially some biases, errors may persist (Rummukainen, 2010). Climate models biases can be an important source of uncertainty in future climate projections in

Chile, both because of its complex topography (Arévalo et al., 2024; Torrez-Rodriguez et al., 2023) and the diversity of climates that exist along its 4400 km latitudinal span. For example, within the CORDEX datasets, significant climate biases have been detected in Chile; among them a prominent cold bias at high elevations north of 35^oS, especially above 2000 m.a.s.l. (Torrez-Rodriguez et al., 2023). It is well-known that using climate model projections for downstream applications and impact studies requires performing a bias-adjustment. Various bias-adjustment methods of different complexities have been developed in recent years (Li & Li, 2023). Several studies have been conducted on the projection of precipitation and temperatures in Chile, mainly using GCMs from CMIP5/CMIP6 but also RCMs with a coarse resolution of 50 km from the CORDEX South-America dataset (Aguayo et al., 2021; Boisier et al., 2024; Moya et al., 2024; Souvignet et al., 2010; Vásquez et al., 2024). An important aspect of bias-adjustment methods when applying to future climate projections is to preserve trends in mean and variance. However, if applied to relatively coarse-resolution projections, the bias-adjustment methods do not allow capturing regional-scale details and eventual heterogeneities in the climate change signal.

The aim of this study is to evaluate the effects of climate change on heat waves in Chile using a high-resolution regional model (grid spacing of 12.5 km and 91 vertical levels) with a suitable bias-adjustment scheme, with a special emphasis on the risk analysis of extreme events. The analysis is deliberately risk-oriented: it relies on the two high-emission pathways available for this model configuration (SSP3-7.0 and SSP5-8.5) to explore upper-range warming conditions relevant for adaptation planning and risk management, rather than to quantify the full range of scenario or structural uncertainty. The remainder of the paper is organized as follows: Section 2, Data and Methods, presents a brief overview of the CNRM-ALADIN (Goubanova et al., 2024) regional climate model and the bias-adjustment procedure used in the study. It also introduces the methodology for defining heat waves, calculating risk ratios, defining start and end-dates of heat waves, and analyzing the distribution of warm and cold seasons. Section 3, Results, presents the projected changes in the frequency, intensity, and magnitude of heatwaves, focusing on the risk relationships between the historical and future projections. In addition, we analyze the evolution of warm and cold seasons, focusing on a few representative Chilean cities: Concepción, Santiago, and La Serena. Finally, Section 4 discusses the implications of the findings, mentions limitations of our work and outlines future research directions.

2 Data and Methods

2.1 Data

2.1.1 CNRM-ALADIN regional climate model

CNRM-ALADIN version 6.4 (Table 1), hereinafter referred to as "ALADIN", is a bi-spectral hydrostatic area-limited regional climate model (Nabat et al., 2020), that uses a semi-Lagrangian advection and a semi-implicit scheme. ALADIN has been used for regional climate studies over various world regions, including Euro-CORDEX (Vautard et al., 2021) and Med-CORDEX (Ruti et al., 2016) domains. The present study relies on the regional simulations over a new domain covering the Northern and Central Chile (Figure 1) that were recently performed within a collaboration between CNRM (National Centre for Meteorological Research) and CEAZA (Center for Advanced Studies in Arid Zones). The projections were carried out with the version 6.4 of ALADIN which shares the same dynamic core, atmospheric physics and land surface modules as its global counterparts participating in CMIP6, namely CNRM-CM6 and CNRM-ESM2-1 global climate models (Roehrig et al., 2020). Notably, ALADIN incorporates the interactive aerosol scheme TACTIC simulating the life cycle of seven aerosol species - dust, sea salt, sulfate, black carbon, organic matter, nitrate and ammonium particles - and considering their interactions with radiation and clouds. Surface processes are representing using the SURFEX modeling platform (Decharme et al., 2019) employing a tile approach that separates land surfaces, lakes, and sea areas for surface irradiance calculations. The land surface is modeled with the Interaction Soil Biosphere Atmosphere (ISBA) model. In the configuration used in the present study, the river routing model was not activated. Further details and references on ALADIN's components and physical parametrizations can be found in (Nabat et al., 2020). The configuration used in this study has a 12.5 km (approximately 0.1^o) horizontal resolution and 91 vertical levels. This high horizontal and vertical resolution is particularly important for capturing the steep and complex orography of Chile. The model grid

employs a Lambert conformal projection centered at 29^{o}S,77^{o}W with 270 points in longitude and 324 points in latitude including the bi-periodization (11 points on north and east) and the relaxation zones (8 points on each side). It covers continental Chile from its northern limit at 17^{o}S to up to 45^{o}S in the south.

The ALADIN simulation used in this study span from 1950 to 2100 covering the historical period (1950–2014) and future projections under both the SSP3-7.0 and the SSP5-8.5 scenarios (2015–2100) (Meinshausen et al., 2020; Riahi et al., 2017). The main text uses SSP5-8.5 as the headline high-emission trajectory, while the parallel SSP3-7.0 simulation, processed with the same bias-adjustment pipeline, is reported throughout the Supplementary Material (see Supplementary Text SM4, Figs. S2–S9) and is used in Section 3 (Fig. 3) to test whether the heatwave response collapses onto a single function of regional warming. It was driven by the CNRM-ESM2-1 global model (Séférian et al., 2019) using the first member (r1i1p1f2) of the corresponding multi-member ensemble. Initial conditions for atmospheric and surface variables were derived from an ALADIN evaluation run driven by ERA5 reanalysis data. A two-year spin-up was included to ensure the stability of the land-surface scheme. The SSP5-8.5 scenario represents a high-emission future characterized by extensive fossil fuel use, rapid economic growth, and limited international cooperation on environmental issues, leading to a radiative forcing of 8.5 W/m^2 by the end of the century (O'Neill et al., 2016). This scenario helps explore potential extreme future conditions, providing valuable insights for risk assessment and policy planning. The daily maximum and minimum temperature are calculated from the hourly near-surface temperature (instantaneous values at the top of each hour) as the maximum and minimum hourly values, respectively.

2.1.2 CR2MET dataset

CR2MET (Table 1) is a high-resolution (0.05^o x 0.05^o regular latitude-longitude grid (5 km)) gridded dataset providing Daily Precipitation (pr), Daily Maximum 2 m air Temperature (tasmax, hereafter T_{max}), Daily Minimum 2 m air Temperature (tasmin, hereafter T_{min}) data for continental Chile between 1960 and 2021, that were generated by integrating station data, ERA5 reanalysis data (Hersbach et al., 2020) and MODIS satellite observations (J. P. Boisier, 2023). The station records used in its calibration comprise the major Chilean national surface networks — DGA, DMC, SERVIMET, INIA and FDF (J. P. Boisier, 2023) — making CR2MET the standard observational reference for continental Chile, adopted for national water accounting and as the evaluation baseline for regional and global climate models over the country (Alvarez-Garreton et al., 2018; González-Reyes et al., 2023; Torrez-Rodriguez et al., 2023).

Dataset	**Description**	**Climate Variables and Temporal Resolution**	**Spatial Resolution**	**Ref**
CNRM-ALADIN64	Regional climate model output	Hourly average near surface temperature. Historical (1950-2014) and SSP 3-7.0/5-8.5 (2015-2100) scenarios	Irregular grid, horizontal resolution of 12.5 km	(CNRM, 2024; Goubanova et al., 2024)
CR2MET V2.5	Observational product based on statistical downscalig of the ERA5 reanalysis calibrated with observational data, ETOPO1 topography, and MODIS satellite temperature estimates	Daily maximum and minimum temperature at 2m over the period 1960-2021	Regular grid of 0.05^o latitude-longitude	(J. P. Boisier, 2023)

Table 1: Description of CNRM-ALADIN and CR2MET datasets

2.1.3 Spatial sub-domains and cities

We divide the territory into three sub-domains: North, Center, and South, all of equal latitudinal extent. Details on the regions can be found in Supplementary Table S1 (Supplementary Text SM1). For the zonal analyses, spatial aggregation was performed by pooling the time series data from all grid points within each respective sub-domain. Consequently, the statistics for each 11-year moving window were calculated from this combined distribution, reflecting the collective behavior of the entire region. Among these, we report the mean, the 10th percentile (p10) and the 90th percentile (p90), which respectively represent the lower and upper bounds of the central 80% of the distribution. These percentiles are useful for characterizing the range and variability of the climate signal within each sub-domain.

Additionally, in the main text, we focus on three representative cities: La Serena, Santiago, and Concepción, located in the northern, central, and southern sub-domains, respectively. The choice of these cities is based on their demographic significance and their distinct climatic conditions. **Santiago**, the national capital, is the country's primary political and economic hub, concentrating over 7 million inhabitants in its metropolitan area, which represents more than a third of the national population (Instituto Nacional de Estadísticas (INE Chile), 2024). It features a semi-arid Mediterranean climate (Csb), characterized by hot, dry summers and cool, wet winters. **Concepción** is the nucleus of Chile's second-largest metropolitan area, with a population of approximately one million people, and serves as a major industrial and academic center (Instituto Nacional de Estadísticas (INE Chile), 2024). Its climate is oceanic (Cfb), with milder, rainier summers compared to Santiago. Finally, **La Serena**, part of the La Serena-Coquimbo conurbation of over 500,000 inhabitants, is a key administrative capital and tourist center in northern Chile. It possesses a coastal desert climate (BWk) with semi-arid conditions but moderate temperatures year-round due to the influence of the oceanic Humboldt Current (Sarricolea et al., 2017). These climate types correspond to the Köppen–Geiger classification system (Peel et al., 2007), where Csb denotes a warm-summer Mediterranean climate, Cfb an oceanic climate with no dry season, and BWk a cold desert climate with arid conditions. The locations and climate settings of the three cities are shown in Figure 1. Results for other major cities (Iquique, Valparaíso, Temuco, Osorno) are presented in Supplementary Text (SM 5, Seven-city extended analyses, S10–S11).

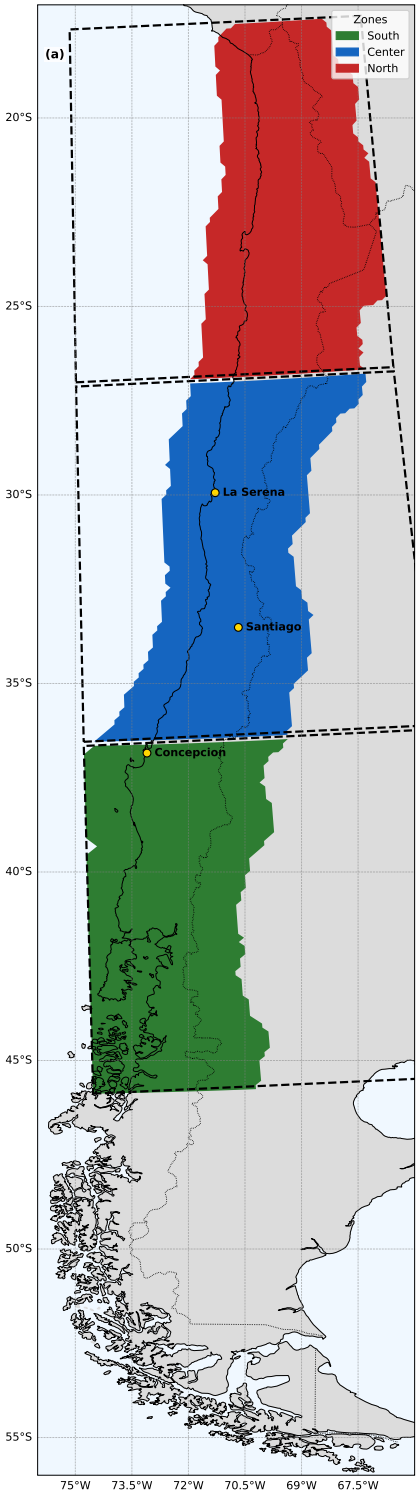

Figure 1: Map of Chile showing the locations of the three main study cities: Concepción (South: −36.8°S, −73.1°W), Santiago (Center: −33.5°S, −70.7°W), and La Serena (North: −29.9°S, −71.3°W). The filled areas indicate the spatial domain of overlap between the CR2MET dataset and the CNRM-ALADIN model simulation, segmented into North (red), Center (blue), and South (green) zones. The dashed rectangles delimit the boundaries of the CNRM-ALADIN subdomain used for regional analysis in each zone. Locations of other cities (Iquique, Valparaíso, Temuco, Osorno) are shown in Figure S1 (Supplementary Text SM1)

2.2 Methods

2.2.1 bias-adjustment

Although ALADIN better resolves local processes and topography than the driving GCM (effectively providing a dynamical downscaling), it still generates a biased simulation of the local climate. For this reason, we applied a bias-adjustment procedure to the ALADIN output using the CR2MET V2.5 (J. P. Boisier, 2023) as the reference dataset and baseline. Both ALADIN and CR2MET data provide daily surface temperature data, covering variables such as maximum temperature (T_{max}), minimum temperature (T_{min}), and mean temperature (Tmean). Prior to bias-adjustment the CR2MET dataset is regridded using bilinear interpolation to the ALADIN grid. We applied various bias-adjustment methods, all available in the Python library climQMBC (Chadwick et al., 2023), including QM (Quantile Mapping) (Panofsky & Brier, 1958), DQM (Detrended Quantile Mapping, which adjusts quantiles after removing the climate trend) (Bürger et al., 2013) and QDM (Quantile Delta Mapping, which preserves relative changes in quantiles), (Cannon et al., 2015) UQM (Unbiased Quantile Mapping) (Chadwick et al., 2023), and SDM (scaled distribution mapping) (Switanek et al., 2017). From these options, UQM was selected for this study because it has shown a general better performance/scores (See Supplementary Text SM2). We note that over the historical calibration period UQM, reduces to the standard empirical quantile mapping (QM) correction, whose calibration-period performance is well established (Cannon et al., 2015; Panofsky & Brier, 1958); the methods differ in how the correction is transferred to the projection period. UQM is a quantile mapping method designed to preserve the raw trends in both mean and standard deviation as projected by the climate model, making it particularly suitable for climate change studies (Chadwick et al., 2023). The transferability of the adjustment to a warmer climate is further validated out-of-sample in Supplementary Text SM7 (Figures S13–S16): even when UQM is calibrated on the coldest half of the historical record and evaluated on the warmest half — a deliberate worst-case stress test — the adjusted output retains a several-fold smaller tail bias than the raw model, with a slightly cold residual at high percentiles, implying that the projected heatwave statistics are, if anything, conservative.

2.2.2 Heat wave definition

To calculate extreme temperatures, we used bias-adjusted ALADIN model outputs, specifically the daily maximum surface temperature (T_{max}) and daily minimum surface temperature (T_{min}). We defined a heat wave based on the historically simulated daily maximum temperatures (T_{max}) (1980–2010, end year exclusive) at a given grid point. To do this, we constructed, for each grid point, the distribution of all daily T_{max} values over the full 1980–2010 reference period and determined its 90th percentile (P_{90}), used as the threshold above which the maximum temperature is considered abnormally high for that location. This yields a single, time-constant value per grid point: P_{90} is not computed on a calendar-day or seasonal basis, and the same threshold is applied unchanged to both the historical and future periods. A heat wave is defined as an event characterized by an uninterrupted temporal sequence of days (starting from 1 day) in which the T_{max} simulated at the given location exceeds P90. A direct consequence of this fixed climatological threshold is that detected heat waves naturally concentrate in the austral warm season (DJF and adjacent months), when T_{max} regularly exceeds P_{90}. This is a deliberate choice: the fixed threshold targets absolute, impact-relevant extremes with respect to the historical climate rather than anomalies relative to each season (Amaya et al., 2023; Smith et al., 2025) (a complementary analysis using a moving threshold is provided in the Supplementary text SM8, figures S17 and S19).

We define the characteristics of a heat wave as follows:

- **Intensity**$[C]$ is defined as the difference between the maximum value of T_{max} reached during the event and the threshold P_{90}.
- **Duration**$[days]$ refers to the number of consecutive days in which the temperature remains above the P_{90} threshold.
- **Magnitude**$[C \cdot days]$ is the integral of the difference between T_{max} and P_{90} over the duration of the event. The magnitude defined here is the same as the cumulative intensity and is analogous to some definitions of degree-days (Luo et al., 2023; Siebers et al., 2017).

Similarly, cold waves have the same characteristics as heat waves, intensity, duration and magnitude, but the definition is when T_{min} is under P10 instead.

2.2.3 Construction of Time Series

The time series shown in Figure 2 are constructed using a moving-window analysis to depict the evolution of heatwave characteristics over time. This analysis is performed in two steps to differentiate between the behavior of all events and that of the most extreme ones.

First, to generate the statistics for all heatwaves (represented by the gray shaded areas in Figure 2), an 11-year moving window is applied across each region. An 11-year moving window was deliberately selected to filter out interannual variability while preserving the decadal climate signal. Sensitivity analyses confirmed the robustness of the projected trends (see Supplementary Figures S12 and S18). Within each window, the 10th percentile (p10), mean, and 90th percentile (p90) are calculated for the intensity, duration, and magnitude of every heatwave event.

Second, to specifically isolate the trend of the most severe heatwaves (the red shaded areas), the procedure is repeated on a subset of the data. Within each 11-year window, we first select the top 10% of events based on their extremity (e.g., the 10% with the highest magnitude). The same statistics (p10, mean, and p90) are then calculated exclusively for this group of high-impact events.

To complement the temporal evolution analysis, we introduce a sensitivity assessment that directly relates heatwave characteristics to regional warming levels. This approach examines the underlying relationship between the background climate state and extreme events, while filtering inter-annual variability. To achieve this, we employ an 11-year moving window to analyze both regional temperature anomalies and the corresponding heatwave metrics.

2.2.4 Tracking temporal projections of season changes and average initial and starting dates of heatwaves

To objectively track shifts in seasonality, we first model the underlying annual temperature cycle. We employ a Fourier analysis to decompose the daily temperature time series into a set of simple, constituent sine waves known as *harmonics*. Each harmonic represents a fundamental frequency of the annual cycle. By summing the first four harmonics, we reconstruct a smoothed, idealized representation of the seasonal temperature curve. This approach captures the main seasonal trend while filtering out high-frequency 'noise' from daily weather variability.

Using this smoothed curve, we defined the seasons based on the historical period (1980-2010) temperature distributions (see SM3; see Figure 4). The **warm season** is defined as the period where the reconstructed seasonal cycle of maximum temperature (T_{max}) exceeds the 75th percentile of the historical T_{max} distribution. Similarly, the **cold season** is the period where the reconstructed seasonal cycle of minimum temperature (T_{min}) falls below the 25th percentile of the historical T_{min} distribution. We then estimate the trend in the length of these warm and cold seasons by applying a linear regression to their respective start and end dates over the century.

Similarly, we identify periods within the year characterized by heat waves and cold waves, using the definitions mentioned earlier. We estimate the trend in the duration of these heat wave and cold wave periods under global warming by applying linear regression to the occurrence dates of the first and last heat wave or cold wave event of the respective season.

2.2.5 Calculation of risk ratios

We use risk ratios (RR) (Martinez-Villalobos & Neelin, 2023; Neelin et al., 2017; Stott et al., 2004) to quantify global warming changes in the duration, intensity and magnitude of heat waves. A risk ratio compares the probability of a heat wave having a certain intensity, duration, or magnitude under a global warming scenario to the probability of the heat wave having the same intensity, duration, or magnitude in the historical climate. Hence, a RR of one implies no change in time. As an example, a risk ratio equal to three (RR=3) for duration ≥ 5 days implies that heat waves of duration of 5 or more days are

three times more frequent in the future compared to the historical conditions, and represents the ratio between the future extreme event frequency and that of the historical period. To compute the risk ratios,

the ranges of heatwave duration, intensity, and magnitude were first discretized. We used 100 bins with a *logarithmic* spacing, which provides higher resolution for more common, lower-value events while still capturing the full range of rare, high-value extremes. The risk ratio was then calculated for the threshold defined by the start of each bin.

To ensure the statistical robustness of the analysis and avoid artifacts from sparse data, only thresholds where at least three events were identified in the historical period were considered. For each of these thresholds (x), the risk ratio was calculated as the ratio of cumulative probabilities:

$$\text{Risk Ratio}(X \geq x) = \frac{P_{\text{future}}(X \geq x)}{P_{\text{historical}}(X \geq x)}$$

where X is the heatwave characteristic (e.g., duration) and $P(X \geq x)$ is the probability of an event equal to or exceeding the threshold x. In order to assess uncertainties in RR indices, the procedure was performed over 10^4 iterations, a number sufficient to ensure convergence of the 5th and 95th percentiles used below as confidence bounds. In each iteration, we generated a new 30-year "historical" dataset by randomly sampling 30 years, with replacement, from the original 1980-2010 period. Similarly, a new 30-year "future" dataset was generated by sampling 30 years, with replacement, from the 2050-2080 period. For each pair of resampled datasets, a full risk ratio curve was calculated. This process yielded a distribution of 10^4 risk ratio values for each point on the curve. From this distribution, we derived the final risk indices and their associated uncertainties, using the 5th and 95th percentiles to define the 90% confidence interval. This approach allows us to rigorously quantify the effect of sampling variability—that is, how much our results might change due to the specific set of years included in our 30-year analysis periods. The length of each period follows the World Meteorological Organization standard for climate normals (Arguez & Vose, 2011), long enough to average out interannual variability while still resolving the climate-change signal.

3 Results

This section presents the main findings of our study, using the bias-adjusted ALADIN temperature data (as described in Section 2.2.1) to assess the projected changes in heatwaves across Chile. We structure our analysis to move from broad temporal trends to specific risk quantification.

First, in Section 3.1, we examine the long-term evolution of temperature and key heatwave characteristics (intensity, duration, magnitude) throughout the 21st century to establish the overall trajectory of change. To link these temporal trends directly to global warming levels, Section 3.2 reformulates these trajectories as a function of regional warming (ΔT), demonstrating that the heatwave response under both the SSP3-7.0 and SSP5-8.5 scenarios collapses onto a single, common response curve. Following this, in Section 3.3, we analyze how these changes reshape the seasonal cycle, focusing on the projected lengthening of the warm season and the corresponding reduction and potential disappearance of the cold season.

Next, we provide a detailed statistical comparison between the historical (1980-2010) and future (2050-2080) periods in Section 3.4. Here, we use probability distributions to illustrate the shifts in the frequency, intensity, and magnitude of both heatwaves and cold waves. Building on this, Section 3.5 delves into the critical, non-linear relationship between heatwave intensity and magnitude, showing how increased duration amplifies the overall severity of events. Finally, in Section 3.6, we synthesize these findings into a forward-looking risk assessment, using risk ratios to quantify how much more frequent dangerous heatwave events are projected to become.

3.1 Temporal evolution of temperature and characteristics of extreme events

To understand how global warming will reshape extreme temperature events in Chile, we begin by examining the long-term evolution of key heatwave metrics across the northern, central, and southern regions of the country. Using 11-year moving windows, we analyze changes in temperature, number of extreme days, and the intensity, duration, and magnitude of heatwaves (Figure 2).

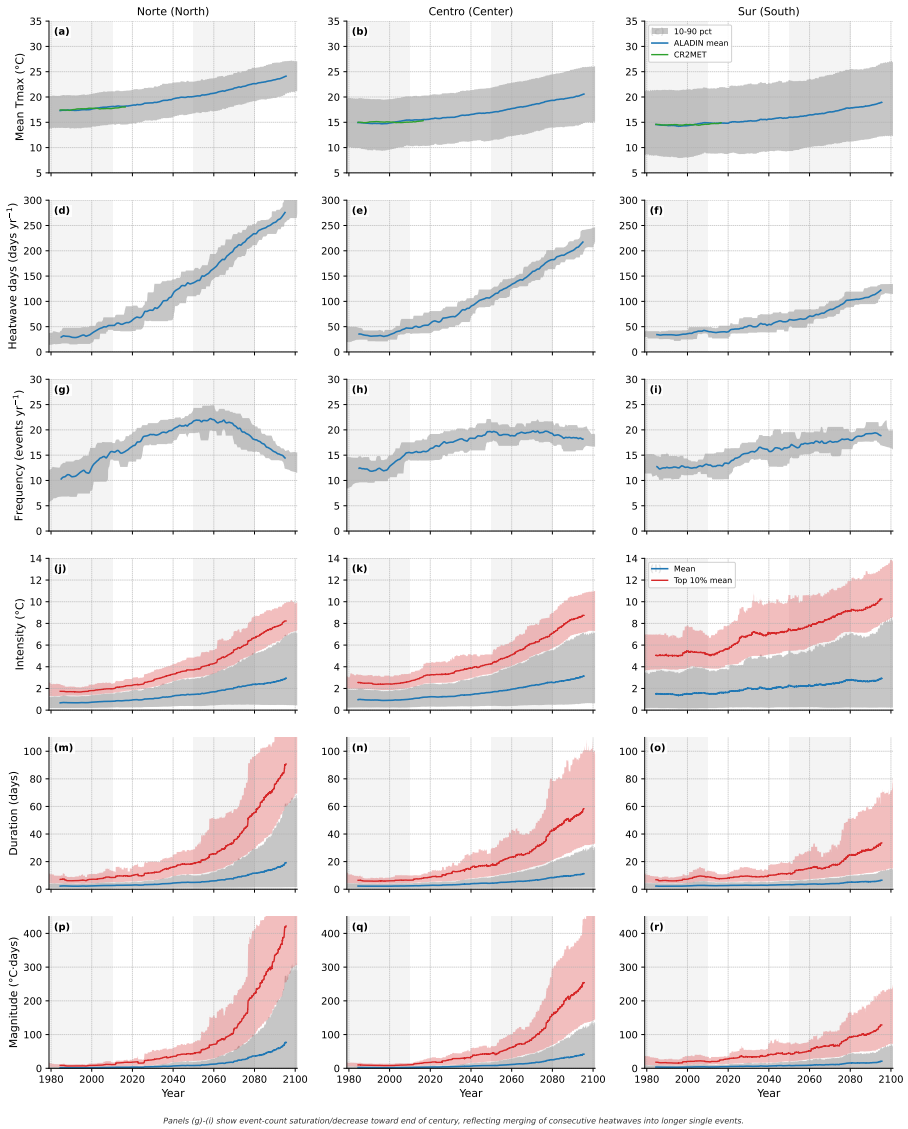

Figure 2: Time series of temperature and heat wave characteristics in the northern (left), central (center), and southern (right) regions of Chile. Panels (a)–(c) show the 30-year moving window mean temperature (in °C) for ALADIN (blue) and CR2MET (green), with the 10th–90th percentile range shaded. To prevent edge artifacts, the graphical representation of these mean lines is restricted to the interval where the 30-year window is completely contained within the available data, removing the first and last 15 years. Panels (d)–(f) show the moving window mean of the number of heat wave days per year. Panels (g)–(i) show the moving window mean of the number of heat wave events per year. In particular, in panels (g)–(i), it can be observed that the number of discrete events per year tends to stabilize or even decrease towards the end of the century. This reflects the progressive merging of consecutive heatwaves into single but longer events. Panels (j)–(l) show the moving window mean of event intensity. Panels (m)–(o) show the moving window mean of event duration. Panels (p)–(r) show the moving window mean of event magnitude. For all metrics, the 10th–90th percentile range is shaded in gray. In panels (j)–(l), (m)–(o), and (p)–(r), the mean of the top 10% of events within each 11-year window is shown in red, with its 10th–90th percentile range shaded. For the SSP3-7.0 scenario, see Supplementary Figure S2.

A significant increase is observed in the projected temperature for the three zones (South, Central, and North), with an average increase ranging from $\Delta T = 0.2\,^{\circ}\mathrm{C}$/decade in the southern zone to $\Delta T = 0.4\,^{\circ}\mathrm{C}$/decade in the northern zone. A marked increase is observed in the number of days with extreme temperatures exceeding the 90th percentile (Figure 2, second row), reaching 250, 160, and 90 extreme

temperature days per year on average for the period 2050-2080, that is, 6.8, 4.3 and 2.5 times the historical climate, in the North, Central, and South zones, respectively. While intensity and duration (Figure 2, fourth and fifth row) exhibit a predominantly linear increase over time, the magnitude, being an integrated metric (Figure 2, sixth row), shows accelerated, exponential growth. Focusing on the set of most extreme events (the top 10% marked in red), we can note accelerated growth for each characteristic, especially for duration and magnitude, which show exponential and superexponential behaviors, respectively. This is particularly noticeable in the north case, where an increase of $\Delta T = 0.4\,^{\circ}\mathrm{C}$/decade was associated with an increase in the magnitude of the most extreme events of $\Delta M = 80\,^{\circ}\mathrm{C} \cdot \mathrm{day}$ for the year 2080 (Figure 2 subpanel p).

3.2 Relationship between heatwave characteristics and regional warming

Figure 3 complements the temporal analysis by illustrating the relationship between sustained regional warming (11-year mean ΔT) and heatwave characteristics. A clear positive correlation is evident across all metrics and zones: as the 11-year average temperature anomaly increases, so do the frequency, duration, intensity, and magnitude of heatwaves. For instance, in the Central region, an increase in the mean temperature anomaly from 1°C to 3°C is associated with a shift in heatwave frequency from approximately 20 to 25 events per year. The dispersion of data points increases at higher warming levels, particularly for the magnitude metric, suggesting enhanced event-to-event variability of extreme events in a warmer climate.

A critical finding is the differential response of extreme events compared to average events. In the panels for duration, intensity, and magnitude, the red dots (representing the 90th percentile of events) consistently show a steeper increase than the blue dots (representing the average across all events). This is most pronounced in the Central region, where at a warming level of +3°C, the average duration of the most extreme heatwaves is approximately 7 days longer than that of an average heatwave (while in the historical climate, the difference between the longest events and the average event was only two days). This growing gap indicates that the most severe heatwaves are becoming disproportionately longer, more intense and larger in magnitude as the climate warms, posing an escalating threat.

Comparing the regions reveals distinct response pathways to regional warming. The Southern region, for example, shows a particularly marked increase in the intensity of its heatwaves, while the Northern region's response is more pronounced in event duration. The Central region, in contrast, shows a more balanced response, with increases across all characteristics. Interestingly, when these distinct effects are combined into the integrated magnitude metric, the overall response to warming becomes notably similar across the three regions. For instance, at a warming level of +2°C, all three region show a mean heatwave magnitude (blue dots) of between 8 and 10 °C-days, while the mean magnitude of the most extreme events (red dots) converges between 18 and 24 °C-days. This suggests that while the nature of the heatwaves evolves differently in each zone, the cumulative heat stress (magnitude) follows a comparable trajectory of intensification.

In summary, this analysis provides evidence that the projected increase in heatwave severity is closely linked to regional warming levels. It demonstrates that not all heatwaves will intensify equally; the most extreme events are projected to amplify at an accelerated rate across all their characteristics. This finding underscores that future impacts may not scale linearly with mean temperature increases, a conclusion strongly supported by recent literature. While the intensity of extreme heat events may exhibit a linear shift with global warming, other critical characteristics follow distinctly non-linear patterns (Vautard, Barnes, Philip, Kew, Pinto, & Otto, 2024). For instance, the duration of the longest heatwaves is shown to increase quadratically with temperature, indicating a clear acceleration (Martinez-Villalobos et al., 2025). However, this non-linear response is not limited to acceleration. In some regions, particularly in the tropics, projections suggest a potential saturation in the *number* of discrete heatwave events, as they begin to merge into single, prolonged periods of extreme heat under higher warming thresholds (Perkins-Kirkpatrick & Gibson, 2017). This complex interplay of linear shifts, accelerated responses, and saturation points is a crucial consideration for developing robust and effective climate adaptation strategies.

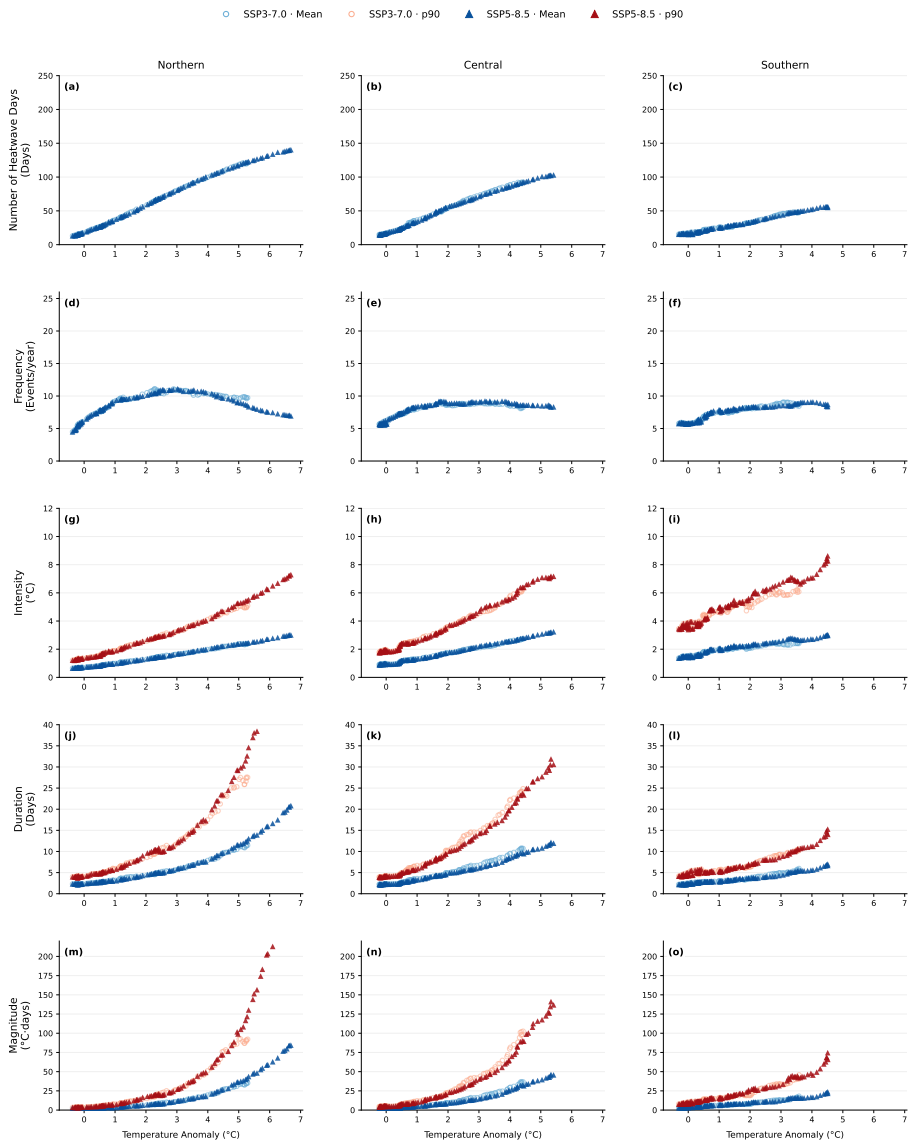

Figure 3: Sensitivity of heatwave characteristics to regional warming, plotted as a scenario overlay of SSP3-7.0 and SSP5-8.5. Each panel plots a heatwave metric against the 11-year moving average of the regional temperature anomaly (ΔT, in °C), calculated relative to the 1980–2010 baseline. Each point represents an 11-year moving window. Panels (a)–(c) show total annual heatwave days, (d)–(f) show event frequency, (g)–(i) show mean intensity, (j)–(l) show mean duration, and (m)–(o) show mean magnitude. Four series are shown per panel, encoded by a saturation-by-scenario palette combined with marker shape: small circles (○) denote the lower-emissions pathway SSP3-7.0 (light blue for the all-event mean; light salmon for the p90 of the most extreme events), while larger filled triangles (△) denote the high-emissions pathway SSP5-8.5 (deep saturated blue for the mean; deep red for the p90). For duration, intensity, and magnitude (panels g–o), the p90 series shows the mean restricted to the 90th percentile of the most extreme events within each window, enabling a direct comparison of how average and extreme heatwaves respond to sustained warming. The two scenario clouds trace a common underlying curve in every panel: the SSP5-8.5 points extend the SSP3-7.0 trajectory to higher ΔT, demonstrating that the per-°C response of each heatwave characteristic is essentially invariant to the emissions pathway.

3.3 Distribution of the start date, end date, and duration of the warm and cold seasons

Building on the finding that sustained regional warming amplifies the severity of extreme events, this section now examines how this warming trend fundamentally reshapes the annual climate calendar. We analyze the projected changes in the start, end, and overall duration of the warm and cold seasons, providing a broader perspective on how the baseline climate is expected to shift throughout the century.

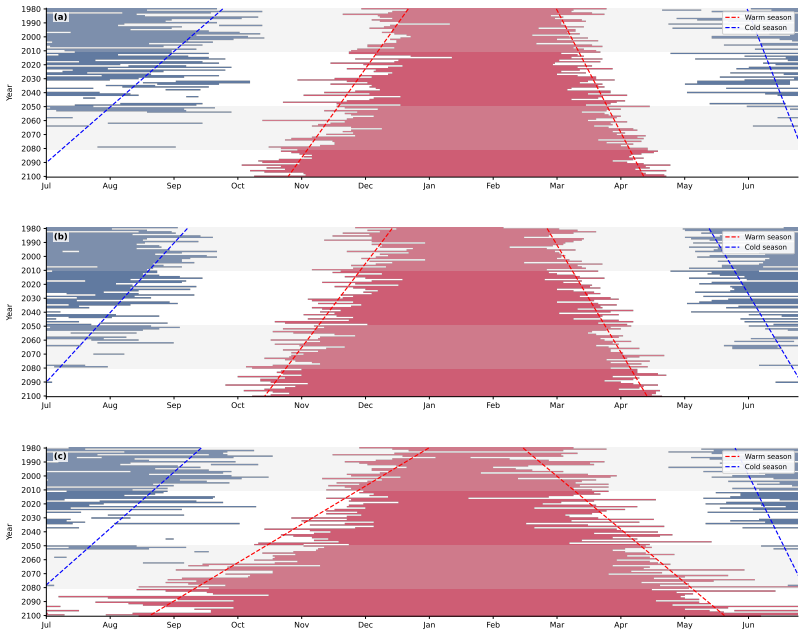

Figure 4: Changes in the seasonality of warm (red) and cold (blue) seasons in panels (a) Concepción, (b) Santiago, and (c) La Serena during 1980–2080. Seasons are defined using the annual cycle of daily maximum (warm season) and minimum (cold season) temperature, reconstructed from the first four Fourier harmonics. The warm season is the period when the reconstructed maximum temperature exceeds the 75th percentile of the 1980–2010 historical distribution. The cold season is the period when the reconstructed minimum temperature falls below the 25th percentile of the 1980–2010 historical distribution. Dotted lines show the linear regression of the start and end dates for each season. For the SSP3-7.0 scenario, see Supplementary Figure S3.

At the global scale, an increase in the length of summers and shortening of the winters is an expected outcome of global warming (Wang et al., 2021). Accordingly, we find a significant increase in the duration of the warm season in Chile. For example, in Santiago (Figure 4b), summers are projected to extend 8.5 days per decade, with an expected duration of 174 days by 2080, 90% more extensive than the historical climate (Figure 4). Both in Concepción and La Serena, the duration of warm season will also extend significantly, reaching durations of 142 and 205 days, an increase of 55% and 124% (Figure 4), respectively. This implies that temperatures which historically occurred only on the hottest 25% of days during the summer season (i.e., above the 75th percentile of historical summer T_{max}) will become much more frequent. By 2080, such temperatures are projected to occur on 39% of the year in Concepción, 44% in Santiago, and 56% in La Serena, indicating a major shift in the baseline of daily maximum temperatures.

By applying a linear trend analysis, we find that the expansion of summer occurs asymmetrically, with more pronounced changes in the astronomical spring months. For instance, in Santiago, projections indicate that the warm season will, on average, begin 4.4 days earlier per decade, while conclude 4.1 days later per decade during the period from 1980 to 2080. According to these projections, all these cities are projected to have completely lost their cold season by 2080. However, in some cities such as La Serena, this transition could occur as early as the next decade, by 2035 (Figure 4).

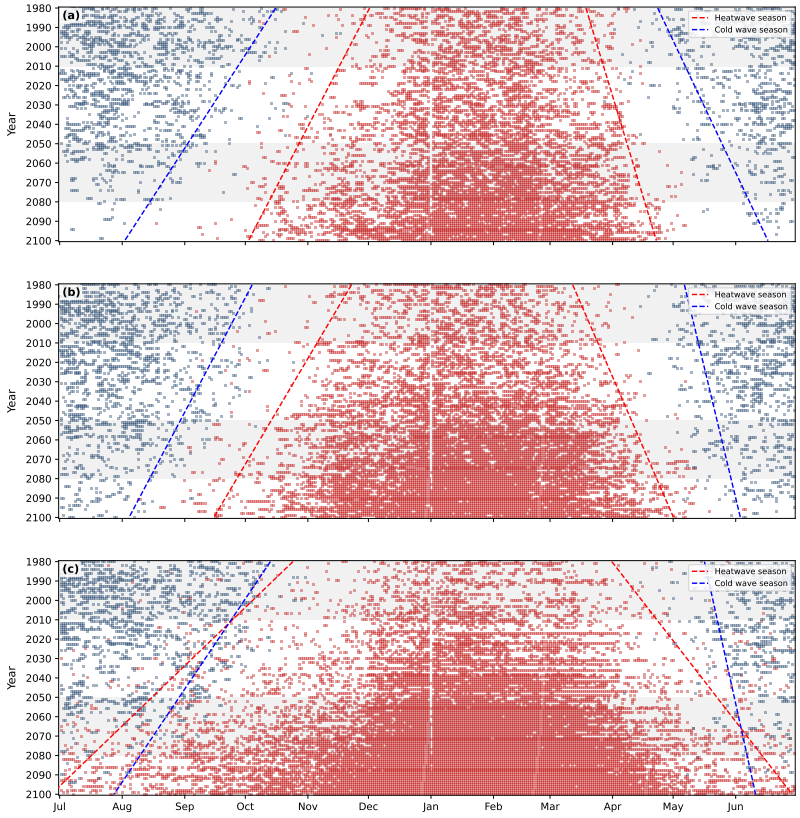

Figure 5: Changes in the seasonality of heat waves (red) and cold waves (blue) in panels (a) Concepción, (b) Santiago, and (c) La Serena during 1980–2080. Heat waves are defined as periods when daily maximum temperature exceeds the 90th percentile of the 1980–2010 historical distribution. Cold waves are defined as periods when daily minimum temperature falls below the 10th percentile of the 1980–2010 historical distribution. Dotted lines show the linear regression of the annual first and last occurrence dates for both heat waves and cold waves, highlighting the temporal shift of these seasons. For the SSP3-7.0 scenario, see Supplementary Figure S4.

To complement the analysis of changes in the warm and cold seasons, we examine the annual timing of heatwave occurrences, identifying the first and last day of each year with heatwave conditions. This provides a more direct estimate of how the heatwave season itself is expanding under climate change —important for understanding exposure beyond shifts in seasonal averages. As illustrated in Figure 5, the timing of heatwaves generally aligns with the summer months throughout the historical period. However, projections reveal a clear prolongation of the heat wave season beyond the summer, with events increasingly extending into the historical spring and autumn, and even into the historical winter in some regions. This phenomenon is a direct consequence of using a fixed temperature threshold (the 90th percentile of the historical period 1980-2010) to define a heat wave. As the climate warms, temperatures during the spring and autumn months will more frequently exceed this historical reference value, and will therefore be classified as heat wave days. The dotted lines in the figure trace the annual first and last heatwave days, highlighting this shift.

Similar to the seasonality analysis, an asymmetry is projected in the lengthening of the heat wave seasons, with the start of the heatwave season advancing more rapidly than its end. For example, in Santiago (Figure 5b), the first heatwave of the year occurred around mid-November in 1980 but is projected to occur as early as late September by 2080, advancing 46 days. Meanwhile, the last heatwave shifts from March to early May. An even more critical case can be observed in La Serena, where potential heat waves are projected throughout the entire year. While they originally occurred from late October to March reaching a total duration of 308 days, by the end of the century, only a few days in mid-July are expected to be free of heatwaves.

3.4 Changes in heat waves probability distributions

When comparing the historical and future periods, our analysis reveals a significant increase in the frequency of heat waves of all magnitudes, as shown in Figure 6. This change manifests not only in a greater number of events but also in an intensification of their characteristics. The results for the analyzed cities show that future events will exceed historical records, reaching unprecedented durations, intensities, and magnitudes. This increase is primarily concentrated in the most extreme events, indicating a clear shift in the probability distributions toward more severe values.

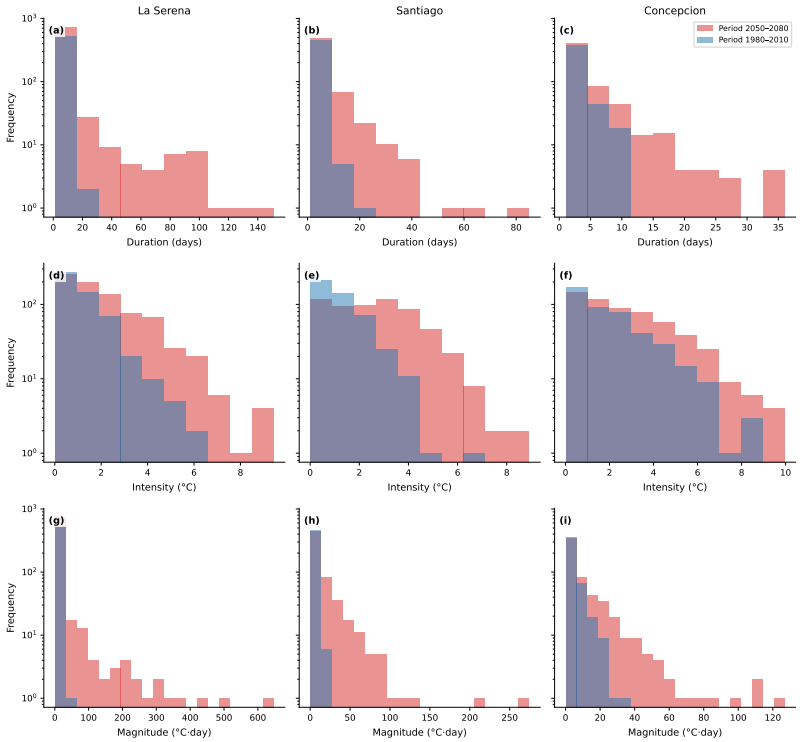

Figure 6: Histogram of the duration (top), intensity (middle), and magnitude (bottom) of heat waves in Concepción (left), Santiago (center), and La Serena (right) during the periods 1980-2010 (blue) and projections for 2050-2080 (red). Note that the y-axis of this graph is on a logarithmic scale. Also note that the duration (top) and intensity (middle) graphs have 10 bins, while the magnitude (bottom) graphs have 20 bins. This latter choice was made because the high magnitude values in the projected regime grouped a large portion of the historical regime data into just a few bins. For the SSP3-7.0 scenario, see Supplementary Figure S5.

A comparison of historical (1980-2010) and future (2050-2080) periods reveals an increase in the frequency of heat waves across all magnitudes. In La Serena, for example, events are projected with durations up to seven times greater, intensities up to 3°C higher, and magnitudes 18 times greater than those in the historical record. Overall, the frequency of heat waves is estimated to increase by 30% in Concepción, 32% in Santiago, and 48% in La Serena. Across the broader territory, these frequency changes vary significantly, ranging from a 27% decrease along the northern coast to a 123% increase in the Andes mountain range. While all heat wave metrics (intensity, duration, and magnitude) are projected to increase, this increase is primarily concentrated in extreme events (those with the greatest duration, intensity, and magnitude). Projections show that all three metrics in each considered city (Concepcion, Santiago, and La Serena) will reach unprecedented levels, exceeding the most extreme events in the historical regime.

On the other hand, the increase in less impactful heat waves (which are the most frequent) will be much more modest, reflecting the shift of the probability curve towards extreme events. For example, in La Serena, the increase in heat waves lasting less than 14 days will be 31% (compared to 48% for heat waves in general) (Figure 6) This suggests that while the most extreme heat waves will become significantly more intense,

frequent, and longer-lasting, the changes in moderate heat waves will be less pronounced (Figure 6).

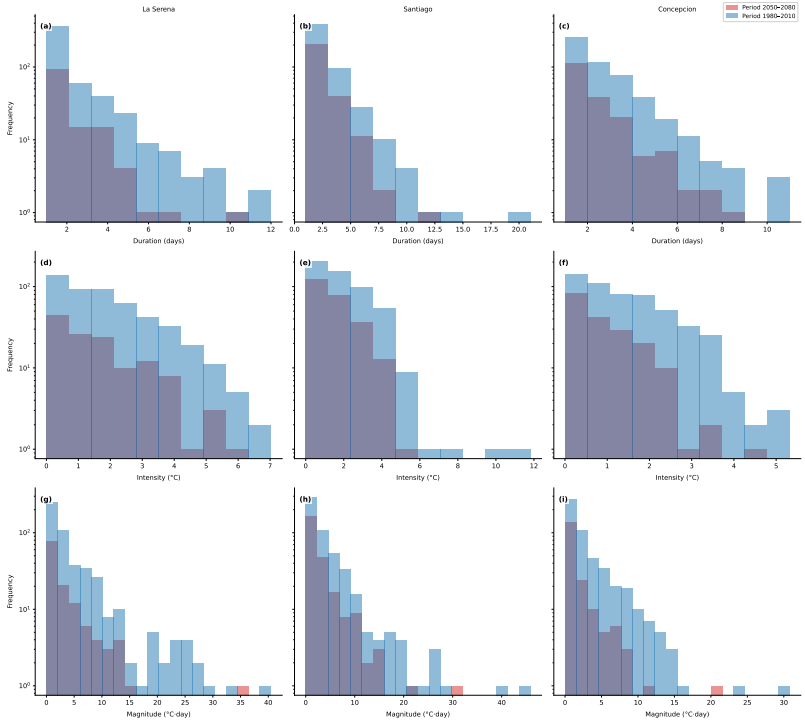

Figure 7: Histogram of the duration (top), intensity (middle), and magnitude (bottom) of cold waves in Concepción (left), Santiago (center), and La Serena (right) during the periods 1980-2010 (blue) and projections for 2050-2080 (red). Note that the y-axis of this graph is on a logarithmic scale. Also note that the duration (top) and intensity (middle) graphs have 10 bins, while the magnitude (bottom) graphs have 20 bins. This latter choice was made because the high magnitude values in the historical regime grouped a large portion of the projected regime data into just a few bins. For the SSP3-7.0 scenario, see Supplementary Figure S6.

Similarly, when calculating cold waves based on daily minimum temperature we observe a significant decrease in their frequency, intensity, and magnitude (Figure 7). For example, in La Serena, cold waves with durations exceeding the historical 90th percentile (P90) are projected to occur only 2.9% of the time (Figure 7). Similarly, the most intense P90 cold waves will occur just 4.2% of the time, and the highest magnitude P90 events will occur only 2.1% of the time (Figure 7). This highlights a very significant decline in cold wave activity in La Serena, with only 53 events projected over a 30-year period between 2050 and 2080 (Figure 7), compared to 470 events during the same interval in the historical period—a reduction of 88.7% of the events. Although, Santiago and Concepción also experience significant changes, with reductions of 61.7% and 64.0% of cold wave events, respectively, these changes are less severe than those in La Serena (Figure 7). It is important to emphasize that the reduction in cold waves occurs at a much faster rate than the increase in heat waves. For example, in La Serena, while the overall frequency of heat waves increases by 48%, extreme cold waves are drastically reduced by 88.7% from historical levels. Similarly, in Santiago and Concepción, despite heat waves increasing by 32% and 30% respectively, the incidence of cold waves contracts by 61.8% and 63.1% compared to their historical frequency. These projections show that, in the face of global warming, the loss of cold events is proportionally more pronounced.

3.5 Duration vs. Magnitude of Heat Waves

Building upon the previously discussed individual changes in heatwave characteristics, this section delves into the significant interplay between heatwave intensity and its cumulative magnitude. Understanding this relationship is important, as magnitude, which integrates both the peak temperature and the persistence of

a heatwave, offers a more comprehensive measure of its potential impact. We specifically investigate how changes in heatwave duration, a key feature of a warming climate (Martinez-Villalobos et al., 2025), might be altering this intensity-magnitude dynamic.

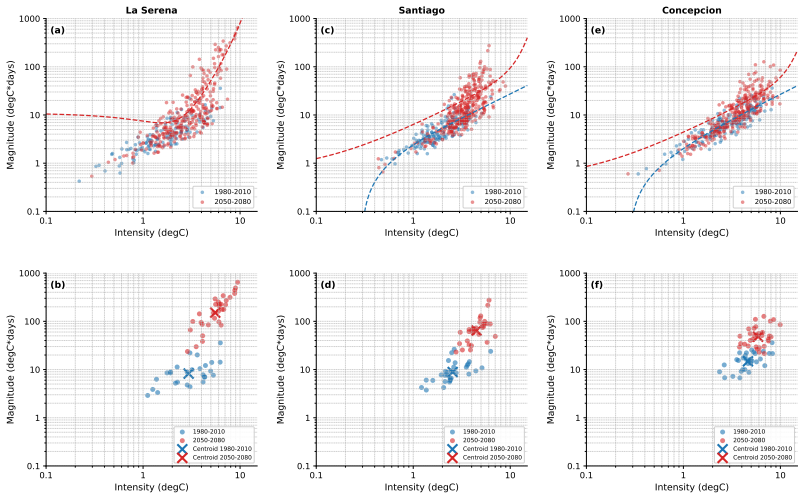

Figure 8: Relationship between the intensity and magnitude of simulated heat wave events in (left) La Serena, (center) Santiago, and (right) Concepción during the historical (1980-2010, in blue) and future (2050-2080, in red) periods. The first row displays the heat wave events for each city, along with an exponential regression. The second row highlights the most extreme event of each year within the 30-year periods, as well as the "typical annual heat wave", represented by the centroid of the events in each period (marked with an "x"). For the SSP3-7.0 scenario, see Supplementary Figure S7.

Examination of heatwave events in the three selected cities (Figure 8, first row) reveals a strongly non-linear relationship between the intensity and magnitude of heat waves. This exponential behavior implies that even modest increases in a heatwave's peak temperature (intensity) can lead to a disproportionately larger increase in its overall magnitude, making the prevention of small escalations in peak temperatures of particular importance due to these amplified effects. Furthermore, a significant shift is evident when comparing historical and future projections: for the same level of intensity, future heatwaves are projected to exhibit a significantly greater magnitude. This amplification, even without an increase in peak temperature, underscores the growing relevance of heatwave duration; as heatwaves persist longer, their cumulative magnitude escalates, intensifying their overall impact (Figure 8). This effect becomes more pronounced when focusing on the most intense heat waves, which, for the same intensities, can have magnitudes up to tree times greater, as is the case in La Serena (Figure 8). This finding suggests that event duration increasingly dominates magnitude in a warming climate.

The second row of Figure 8, which isolates the "typical annual heatwave" and the most extreme event of each year, reveals an even more pronounced trend.. When comparing the periods, heat waves doubled their duration and reached magnitudes five times greater. This indicates that for these already impactful events, the extended duration plays an increasingly dominant role in driving their magnitudes to levels beyond historical precedent, especially for the highest-impact future heatwaves which will be characterized not just by higher peaks but by substantially prolonged periods of extreme heat. This result is consistent across all three main cities analyzed and underlines how the most extreme events in the future will not just be hotter, but also substantially longer, amplifying their overall impact. This escalating severity, driven by the non-linear intensity-magnitude relationship and significantly amplified by increased duration, contributes to a heightened risk landscape, which we will quantify in the following section.

3.6 Risk Ratio of Magnitude and Duration of Events

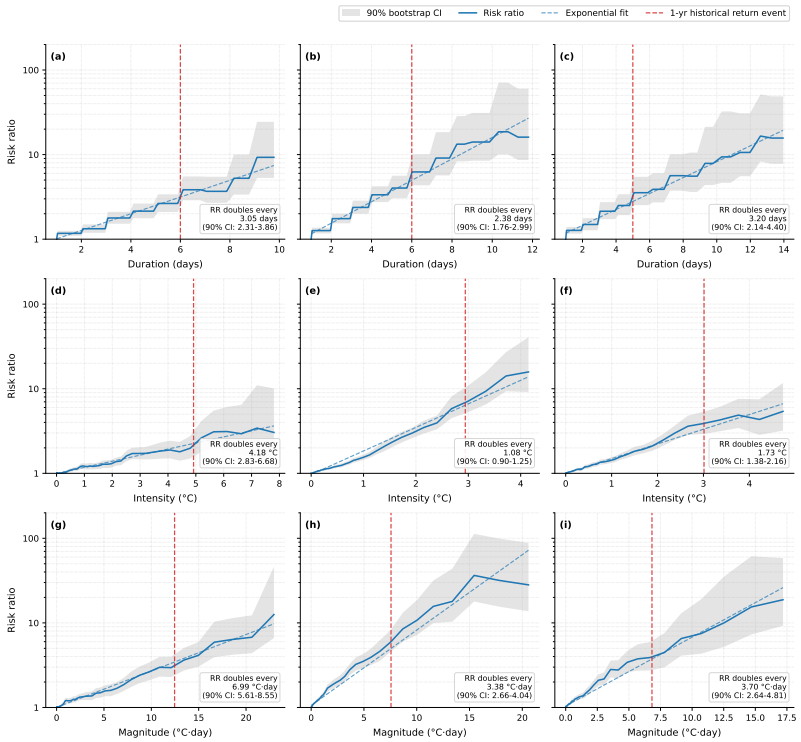

Figure 9: Risk ratio for heatwave duration (first row), intensity (second row), and magnitude (third row) in Concepción (first column), Santiago (second column), and La Serena (third column). The analysis compares the future period (2050–2080) against the historical baseline (1980–2010). Dashed lines represent an exponential regression fit (linear in log-scale) for each panel. The shaded gray area represents the 90% confidence interval, estimated using a bootstrap method with 10^4 iterations. The vertical dashed red line indicates the threshold for events with an average one-year return period in the historical climate. For the SSP3-7.0 scenario, see Supplementary Figure S8.

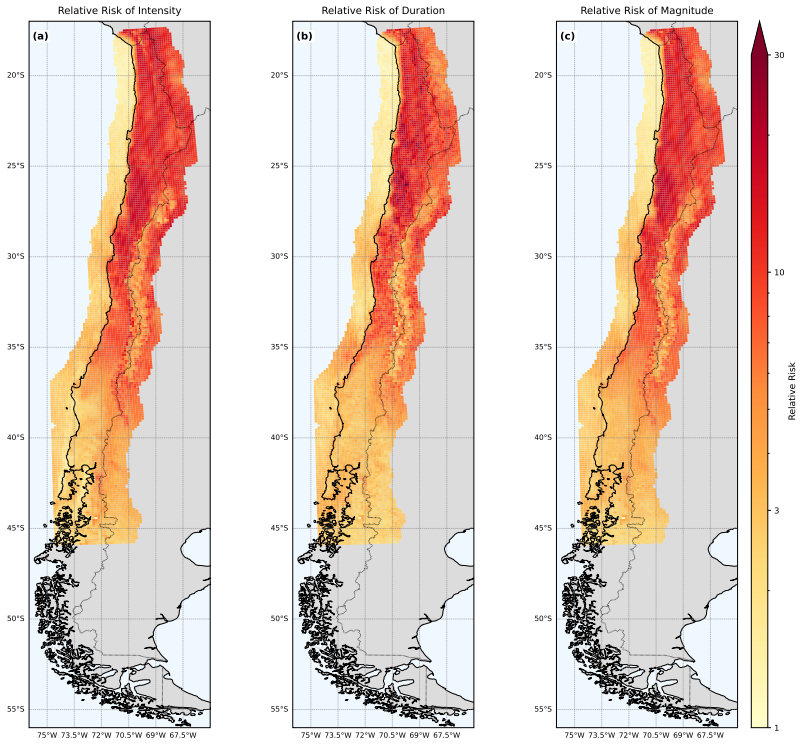

Figure 10: Projected increase in the frequency of historically significant heatwaves across Chile. The maps show the risk ratio (RR) for heatwave (left) intensity, (center) duration, and (right) magnitude. The values indicate how many times more frequent a heatwave with the intensity, duration, or magnitude that historically occurred once per year (the "typical annual event" between 1980-2010) is projected to become in the future period (2050-2080). For example, an RR of 10 in a specific location means that the heatwave intensity that was typical for that area once a year in the past is expected to occur 10 times more frequently in the future. Note the exponential scale of the color bar, indicating a rapid increase in risk. For the SSP3-7.0 scenario, see Supplementary Figure S9.

In this subsection, we use risk ratios to quantify projected changes in the frequency of heat waves based on their duration, intensity, and magnitude (Figures 9 and 10). Increased risks are observed across all analyzed values for these characteristics, and this increase becomes more pronounced for the most extreme events (Figure 9). Specifically, risk ratios for heatwave duration, intensity, and magnitude exhibit an exponential relationship, depicted as a linear trend in Figure 9 due to the log-linear scale. This exponential nature signifies that the risk escalates dramatically for more extreme events, implying that events unprecedented in the historical record could carry relative risks considerably higher than those shown in the figure 9.

To exemplify the projected increases, the dotted red line in Figure 9 represents the threshold corresponding to events that occur, on average, once per year in the historical regime. Consequently, between 2050 and 2080, events exceeding the magnitude of these historical annual occurrences are projected to be three (Figure 9 (g)), five (Figure 9 (h)), and seven (Figure 9 (i)) times more likely in Concepción, Santiago, and La Serena, respectively. In contrast, the most extreme events—those with a historical return period of one event per decade—are projected to become 10 (Figure 9 (g)), 20 (Figure 9 (h)), and 40 (Figure 9 (i)) times more likely in Concepción, Santiago, and La Serena, respectively. These represent significantly greater increases in risk compared to the events with a 1-year return period. By setting the metric to certain magnitudes, the frequency of prolonged heat waves ($\geq$10 days) increases by factors of approximately 54, 21 and 12 in Concepción, Santiago and La Serena respectively, and that of high magnitude events ($\geq 15,^\circ C{\cdot}$day) by factors of 4, 42 and 16 (Figure 9).

The maps in figures 10 show increases in the frequency of events whose duration, intensity, and magnitude occur on average once a year in the historical regime. One can see that the risk of extreme duration and magnitude will increase more than extreme intensity events, showing that, as in the example cities (Figure 8), throughout the territory, small changes in the intensity of heat waves can cause a significant increase in

their magnitude. Here, we observe a hot spot in the intermediate trough, especially at latitudes 40.5S and 34.5S, where the projected increases in the risk of extreme intensity events are close to 10, while the relative risk of extreme magnitude and duration events are greater than 17.

To contextualize these findings, we analyze the projected risk increase for heatwaves of a magnitude comparable to those that occurred during the major wildfires in the Temuco region. For example, the 2016/17 mega-fire season, which burned over 500,000 hectares, was accompanied by a heatwave with a magnitude of 51.6 °C·day (Carrasco-Escaff et al., 2024; De la Barrera et al., 2018). Our projections for 2050-2080 show that events of this magnitude will have a risk ratio of 5.3. Similarly, the heatwaves that coincided with the 2012 and 2019 fires reached magnitudes of 34.1 °C·day and 40.7 °C·day, corresponding to future risk ratios of 3.6 and 4.5, respectively. In summary, heatwaves as severe as those associated with these catastrophic wildfires are projected to be 3 to 6 times more frequent than in the historical period.

4 Discussion

This study employs the high-resolution CNRM-ALADIN regional climate model to project changes in heatwave characteristics in Chile throughout the 21st century under two high-emission scenarios — SSP5-8.5, used as the headline trajectory in the main text, and SSP3-7.0, reported in the Supplementary Material — using temperatures bias-adjusted with the Unbiased Quantile Mapping (UQM) method. A single RCM driven by one GCM does not allow accounting for the full range of uncertainties associated with these projections. While the methodological limitations of this study are acknowledged, most notably the use of a single RCM driven by a single GCM, its value lies in providing a scientifically consistent projection of a plausible, high-impact future climate trajectory for Chile. In the context of risk-informed policymaking, such pessimistic scenarios serve as stress-tests for infrastructure, public health, and adaptation strategies. Anticipating these potential pathways enables decision-makers to better assess vulnerabilities, identify early warning signals, and design more resilient systems in the face of intensifying climate extremes.

Nevertheless, our study provides valuable insight into a potential worst-case future heatwave risk and serves as a useful basis for more comprehensive regional analysis. Under the SSP5-8.5 scenario, results reveal a consistent and sharp increase in heatwave activity—defined by longer duration, higher intensity, and significantly greater cumulative magnitude—especially in central and northern Chile. Results indicate a substantial lengthening of the warm season, even leading to the disappearance of the cold season in some regions, though the timing and rate of change vary considerably by latitude. In Santiago, for example, the cold season disappears around 2080, while in La Serena this transition may occur as early as 2035. In southern cities like Concepción, the cold season contracts more slowly. The rate of warm season expansion ranges from approximately 12.0 to 14.0 days per decade, depending on the region.

To probe the scenario dependence of these projections, the analysis was repeated under the milder SSP3-7.0 forcing (see Supplementary Text SM4, Figs. S2–S9). The two scenarios yield qualitatively identical responses; SSP3-7.0 simply reaches a smaller end-of-century warming (e.g. $\Delta T \approx 3.1$°C against 3.7°C in the Northern subdomain), and when heatwave metrics are plotted against regional ΔT instead of calendar year both trajectories collapse onto a single curve (Fig. 3). Within this model configuration, the forcing pathway primarily controls when a given warming level is reached, while the heatwave response at matched regional warming is similar across the two scenarios, and the signals reported in this study can be regarded as conditional on the regional warming level rather than on a specific emission pathway. The residual uncertainty is therefore primarily internal and structural, since the two pathways produce nearly identical heatwave responses at a given regional warming level. However, a single CNRM-ALADIN realization driven by one GCM cannot sample either internal climate variability or the spread of dynamical responses captured by multi-model ensembles such as CORDEX (Vautard et al., 2021), an extension along the lines proposed by Hawkins and Sutton, 2009 that constitutes the natural next step.

These changes likely reflect three complementary mechanisms: a thermodynamic shift of the daily temperature distribution relative to the fixed historical threshold, which lengthens the heatwave season (Section 3.3); the temporal persistence of daily temperatures, whose duration tail scales nonlinearly with warming (Martinez-Villalobos et al., 2025) and explains why duration and magnitude increase faster than intensity (Sections 3.4–3.6); and Chile's land–sea and orographic contrasts, which likely modulate these trends spatially (Figures 9–10). A full dynamical attribution is beyond the scope of this study.

A significant increase is projected across all analyzed heatwave characteristics—duration, intensity, and magnitude— particularly in the upper tails, i.e. the most extreme parts, of their distributions. While moderate events are expected to become more common, the most substantial changes are concentrated among the most extreme events. For example, less severe heatwaves (e.g., 3 days in duration or 5 °C·day in magnitude) are projected to become 2.2 to 4.8 times more frequent. In stark contrast, events previously considered rare or unprecedented become substantially more common. The frequency of prolonged heatwaves ($\geq$ 10 days) is projected to increase by factors of approximately 54, 21, and 12 in Concepción, Santiago, and La Serena, respectively. Similarly, the occurrence of high-magnitude heatwaves ($\geq$ 15 °C·day) is projected to increase by factors of 4, 42, and 16 for the same cities.

These changes reflect not only a shift in the average values but also a transformation in the shape of the probability distribution functions (PDFs) of heatwave metrics. Our results suggest that while the overall form of the PDFs remains similar (e.g., right-skewed), the distributions shift toward higher values and become stretched, particularly in the tails. This behavior is consistent with findings in (Martinez-Villalobos et al., 2025), who show that under global warming, heatwave durations can increase quadratically with temperature, and frequencies increase superexponentially. As a result, the "typical" heatwave becomes more extreme, and the most extreme events become disproportionately more common.

Our finding that cities like Santiago are projected to lose their cold season entirely by 2080 carries implications that align with established global concerns. Global warming's effect on the phase and amplitude of seasons is known to cause significant disruptions (Buermann et al., 2018; Steltzer & Post, 2009). The change in the duration and seasonality of the cold and warm seasons can have strong repercussions, affecting the development of crops (Schlenker & Roberts, 2009), the behavior of migratory birds (Both et al., 2006; Saino et al., 2009) and mosquitoes (Campbell-Lendrum et al., 2015; Paz, 2015), and consequently impacting the economy (Chisale et al., 2021), food security (Bonuedi et al., 2022), and public health (Sutherst, 2004). The results from our study provide a high-resolution regional confirmation of these global risks for Chile.

Intriguingly, the spatial analysis reveals some areas where extreme heatwave metrics show less pronounced growth. These patterns may reflect regional atmospheric circulation shifts or coastal moderation effects and warrant deeper analysis. It is important to note that while the application of the UQM bias-adjustment method improves the accuracy of ALADIN simulations, the quality of the objective model CR2MET limits this adjustment (Fernández et al., 2021; González-Reyes et al., 2023). Despite its high resolution and precision, this model has its own biases and limitations, stemming, among other factors, from the density and quality of observational data used in its construction (Herrera et al., 2019). Therefore, the results of this study must be interpreted considering this inherent limitation of the bias-adjustment process. Although UQM helps align model outputs with observed climate patterns—particularly for mean and variability in temperature—its performance depends on the quality of the observational dataset. In regions with sparse station coverage or complex topography, such as the Andes, residual biases may persist and affect projections. The out-of-sample stress tests of Supplementary Text SM7 bound this effect: residual tail biases after adjustment are several times smaller than those of the raw model and slightly cold in the warming-analogue test, so they are unlikely to inflate the projected changes. Therefore, fine-scale results should be interpreted with appropriate caution.

Our findings reinforce the notion that climate change intensifies heatwaves in Chile, which will have significant implications for various sectors. The increase in the frequency and intensity of heatwaves raises the risk of heat-related illnesses and mortality, especially among vulnerable groups such as children, the elderly, and individuals with chronic diseases (Arsad et al., 2022; González et al., 2024). Furthermore, sectors like agriculture and energy will suffer, with potential losses in agricultural (Luo et al., 2023; Siebers et al., 2017) production and an increased demand for energy for cooling and other effects (G. Gesangyangji et al., 2025; Gesangyangji et al., 2022). Importantly, these projections go beyond average trends to expose deep structural shifts in climate extremes. For instance, heatwaves with magnitudes comparable to those associated with the catastrophic 2017 wildfires—around 51.6 $^oC \cdot day$—are projected to occur 5.3 times more often in central Chile by 2050–2080. These changes pose serious risks to public health, ecosystems, and infrastructure. The compounding effects of more frequent, longer, and more intense heatwaves can lead to higher rates of heat-related illnesses, increased wildfire potential, and strain on energy systems due to cooling demands (Hopke, 2020; Varghese et al., 2019; Yang et al., 2025). These results are consistent with other studies highlighting Chile's growing vulnerability to climate-related extremes (Hidalgo-Corrotea et al., 2023).

This study contributes high-resolution, bias-adjustment projections of heatwave characteristics in Chile, revealing how event frequency, intensity, and duration are expected to evolve under continued warming. Several open research questions emerge from this analysis. It is unclear whether the increasing frequency of heatwaves will translate into impacts that grow at the same rate, or more rapidly, due to nonlinear sensitivities in social, ecological, or infrastructural sensitivities (Khan et al., 2024; Liu et al., 2024). Compound events, such as heatwaves coinciding with prolonged droughts, may also amplify risks far beyond those caused by individual stressors (Zhou et al., 2024). Exploring interactions with water scarcity, air pollution, and pressure on health and energy systems remains a priority. The nonlinear growth in heatwave characteristics confirmed here underscores the urgency of identifying the regional dynamics and thresholds that drive such escalation, particularly those that may lead to abrupt or outsized societal impacts.

References

Aguayo, R., León-Muñoz, J., Garreaud, R., & Montecinos, A. (2021). Hydrological droughts in the southern andes (40–45°s) from an ensemble experiment using cmip5 and cmip6 models. *Scientific Reports*, *11*(1), 5530. https://doi.org/10.1038/s41598-021-84807-4

Alimagham, S., van Loon, M. P., Ramirez-Villegas, J., Adjei-Nsiah, S., Baijukya, F., Bala, A., Chikowo, R., Silva, J. V., Soulé, A. M., Taulya, G., et al. (2024). Climate change impact and adaptation of rainfed cereal crops in sub-saharan africa. *European Journal of Agronomy*, *155*, 127137.

Alvarez-Garreton, C., Mendoza, P. A., Boisier, J. P., Addor, N., Galleguillos, M., Zambrano-Bigiarini, M., Lara, A., Puelma, C., Cortes, G., Garreaud, R., McPhee, J., & Ayala, A. (2018). The CAMELS-CL dataset: Catchment attributes and meteorology for large sample studies – Chile dataset. *Hydrology and Earth System Sciences*, *22*(11), 5817–5846. https://doi.org/10.5194/hess-22-5817-2018

Amaya, D. J., Jacox, M. G., Fewings, M. R., Saba, V. S., Stuecker, M. F., Rykaczewski, R. R., Ross, A. C., Stock, C. A., Capotondi, A., Petrik, C. M., Bograd, S. J., Alexander, M. A., Cheng, W., Hermann, A. J., Kearney, K. A., & Powell, B. S. (2023). Marine heatwaves need clear definitions so coastal communities can adapt. *Nature*, *616*, 29–32. https://doi.org/10.1038/d41586-023-00924-2

Araya-Osses, D., Casanueva, A., Rom'an-Figueroa, C., Uribe, J. M., & Paneque, M. (2020). Climate change projections of temperature and precipitation in chile based on statistical downscaling. *Climate Dynamics*, *54*(9-10), 4309–4330. https://doi.org/10.1007/s00382-020-05231-4

Arévalo, J., Marín, J. C., Díaz, M., Raga, G., Pozo, D., Córdova, A. M., & Baumgardner, D. (2024). Sensitivity of simulated conditions to different parameterization choices over complex terrain in central chile. *Atmosphere*, *15*(1), 10. https://doi.org/10.3390/atmos15010010

Arguez, A., & Vose, R. S. (2011). The definition of the standard wmo climate normal: The key to deriving alternative climate normals. *Bulletin of the American Meteorological Society*, *92*(6), 699–704.

Arsad, F. S., Hod, R., Ahmad, N., Ismail, R., Mohamed, N., Baharom, M., Osman, Y., Radi, M. F. M., & Tangang, F. (2022). The impact of heatwaves on mortality and morbidity and the associated vulnerability factors: A systematic review. *International Journal of Environmental Research and Public Health*, *19*(23), 16356. https://doi.org/10.3390/ijerph192316356

Bambach, N. E., Rhoades, A. M., Hatchett, B. J., Jones, A. D., Ullrich, P. A., & Zarzycki, C. M. (2022). Projecting climate change in south america using variable-resolution community earth system model: An application to chile. *International Journal of Climatology*, *42*(4), 2514–2542.

Boisier, Alvarez-Garreton, C., Marinao, R., & Galleguillos, M. (2024). Increasing water stress in chile evidenced by novel datasets of water availability, land use and water use. *EGUsphere*, *2024*, 1–50.

Boisier, J. P. (2023). CR2MET: A high-resolution precipitation and temperature dataset for the period 1960-2021 in continental Chile. (v2.5). https://doi.org/10.5281/zenodo.7529682

Bonuedi, I., Kornher, L., & Gerber, N. (2022). Agricultural seasonality, market access, and food security in sierra leone. *Food Security*, *14*(2), 471–494.

Both, C., Bouwhuis, S., Lessells, C. M., & Visser, M. E. (2006). Climate change and population declines in a long-distance migratory bird. *Nature*, *441*(7091), 81–83.

Bozkurt, D., Rojas, M., Boisier, J. P., Rondanelli, R., Garreaud, R., & Gallardo, L. (2019). Dynamical downscaling over the complex terrain of southwest south america: Present climate conditions and added value analysis. *Climate Dynamics*, *53*(11), 6745–6767.

Buermann, W., Forkel, M., O'sullivan, M., Sitch, S., Friedlingstein, P., Haverd, V., Jain, A. K., Kato, E., Kautz, M., Lienert, S., et al. (2018). Widespread seasonal compensation effects of spring warming on northern plant productivity. *Nature*, *562*(7725), 110–114.

Bürger, G., Sobie, S., Cannon, A., Werner, A., & Murdock, T. (2013). Downscaling extremes: An intercomparison of multiple methods for future climate. *Journal of Climate*, *26*(10), 3429–3449.

Campbell-Lendrum, D. H., Manga, L., Bagayoko, M., & Sommerfeld, J. (2015). Climate change and vector-borne diseases: What are the implications for public health research and policy? *Philosophical Transactions of the Royal Society B: Biological Sciences*, *369*(1645), 20130552.

Cannon, A. J., Sobie, S. R., & Murdock, T. Q. (2015). Bias correction of gcm precipitation by quantile mapping: How well do methods preserve changes in quantiles and extremes? *Journal of Climate*, *28*(17), 6938–6959.

Carrasco-Escaff, T., Garreaud, R., Bozkurt, D., Jacques-Coper, M., & Pauchard, A. (2024). The key role of extreme weather and climate change in the occurrence of exceptional fire seasons in south-central Chile. *Weather and Climate Extremes*, *45*, 100716. https://doi.org/10.1016/j.wace.2024.100716

Chadwick, C., Gironás, J., González-Leiva, F., & Aedo, S. (2023). Bias adjustment to preserve changes in variability: The unbiased mapping of GCM changes. *Hydrological Sciences Journal*, *68*(8), 1184–1201. https://doi.org/10.1080/02626667.2023.2201450

Chisale, H. L., Chirwa, P. W., Babalola, F. D., & Manda, S. O. (2021). Perceived effects of climate change and extreme weather events on forests and forest-based livelihoods in malawi. *Sustainability*, *13*(21), 11748.

CNRM. (2024). Cnrm-aladin64 model output prepared for cmip6 and cordex [Accessed: 2024-12-27].

de Paula Corrêa, M. (2024). Heatwaves, biodiversity and health in times of climate change. *Jornal de Pediatria*.

De la Barrera, F., Barraza, F., Favier, P., Ruiz, V., & Quense, J. (2018). Megafires in chile 2017: Monitoring multiscale environmental impacts of burned ecosystems. *Science of the total environment*, *637*, 1526–1536.

Decharme, B., Delire, C., Minvielle, M., Colin, J., Vergnes, J.-P., Alias, A., Saint-Martin, D., Séférian, R., Sénési, S., & Voldoire, A. (2019). Recent changes in the isba-ctrip land surface system for use in the cnrm-cm6 climate model and in global off-line hydrological applications. *Journal of Advances in Modeling Earth Systems*, *11*(5), 1207–1252.

Demortier, A., Bozkurt, D., & Jacques-Coper, M. (2021). Identifying key driving mechanisms of heat waves in central chile [Published: 14 May 2021]. *Climate Dynamics*, *57*, 2415–2432.

Eyring, V., Bony, S., Meehl, G. A., Senior, C. A., Stevens, B., Stouffer, R. J., & Taylor, K. E. (2016). Overview of the coupled model intercomparison project phase 6 (cmip6) experimental design and organization. *Geoscientific Model Development*, *9*(5), 1937–1958. https://doi.org/10.5194/gmd-9-1937-2016

Fernández, A., Schumacher, V., Ciocca, I., Rifo, A., Muñoz, A. A., & Justino, F. (2021). Validation of a 9-km wrf dynamical downscaling of temperature and precipitation for the period 1980–2005 over central south chile. *Theoretical and Applied Climatology*, *143*, 361–378.

García-León, D., Casanueva, A., Standardi, G., Burgstall, A., Flouris, A. D., & Nybo, L. (2021). Current and projected regional economic impacts of heatwaves in europe. *Nature communications*, *12*(1), 5807.

Garreaud, R. D., Boisier, J. P., Rondanelli, R., Montecinos, A., Sepúlveda, H. H., & Veloso-Aguila, D. (2020). The central chile mega drought (2010–2018): A climate dynamics perspective. *International Journal of Climatology*, *40*(1), 421–439.

Gesangyangji, G., Holloway, T., Vimont, D. J., Mastrucci, A., Byers, E., & Acker, S. J. (2025). The hours matter: Comparing indicators of us residential cooling from hourly versus daily climate variables. *Environmental Research Letters*, *20*(4), 044024. https://doi.org/10.1088/1748-9326/adbd54

Gesangyangji, Vimont, D. J., Holloway, T., & Lorenz, D. J. (2022). A methodology for evaluating the effects of climate change on climatic design conditions for buildings and application to a case study in madison, wisconsin. *Environmental Research: Infrastructure and Sustainability*, *2*(2), 025007. https://doi.org/10.1088/2634-4505/acbe01

Giorgi, F. (2019). Thirty years of regional climate modeling: Where are we and where are we going next? *Journal of Geophysical Research: Atmospheres*, *124*(11), 5696–5723. https://doi.org/10.1029/2018JD030094

González, P., Ortíz, V., Domínguez, A., Moraga, A. M., Zaror, C., & González Rodríguez, L. (2024). Assessment of short-term effects of heat waves and warm days on human health in santiago-chile [Preprint]. *Research Square*. https://doi.org/10.21203/rs.3.rs-4480998/v1

González-Reyes, Á., Jacques-Coper, M., Bravo, C., Rojas, M., & Garreaud, R. (2023). Evolution of heatwaves in chile since 1980 [Under a Creative Commons license, open access]. *Weather and Climate Extremes*, *40*, 100588. https://doi.org/10.1016/j.wace.2023.100588

Goubanova, K., Caballero, T., Doury, A., Nabat, P., Farías, H., Ortiz, D., & Somot, S. (2024). Assessment of the performance of convolutional neural network based rcm-emulator in representing daily near-surface temperature over the complex terrain of subtropical chile. *Proceedings of the 15th International Meeting on Statistical Climatology (15th IMSC)*.

Hansen, J. E., Sato, M., Simons, L., Nazarenko, L. S., Sangha, I., Kharecha, P., Zachos, J. C., von Schuckmann, K., Loeb, N. G., Osman, M. B., et al. (2023). Global warming in the pipeline. *Oxford Open Climate Change*, *3*(1), kgad008. https://doi.org/10.1093/oxfclm/kgad008

Hawkins, E., & Sutton, R. (2009). The potential to narrow uncertainty in regional climate predictions. *Bulletin of the American Meteorological Society*, *90*(8), 1095–1107. https://doi.org/10.1175/2009BAMS2607.1

Herrera, S., Kotlarski, S., Soares, P. M., Cardoso, R. M., Jaczewski, A., Gutiérrez, J. M., & Maraun, D. (2019). Uncertainty in gridded precipitation products: Influence of station density, interpolation method and grid resolution.

Hersbach, H., Bell, B., Berrisford, P., Hirahara, S., Horányi, A., Muñoz-Sabater, J., Nicolas, J., Peubey, C., Radu, R., Schepers, D., et al. (2020). The era5 global reanalysis. *Quarterly Journal of the Royal Meteorological Society*, *146*(730), 1999–2049.

Hidalgo-Corrotea, C., Alaniz, A. J., Vergara, P. M., Moreira-Arce, D., Carvajal, M. A., Pacheco-Cancino, P., & Espinosa, A. (2023). High vulnerability of coastal wetlands in chile at multiple scales derived from climate change, urbanization, and exotic forest plantations. *Science of the Total Environment*, *903*, 166130.

Hoegh-Guldberg, O., Jacob, D., Taylor, M., Bindi, M., Brown, S., Camilloni, I., Diedhiou, A., Djalante, R., Ebi, K., Engelbrecht, F., Guiot, J., Hijioka, Y., Mehrotra, S., Payne, A., Seneviratne, S., Thomas, A., Warren, R., & Zhou, G. (2018). Impacts of 1.5ºc global warming on natural and human systems [In Press]. In V. Masson-Delmotte, P. Zhai, H.-O. Pörtner, D. Roberts, J. Skea, P. Shukla, A. Pirani, W. Moufouma-Okia, C. Péan, R. Pidcock, S. Connors, J. Matthews, Y. Chen, X. Zhou, M. Gomis, E. Lonnoy, T. Maycock, M. Tignor, & T. Waterfield (Eds.), *Global warming of 1.5˚c. an ipcc special report on the impacts of global warming of 1.5˚c above pre-industrial levels and related global greenhouse gas emission pathways, in the context of strengthening the global response to the threat of climate change, sustainable development, and efforts to eradicate poverty.*

Hopke, J. E. (2020). Connecting extreme heat events to climate change: Media coverage of heat waves and wildfires. *Environmental Communication*, *14*(4), 492–508.

Instituto Nacional de Estadísticas (INE Chile). (2024). *Estimaciones y proyecciones de la población de chile 1992-2050* (tech. rep.) (Accessed on August 7, 2025. Available at: https://www.ine.gob.cl/estadisticas/sociales/demog y-vitales/proyecciones-de-poblacion). Instituto Nacional de Estadísticas. Santiago, Chile.

IPCC. (2021). Ipcc sixth assessment report [Available online at: https://www.ipcc.ch/assessment-report/ar6/].

Jacques-Coper, M., Veloso-Aguila, D., Segura, C., & Valencia, A. (2021). Intraseasonal teleconnections leading to heat waves in central chile. *International Journal of Climatology*, *41*. https://doi.org/10.1002/joc.7096

Jägermeyr, J., Müller, C., Ruane, A. C., Elliott, J., Balkovic, J., Castillo, O., Faye, B., Foster, I., Folberth, C., Franke, J. A., et al. (2021). Climate impacts on global agriculture emerge earlier in new generation of climate and crop models. *Nature Food*, *2*(11), 873–885.

Jones, M. W., Abatzoglou, J. T., Veraverbeke, S., Andela, N., Lasslop, G., Forkel, M., Smith, A. J., Burton, C., Betts, R. A., van der Werf, G. R., et al. (2022). Global and regional trends and drivers of fire under climate change. *Reviews of Geophysics*, *60*(3), e2020RG000726.

Junquas, C., Martinez, J., Bozkurt, D., Viale, M., Fita, L., Trachte, K., Campozano, L., Arias, P. A., Boisier, J., Condom, T., et al. (2024). Recent progress in atmospheric modeling over the andes–part ii: Projected changes and modeling challenges. *Frontiers in Earth Science*, *12*, 1427837.

Khan, L., Kawano, T., Hutton, J., Asamoah-Boaheng, M., Scheuermeyer, F. X., Christian, M., Baranowski, L., Barbic, D., Christenson, J., & Grunau, B. (2024). The association of extreme environmental heat with incidence and outcomes of out-of-hospital cardiac arrest in british columbia: A time series analysis. *Resuscitation Plus*, *17*, 100560.

Lagos-Zúñiga, M., Balmaceda-Huarte, R., Regoto, P., Torrez, L., Olmo, M., Lyra, A., Pareja-Quispe, D., & Bettolli, M. L. (2024). Extreme indices of temperature and precipitation in south america: Trends and intercomparison of regional climate models [Published online on 23 December 2022]. *Climate Dynamics*, *62*, 4541–4562.

Lagos-Zúñiga, M., Mendoza, P. A., Campos, D., & Rondanelli, R. (2024). Trends in seasonal precipitation extremes and associated temperatures along continental chile. *Climate Dynamics*, *62*, 4205–4222. https://link.springer.com/article/10.1007/s00382-023-06765-1

Li, X., & Li, Z. (2023). Evaluation of bias correction techniques for generating high-resolution daily temperature projections from cmip6 models. *Research Article*. https://doi.org/10.21203/rs.3.rs-1788844/v1

Liu, Q., Wang, J., & Bai, B. (2024). Unveiling nonlinear effects of built environment attributes on urban heat resilience using interpretable machine learning. *Urban Climate*, *56*, 102046.

Lowe, D., Ebi, K. L., & Forsberg, B. (2011). Heatwave early warning systems and adaptation advice to reduce human health consequences of heatwaves. *International journal of environmental research and public health*, *8*(12), 4623–4648.

Luo, N., Mueller, N., Zhang, Y., Feng, P., Huang, S., Liu, D. L., Yu, Y., Wang, X., Wang, P., & Meng, Q. (2023). Short-term extreme heat at flowering amplifies the impacts of climate change on maize production. *Environmental Research Letters*, *18*(8), 084021. https://doi.org/10.1088/1748-9326/ace7e3

Lupo, A., Kininmonth, W., Armstrong, J., & Green, K. (2013). Global climate models and their limitations. The Heartland Institute Chicago, IL.

Maraun, D., Shepherd, T. G., Widmann, M., Zappa, G., Walton, D., Gutiérrez, J. M., Hagemann, S., Richter, I., Soares, P. M., Hall, A., et al. (2017). Towards process-informed bias correction of climate change simulations. *Nature Climate Change*, *7*(11), 764–773.

Maraun, D., Truhetz, H., & Schaffer, A. (2021). Regional climate model biases, their dependence on synoptic circulation biases and the potential for bias adjustment: A process-oriented evaluation of the austrian regional climate projections. *Journal of Geophysical Research: Atmospheres*, *126*(6), e2020JD032824. https://doi.org/10.1029/2020JD032824

Martinez-Villalobos, C., Fu, D., Loikith, P. C., & Neelin, J. D. (2025). Accelerating increase in the duration of heatwaves under global warming. *Nature Geoscience*, 1–8.

Martinez-Villalobos, C., & Neelin, J. D. (2023). Regionally high risk increase for precipitation extreme events under global warming. *Scientific Reports*, *13*(1), 5579.

Meinshausen, M., Nicholls, Z. R. J., Lewis, J., Gidden, M. J., Vogel, E., Leach, N., Bauer, N., Canadell, J. G., Ciais, P., Collins, W. D., Drijfhout, S., Forster, P., Gasser, T., Hagemann, S., Joos, F., Kriegler, E., Nauels, A., O'Neill, B. C., Riahi, K., ... van Vuuren, D. P. (2020). The shared socio-economic pathway (SSP) greenhouse gas concentrations and their extensions to 2500. *Geoscientific Model Development*, *13*(8), 3571–3605. https://doi.org/10.5194/gmd-13-3571-2020

Moya, H., Althoff, I., Celis-Diez, J. L., Huenchuleo-Pedreros, C., & Reggiani, P. (2024). Impact of future climate scenarios and bias correction methods on the achibueno river basin. *Water*, *16*(8), 1138. https://doi.org/10.3390/w16081138

Nabat, P., Somot, S., Cassou, C., Mallet, M., Michou, M., Bouniol, D., Decharme, B., Drugé, T., Roehrig, R., & Saint-Martin, D. (2020). Modulation of radiative aerosols effects by atmospheric circulation over the euro-mediterranean region. *Atmospheric Chemistry and Physics*, *20*(14), 8315–8349. https://doi.org/10.5194/acp-20-8315-2020

Neelin, J. D., Sahany, S., Stechmann, S. N., & Bernstein, D. N. (2017). Global warming precipitation accumulation increases above the current-climate cutoff scale. *Proceedings of the National Academy of Sciences*, *114*(6), 1258–1263.

Nguyen, P. L., Alexander, L. V., Thatcher, M. J., Truong, S. C. H., Isphording, R. N., & McGregor, J. L. (2024). Selecting cmip6 global climate models (gcms) for coordinated regional climate downscaling experiment (cordex) dynamical downscaling over southeast asia using a standardised benchmarking framework. *Geoscientific Model Development*, *17*(19), 7285–7315. https://doi.org/10.5194/gmd-17-7285-2024

O'Neill, B. C., Tebaldi, C., Van Vuuren, D. P., Eyring, V., Friedlingstein, P., Hurtt, G., Knutti, R., Kriegler, E., Lamarque, J.-F., Lowe, J., et al. (2016). The scenario model intercomparison project (scenariomip) for cmip6. *Geoscientific Model Development*, *9*(9), 3461–3482.

Panofsky, H. A., & Brier, G. W. (1958). *Some applications of statistics to meteorology*. Mineral Industries Extension Services, College of Mineral Industries ...

Paz, S. (2015). Climate change impacts on west nile virus transmission in a global context. *Philosophical Transactions of the Royal Society B: Biological Sciences*, *370*(1665), 20140120.

Peel, M. C., Finlayson, B. L., & McMahon, T. A. (2007). Updated world map of the köppen-geiger climate classification. *Hydrology and earth system sciences*, *11*(5), 1633–1644.

Perkins-Kirkpatrick, S. E., & Gibson, P. B. (2017). Changes in regional heatwave characteristics as a function of increasing global temperature. *Scientific Reports*, *7*(1), 12256. https://doi.org/10.1038/s41598-017-12520-2

Perkins-Kirkpatrick, S. E., & Lewis, S. C. (2020). Increasing trends in regional heatwaves. *Nature Communications*, *11*(3357). https://doi.org/10.1038/s41467-020-16970-7

Piticar, A. (2018). Changes in heat waves in chile. *Global and Planetary Change*, *169*, 234–246.

Rampal, N., Hobeichi, S., Gibson, P. B., Baño-Medina, J., Abramowitz, G., Beucler, T., González-Abad, J., Chapman, W., Harder, P., & Gutiérrez, J. M. (2024). Enhancing regional climate downscaling through advances in machine learning. *Artificial Intelligence for the Earth Systems*, *3*(2), e230066. https://doi.org/10.1175/AIES-D-23-0066.1

Riahi, K., van Vuuren, D. P., Kriegler, E., Edmonds, J., O'Neill, B. C., Fujimori, S., Bauer, N., Calvin, K., Dellink, R., Fricko, O., Lutz, W., Popp, A., Cuaresma, J. C., KC, S., Leimbach, M., Jiang, L., Kram, T., Rao, S., Emmerling, J., ... Tavoni, M. (2017). The Shared Socioeconomic Pathways and their energy, land use, and greenhouse gas emissions implications: An overview. *Global Environmental Change*, *42*, 153–168. https://doi.org/10.1016/j.gloenvcha.2016.05.009

Roehrig, R., Beau, I., Saint-Martin, D., Alias, A., Decharme, B., Guérémy, J.-F., Voldoire, A., Abdel-Lathif, A. Y., Bazile, E., Belamari, S., et al. (2020). The cnrm global atmosphere model arpege-climat 6.3: Description and evaluation. *Journal of Advances in Modeling Earth Systems*, *12*(7), e2020MS002075.

Romanell, M., McGushin, A., Di Napoli, C., Drummond, P., Hughes, N., Jamart, L., et al. (2021). The 2021 report of the lancet countdown on health and climate change: Code red for a healthy future. *The Lancet*, *398*(10311), 1619–62.

Rummukainen, M. (2010). State-of-the-art with regional climate models. *Wiley Interdisciplinary Reviews: Climate Change*, *1*(1), 82–96.

Ruti, P. M., Somot, S., Giorgi, F., Dubois, C., Flaounas, E., Obermann, A., Dell'Aquila, A., Pisacane, G., Harzallah, A., Lombardi, E., et al. (2016). Med-cordex initiative for mediterranean climate studies. *Bulletin of the American Meteorological Society*, *97*(7), 1187–1208.

Saino, N., Rubolini, D., Lehikoinen, E., Sokolov, L. V., & Bonisoli-Alquati, A. (2009). Climate change effects on migration phenology may mismatch brood parasitic cuckoos and their hosts. *Biology letters*, *5*(4), 539–541.

Salazar, A., Thatcher, M., & Goubanova, e. a., Katerina. (2023). Cmip6 precipitation and temperature projections for chile [PREPRINT (Version 1)]. *Clim Dyn*.

Sarricolea, P., Herrera-Ossandon, M., & Meseguer-Ruiz, Ó. (2017). Clasificación de los climas de chile. *Revista de Geografía Norte Grande*, (67), 27–52. https://doi.org/10.4067/S0718-34022017000200003

Schlenker, W., & Roberts, M. J. (2009). Nonlinear temperature effects indicate severe damages to us crop yields under climate change. *Proceedings of the National Academy of Sciences*, *106*(37), 15594–15598.

Séférian, R., Nabat, P., Michou, M., Saint-Martin, D., Voldoire, A., Colin, J., Decharme, B., Delire, C., Berthet, S., Chevallier, M., et al. (2019). Evaluation of cnrm earth system model, cnrm-esm2-1: Role of earth system processes in present-day and future climate. *Journal of Advances in Modeling Earth Systems*, *11*(12), 4182–4227.

Siebers, M. H., Slattery, R. A., Yendrek, C. R., Locke, A. M., Drag, D., Ainsworth, E. A., Bernacchi, C. J., & Ort, D. R. (2017). Simulated heat waves during maize reproductive stages alter reproductive growth but have no lasting effect when applied during vegetative stages. *Agriculture, Ecosystems and Environment*, *240*, 162–170. https://doi.org/10.1016/j.agee.2016.11.008

Smith, K. E., Sen Gupta, A., Amaya, D., Benthuysen, J. A., Burrows, M. T., Capotondi, A., Filbee-Dexter, K., Frölicher, T. L., Hobday, A. J., Holbrook, N. J., Malan, N., Moore, P. J., Oliver, E. C. J., Richaud, B., Salcedo-Castro, J., Smale, D. A., Thomsen, M., & Wernberg, T. (2025). Baseline matters: Challenges and implications of different marine heatwave baselines. *Progress in Oceanography*, *231*, 103404. https://doi.org/10.1016/j.pocean.2024.103404

Souvignet, M., Gaese, H., Ribbe, L., Kretschmer, N., & Oyarzún, R. (2010). Statistical downscaling of precipitation and temperature in north-central chile: An assessment of possible climate change impacts in an arid andean watershed. *Hydrological Sciences Journal - Journal des Sciences Hydrologiques*, *55*.

Steltzer, H., & Post, E. (2009). Seasons and life cycles. *Science*, *324*(5929), 886–887.

Stott, P. A., Stone, D. A., & Allen, M. R. (2004). Human contribution to the european heatwave of 2003. *Nature*, *432*(7017), 610–614.

Sutherst, R. W. (2004). Global change and human vulnerability to vector-borne diseases. *Clinical microbiology reviews*, *17*(1), 136–173.

Switanek, M. B., Troch, P. A., Castro, C. L., Leuprecht, A., Chang, H.-I., Mukherjee, R., & Demaria, E. (2017). Scaled distribution mapping: A bias correction method that preserves raw climate model projected changes. *Hydrology and Earth System Sciences*, *21*(6), 2649–2666.

Torrez-Rodriguez, L., Goubanova, K., Munoz, C., & Montecinos, A. (2023). Evaluation of temperature and precipitation from cordex-core south america and eta-rcm regional climate simulations over the complex terrain of subtropical chile. *Climate Dynamics*.

Urrutia-Jalabert, R., González, M. E., González-Reyes, Á., Lara, A., & Garreaud, R. (2018). Climate variability and forest fires in central and south-central chile. *Ecosphere*, *9*(4), e02171.

Varghese, B. M., Hansen, A., Nitschke, M., Nairn, J., Hanson-Easey, S., Bi, P., & Pisaniello, D. (2019). Heatwave and work-related injuries and illnesses in adelaide, australia: A case-crossover analysis using the excess heat factor (ehf) as a universal heatwave index. *International archives of occupational and environmental health*, *92*, 263–272.

Vásquez, N. A., Mendoza, P. A., Knoben, W. J., Arnal, L., Lagos-Zúñiga, M., Clark, M., & Vargas, X. (2024). The key role of temporal stratification for gcm bias correction in climate impact assessments. *Earth's Future*, *12*(8), e2023EF004242.

Vautard, R., Barnes, C., Philip, S., Kew, S., Pinto, I., & Otto, F. E. (2024). Heat extremes linearly shift with global warming, with frequency doubling per decade since 1979.

Vautard, R., Barnes, C., Philip, S., Kew, S., Pinto, I., & Otto, F. E. L. (2024). Heat extremes linearly shift with global warming, with frequency doubling per decade since 1979. *Environmental Research Letters*, *19*(9), 094033. https://doi.org/10.1088/1748-9326/ad63be

Vautard, R., Kadygrov, N., Iles, C., Boberg, F., Buonomo, E., Bülow, K., Coppola, E., Corre, L., van Meijgaard, E., Nogherotto, R., et al. (2021). Evaluation of the large euro-cordex regional climate model ensemble. *Journal of Geophysical Research: Atmospheres*, *126*(17), e2019JD032344.

Vautard, R., van Aalst, M., Boucher, O., Drouin, A., Ha, K.-C., hoolohan, C., Jeanne, M., Li, L., Schneider, M., Sippel, S., et al. (2024). Heat extremes linearly shift with global warming, with frequency doubling per decade since 1979. *npj Climate and Atmospheric Science*, *7*(1), 49. https://doi.org/10.1038/s41612-024-00582-1

Wang, J., Guan, Y., Wu, L., Guan, X., Cai, W., Huang, J., Dong, W., & Zhang, B. (2021). Changing Lengths of the Four Seasons by Global Warming. *Geophysical Research Letters*, *48*(4), e2020GL091753. https://doi.org/10.1029/2020GL091753

Yang, X., Yao, L., Li, M., Cao, J., Zhong, Q., Peng, W., Wu, W., & Zhou, J. (2025). How heat waves and urban microclimates affect building cooling energy demand? insights from fifteen eastern chinese cities. *Applied Energy*, *384*, 125424.

Zhou, S., Wu, S., Gao, J., Liu, L., Li, D., Yan, R., & Wang, J. (2024). Increased stress from compound drought and heat events on vegetation. *Science of the Total Environment*, *949*, 175113.

Statements & Declarations

Funding

This work was supported by the Data Observatory Foundation, ANID Technology Center No. DO210001,Proyecto ANID Fondecyt Iniciación 11250471,FONDECYT 1241321 Grant, Concurso de Fortalecimiento al Desarrollo Científico de Centros Regionales 2020-R20F0008-CEAZA, and ANID ACT210046 grant and by institutional resources from Universidad Adolfo Ibáñez and partner institutions. No other funding was received for this study.

Competing interests

The authors declare that they have no competing interests, either financial or non-financial, that could have influenced the work reported in this manuscript.

Author contributions

J.P.L. led the study design, carried out the analysis, and wrote the first draft of the manuscript. C.M.V. acted as academic supervisor, guiding the research design and interpretation of results. C.C. contributed to revisions and provided detailed corrections throughout the manuscript. K.G. and P.N. contributed their expertise on the ALADIN regional climate model, supporting both the implementation of simulations and the interpretation of model performance. All authors reviewed and approved the final version of the manuscript.

Data availability

The regional climate model outputs used in this study were produced with the CNRM-ALADIN model. As the model simulation data are not yet publicly released, they are available from the corresponding author upon reasonable request.

M.2. Artículo 2. Vulnerabilidad a olas de calor de la red chilena a nivel de subestación

Título *Substation-Level Heat-Wave Vulnerability of the Chilean Grid Under Global Warming*.

Autores J. Petit-Laurent, C. Martinez-Villalobos y K. Goubanova.

Conferencia 2026 IEEE International Conference on Environment and Electrical Engineering and 2026 IEEE Industrial and Commercial Power Systems Europe (EEEIC/I&CPS Europe), Lisboa, Portugal.

Estado editorial **Aceptado tras revisión de pares y presentado** por el autor de esta tesis en la conferencia. En proceso de publicación e indexación en IEEE *Xplore*. ISBN de las actas: 979-8-3195-1058-7.

Rol del autor de esta tesis Primer autor y expositor: diseño del estudio, construcción del panel de demanda, ajuste de los modelos, formulación de la razón de riesgo de cola, análisis, figuras y redacción.

Relación con esta tesis Corresponde a la **rama eléctrica** del trabajo. Reformula el modelo aditivo generalizado de la Sección 5.7 y el ejercicio de proyección de la Sección 5.9 sobre una unidad de análisis distinta.

M.2.1. Qué aporta el Artículo 2 respecto del cuerpo de esta tesis

- **Razón de riesgo de cola de las anomalías de demanda.** Contribución metodológica que no forma parte de esta tesis: traslada el aparato de la razón de riesgo desde las métricas climáticas hacia las anomalías de demanda eléctrica, con intervalos por remuestreo estratificado por subestación. Cuantifica el fenómeno que la Sección 6.7.3 describe de forma cualitativa.
- **Agregación ponderada por capacidad.** Introduce una ponderación por capacidad instalada, distinta de la ponderación por demanda histórica empleada en la Sección 5.9.3, y la métrica derivada de amplificación de cola.
- **Encuadre operacional.** Presenta las curvas contrafactuales por subestación como insumo de calibración nodal para gemelos digitales del SEN, con recomendaciones de priorización de refuerzo de red.
- **Validación por pares de la heterogeneidad zonal.** Recupera de forma independiente, con panel y parametrización distintos, el mismo ordenamiento cualitativo de macrozonas que sustenta la hipótesis H1 de esta tesis.

M.2.2. Diferencias que deben tenerse presentes al comparar cifras

- **Unidad de análisis y tamaño del panel.** El artículo ajusta un modelo por subestación sobre 133 subestaciones, de las cuales 112 superan el control de calidad y 76 quedan disponibles para proyección. Esta tesis ajusta 2.529 modelos per-(barra, cliente) sobre 399 subestaciones, con un modelo paralelo a nivel de subestación agregada sobre 335 series (Apéndice L). No se trata de subconjuntos anidados, sino de paneles distintos.

- **Ponderación.** Capacidad instalada en el artículo; demanda histórica en esta tesis. Las magnitudes de las anomalías proyectadas no son directamente comparables por esta razón.
- **Métricas de ajuste.** El artículo reporta un coeficiente de determinación ajustado mediano de 0,862 y un error porcentual absoluto medio de 0,93 %; esta tesis reporta 0,624 y 5,02 % en el ajuste per-(barra, cliente). La diferencia refleja el nivel de agregación —la suma de series cancela ruido idiosincrático, como se documenta en la Sección 6.4.1— y no una diferencia de especificación.
- **Período de referencia.** 1980–2014 en el artículo; 1980–2010 en esta tesis.

Substation-Level Heat-Wave Vulnerability of the Chilean Grid Under Global Warming

Jorge Petit-Laurent
Universidad Adolfo Ibáñez &
Data Observatory Foundation
Santiago, Chile
jpetitlaurent@alumnos.uai.cl
0009-0006-2945-610X

Cristian Martinez-Villalobos
Universidad Adolfo Ibáñez &
Data Observatory Foundation
Santiago, Chile
cristian.martinez.v@uai.cl
0000-0001-7057-5553

Katerina Goubanova
Centro de Estudios Avanzados
en Zonas Áridas (CEAZA)
La Serena, Chile
katerina.goubanova@ceaza.cl
0009-0002-2143-0352

***Abstract*—Heat waves stress power systems by elevating cooling demand while degrading grid and generation capacity. Demand studies aggregated to the national scale cannot resolve the asset-level heterogeneity that planners confront. This paper delivers a substation-level assessment of heat-wave vulnerability across Chile's National Electric System (SEN) under SSP3-7.0. We combine (i) hourly climate projections from CNRM-ALADIN64 at 12.5 km, bias-corrected via unbiased quantile mapping; (ii) an hourly heat-wave climatology 1979–2100; (iii) hourly withdrawal records for 133 SEN substations (2017–2025); and (iv) 112 substation-specific generalized additive models with tensor-product interactions among five climate variables and thermal-memory, diurnal and calendar effects. Three findings emerge. First, thermal-response curves differ *qualitatively* among the four Chilean macrozones, not merely in amplitude. Second, a capacity-weighted stress trajectory of 76 substations reveals that heat-wave demand anomalies intensify most sharply in Near North and in the Central-zone tail. Third, the tail risk ratio of extreme positive anomalies rises to 10–25× by 2070–2100 for the most vulnerable zones, while the system-median stays below 1.5% — a tail amplification invisible to mean-based planning. These results inform spatially differentiated grid reinforcement and the calibration of climate-aware digital twins of the SEN. Operationally, these findings identify the substations where reinforcement, demand-response programs and AC-saturation policies should be prioritized.**

***Index Terms*—heat waves; electricity demand; climate projections; generalized additive models; spatial vulnerability; SSP3-7.0; Chile; risk ratio; capacity-weighted; digital twin.**

J.P. acknowledges the support from the Data Observatory Foundation, ANID Technology Center number DO210001. C.M.-V. acknowledges support from Proyecto ANID Fondecyt Iniciación 11250471 and Data Observatory Foundation ANID Technology Center number DO210001. K.G. acknowledges the support from FONDECYT 1241321 Grant, Concurso de Fortalecimiento al Desarrollo Científico de Centros Regionales 2020-R20F0008-CEAZA, and ANID ACT210046 grant. Pierre Nabat and Samuel Somot are gratefully thanked for their guidance in performing the simulations with CNRM-ALADIN model. The authors acknowledge the High-Performance Computing (HPC) Cluster of the Faculty of Engineering and Sciences at Universidad Adolfo Ibáñez for providing the computing resources that contributed to the research results reported within this paper.

979-8-3195-1058-7/26/$31.00 ©2026 IEEE

I. Introduction

The frequency, intensity, and duration of heat waves are increasing on every inhabited continent [1]. For power systems, heat waves are a compound stressor: they simultaneously elevate cooling demand and reduce the thermal capacity of transmission, transformers and thermal generation. Crucially, warming alters the *shape* of the load distribution, not only its mean; peak and tail events, which drive reserve-margin adequacy, respond non-linearly to temperature extremes [2].

Chile is a pertinent case. Its grid, the Sistema Eléctrico Nacional (SEN), operates along a 4000 km latitudinal transect spanning the hyper-arid Atacama, the Mediterranean central valley and the temperate rainforest south. The prolonged Central Chile megadrought that began in 2010 [3], [4] has severely impacted regional climatic conditions; heat-wave activity has intensified nationally since 1980 [5]; and regional projections indicate warming above 2 °C over the Mediterranean and arid interior zones by mid-century [6]. Yet published Chilean demand studies operate at national or macrozone level and therefore mask asset-level heterogeneity. Romitti and Sue Wing [7] show that aggregated assessments can miss local vulnerability by a factor of several, and Rouault et al. [8] confirm sharp zonal contrasts for Chilean residential cooling. No prior work, to our knowledge, delivers a bias-corrected, hourly, substation-resolved demand projection for the SEN. Providing this granularity is essential for the emerging class of grid digital twins or models which require node-level climatic calibration to accurately simulate infrastructure resilience under extreme climate stress.

This paper closes that gap. Our contributions are four-fold: (i) 112 substation-level GAMs with tensor-product interactions among five climate drivers produce the first asset-resolved thermal-response atlas of the SEN; (ii) an hourly, bias-corrected, 12.5-km heat-wave climatology spans 1979–2100 under SSP3-7.0; (iii) the capacity-

weighted tail risk ratio, following Stott et al. [9], of positive heat-wave demand anomalies exhibits tail amplification of 10–25× by 2070–2100 in the most vulnerable zones; and (iv) the per-substation sensitivity curves serve directly as calibration inputs for climate-aware digital twins of resilient, carbon-neutral power systems.

II. Related Work

The non-linear relation between temperature and peak demand is established at the US national [2], [10] and global [11] scales: warming compounds peak load disproportionately through air-conditioning saturation and income-coupled cooling-stock growth. Steinberg et al. [12] decompose the US signal into supply- and demand-side components, showing that demand-side thermal amplification is dominant for temperate baselines. Spatially, Romitti and Sue Wing [7] find that climate impacts on electricity demand are strongly heterogeneous across world cities and frequently cross the sign boundary within a single country, invalidating single-coefficient national elasticities. For Chile, Rouault et al. [8] document residential energy-need changes from −40% (South) to +60% (North) along the same latitudinal gradient we address here.

For demand projections to be credible the climate forcing must faithfully represent distributional tails. Chadwick et al. [13] introduce unbiased quantile mapping (UQM), which preserves projected changes in distributional shape — a property standard QM methods violate [14].

III. Data and Methods

A. Climate Forcing

Climate forcing comes from CNRM-ALADIN64 driven by CNRM-ESM2-1 at ≈ 12.5 km and hourly cadence, for 1979–2005 historical and 2006–2100 under SSP3-7.0. Five variables are retained: air temperature (*tas*), dew-point (*Td*), surface wind speed (*sfcWind*), shortwave radiation (*rsds*) and precipitation (*pr*). Bias correction uses UQM [13], with ERA5-Land as reference dataset. Diurnal consistency is enforced [15] and the QM variance-inflation pathology [14] is mitigated by UQM's preservation of quantile changes.

B. Heat-Wave Climatology

Heat waves follow Perkins and Alexander [16]: at least three consecutive days on which the daily maximum of the hourly *tas* series exceeds the 90th percentile of the 1980–2014 reference distribution, computed pixel-wise. Thresholds are therefore station-specific, making event counts comparable across zones. Magnitudes are computed hourly to capture nocturnal heat that daily-only definitions collapse. Events at each ALADIN pixel are transferred to each substation by nearest-neighbour spatial join through the Infotécnica UTM registry.

C. Substation-Level Demand

Hourly withdrawals come from the Coordinador Eléctrico Nacional (CEN) public API for 133 SEN substations over 2017-01 to 2025-12. Pre-processing merges hour-25 DST artefacts, flags dead-data stretches (mean-to-peak ratio < 0.40 for >12 h) as missing, linearly interpolates gaps of ≤ 6 h, and retains negative withdrawals (net-metering). A composite quality score retains 112 substations as ready for GAM fitting.

D. Tensor-Product GAM Specification

One GAM per substation is fitted with `mgcv::bam`, fast REML, discrete [17], [18]. Let y_t be log hourly withdrawal. The linear predictor is

$$\log y_t = \beta_0 + \sum_{x \in \mathcal{C}} s_{k=5}(x_t) + s(EWMA_t) + ti(EWMA_t, hod_t) + ti(tas_t, doy_t) + ti(hod_t, dow_t) + \mathrm{cal}_t + \varepsilon_t$$

with climate set $\mathcal{C} = \{tas, Td, sfcWind, rsds, pr\}$; *hod*, *dow* and *doy* cyclic where appropriate; EWMA is an exponentially weighted moving average of *tas* (half-life ≈ 20 h) capturing thermal inertia [19]; and cal groups holiday and COVID indicators. Marginal smooths use $k = 5$ to control concurvity; tensor `ti` terms isolate load-shape effects from marginal climate effects. Residual AR(1) absorbs remaining autocorrelation. Climate responses are read via counterfactual prediction curves (non-climate predictors fixed at climatological values, each climate variable swept over observed P1–P99), avoiding the misinterpretation of partial effects in the presence of tensor interactions.

E. Capacity-Weighted Aggregation and Risk Ratio

Substation aggregates use capacity-weighting, with weights equal to historical baseline demand (kW), so the aggregate reflects total capacity at risk rather than unweighted substation count. While the concept of evaluating the probability ratio of specific extreme events was originally adapted to climate science by Stott et al. [9], we adopt a continuous approach to assess the full distribution tail [20], [21]. Accordingly, we define a tail risk ratio for positive heat-wave demand anomalies,

$$\mathrm{RR}(m) = \frac{\Pr(\Delta D / D_{\mathrm{base}} \geq m \mid 2070\text{–}2100)}{\Pr(\Delta D / D_{\mathrm{base}} \geq m \mid 1980\text{–}2014)}, \qquad (1)$$

estimated empirically on per-substation event series and smoothed on RR (not separately on numerator and denominator, which introduces artifacts). Bootstrap CIs use 200 resamples stratified by substation; curves are truncated where $\Pr_{\mathrm{base}} < 1/N_{\mathrm{base}}$.

IV. Results

A. Study Domain and Model Validation

Fig. 1 places the 133 SEN substations in their climatic context, showing the four-zone macro-partition used throughout. Among the 112 substations passing quality control, the median adjusted coefficient of determination

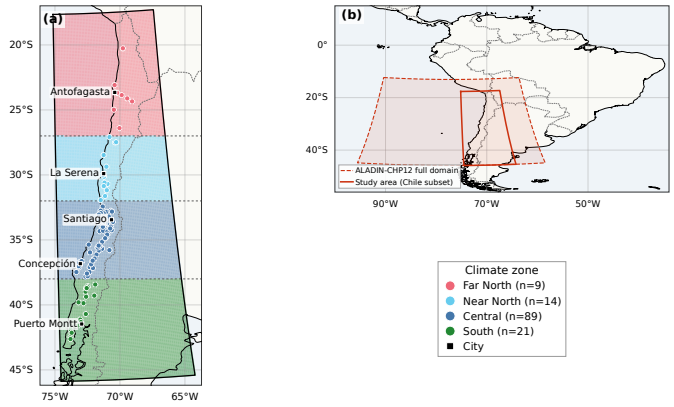

Fig. 1: Study domain. Geographical distribution of the 133 SEN substations (left), colour-coded by macrozone (Far North, Near North, Central, South), with the spatial subset bounds of the CNRM-ALADIN64 CHP12 simulation overlaid. The right inset shows Chile within South America with a 500-km scale bar. The substation sample spans ∼4 000 km of latitude, from hyper-arid Atacama to temperate rainforest.

TABLE I: Out-of-sample validation of the substation-level GAM. Statistics are summarised across the 112 fitted models: median with [P25, P75] in brackets. R^2_{adj} is the adjusted coefficient of determination; MAPE is the mean absolute percentage error on held-out weeks; ACF_1 is the lag-1 autocorrelation of Pearson residuals after AR(1) correction; concurvity is the worst-case pairwise smooth-term concurvity index (lower is better, < 0.4 standard mgcv threshold).

Metric	mean (112 SEs)
R^2_{adj}	0.862 [0.82, 0.90]
MAPE (%)	0.93 [0.71, 1.28]
ACF_1 of residuals	0.15 [0.08, 0.23]
Pre-AR(1) ACF_1	0.885 [0.83, 0.92]
Worst-pair concurvity	0.31 [0.24, 0.38]
Effective degrees of freedom	58 [51, 65]

is $R^2_{\text{adj}} = 0.862$ (interquartile range 0.82–0.90), held-out MAPE is 0.93%, and the worst-pair concurvity index is 0.31, below the standard 0.40 threshold (Table I). Residual AR(1) coefficient reduces the lag-1 autocorrelation from 0.885 (raw) to 0.15 after correction, indicating that the climate–demand structural signal is fully captured.

B. Spatial Heterogeneity of Thermal Response

Thermal-response curves across the four macrozones are not merely scaled versions of each other but *qualitatively distinct* (Fig. 2). Far North responds weakly and almost flatly: baseline mining and process loads dominate. Near North shows the archetypal cooling-load signature: a sharp positive response from ∼18 °C upwards, exceeding a +5% relative load near its observed P99. The Central zone shows a shallow U-shape with minimum near 14 °C: heating demand at low temperatures and cooling demand at high temperatures. The South zone is cold-dominated with monotonically decreasing demand as temperature rises. These qualitatively different shapes are why national aggregates mislead: they average responses of opposite sign.

TABLE II: Heat-wave demand anomaly by macrozone and future period under SSP3-7.0, relative to the historical baseline (1980–2014). $\Delta\overline{D}$ is the capacity-weighted mean demand change across substations within a zone; ΔP_{95} is the same statistic for the 95th-percentile hourly demand. Amplification $= \Delta P_{95}/\Delta\overline{D}$ reports the disproportionate growth of the tail relative to the mean.

Period	Zone	n	$\Delta\overline{D}$ (%)	ΔP_{95} (%)	Amplif.
Near (2030–2050)	Far N.	1	−0.44	+0.07	−0.16×
	Near N.	7	+3.41	+1.86	0.55×
	Central	43	+0.49	−0.47	−0.96×
	South	25	+0.40	−0.62	−1.57×
Mid (2041–2060)	Far N	1	−0.57	−0.11	0.19×
	Near N.	7	+3.48	+2.68	0.77×
	Central	43	+0.57	−0.73	−1.30×
	South	25	+0.68	−1.04	−1.52×
End (2081–2100)	Far N.	1	−2.01	−0.95	0.47×
	Near N.	7	+5.33	+7.08	**1.33**×
	Central	43	+0.17	−0.95	−5.62×
	South	25	−0.04	−1.40	>10×

C. Stress Trajectory 1980–2090

Translating these thermal responses into projected heat-wave demand anomalies produces the capacity-weighted stress trajectory of Fig. 3. Each of the 76 projection-ready substations is a row whose *height* is proportional to baseline capacity (kW), so cell area encodes capacity-weighted stress. Columns are decades; colour is the median demand anomaly during heat-wave hours (pale blue for cooling anomalies). A pattern of increasing stress emerges over time, evident in the gradual darkening across Near North and the upper rows of the Central zone: tall-row substations concentrate an increasing share of the system heat-wave anomaly after 2050. The South shows predominantly cool-toned rows, a heating-relief effect as its climate shifts towards Central-like conditions.

D. Risk Ratio and Capacity-Weighted Amplification

The tail risk ratio (Fig. 4) quantifies the tail amplification hinted at by Fig. 3. In the mean, heat-wave anomalies remain small (Table II): Near North's capacity-weighted $\Delta\overline{D}$ reaches +5.3% by 2081–2100 while Central and South stay within ±0.2%. The tail, however, diverges. For Near North, the risk ratio of a heat-wave anomaly $\geq$ 10% reaches $\sim$ 20× by 2070–2100 relative to 1980–2014; for Central, $\sim$ 15× at $m = 15\%$. Critically, Near North's ΔP_{95} of +7.08% (II) at end-century exceeds its $\Delta\overline{D}$ of +5.33%, yielding an amplification of 1.33×: the tail grows one-third faster than the mean.

E. Temporal Evolution of the System Signal

Fig. 5 closes the loop. Panel (a): the system capacity-weighted median of the relative heat-wave demand anomaly across substations (percent deviation of mean heat-wave-hour demand from the local non-heat-wave baseline) and P25–P75 band stay near zero throughout 1980–2100, reaching +1.5% by end-century — a value that, read in isolation, would suggest a modest heat-wave

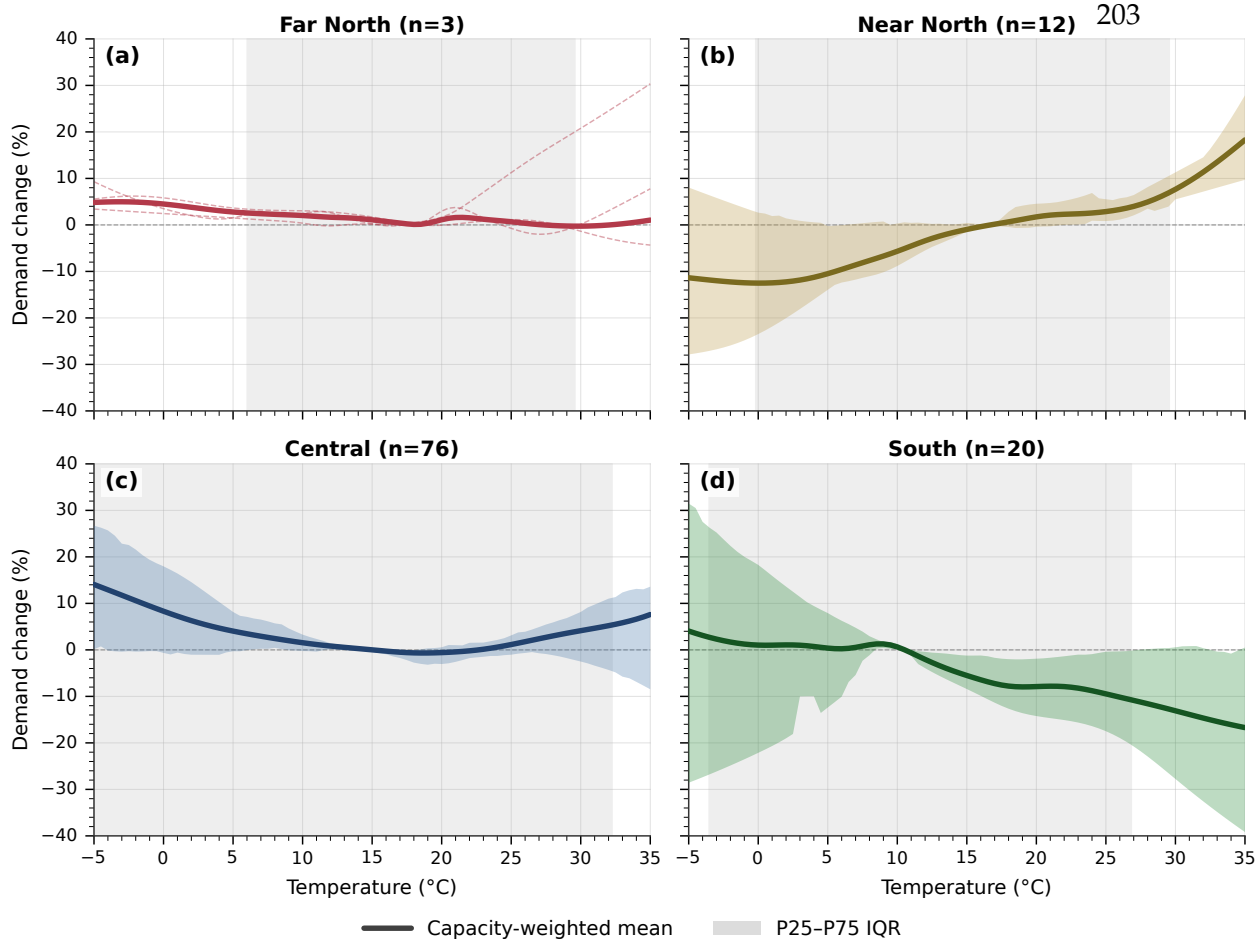

Fig. 2: Thermal response heterogeneity by macrozone. Each panel shows the capacity-weighted zonal mean of the GAM counterfactual demand–*tas* curve (solid), bounded by the substation P25–P75 interquartile band (shaded). Observed P1–P99 temperature ranges are shaded grey. Far North ($n = 3$) is shown as three individual dashed curves rather than as an IQR band; the counterfactual curves derive from GAM coefficients alone, hence are independent of the coastal-NaN projection limitation restricting later figures.

impact. The dashed P90 line tells the opposite story: the upper decile of substation-level anomalies rises from $\sim 3\%$ to $\sim 7\%$, more than doubling across the century. This tail-inflation-while-median-flat signature is the operational bridge to the large risk ratios of Fig. 4. Panel (b) decomposes by zone: Near North dominates, reaching $+3\%$ by end-century, while Central, South and Far North remain within $\pm 1\%$; the divergence is monotone from 2020 and accelerates after 2050.

V. Discussion

a) Aggregation bias is large and directional: Single-coefficient national elasticities mis-describe a grid whose substations respond to temperature with qualitatively different shapes. The Near North cooling-surge signal and the South heating-relief signal of opposite sign almost cancel in an unweighted national mean. For the SEN, the capacity-weighted national mean of the heat-wave demand anomaly at end-century is under $+2\%$, yet the zonal capacity-weighted mean for Near North exceeds $+5\%$ and its P_{95} exceeds $+7\%$. Any planner using a system-mean as a heat-wave stress proxy will systematically underestimate reinforcement needs in the most exposed zone — a higher-resolution confirmation of the cross-city finding of Romitti and Sue Wing [7].

b) Relevance to digital-twin frameworks: Our per-substation counterfactual response curves provide a direct, weather-driven calibration input for the emerging class of climate-aware digital twins of the SEN. Because each substation's thermal-response surface is a low-dimensional function of five bias-corrected climate predictors plus thermal memory, it acts as the missing spatially resolved contingency input for these platforms. Embedded seamlessly into a digital twin's contingency analysis loop, this architecture enables operators to generate predictive, on-the-fly estimates of climate-stressed nodal injections under extreme scenarios, without computationally expensive re-fitting. This node-level parameterization supports dynamic grid resilience assessment, representing a materially different use case from traditional building-level estimators [8] that cannot be integrated directly into power-flow

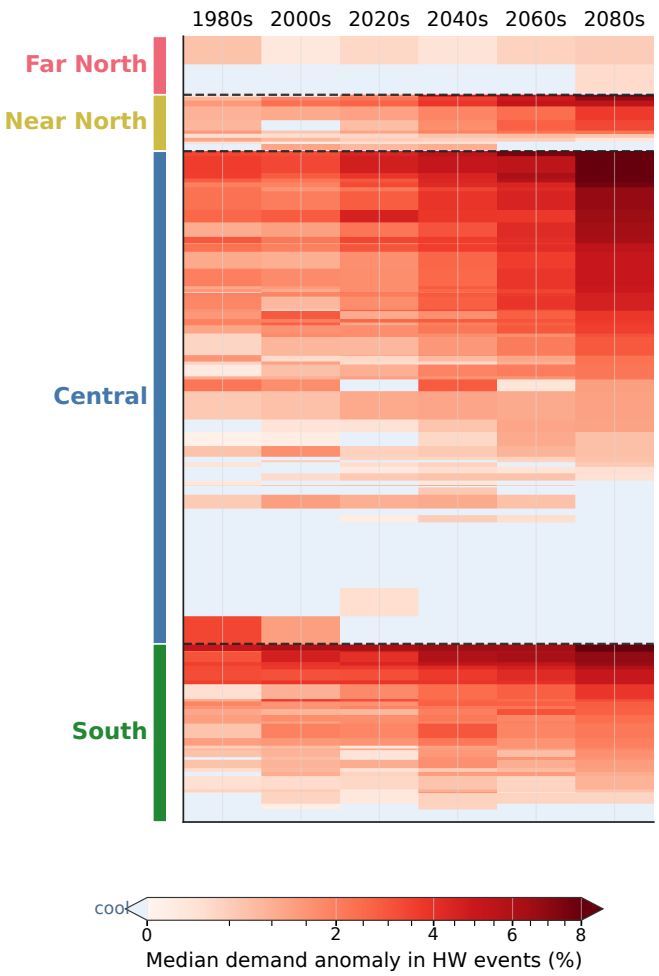

Fig. 3: Heat-wave demand-anomaly stress trajectory, 1980s–2080s. Rows: the 76 SEN substations with valid SSP3-7.0 projection data, with row height proportional to baseline capacity (kW) (capacity-weighted by construction). Columns: decades (shown every other decade in this column-width view). Colour: median relative demand anomaly during heat-wave hours; cooling anomalies in pale blue. The left-edge coloured stripe indicates each substation's macrozone (Far North, Near North, Central, South); segment height reflects the zone's share of capacity-weighted rows. Substations are sorted within each macrozone by 2080s anomaly. Far North reduces to $n = 1$ SE (Diego de Almagro) due to the ALADIN coastal-NaN limitation (Sec. III-A).

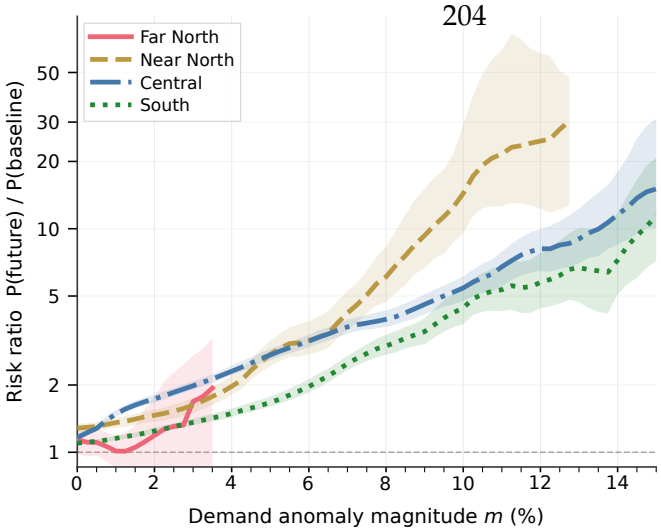

Fig. 4: Tail risk ratio of positive heat-wave demand anomalies, by macrozone, end-century (2070–2100) vs. historical baseline (1980–2014). The horizontal axis is the relative anomaly threshold m (%); the vertical axis is the ratio $\mathrm{RR}(m)$ on log-scale. Shaded bands are bootstrap P10–P90 envelopes (200 resamples). Curves are capacity-weighted within zone and smoothed on RR (not on numerator and denominator separately, which would introduce artefacts). Curves are truncated where the baseline probability falls below $1/N_{\text{base}}$. Far North ($n = 1$ SE, indicative) is labelled accordingly.

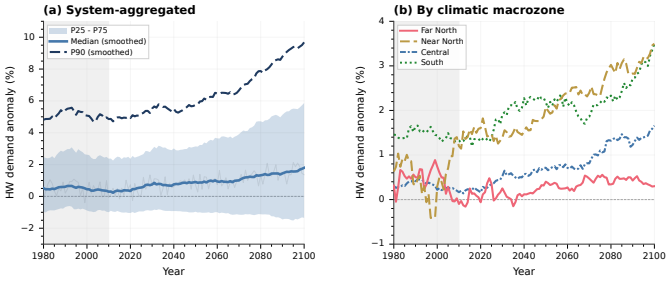

Fig. 5: Temporal evolution of the heat-wave demand anomaly under SSP3-7.0. (a) System-aggregate capacity-weighted median (solid), P25–P75 band (light) and P90 (dashed) with 11-year centred rolling mean; baseline 1980–2010 shaded grey. (b) Zonal decomposition: capacity-weighted median per macrozone (four lines). The P90 line in (a) carries the narrative: tail inflation while the median stays flat.

simulators.

c) Limitations: Four caveats bound these results. (i) The forcing rests on a single CNRM-ESM2-1 → CNRM-ALADIN64 chain; structural uncertainty is not quantified by an ensemble spread [22]. (ii) Demand models are trained on 2017–2025; structural shifts from EV, PV and AC adoption — the latter with a known income-elasticity channel [2], [11] — are not captured, so our Near North tail-growth estimate is a lower bound. (iii) Our framework treats heat-wave inclusion via a binary threshold ($\geq$ 3 days) and limits thermal memory to a ∼20-hour half-life. The frequency of long-duration heat waves scales super-exponentially with warming [23], and prolonged events compound cooling demand through urban heat island effects [24], building-envelope thermal saturation [25], and adaptive thermal comfort failure [26]. Our specification therefore yields conservative tail-growth estimates. (iv) Supply-side effects [12] are out of scope.

d) Policy: Grid reinforcement in Near North should be sized against the P_{90} of the substation-level anomaly, not the national mean. Cooling energy-efficiency and distributed-generation incentives should be targeted where thermal sensitivity is highest (Fig. 2).

VI. Conclusion

Four findings summarise the paper. (i) A substation-resolved GAM atlas of the SEN reveals qualitatively heterogeneous thermal responses across the four Chilean macrozones, not merely a scale-different single shape. (ii) The capacity-weighted heat-wave stress trajectory

1980–2090 concentrates future demand risk in Near North and in the high-capacity substations in the Central zone. (iii) The tail risk ratio for positive heat-wave demand anomalies rises to 10–25× by 2070–2100 in the most vulnerable zones, while the system-median anomaly stays below 1.5%, a dissociation invisible in mean-based planning. (iv) These per-substation thermal-response curves are directly usable as calibration inputs for real-time climate-aware digital twins of the SEN, closing the loop on the resilient power systems theme. Future work will extend the climate forcing to a CORDEX-CORE multi-model ensemble and couple the substation sensitivities to an AC power-flow simulator to quantify reserve-margin adequacy under compound heat-wave stress.

References

[1] S. I. Seneviratne, X. Zhang, M. Adnan, W. Badi, C. Dereczynski, A. Di Luca, S. Ghosh, I. Iskandar, J. Kossin, S. Lewis, F. Otto, I. Pinto, M. Satoh, S. M. Vicente-Serrano, M. Wehner, and B. Zhou, "Weather and climate extreme events in a changing climate," in *Climate Change 2021: The Physical Science Basis. Contribution of Working Group I to the Sixth Assessment Report of the Intergovernmental Panel on Climate Change*. Cambridge University Press, 2021, pp. 1513–1766.

[2] M. Auffhammer, P. Baylis, and C. H. Hausman, "Climate change is projected to have severe impacts on the frequency and intensity of peak electricity demand across the united states," *Proceedings of the National Academy of Sciences*, 2017.

[3] R. Garreaud, C. Alvarez-Garreton, J. Barichivich, J. Boisier, D. Christie, M. Galleguillos, C. LeQuesne, J. McPhee, and M. Zambrano-Bigiarini, "The 2010–2015 megadrought in central chile: impacts on regional hydroclimate and vegetation," *Hydrology and Earth System Sciences*, 2017.

[4] R. Garreaud, J. Boisier, R. Rondanelli, A. Montecinos, H. Sepúlveda, and D. Veloso-Aguila, "The central chile mega drought (2010–2018): A climate dynamics perspective," *International Journal of Climatology*, 2020.

[5] Á. González-Reyes, M. Jacques-Coper, C. Bravo, M. Rojas, and R. Garreaud, "Evolution of heatwaves in chile since 1980," *Weather and Climate Extremes*, 2023.

[6] A. Piticar, "Changes in heat waves in chile," *Global and Planetary Change*, 2018.

[7] Y. Romitti and I. Sue Wing, "Heterogeneous climate change impacts on electricity demand in world cities circa mid-century," *Scientific Reports*, 2022.

[8] F. Rouault, F. Ossio, P. González-Levín, and F. Meza, "Impact of climate change on the energy needs of houses in chile," *Sustainability*, 2019.

[9] P. A. Stott, D. A. Stone, and M. R. Allen, "Human contribution to the european heatwave of 2003," *Nature*, vol. 432, pp. 610–614, 2004.

[10] N. Miller, K. Hayhoe, J. Jin, and M. Auffhammer, "Climate, extreme heat, and electricity demand in california," *Journal of Applied Meteorology and Climatology*, 2008.

[11] B. J. van Ruijven, E. De Cian, and I. Sue Wing, "Amplification of future energy demand growth due to climate change," *Nature Communications*, 2019.

[12] D. C. Steinberg, B. K. Mignone, J. Macknick, Y. Sun, K. Eurek, A. Badger, B. Livneh, and K. Averyt, "Decomposing supply-side and demand-side impacts of climate change on the us electricity system," *Climatic Change*, 2020.

[13] C. Chadwick, J. Gironás, F. González-Leiva, and S. Aedo, "Bias adjustment to preserve changes in variability: the unbiased mapping of gcm changes," *Hydrological Sciences Journal*, 2023.

[14] Maraun and Douglas, "Bias correction, quantile mapping, and downscaling: Revisiting the inflation issue," *Journal of Climate*, 2013.

[15] M. N. Agbazo and P. Grenier, "Characterizing and avoiding physical inconsistency generated by the application of univariate quantile mapping on daily minimum and maximum temperatures over hudson bay," *International Journal of Climatology*, vol. 40, pp. 3868–3884, 2020.

[16] S. E. Perkins and L. V. Alexander, "On the measurement of heat waves," *Journal of Climate*, vol. 26, pp. 4500–4517, 2013.

[17] S. N. Wood, *Generalized Additive Models*. Chapman and Hall/CRC, 2017.

[18] M. Fasiolo, R. Nedellec, Y. Goude, and S. N. Wood, "Scalable visualisation methods for modern generalized additive models," *Journal of Computational and Graphical Statistics*, vol. 29, pp. 78–86, 2020.

[19] P. Gaillard, Y. Goude, and R. Nedellec, "Additive models and robust aggregation for gefcom2014 probabilistic electric load and electricity price forecasting," *International Journal of Forecasting*, 2016.

[20] J. D. Neelin, S. Sahany, S. N. Stechmann, and D. N. Bernstein, "Global warming precipitation accumulation increases above the current-climate cutoff scale," *Proceedings of the National Academy of Sciences*, vol. 114, no. 6, pp. 1258–1263, Feb. 2017. [Online]. Available: https://pnas.org/doi/full/10.1073/pnas.1615333114

[21] C. Martinez-Villalobos and J. D. Neelin, "Shifts in Precipitation Accumulation Extremes During the Warm Season Over the United States," *Geophysical Research Letters*, vol. 45, no. 16, pp. 8586–8595, Aug. 2018. [Online]. Available: https://agupubs.onlinelibrary.wiley.com/doi/10.1029/2018GL078465

[22] L. Torrez-Rodriguez, K. Goubanova, C. Muñoz, and A. Montecinos, "Evaluation of temperature and precipitation from cordex-core south america and eta-rcm regional climate simulations over the complex terrain of subtropical chile," *Climate Dynamics*, 2023.

[23] C. Martinez-Villalobos, D. Fu, P. C. Loikith, and J. D. Neelin, "Accelerating increase in the duration of heatwaves under global warming," *Nature Geoscience*, vol. 18, no. 8, pp. 716–723, 2025.

[24] Y. Zou, Z. Wu, B. Li, and Y. Jia, "Cooling energy challenges in residential buildings during heat waves: urban heat island impacts in a hot-humid city," *Buildings*, vol. 14, no. 12, p. 4030, 2024.

[25] I. Staffell, S. Pfenninger, and N. Johnson, "A global model of hourly space heating and cooling demand at multiple spatial scales," *Nature Energy*, vol. 8, no. 12, pp. 1328–1344, 2023.

[26] R. Castaño-Rosa, R. Barrella, C. Sánchez-Guevara, R. Barbosa, I. Kyprianou, E. Paschalidou, N. S. Thomaidis, D. Dokupilova, J. P. Gouveia, J. Kádár *et al.*, "Cooling degree models and future energy demand in the residential sector. a seven-country case study," *Sustainability*, vol. 13, no. 5, p. 2987, 2021.

M.3. Correspondencia entre los objetivos específicos y los anexos

CUADRO M.1: Correspondencia entre los objetivos específicos de esta tesis, los capítulos donde se abordan y los artículos derivados que los han sometido a revisión de pares.

Objetivo	**Contenido**	**En esta tesis**	**Revisión de pares**
SO.1	Corrección de sesgo de las forzantes climáticas	Sec. 6.1, Ap. A	Artículo 1
SO.2	Sensibilidad térmica de la demanda	Sec. 6.5.1	Artículo 2
SO.3	Especificación y validación del modelo GAM	Sec. 6.4, Ap. E	Artículo 2
SO.4	Proyecciones de demanda bajo cambio climático	Sec. 6.7, Ap. I	Artículo 2
SO.5	Climatología de olas de calor y de frío	Sec. 6.2, Ap. C	Artículo 1

M.4. Nota sobre derechos de reproducción

El manuscrito de la Sección M.1 se reproduce en su versión enviada, forma que la política de auto-archivo de Wiley autoriza a incluir en una tesis y a depositar en repositorios institucionales sin período de embargo.

El artículo de la Sección M.2 se reproduce en su versión aceptada, única versión que la política de IEEE permite incluir en una tesis que se publique en línea. IEEE no exige tramitar una licencia formal para este uso, pero sí requiere que se consigne la siguiente nota de crédito:

> © 2026 IEEE. Reprinted, with permission, from J. Petit-Laurent, C. Martinez-Villalobos and K. Goubanova, "Substation-Level Heat-Wave Vulnerability of the Chilean Grid Under Global Warming," *2026 IEEE International Conference on Environment and Electrical Engineering and 2026 IEEE Industrial and Commercial Power Systems Europe (EEEIC/I&CPS Europe)*, Lisbon, Portugal, 2026.